




Big data e ciência de dados aula 02

Luisa Mariele Strauss




Agenda

- Analisar problemas trazidos pelos alunos no fórum
- Conceitos relacionados a ciência de dados
- Retomar tipos de estudos e análises
- Quem é o cientista de dados?
- Data literacy

Debate sobre os
problemas postados no
fórum

Em resumo...Ciência de Dados





Pensamento analítico de dados, tipos
de análise e nível de maturidade


Tipos de estudos



Observacional: entender, sem mudar



Experimento: mudar variáveis de parte da população



Simulação: modelagem para reproduzir parte da realidade



Análise de dados: vários níveis

Tipos de análise de dados

- Exploratória vs explanatória
- Descritiva
- Diagnóstica
- Preditiva
- Prescritiva





Exploratória e explanatória

- Explorar o conjunto de dados – compreensão do próprio analista
- Apresentar a análise exploratória/descritiva para audiência
- Encontrar padrões e explicações interessantes – explanatória

Knaflitz (2018)

Descritiva

- O que está acontecendo/aconteceu?
- Análise do passado
- Informações instantâneas
- Uso de estatísticas “básicas”
- Gráficos, tabelas, infográficos etc
- Exemplos?



Diagnóstica

- Por que isso está acontecendo/aconteceu?
- Relações causais
- Exemplos?





Preditiva

- O que vai acontecer?
- Identificação de padrões futuros a partir de eventos passados
- Uso de estatística multivariada, data mining, ciência de dados
- Exemplos?

Prescritiva

- Qual a melhor ação tomar?
- Pode complementar a análise preditiva
- Combina regras de negócio e previsões
- Exemplos?





Exemplos – problema 1

Problema de negócio:

- **Previsão de compras está sendo insuficiente, sendo assim, não tendo uma compra assertiva, como são produtos que possuem muitos casos de venda sazonal, atinge grandes áreas da empresa, como financeiro/vendas/estoque.**

Impacto

- 1º Precisão nas informações;
- 2º Grave problema de rentabilidade/fluxo de caixa
- 3º Impacto na gestão de estoques
- 4º Gargalo na venda por falta de produtos.

Dados disponíveis

- ERP da empresa com análise de estoque, análise de giro e histórico de vendas.
- Planilhas de Excel



Exemplos – problema 2

Problema do negócio

- Carência de controle de produtos programados e necessidades devidamente geradas para fabricação e compras de materiais no sistema.

Impacto para negócio

- Necessidades de fabricação e compra de materiais não são geradas no momento correto ou simplesmente não são geradas , causando atraso nas expedições dos produtos.

Dados disponíveis

- Todos dados serão extraídos do sistema ERP da empresa;
- Relatório de produtos com confirmação de programação;
- Relatório de produtos com confirmação de MRP gerado/liberado;
- Necessidades de fabricações individuais geradas para cada produto com programação confirmada e MRP gerado/liberado;



Exemplos – problema 3

Problema do negócio

- Fornecedores de matérias-primas de um determinado produto eletrônico entregam muito bem alguns materiais, porém muito mal outros. Porém, o parâmetro cadastrado no sistema para todos os materiais é o mesmo. Ou seja, materiais com diferentes desempenhos de entrega, possuem os mesmos parâmetros de Planejamento

Impacto para negócio

- Excesso de estoque para os materiais que entregam com alto desempenho e falta de materiais para o Almoxarifado separar e posteriormente para a Produção Eletrônica montar. Logo, há o impacto financeiro com excesso de estoque, além do impacto de restrição de espaço físico. E, também, o impacto financeiro com as paradas de linha. Além disso, o impacto de atraso nas entregas para os clientes

Dados disponíveis

- As tabelas do banco de dados do sistema ERP da empresa. Toda a base de pedidos de compra, em que temos as datas de emissão dos pedidos, quantidades, códigos de materiais, datas planejadas de entrega, datas reais de recebimento dos pedidos, dados de estoque.



Exemplos – problema 4

Problema do negócio nº 5

- Excesso de matéria-prima em estoque. O atual fluxo do pedido de vendas ocorre em um intervalo de 25 a 45 dias, enquanto o fluxo de compras opera de 60 a 70 % de seu volume em um lead time de 150 a 365 dias. Oscilações de demanda do mercado, *forecasts* de clientes com previsões errôneas, entre outros fatores influenciam no nível de estoque que a empresa apresenta.

Impacto para negócio

- O modelo de negócios da empresa determina a necessidade de colocar capital a frente investido no estoque para o atendimento dos clientes. Contudo, é necessário encontrar um ponto ótimo para esta equação, na medida em que o impacto de compras sobre o faturamento da empresa se torna elevado e afeta diretamente o fluxo de caixa da empresa. O balanceamento correto desse nível de estoque certamente gera mais saúde financeira para a empresa.


Dados disponíveis

- - Nível de estoque da empresa; - Ordens de compras pendentes em sistema; - Informações de Forecast; - Pedidos de venda em sistema; - Média de vendas por item; - Total comprometido por item.

Cientista de dados


"A profissão mais sexy do século 21"


Davenport & Patil, (2012)



“Alguém que entende como procurar respostas para questões de negócio relevantes a partir do tsunami de informações não estruturadas existentes atualmente.”

- “Nem estatísticos, nem analistas de dados, nem cientistas da computação, nem engenheiros de sistemas, nem analistas de negócios. Tem algum conhecimento em cada uma dessas áreas, mas também alguns conhecimentos fora delas.”





“Um especialista capaz de extrair valor significativo dos dados e gerenciar todo o ciclo de vida dos dados.”

Habilidades – *Hard skills*



COMPUTAÇÃO E
DESENVOLVIMENTO



NEGÓCIOS – DOMÍNIO
DE CONHECIMENTO



INTELIGÊNCIA
ARTIFICIAL

Habilidades – *Hard skills*



COMPUTAÇÃO E DESENVOLVIMENTO

- Programação
- *Big data*
- *Cloud*
- Banco de dados
- ETL (Extração, transformação e carga)

Habilidades – *Hard skills*



NEGÓCIOS

- "Conhecimento de negócio ou de uma área de conhecimento específica"
- Inglês
- Métodos ágeis
- Gestão
- Comunicação

Habilidades – *Hard skills*

- Modelagem
- *Machine Learning*
- Otimização
- Construção de *data sets*
- NLP (Processamento linguagem natural)



INTELIGÊNCIA
ARTIFICIAL

Habilidades – *Soft skills*

- Paixão
- Pensamento analítico
- Proatividade
- Raciocínio lógico
- Multicultural

Castello (2021)



“Super-heróis com todas as qualidades e conhecimentos para realizar um projeto de ciência de dados bem-sucedido.”





Tá, mas o que é cientista de dados então?

Cientista de dados é um profissional orientado para impactar o negócio por meio da criação de modelos utilizando técnicas de *machine learning* e, preferencialmente, métodos científicos. Pode possuir formações diversas, mas, necessariamente, possui sólidos conhecimentos em métodos quantitativos.

Definição

Cientista de dados é um profissional orientado para impactar o negócio através da criação de modelos utilizando técnicas de *machine learning* e, preferencialmente, métodos científicos. Pode possuir formações diversas, mas, necessariamente, possui sólidos conhecimentos de métodos quantitativos

Formação

- ✳ Não há uma área de formação mandatória, mas há necessidade de *background* em métodos quantitativos;
- ✳ Formação superior completa, preferencialmente em áreas de exatas (estatística, matemática, computação, engenharia ou física);
- ✳ Pós-graduação em geral, e mestrado ou doutorado em particular.

- ✳ Mandatório: indispensável para exercer as atividades de cientista de dados;
- ✳ Desejável: prevalentes na academia, no mercado e nas pessoas que praticam ciência de dados;
- ✳ Diferencial: tendências ou conhecimentos específicos que promovem destaque de cientistas de dados junto ao mercado.

Habilidades e ferramentas

Soft skills

- ✳ Ser curioso, atuar de forma ética e com paixão, e ter pensamento analítico;
- ✳ Ser proativo, pensar de forma lógica, ter capacidade de trabalhar em ambientes multiculturais, possuir bom relacionamento interpessoal e a capacidade de comunicar-se de forma efetiva com públicos diversos;
- ✳ Ser criativo, pensar de forma rápida e crítica, possuir espírito empreendedor.

Hard Skills

- ✳ Ter habilidades de programação e de bancos de dados. Ter conhecimento de domínio (negócios), da língua inglesa e dominar metodologias, particularmente as metodologias ágeis e frameworks de projetos de dados, por exemplo CRISP-DM. Criar modelos preditivos usando *machine learning*;
- ✳ Trabalhar em nuvem. Conhecer métodos de ETL para construção de *datasets*. Entender os principais conceitos de *business intelligence*, inclusive visualização dados. Ter conhecimento de gestão de negócios (com destaque para administração e finanças) e de gestão de conhecimento. Ter habilidade para trabalhar em time. Usar versionamento (GIT);
- ✳ Implementar soluções baseadas em ciência de dados. Integrar diversas fontes de dados, estruturados e não estruturados, e fazer gestão de *pipeline*. Atuar como MLOps (combinação de práticas de desenvolvimento de modelos e do uso dos mesmos em ambiente de produção). Liderar projetos e possuir postura de resolvidor de problemas.

Ferramentas

Linguagens de programação

- ✳ Python (Pandas, Scikit-learn) ou [R];
- ✳ Python (Tensorflow/PyTorch), Scala, SQL (linguagem);
- ✳ Java, Javascript, Matlab, C/C++, Julia, Pig.

Ecossistemas, frameworks e bancos de dados

- ✳ SQL (em geral) e *frameworks* de projeto de ciência de dados, por exemplo CRISP-DM;
- ✳ Hadoop/MapReduce, Spark, NoSQL;
- ✳ MongoDB, Cassandra, Hbase, Snowflake, Cloudera, HortonWorks.

Técnicas de *machine learning* e *deep learning*

- ✳ Regressão linear e logística, *clustering*, algoritmos baseados em árvores de decisão (por exemplo Random Forest e Gradient Boost);
- ✳ Redes neurais, inferência bayesiana, SVM, NLP, visão computacional;
- ✳ *Ensemble* (combinação de classificadores).

Visualização de dados

- ✳ Conceitos de visualização de dados em geral, e de pacotes de visualização em particular (por exemplo: Matplotlib, Seaborn e Dash para Python e ggplot2 e Shiny para [R]);
- ✳ Microsoft PowerBI, Tableau, Qlik, Google Data Studio ou Looker;
- ✳ Microstrategy, Pentaho.



Cientista de dados:
vejo como equipe
multidisciplinar

Carreiras em Ciência de Dados

- Engenheiro de Dados / Engenheiro de *Big Data*
- Arquiteto de Dados
- Cientista de *Machine Learning*
- Engenheiro de *Machine Learning*
- Especialista em *Business Analytics*
- Desenvolvedor de Visualização de Dados
- Gerente de *Analytics*
- Estatístico
- Cientista de Dados

Mercado de trabalho

14/08/2025

01

5.310 + 6.445
vagas para
"Data Scientist"

02

2.689 + 2.038
vagas para
"Data Engineer"

03

2.691 + 2.520
vagas para
"Data Analyst"

15/08/2023

01

3.736 + 14.091
vagas para
"Data Scientist"

02

1.740 + 1.564
vagas para
"Data Engineer"

03

5.050 + 4.097
vagas para
"Data Analyst"



Vagas no LinkedIn

Ciência de dados e conceitos relacionados

- *Business Intelligence*
- *Big data*
- *Big data analytics (BDA)*
- *Data Mining*
- *Machine Learning*



Sales Executive Dashboard



Number of Orders
5,009



Total Sales
\$2,901,677



Total Cost
\$2,541,547



Total Profit
\$360,130

Sales Reps Overview



Anna Andreadi
\$1,035,991



Chuck Magee
\$890,957



Kelly Williams

\$531,552




Cassandra Brandow

\$443,177

Sales by Regions



Sales vs. Cost by Year



Top 50 Customer Sales

Enter Top N Customers

50



Seth Vernon

\$107,150



Raymond Buch

\$43,222



Darrin Martin

\$32,048



Clay Ludtke

\$28,517



Rick Wilson

\$27,784



Dan Reichenbach

\$27,614




William Brown

\$25,539


Monthly Sales Overview



Big Data



Data Mining



Pensamento analítico de dados



Decisões *data driven*



Envolvimento das
pessoas em toda a
organização



Todos devem ter o
pensamento
analítico



Data literacy –
alfabetização em
dados e informações



Readiness para big
data



Maturidade em
analytics



Alfabetização em dados/Data literacy

Capacidade de ler, trabalhar com, analisar e argumentar a partir de dados e informações.

Ler: diferentes formatos – especialmente visuais

Trabalhar com: diferentes significados dos dados por perfil/papel

Analisar: uso de ferramentas específicas

Argumentar: sustentar ideias a partir dos dados

Alfabetização informacional

Conjunto de habilidades que fazem com que os indivíduos “reconheçam quando as informações são necessárias e tenham a capacidade de localizar, avaliar e usar efetivamente as informações necessárias”, sendo capaz de:

- determinar as informações necessárias
- acessar as informações necessárias de forma eficaz e eficiente
- avaliar informações e suas fontes de forma crítica
- incorporar as informações selecionadas na base de conhecimento de uma pessoa
- Usar as informações de maneira eficaz para atingir um objetivo específico
- Compreender os problemas econômicos, legais e sociais que envolvem o uso das informações, e acessar e usar as informações ética e legalmente.

Quem é alfabetizado deve ser capaz de...



Determinar precisão, relevância e abrangência de um dado



Distinguir entre fatos, pontos de vista e opiniões



Identificar informações enganosas e imprecisas



Selecionar as informações apropriadas ao problema em questão

Em que nível de alfabetização você está? E as pessoas na sua empresa?



Evitador de
dados



Dados Iniciante



Aprendiz de
dados



Guru de dados


Avaliação on-line em: <https://thedataliteracyproject.org/assessment/>

Níveis de maturidade em uso de dados


O que é maturidade?



Pronto, completo,
perfeito




Resultado de um
processo




Medida para avaliar as
capacidades

Big Data Business Maturity Model Index, Bill Schmarzo



Mudando de níveis



Básico

Oportunista

Sistemático

Diferenciado

Transformador

Modelo de
Maturidade
de Dados e
Analytics da
Gartner

Básico

- Os dados são usados, mas seu real valor não é potencializado.
- Dados e análises são gerenciados em silos.
- Há muito argumento sobre quais dados estão ou são corretos.
- As análises acontecem ad hoc, de forma reativa.
- Dados em planilhas concorrem com dados em bancos de dados.
- Basicamente transacional.





Oportunista

- A equipe de TI tenta formalizar fontes e disponibilidade de informações.
- A iniciativa encontra dificuldades em função de **cultura organizacional** e iniciativas concorrentes.
- Barreiras organizacionais e **falta de liderança**.
- Estratégia possui mais de 100 páginas, não é relevante para os negócios.
- **Iniciativas de melhorar qualidade de dados e gerar insights**, mas ainda em silos.

Sistemático

- Diferentes dados ainda são tratados de formas distintas.
- Visão e estratégia agora formam poucas páginas.
- Agilidade.
- **Dados externos** são integrados facilmente.
- Executivos de negócio se tornam “**campeões de dados**”.



Diferenciado

- Executivos capitaneiam e comunicam melhores práticas.
- Ações são *business driven*.
- Dados e analytics são um insumo indispensável para melhorar desempenho e para inovação, e integrado entre programas.
- Mentalidade de gerenciamento buscando sinergia.
- Vinculação com resultados e análises de Retorno de Investimento (ROI).




Transformador

- Dados e *analytics* são centrais para os negócios.
- O valor dos dados influencia os investimentos.
- Estratégia e execução estão alinhadas e em contínuo aprimoramento.
- Perspectiva de dentro para fora.
- Diretoria de dados faz parte da alta administração.



TDWI Analytics Maturity Model



- *Survey* online
- Dimensões de análise: Organização, Infraestrutura de TI, Gerenciamento de Dados, Analytics e Governança
- Faça a avaliação: <https://tdwi.org/pages/assessments/diq-all-data-management-maturity-model-assessment.aspx>

Principais referências

- ABBASI, A.; SARKER, S.; CHIANG, R. H. L. Big data research in information systems: Toward an inclusive research agenda. *Journal of the Association of Information Systems*, v. 17, n. 2, p. 1–32, 2016.
- CASTELLO, Fabiano. Cientistas de dados: proposta de um modelo conceitual considerando sua definição, sua formação, suas habilidades e as ferramentas que utilizam. Dissertação (Mestrado). Universidade de São Paulo (USP), 2021.
- KNAFLIC, C.N. *Storytelling com Dados*. Rio de Janeiro: Alta Books, 2018.
- DATA SCIENCE ACADEMY. 10 Carreiras em Big Data e Data Science, 2022. Disponível em <https://blog.dsacademy.com.br/10-carreiras-em-big-data-e-data-science/>
- DAVENPORT, T. H. *Big data no trabalho: derrubando mitos e descobrindo oportunidades*. Trad.: Cristina Yamagami. 1. Ed. Rio de Janeiro: Elsevier, 2014.
- MÜLLER, O. et al. Utilizing big data analytics for information systems research: challenges, promises and guidelines. *European Journal of Information Systems*, v. 25, n. 4, p. 289–302, 2016.
- PROVOST, F. FAWCETT, T. *Data Science para Negócios*. Rio de Janeiro: Alta Books, 2016.
- ROSALES, Luana. Arezzo aposta em machine learning com AWS, 2020. Disponível em <<https://www.baguete.com.br/noticias/01/10/2020/arezzo-aposta-em-machine-learning-com-aws>>