

UNIVERSIDADE DE SÃO PAULO
FACULDADE DE ECONOMIA, ADMINISTRAÇÃO E CONTABILIDADE
DEPARTAMENTO DE ADMINISTRAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM ADMINISTRAÇÃO

Fabiano Castello

Cientistas de dados: proposta de um modelo conceitual considerando sua definição, sua formação, suas habilidades e as ferramentas que utilizam

São Paulo
2021

FABIANO CASTELLO

Cientistas de dados: proposta de um modelo conceitual considerando sua definição, sua formação, suas habilidades e as ferramentas que utilizam

Dissertação apresentada ao Programa de Pós-Graduação em Administração do Departamento de Administração da Faculdade de Economia, Administração e Contabilidade da Universidade de São Paulo, como requisito parcial para a obtenção de título de Mestre em Ciências.

Orientador: Prof. Dr. Cesar Alexandre de Souza

Versão Corrigida

(versão original disponível na Biblioteca da Faculdade de Economia, Administração e Contabilidade)

São Paulo

2021

Autorizo a reprodução e divulgação total ou parcial deste trabalho, por qualquer meio convencional ou eletrônico, para fins de estudo e pesquisa, desde que citada a fonte.

Catálogo na publicação
Serviço de Biblioteca e Documentação
Faculdade de Administração e Contabilidade da Universidade de São Paulo

Castello, Fabiano.

Cientistas de dados: proposta de um modelo conceitual considerando sua definição, sua formação, suas habilidades e as ferramentas que utilizam / Fabiano Castello. - São Paulo, 2021.

195 p.

Dissertação (Mestrado) - Universidade de São Paulo, 2021.

Orientador: Cesar Alexandre de Souza.

1. Cientista de dados. 2. Inteligência artificial. 3. Big data. 4. Gestão de competências. 5. Recrutamento e seleção. I. Universidade de São Paulo. Faculdade de Economia, Administração e Contabilidade. II. Título.

Prof. Dr. Vahan Agopyan

Reitor da Universidade de São Paulo

Prof. Dr. Professor Titular Fabio Frezatti

Diretor da Faculdade de Economia, Administração e Contabilidade

Prof. Dr. Moacir de Miranda Oliveira Júnior

Chefe de Departamento Administração

Prof. Dr. Eduardo Kazuo Kayo

Coordenador do Programa de Pós-Graduação em Administração

Nome: Castello, Fabiano

Título: Cientistas de dados: proposta de um modelo conceitual considerando sua definição, sua formação, suas habilidades e as ferramentas que utilizam

Dissertação apresentada ao programa de pós-graduação em administração da Faculdade de Economia, Administração e Contabilidade da Universidade de São Paulo, como requisito parcial para a obtenção do título de Mestre em Ciências.

Aprovado em: 29/09/2021

Banca Examinadora

Prof. Dr. Rodrigo Baroni

Instituição: Pontifícia Universidade Católica – Minas Gerais

Julgamento: aprovado

Profa. Dra. Daielly Melina Nassif Mantovani

Instituição: Faculdade de Economia, Administração e Contabilidade
da Universidade de São Paulo

Julgamento: aprovado

Prof. Dr. Alexandre Del Rey

Instituição: A2A1 - International Association of Artificial Intelligence

Julgamento: aprovado

AGRADECIMENTOS

Ao Prof. Dr. Cesar Alexandre de Souza pela orientação (e paciência).

Ao Núcleo de Estudos em Tecnologias, Modelagem e Sistemas em Administração (NETS FEA-USP), pelas discussões que me permitiram aperfeiçoar a pesquisa e me desenvolver como pesquisador, particularmente as colegas Anna Célia Affonso dos Santos e Luisa Mariele Strauss, pela revisão e contribuições na fase final do trabalho.

À Valéria Feitosa e Antônio Braz pela ajuda inicial no processo de revisão da literatura.

Ao amigo Gustavo Galeale pelo incentivo e apoio.

Aos amigos Hugo Werninghaus e Fabiana Ribeiro, pelo apoio e amizade durante todos esses anos.

À Maira Petrini, que com esmero e carinho ímpares cuida de nosso filho Pedro, pelo apoio no começo deste projeto de mestrado.

Ao Prof. Dr. Antônio Geraldo da Rocha Vidal, por todo o conhecimento que me aportou há 30 anos, quando eu aprendia Clipper usando seus livros, num tempo que não existia Stackoverflow, e depois, quando convivemos durante o mestrado.

Ao amigo Juarez Lopes de Araújo, meu primeiro chefe no mundo corporativo e um mentor nos últimos 28 anos.

Diversos profissionais contribuíram para minha formação profissional e pessoal, seja como meus líderes, como meus pares ou como minha equipe. Entre eles, destaco, em ordem alfabética: Álvaro “Alvarão” de Sousa, Anna Olson-Leijon, Celso Giacometti, José Fernando Alves, Helene Bergquist, Ives P. Müller, Marco André Tassinari Rocha, Rene Andrich, Rodrigo Mendes Duarte, Ronaldo Perez Fragoso e Waldemir Bulla.

À minha mãe, que não entende nada de matemática ou computação, mas sabe tudo sobre ética e caráter.

À Lili, minha esposa, que na prática deu todo o suporte, com muita paciência, nas intermináveis horas de pesquisa, e teve que se contentar com Netflix vários sábados à noite quando prazos se aproximavam.

Aos meus filhos Pedro, Rafael e Julia porque, no final das contas, tudo que faço é por eles.

Fabiano Castello

Julho de 2021

“Data Scientist: The Sexiest Job of the 21st Century”
Thomas Davenport and D. J. Patil

“Let the dataset change your mindset.”
Hans Hösling (1948-2017)

*“Few people will appreciate the music if I just show them the notes.
Most of us need to listen to the music to understand how beautiful it is.
But, often, that's how we present statistics:
we just show the notes, we don't play the music,”*
Hans Hösling (1948-2017)

RESUMO

Castello, F. (2021). *Cientistas de dados: proposta de um modelo conceitual considerando sua definição, sua formação, suas habilidades e as ferramentas que utilizam* (Dissertação de Mestrado). Faculdade de Economia, Administração e Contabilidade, Universidade de São Paulo, São Paulo.

Cientistas de dados estão entre os atores que exploram o potencial do *big data* para gerar conhecimento e criar novas formas de valor que transformam as organizações e a sociedade. É uma profissão sobre a qual existem poucos estudos publicados com relação ao que a define e quais habilidades profissionais esse tipo de função demanda. O objetivo deste estudo é propor um modelo conceitual para cientistas de dados, considerando sua definição, sua formação, suas habilidades e as ferramentas que utilizam. O estudo é exploratório e tem abordagem qualitativa, e foi conduzido a partir de três perspectivas. Primeiro, da academia, onde foi realizada revisão sistemática de literatura, partindo de 2.245 documentos. Segundo, do mercado, através da coleta e análise de 1.308 vagas de emprego. Terceiro, das pessoas que praticam ciência de dados, através da análise de dados secundários da pesquisa Data Hackers BR de 2019. O conjunto das três perspectivas gerou um modelo conceitual para cientistas de dados, que foi então validado junto a 201 especialistas da academia e do mercado. A partir do resultado deste processo, que gerou um modelo conceitual para cientistas de dados robusto e abrangente, é possível concluir sobre (a) a existência de uma diferença relevante de entendimento sobre a profissão entre os praticantes de ciência de dados e as empresas que buscam contratá-los; (b) a questão da “super-qualificação”, no sentido de que são necessárias muitas habilidades, dificilmente encontradas em apenas um profissional, e sugerindo que existem grupos ou famílias de cientistas de dados, com conjunto de habilidades mais específicas, mas que ainda não estão explicitamente definidas; e (c) a necessidade de aperfeiçoamento contínuo, dada a heterogeneidade de técnicas e ferramentas necessárias, bem como o dinamismo com que elas evoluem. Adicionalmente, o método utilizado, com o uso extensivo de recurso de processamento de linguagem natural e mineração de texto, poderá ser automatizado e utilizado por outros autores para futuros estudos de perfis de profissionais, inclusive para outras profissões que não sejam a de cientistas de dados.

Palavras-chave: Ciência de dados. Cientista de dados. Inteligência artificial. *Big data*. Aprendizado de máquina. Gestão de competências. Habilidades técnicas. Alocação de Recursos Humanos. Recursos Humanos. Empregabilidade. Recrutamento e seleção.

ABSTRACT

Castello, F. (2021). *Data Scientists: Proposal of a Conceptual Model Considering their Definition, Education, Skills and Tools They Use* (Dissertação de Mestrado). Faculdade de Economia, Administração e Contabilidade, Universidade de São Paulo, São Paulo.

Data scientists are one of the actors that explore the potential of big data to generate insights and create new forms of value that transform organizations and society. It is a profession where there are few published studies on what a data scientist is and what professional skills this type of function demands. The aim of this study is to propose a conceptual model for data scientists, considering their definition, education, skills and tools they use. The study is exploratory and has a qualitative approach and was conducted from three perspectives. First, from the academy, where a systematic literature review was carried out, based on 2,245 documents. Second, from the market, through the collection and analysis of 1,308 job openings. Third, from people who practice data science, through the analysis of secondary data from the 2019 Data Hackers BR survey. The set of three perspectives generated a conceptual model for Data Scientists, which was then validated with 201 experts from academia and the market. As a result of this process, which generated a robust and comprehensive conceptual model for data scientists, it is possible to conclude on (a) the existence of a meaningful distance of understanding about the profession between data science practitioners and the companies that seek to hire them; (b) the issue of "over-qualification", in the sense that many skills are needed, hardly found in just one professional, suggesting that there are groups or families of data scientists, with more specific skill sets but that not yet explicitly defined; and (c) the need for continuous improvement given the heterogeneity of techniques and tools needed, as well as the dynamism with which they evolve. Additionally, the method used, with the extensive use of natural language processing (NLP) and text mining resources, can be automated and used by other authors for future studies of professional profiles, including those for professions other than data scientists.

Keywords: Data science. Data scientist. Big Data. Artificial Intelligence. Machine learning. Competence management. Technical skills. Allocation of Human Resources. Human Resources. Employability. Recruitment and selection.

LISTA DE FIGURAS

Figura 1 – Interesse, segundo Google Trends, pelos termos relacionados a cientistas de dados	17
Figura 2 – Estrutura do estudo.....	22
Figura 3 – Bases de dados e resultados.....	30
Figura 4 – Nuvem de habilidades de HU (2018)	46
Figura 5 – Nuvem de palavras de termos mais frequentes nas definições de cientista de dados.....	61
Figura 6 – Exemplo esquemático de modelo conceitual para cientistas de dados.....	84
Figura 7 – Matriz de amarração.....	85
Figura 8 – Protocolo de pesquisa.....	86
Figura 9 – Principais atividades realizadas na fase de tratamento de dados (perspectiva de mercado).....	89
Figura 10 – Exemplo de uma oferta típica de vaga de emprego.....	95
Figura 11 – Estatísticas do grupo Data Hackers BR.....	122
Figura 12 – Gartner: “ <i>Magic Quadrant for Analytics and Business Intelligence Platforms</i> ”..	134
Figura 13 – Modelo conceitual prévio para cientistas de dados.....	139
Figura 14 – Resultado quantitativo global do questionário para validação da proposta de modelo conceitual para cientistas de dados.....	142
Figura 15 – Resultados quantitativos do questionário para validação da proposta de modelo conceitual para cientistas de dados.....	144
Figura 16 – Modelo conceitual para cientistas de dados.....	160

LISTA DE TABELAS

Tabela 1 – Fórmulas utilizadas para procura de artigos.....	25
Tabela 2 – Relação de buscas realizadas.....	27
Tabela 3 – Definições de cientistas de dados.....	32
Tabela 4 – Frequência de palavras encontradas nas definições de cientista de dados.....	62
Tabela 5 – Formações de cientistas de dados encontradas na literatura e suas respectivas frequências.....	64
Tabela 6.1 – <i>Hard skills</i> - Conhecimentos gerais em computação e desenvolvimento de sistemas.....	68
Tabela 6.2 – <i>Hard skills</i> - Conhecimentos gerais em negócios.....	71
Tabela 6.3 – <i>Hard skills</i> - Inteligência artificial.....	74
Tabela 6.4 – <i>Soft Skills</i>	76
Tabela 6.5 – Ferramentas - Ecossistemas, <i>frameworks</i> e bancos de dados.....	77
Tabela 6.6 – Ferramentas - Linguagens de programação ou <i>scripts</i>	78
Tabela 6.7 – Ferramentas - Visualização de dados.....	79
Tabela 6.8 – Ferramentas - Outros: plataformas específicas, ambientes em nuvem e ambientes integrados.....	80
Tabela 7 – Resumo de pesquisas realizadas e vagas coletadas.....	89
Tabela 8 – Totalização das vagas coletadas por nível requerido.....	90
Tabela 9 – Totalização das vagas coletadas por setor (indústria)	91
Tabela 10 – Distribuição de vagas por Unidade Federativa.....	92
Tabela 11 – Resumo do tratamento de dados estruturados.....	93
Tabela 12 – Resumo de pesquisas realizadas e vagas coletadas.....	94
Tabela 13 – Vinte termos mais frequentes nos <i>corpora</i> de vagas.....	97
Tabela 14 – Bigramas mais frequentes nos <i>corpora</i> de vagas.....	98
Tabela 15 – Resultado da revisão manual em números.....	103
Tabela 16 – Vinte termos mais frequentes nos <i>corpora</i> de vagas manualmente revisadas.....	103
Tabela 17 – Bigramas mais frequentes nos <i>corpora</i> de vagas manualmente revisadas.....	104
Tabela 18 – Exemplos de casos de vagas similares oferecidas em vários locais.....	105
Tabela 19 – Vinte elementos com maior índice TF-IDF.....	109
Tabela 20 – Cruzamento das vagas que mencionam experiência com as que mencionam nível de formação.....	113
Tabela 21 – Totalização das vagas coletadas e frequência de palavras-chave.....	113

Tabela 22 – Totalização das vagas coletadas por nível requerido.....	115
Tabela 23 – Vinte principais habilidades e ferramentas identificadas no conteúdo das vagas analisadas.....	117
Tabela 24 – Cargos presentes na pesquisa Data Hackers BR.....	123
Tabela 25 – Referência cruzada de áreas e nível de formação.....	125
Tabela 26 – Consolidação de habilidades e ferramentas – Pesquisa Data Hackers BR – P20 - Métodos.....	126
Tabela 27 – Consolidação de habilidades e ferramentas – Pesquisa Data Hackers – P21 - Linguagens.....	126
Tabela 28 – Consolidação de habilidades e ferramentas – Pesquisa Data Hackers – P23 - Fontes de dados.....	127
Tabela 29 – Consolidação de habilidades e ferramentas – Pesquisa Data Hackers – P25 - Nuvem (cloud)	127
Tabela 30 – Consolidação de habilidades e ferramentas – Pesquisa Data Hackers – P27 - Bancos de dados.....	128
Tabela 31 – Consolidação de habilidades e ferramentas – Pesquisa Data Hackers – P28 - Ferramentas de BI.....	128
Tabela 32 – Consolidação de habilidades e ferramentas – Pesquisa Data Hackers – P29 - Ferramentas de ETL.....	129
Tabela 33 – Principais habilidades e ferramentas presentes na análise de vagas, segregadas por profissional requerido no título da vaga.....	136
Tabela 34 – Informações das vagas coletadas.....	182

SUMÁRIO

1 INTRODUÇÃO.....	15
1.1 <i>BIG DATA</i> E CIÊNCIA DE DADOS.....	15
1.2 CIÊNCIA DE DADOS E CIENTISTAS DE DADOS.....	16
1.3 A DEMANDA POR CIENTISTAS DE DADOS.....	17
1.4 HABILIDADES DE CIENTISTAS DE DADOS.....	18
1.5 CIENTISTAS DE DADOS COMO PROFISSIONAIS ESSENCIAIS.....	18
1.6 PROBLEMA E OBJETIVO.....	19
1.7 JUSTIFICATIVA.....	21
1.8 SÍNTESE DO ESTUDO.....	21
1.9 ORGANIZAÇÃO DA DISSERTAÇÃO.....	23
2 REFERENCIAL TEÓRICO.....	24
2.1 INTRODUÇÃO.....	24
2.2 PLANEJAMENTO DA PESQUISA.....	24
2.2.1 Identificação da necessidade de revisão.....	24
2.2.2 Apresentação do protocolo.....	25
2.3 CONDUÇÃO DA REVISÃO.....	26
2.3.1 Identificação da pesquisa.....	26
2.3.2 Seleção e avaliação de estudos primários.....	29
2.3.3 Extração e síntese dos dados.....	31
2.4 RELATOS DA REVISÃO.....	31
2.4.1 Eixo 1 – Qual a definição de cientista de dados?.....	31
2.4.2 Eixo 2 – Quais as principais áreas de formação?	36
2.4.3 Eixo 3 – Quais principais habilidades e ferramentas?	38
2.5 CONCLUSÃO DA REVISÃO.....	60
2.5.1 Definição de cientista de dados.....	60
2.5.2 Formação de cientistas de dados.....	63
2.5.3 Habilidades de cientistas de dados e ferramentas utilizadas por cientistas de dados.....	64
2.5.3.1 Nota sobre o uso dos termos “habilidade” e “competência” no contexto deste estudo.....	65
2.5.3.2 <i>Hard skills</i> e <i>soft skills</i>	66
2.5.3.3 Resumo da conclusão sobre habilidades e ferramentas.....	67
3 PESQUISA EXPLORATÓRIA E QUALITATIVA: METODOLOGIA.....	82
3.1 MÉTODO DE PESQUISA.....	82

3.2 DEFINIÇÕES OPERACIONAIS.....	82
3.3 ENFOQUE E ABORDAGEM.....	83
3.4 MATRIZ DE AMARRAÇÃO.....	84
3.5 PROTOCOLO DE PESQUISA.....	86
3.5.1 Perspectiva de mercado.....	87
3.5.1.1 Coleta de dados.....	87
3.5.1.2 Fase 2: Tratamento de dados.....	89
3.5.1.2.1 Tratamento de dados estruturados.....	90
3.5.1.2.2 Tratamento de dados não estruturados.....	94
3.5.1.3 Fase 3: Consolidação de dados.....	112
3.5.1.3.1 Áreas de formação.....	112
3.5.1.3.2 Habilidades e ferramentas.....	115
3.5.2 Perspectiva de pessoas com base em dados secundários da Pesquisa Data Hackers.....	121
3.5.2.1 Fase 1: Coleta de dados.....	121
3.5.2.2 Fase 2: Tratamento de dados.....	123
3.5.2.2.1 Segregação dos casos de pessoas que informaram viverem no Brasil.....	123
3.5.2.2.2 Análise dos cargos anonimizados dos respondentes.....	123
3.5.2.2.3 Definição da base de dados para análise.....	124
3.5.2.3 Consolidação dos dados.....	124
3.5.2.3.1 Áreas de formação.....	124
3.5.2.3.2 Habilidades e ferramentas.....	125
3.6 COMPARAÇÃO ENTRE OS ACHADOS DA PESQUISA E DA REVISÃO SISTEMÁTICA DA LITERATURA.....	129
3.6.1 Áreas de formação.....	129
3.6.2 Habilidades e ferramentas.....	130
3.6.2.1 <i>Hard skills</i> – Conhecimentos gerais em computação e desenvolvimento de sistemas..	131
3.6.2.2 <i>Hard skills</i> – Conhecimentos gerais em negócios.....	132
3.6.2.3 <i>Hard skills</i> – Inteligência artificial.....	133
3.6.2.4 <i>Soft skills</i>	133
3.6.2.5 Ecossistemas, <i>frameworks</i> e bancos de dados.....	133
3.6.2.6 Linguagens de programação ou <i>scripts</i>	133
3.6.2.7 Visualização de dados.....	133
3.6.2.8 Outros: plataformas específicas, ambientes em nuvem e ambientes integrados.....	134

3.7 CONSIDERAÇÕES SOBRE AS DIFERENÇAS E SIMILARIDADES ENTRE CIENTISTAS DE DADOS, ANALISTAS DE DADOS, ENGENHEIROS DE DADOS E ARQUITETOS DE DADOS	134
3.8 PROPOSTA DE MODELO CONCEITUAL PRÉVIO PARA CIENTISTAS DE DADOS.....	138
3.9 VALIDAÇÃO DO MODELO.....	140
3.9.1 Protocolo de validação.....	140
3.9.2 Coleta de respostas.....	141
3.9.3 Resultado quantitativo.....	141
3.9.4 Resultado qualitativo.....	145
3.9.4.1 Definição de cientista de dados.....	145
3.9.4.2 Áreas de formação.....	147
3.9.4.3 <i>Soft skills</i>	148
3.9.4.4 <i>Hard skills</i>	149
3.9.4.5 Linguagens de programação.....	152
3.9.4.6 Ecossistemas, <i>frameworks</i> e bancos de dados.....	153
3.9.4.7 Técnicas de <i>machine learning</i> e <i>deep learning</i>	154
3.9.4.8 Visualização de dados.....	155
3.9.4.9 Comentários sobre a forma de segregação do modelo.....	156
4 APRESENTAÇÃO DOS RESULTADOS E PROPOSTAS DE ESTUDOS FUTUROS.....	158
4.1 MODELO CONCEITUAL PARA CIENTISTAS DE DADOS.....	159
4.2 DINAMISMO DA PROFISSÃO DE CIENTISTA DE DADOS.....	161
4.3 “SUPER-QUALIFICAÇÃO” DE CIENTISTAS DE DADOS.....	162
4.4 NECESSIDADE DO CONHECIMENTO DO NEGÓCIO.....	163
4.5 PYTHON COMO PRINCIPAL LINGUAGEM PARA CIENTISTAS DE DADOS.....	164
4.6 PROPOSTA DE ESTUDOS FUTUROS.....	166
4.6.1 PORTE DAS EMPRESAS CONTRATANTES.....	166
4.6.2 REGULAÇÃO SOBRE INTELIGÊNCIA ARTIFICIAL, ÉTICA E PRIVACIDADE DE DADOS.....	166
4.6.3 CIENTISTAS DE DADOS E ENGENHEIROS DE DADOS.....	166
4.6.4 REALIDADE BRASILEIRA EM RELAÇÃO À REALIDADE INTERNACIONAL..	167
4.6.5 CRIAÇÃO DE MODELOS CONCEITUAIS CONSIDERANDO TEMPO DE EXPERIÊNCIA.....	167

4.6.6 CRIAÇÃO DE MODELOS CONCEITUAIS SEGREGANDO VAGAS PARA CONSULTORIA VS. VAGAS INTERNAS.....	167
4.6.7 FORMAÇÃO DE CIENTISTAS DE DADOS.....	168
4.6.8 FORMAÇÃO POR MEIO DE OUTRAS FORMAS DE APRENDIZADO.....	168
REFERÊNCIAS.....	169
APÊNDICES.....	178

1 INTRODUÇÃO

Cientista de dados é a profissão mais *sexy* do século 21, segundo Davenport & Patil, (2012). Esta afirmação, título de artigo publicado no periódico *Harvard Business Review*, é amplamente conhecida no mercado e amplamente citada na academia. Dos 54 artigos selecionados na literatura acadêmica, como será visto adiante no referencial teórico, nada menos do que 22 artigos citam tal publicação.

Sexy, na visão dos autores, significa ter qualidades raras, que são muito procuradas, que são difíceis de achar e caras de contratar e, devido ao mercado muito competitivo para seus serviços, difíceis de reter. Mas a questão em aberto é: como defini-las? Qual é a formação do profissional que possui essas qualidades? Quais suas habilidades? Quais ferramentas utilizam?

A revista *Nature*, em 1968, fazendo uma resenha do guia *Who's Who in Science in Europe*, aponta a dificuldades em definir critérios determinando quem deveria estar neste guia, que, *a priori*, foi criado com o objetivo de ser um diretório de todos os cientistas da Europa. Numa comparação com o DOBS (*Directory of British Scientists*), a revista aponta, por exemplo, que este último inclui professores de nível secundário e estudantes pesquisadores que não estão no guia resenhado. Adicionalmente, cita que os representantes da Grã-Bretanha parecem estar no nível de acadêmicos de destaque, a ponto de obter o título de *Fellows of the Royal Society*, bem como adquirir funções de líderes de departamentos de pesquisa, tanto da indústria como do governo (Bunney, 1968).

A mesma problemática se apresenta mais de 50 anos depois: quais as fronteiras e critérios para definir um cientista e, particularmente, um cientista de dados? Este é o tema central deste estudo.

1.1 BIG DATA E CIÊNCIA DE DADOS

O potencial do *big data* em gerar conhecimento e criar novas formas de valor transforma as organizações e a sociedade. Apesar da declaração de que o cientista de dados tem “o trabalho mais *sexy* do século 21” (Davenport & Patil, 2012), ainda existem poucos estudos, de acordo com a pesquisa bibliográfica que foi conduzida para esta dissertação, sobre o que é um cientista de dados e quais habilidades profissionais esse tipo de função demanda, como pode ser verificado na revisão da literatura realizada para este estudo.

O aumento pela demanda por *big data* também aumentou a demanda de mercado por cientistas de dados (Chatfield et al., 2014). Essa demanda surge não apenas de *startups* como

também de grandes corporações, sob pressões competitivas globais por inovação e qualidade nas ofertas de serviços e produtos (Chatfield et al., 2014).

1.2 CIÊNCIA DE DADOS E CIENTISTAS DE DADOS

Segundo Yan & Davis (2019), o termo “ciência de dados” foi criado por Jeff C. Wu e foi empregado pela primeira vez durante uma palestra na Universidade de Michigan, em 1997 (Wu 1997 apud Yan & Davis, 2019). No ano seguinte, em outra palestra, Wu sugeriu que o termo “ciência de dados” fosse utilizado como um nome moderno para designar a ciência estatística (Wu 1998 apud Yan & Davis 2019).

Poucos anos depois, Cleveland (2001) criou um esboço de um plano para uma nova disciplina, com abrangência mais ampla que a da estatística, e a chamou de “ciência de dados” sem, no entanto, fazer referência a Wu, citado anteriormente. Do ponto de vista das publicações, o *The International Council for Science: Committee on Data for Science and Technology* começou a publicação do *Data Science Journal*, em 2002 enquanto a Universidade de Columbia iniciou a publicação do *The Journal of Data Science* em 2003.

O termo “ciência de dados” tornou-se popular nos anos 2000, por conta do crescimento de companhias baseadas na internet, tais como Yahoo, Google, LinkedIn, Facebook e Amazon; bem como diversas *startups*, tais como Palantir, Everstring, the Climate Corporation e Stitch Fix. Hoje em dia, o termo “ciência de dados”, em conjunto com o termo *big data*, se tornou um conceito frequente nos negócios, nas notícias, na mídia, nas redes sociais e também na academia, sendo “cientista de dados” um dos mais populares cargos relacionados a ele (Yan & Davis 2019; Columbus 2018).

Conquanto o termo “ciência de dados” ter se tornado popular, e cada vez mais existirem produtos baseados em dados, não há atualmente um consenso sobre o seu significado. A proposta de Wu traz modernidade para uma disciplina antiga, a estatística, mas, segundo Yan & Davis (2019), a maior parte dos praticantes de ciência de dados consideram-na de uma maneira bastante mais abrangente. Ainda segundo Yan & Davis (2019):

We view data science as the science of learning from data: a discipline that provides theory, methodology, principles, and guidelines for the analysis of data for tools, values, or insights. Here tools may include those that can help the user for better analysis, such as tools for visualization, data collection or exploration, and value refers mainly to those with commercial or scientific value. (YAN; DAVIS, 2019, p. 2)

Patil (2011) afirma que o termo “ciência de dados” é antigo, e geralmente referia-se à inteligência de negócios. Por outro lado, o conceito de “cientista de dados” parecia ser novo, uma vez que, desde que foi cunhado, em 2008, não encontrou ninguém que já o usasse antes.

De fato, uma análise do termo “cientista de dados” pesquisado no Google Trends (Figura 1) identifica que, desde 2011, inicia-se uma tendência no interesse ao tema, que permanece constante até maio de 2021.

Figura 1 – Interesse, segundo Google Trends, pelos termos relacionados a cientistas de dados



Fonte: autor; dados: Google Trends

1.3 A DEMANDA POR CIENTISTAS DE DADOS

A mudança de paradigma para negócios orientados para dados impacta a maioria das estratégias, modelos de negócio e processos, ao mesmo tempo que cria novas formas de trabalho, comunicação e interação (Carillo, 2017).

Segundo Provost & Fawcett (2013), não são apenas os cientistas de dados que devem ter habilidades em *analytics*. Isto deve ser considerado de forma mais ampla, como um componente da cultura da organização e, particularmente, dos sujeitos envolvidos no nível gerencial, no sentido de ter melhor engajamento com o time técnico. Whitby (2016) amplia este conceito ao empregar o termo *citizen data scientists* e o classificar como um novo tipo de consumidor de inteligência de negócios, que demanda mais do que indicadores de performance e utiliza as mais recentes tecnologias em *analytics*.

Atualmente, a profissão de cientista de dados é considerada uma das melhores opções

profissionais segundo relatório do sítio de empregos Glassdor e a revista *Forbes* (Columbus, 2019). O relatório define a profissão como a melhor opção, pelo quarto ano seguido, baseado num índice de satisfação dos praticantes, no número de posições disponíveis e na média da remuneração (Columbus, 2019).

Segundo Wallen (2019), a profissão de cientista de dados está em alta demanda: de acordo com a pesquisa *LinkedIn's 2017 U.S. Emerging Jobs Report*, desde 2012 o número de cientistas de dados cresceu impressionantes 650%, graças a organizações que cada vez mais adotam *big data* para tomar decisões. Ainda segundo Wallen (2019), estas organizações variam de grandes empresas globais até pequenos negócios com atuação local.

Ainda que a demanda venha crescendo, é importante reforçar os já citados Chatfield et al. (2014) no sentido que ainda são escassos os estudos publicados sobre o que é um cientista de dados e quais habilidades profissionais esse tipo de função demanda.

1.4 HABILIDADES DE CIENTISTAS DE DADOS

Se não há consenso sobre o termo “ciência de dados” (Yan & Davis 2019), também não há um consenso em relação às habilidades que fazem de um profissional um cientista de dados (Harris, 2013). A necessidade de uma definição para esse conjunto de habilidades é um dos focos da revisão da literatura, bem como uma das justificativas deste projeto.

No sentido de pesquisar o conjunto de habilidades de cientistas de dados, Patil (2011) levanta o questionamento “como encontrar um cientista de dados?”. Ele mesmo se propõe a responder essa indagação: “Quando alguém faz esta pergunta, pedimos a quem nos questionou para buscar outra questão mais fundamental: o que faz de um cientista de dados um bom cientista de dados?” E segue citando o que procuram: (a) *expertise* técnico em alguma disciplina científica; (b) curiosidade, ou o desejo de ir mais profundamente na solução de um problema através de um conjunto claro de hipóteses; (c) *storytelling*, ou a habilidade de usar dados e estar apto a comunicar-se de forma efetiva; e (d) inteligência (*cleverness*), ou a habilidade de buscar soluções para problemas de formas diferentes e criativas.

1.5 CIENTISTAS DE DADOS COMO PROFISSIONAIS ESSENCIAIS

No ano de 2020 foi declarada pandemia mundial relacionada ao COVID-19. Um problema, a princípio sem soluções então existentes, por se tratar de uma situação nova. A quantidade de dados gerada sobre o tema foi (e ainda é) enorme: não apenas as estatísticas de

casos suspeitos, de mortes e de recuperações, mas também de artigos científicos, de notícias, de *posts* em redes sociais e de *fake news*. É trabalho do cientista de dados coletar, segregar, analisar e modelar esta enorme quantidade de dados, e certamente o resultado do seu trabalho contribuiu, assim como segue contribuindo, para dar norte aos cientistas das áreas de saúde sobre os temas estudados.

Polonsky et al. (2019) afirmam que, apesar dos esforços contínuos para melhorar os sistemas de saúde em todo o mundo, epidemias de patógenos continuam sendo uma grande preocupação de saúde pública, e definiu o termo *outbreak analytics* como uma forma de ciência de dados voltada para aspectos tecnológicos e metodológicos, considerando coleta, análise, modelagem e relatórios, e focada na resposta a surtos e epidemias como a da COVID-19. Sua justificativa vem do fato de que dados são cada vez mais complexos devido à sua diversidade e aos diferentes métodos para obtê-los. Marr (2020) informa que a China, em resposta ao COVID-19, apoiou-se fortemente em seu setor de tecnologia e, especificamente, em Inteligência Artificial (IA), uma das áreas da ciência de dados, para combater a pandemia, com papel proeminente de companhias líderes em tecnologia, como Alibaba, Baidu e Huawei, bem como *startups* da área de saúde.

Cientistas de dados são os profissionais que têm condição de realizar a maior parte das atividades apresentadas por Polonsky (2019) e por Marr (2020). De fato, Perakslis (2020) claramente afirma que cientistas de dados se posicionam de forma única porque possuem as habilidades necessárias para minimizar, combater e ajudar na recuperação dos impactos da pandemia.

1.6 PROBLEMA E OBJETIVO

Como foi exposto, não há na literatura consenso em relação a uma definição consolidada sobre o termo cientista de dados, bem como não há consenso sobre habilidades necessárias para que os cientistas de dados cumpram seu papel num ambiente cada vez mais complexo.

Adicionalmente, existem questões pendentes na academia e no mercado sobre a existência de apenas um perfil de cientista de dados e apenas um conjunto de habilidades. Há uma indagação sobre a possibilidade de definir grupos ou famílias de cientistas de dados

baseando-se no tipo de trabalho que realizam e nas ferramentas¹ que utilizam.

A indefinição sobre o perfil dessa nova carreira pode trazer incertezas para (a) os cidadãos, principalmente jovens, em busca da carreira de cientista de dados, no sentido de que há uma dificuldade de definir um caminho de aprendizado; e (b) para empresas que buscam cientistas de dados, no sentido de que elas têm dificuldades para definir o perfil do profissional que precisam recrutar.

Em função de como a situação se apresenta, e com base no estudo das diversas definições e habilidades de cientistas de dados, considerando tanto aquelas oferecidas pela academia, como aquelas demandadas pelo mercado, definimos a questão de pesquisa: **quais aspectos definem um cientista de dados, sob as perspectivas da sua formação, de suas habilidades e das ferramentas que utiliza?**

Com base na questão de pesquisa acima foram definidos os seguintes objetivos primário e secundários:

- a) Objetivo primário: Definir um modelo conceitual para explicar a função de um cientista de dados, considerando a proposta de uma definição de sua atuação e áreas de formação, bem como considerando o conjunto de suas habilidades e as principais ferramentas utilizadas por esses profissionais;
- b) Objetivos secundários:
 - Revisar a literatura de forma sistemática com o objetivo de (a) buscar as definições existentes de cientista de dados e, a partir destas, consolidar a proposta de uma definição abrangente; (b) identificar as principais áreas de formação e o conjunto de habilidades e ferramentas utilizadas por esses profissionais;
 - Identificar no mercado de trabalho quais principais áreas de formação, habilidades e ferramentas são mais requeridas para exercer a profissão;
 - Comparar, através da análise de habilidades e ferramentas, e sob a perspectiva do mercado de trabalho, diferenças e similaridades entre cientistas de dados e atividades correlatas, como, por exemplo, engenharia de dados e análise de dados;

¹ Ferramentas, no contexto de cientistas de dados, referem-se majoritariamente a *software*, como linguagens de programação e bancos de dados.

- Buscar, junto a especialistas da academia e do mercado, a apreciação do modelo conceitual definido no objetivo primário, no sentido de avaliar diferenças e similaridades entre os praticantes *de facto* de ciência de dados e os achados que foram sumarizados no modelo conceitual.

A perspectiva sobre o mercado de trabalho refletirá apenas o mercado brasileiro.

1.7 JUSTIFICATIVA

As definições resultantes deste estudo contribuirão para a discussão sobre a determinação precisa do que é e o que faz um cientista de dados, e quais são as áreas de formação, quais as habilidades necessárias e as principais ferramentas utilizadas por esse tipo de profissional, através de um modelo conceitual, isto é, através de uma representação gráfica organizada, esquematizada, resumida e de fácil entendimento.

O modelo conceitual será útil (a) para cidadãos, particularmente jovens no momento de definição de seus primeiros passos profissionais, que desejam tornar-se cientistas de dados; (b) para profissionais já maduros, ou sem oportunidades de trabalho no seu ofício corrente, que vislumbram outra profissão; e (c) para empresas publicarem vagas com maior clareza e, conseqüentemente, atraírem candidatos mais assertivos para ocupar o cargo de cientista de dados e, com isso, melhorarem a produtividade e diminuir a rotatividade de seus colaboradores.

1.8 SÍNTESE DO ESTUDO

Na Figura 2 a seguir está representada, de forma sintética, a estrutura do estudo.

Figura 2 – Estrutura do estudo

Tema	Proposta de um modelo conceitual considerando definição, formação, habilidades e ferramentas de cientistas de dados			
Lacuna	Ausência de definição consolidada de ciência de dados e cientistas de dados.		Pouca literatura sobre habilidades de cientistas de dados, sobre sua formação e sobre ferramentas que utilizam.	
Problema	Cidadãos, principalmente jovens, em busca da profissão de cientista de dados têm dificuldade em definir uma trilha de aprendizado.		Empresas buscando cientistas de dados têm dificuldade para definir o perfil do profissional que precisam recrutar.	
Pergunta	Quais aspectos definem um cientista de dados, sob as perspectivas da sua formação, de suas habilidades e das ferramentas que utiliza			
Objetivos primário e secundários	(P) Definir um modelo conceitual para explicar a função de um cientista de dados, considerando a proposta de uma definição de sua atuação e áreas de formação, bem como considerando o conjunto de suas habilidades e as principais ferramentas utilizadas por esses profissionais			
	(S1) Revisar a literatura de forma sistemática com o objetivo de (a) buscar as definições existentes de cientista de dados e, a partir destas, consolidar a proposta de uma definição abrangente; (b) identificar as principais áreas de formação e o conjunto de habilidades e ferramentas utilizadas por esses profissionais	(S2) Identificar no mercado de trabalho quais principais áreas de formação, habilidades e ferramentas são mais requeridas para exercer a profissão.	(S3) Comparar, através da análise de habilidades e ferramentas, e sob a perspectiva do mercado de trabalho, diferenças e similaridades entre cientistas de dados e atividades correlatas, como, por exemplo, engenharia de dados e análise de dados.	(S4) Buscar, junto a especialistas da academia e do mercado, a apreciação do modelo conceitual definido no objetivo primário, no sentido de avaliar diferenças e similaridades entre os praticantes de facto de ciência de dados e os achados que foram sumarizados no modelo conceitual.
Referencial teórico	Domínio substantivo		Domínio metodológico	
	Cientista de dados: definição, conjunto de habilidades, áreas de formação e ferramentas.		Revisão sistemática de literatura; coleta de dados automatizada a partir de sítios na internet; tabulação de dados secundários de pesquisa realizada com cientistas de dados	
Método	Revisão sistemática de literatura		Pesquisa exploratória e qualitativa	
	Plano	- identificação da necessidade de revisão - desenvolvimento de um protocolo de revisão	Técnica de coleta de dados automatizada a partir de sítios na internet, denominada <i>webscrap</i>	- sítio de ofertas de empregos: LinkedIn - frequência de termos, agrupamento por similaridade, NLP (processamento de linguagem natural)
	Condução	- identificação de pesquisas - seleção dos estudos primários - avaliação da qualidade do estudo - extração e síntese dos dados	Tabulação de dados secundários de pesquisa realizada com cientistas de dados	- Dados secundários da 1ª pesquisa de mercado de Data Science, realizada pelo grupo Data Hackers Brasil. - Tabulação de dados estruturados
	Conclusão	relato da revisão	Validação do modelo conceitual	Utilização de roteiro de entrevista desenvolvido para validação do modelo conceitual com especialistas da academia e do mercado

Fonte: elaborado pelo autor.

1.9 ORGANIZAÇÃO DA DISSERTAÇÃO

Esta dissertação está organizada da seguinte forma: (1) introdução, questão de pesquisa, objetivos e justificativa; (2) referencial teórico, onde será apresentada a revisão sistemática da literatura; (3) metodologia de pesquisa; (4) apresentação dos resultados e propostas de estudos futuros; (5) referências.

2 REFERENCIAL TEÓRICO

2.1 INTRODUÇÃO

A revisão da literatura é uma atividade essencial do processo de investigação, e deve ser realizada de forma contínua (Bloomberg & Volpe, 2015). Optou-se para esse estudo pela realização de uma Revisão Sistemática da Literatura (RSL), que visa, através de uma busca consistente e parametrizada, identificar e interpretar todas as informações existentes sobre o tema estudado, de forma completa e imparcial (Kitchenham, 2004). Dessa maneira, procurou-se identificar as principais definições do termo “cientista de dados”. Para atingir esse objetivo, foi necessário considerar as áreas de formação e as habilidades associadas a esse tipo de profissional. Além disso, foi preciso consultar na literatura existente quais são as principais ferramentas utilizadas por um cientista de dados.

2.2 PLANEJAMENTO DA PESQUISA

2.2.1 Identificação da necessidade de revisão

Previamente à RSL foi realizada uma pesquisa exploratória, com objetivo de obter uma maior familiarização com o assunto, de modo que a pesquisa subsequente pudesse ser concebida com uma maior compreensão, entendimento e precisão. Segundo Cooper & Schindler (2014), através da pesquisa exploratória, o desenvolvimento da pesquisa torna-se mais claro e é mais fácil para se estabelecerem prioridades e se desenvolverem definições operacionais, melhorando a qualidade da pesquisa de uma forma geral.

O objetivo da pesquisa exploratória, no contexto desta dissertação, foi identificar o que existe relacionado aos praticantes de ciência de dados, ou cientistas de dados, e ajudar na definição das principais palavras-chave (incluindo sinônimos) e das bases de dados a serem utilizadas no protocolo da RSL.

O objetivo da RSL foi responder à questão de pesquisa, desdobrada, para facilitar o entendimento, em 3 eixos:

- a) Eixo 1 – Qual a definição de cientista de dados?
- b) Eixo 2 – Quais as principais áreas de formação?
- c) Eixo 3 – Quais as principais habilidades e ferramentas?

2.2.2 Apresentação do protocolo

A pesquisa exploratória, realizada através do Google Scholar, procurou identificar artigos relacionados aos temas afeitos a este estudo. Além disso, ela foi a base para identificar as palavras-chave utilizadas nas fórmulas de pesquisa que serão expostas a seguir. Foram também consultados, informalmente, profissionais cientistas de dados do mercado. O primeiro termo pesquisado, *data literacy*, foi sugerido com o objetivo estar conectado com as habilidades que profissionais que lidam com dados precisariam possuir e diversos artigos sugerem esta conexão (Ridsdale et al., 2015; D’Ignazio & Bhargava, 2016; Wolff et al., 2016). Um dos termos mais presentes nas buscas no Google Scholar foi “*analytics*”, conceito que se provou demasiadamente genérico, envolvendo outros profissionais além de cientistas de dados, como, por exemplo, profissionais de inteligência de negócios.

As palavras-chave mais relevantes achadas na pesquisa exploratória foram combinadas em fórmulas, de forma a endereçar a questão de pesquisa (Tabela 1):

Tabela 1 – Fórmulas utilizadas para procura de artigos

Fórmula	Conteúdo da Fórmula
1	“ <i>data literacy</i> ”
2	“ <i>data</i> ” AND “ <i>literacy</i> ”
3	“ <i>analytics</i> ” AND “ <i>skills</i> ”
4	“ <i>analyt*</i> ” AND (“ <i>skills</i> ” OR “ <i>compet*</i> ” OR “ <i>abilit*</i> ”)
5	“ <i>data scientist</i> ” AND <i>definition</i>
6	“ <i>data scientist</i> ” AND (“ <i>skills</i> ” or “ <i>abilities</i> ” or “ <i>ability</i> ” or “ <i>competency</i> ” or “ <i>competencies</i> ” or “ <i>knowledge</i> ”)

Fonte: elaborado pelo autor.

Encontrar material relevante para uma ampla revisão da literatura envolve múltiplas estratégias e grande variedade de fontes (Bloomberg & Volpe, 2015) e, portanto, foram identificadas as bases de dados conhecidas, por oferecerem pesquisas científicas e serem utilizadas para outras pesquisas de revisão da literatura na área. Elas são relacionadas abaixo:

- a) ACM
- b) EBSCO
- c) Elsevier Science Direct
- d) Google Scholar
- e) IEEE
- f) Proquest

- g) Scopus
- h) Web of Science

É importante notar que nem todas as fórmulas de pesquisa foram utilizadas em todos os bancos de dados. Por exemplo, como será visto a seguir, termos como “data literacy” revelaram documentos pouco úteis para este projeto de pesquisa, bem como “analytics” revelou-se muito genérico, conforme já mencionado. As pesquisas nas bases de dados revisão da literatura foram realizadas de maio a outubro de 2019 e, ao longo de sua condução, foram realizados refinamentos, que resultaram em 22 pesquisas nas diversas bases de dados. Esta explicação se faz necessária uma vez que 6 fórmulas de pesquisa, em 8 bases de dados, deveriam resultar em 48 pesquisas. Como será visto a seguir, os 2.245 artigos foram coletados a partir de 22 pesquisas.

Concluída a fase de planejamento, iniciou-se a fase de condução da RSL.

2.3 CONDUÇÃO DA REVISÃO

2.3.1 Identificação da pesquisa

O objetivo de uma revisão sistemática é encontrar o maior número de estudos primários relacionados à questão de pesquisa, usando uma estratégia imparcial. O rigor do processo de busca é um fator que distingue revisões sistemáticas de revisões tradicionais (Kitchenham, 2004). Os artigos analisados foram inseridos na plataforma Mendeley e catalogados de forma a assegurar que todos foram contemplados.

A pesquisa com base de dados envolve o processo de discernir entre quais artigos são mais adequados para a pesquisa e aqueles que são periféricos. Dada a quantidade de documentos resultantes das buscas, houve a necessidade de criar filtros específicos. Como toda a revisão deve ser documentada de forma detalhada, visando à evidenciação do rigor da pesquisa (Kitchenham, 2004), o detalhamento de cada uma das pesquisas está documentado a seguir (Tabela 2):

Tabela 2 – Relação de buscas realizadas (continua)

#REF	Base de dados	Fórmula de busca & filtros aplicados	Data da pesquisa	#Documentos identificados
01	Web of Science	TOPIC: (data literacy) Refined by: DOCUMENT TYPES: (ARTICLE OR PROCEEDINGS PAPER) AND WEB OF SCIENCE CATEGORIES: (INFORMATION SCIENCE LIBRARY SCIENCE) AND Timespan: 2000-2019. Indexes: SCI-EXPANDED, SSCI, A&HCI, CPCI-S, CPCI-SSH, ESCI.	12/05/19	464
02	Scopus	TITLE-ABS-KEY (“data literacy”) AND (LIMIT-TO (SUBJAREA, “ARTS”) OR LIMIT-TO (SUBJAREA, “MEDI”) OR LIMIT-TO (SUBJAREA, “DECI”) OR LIMIT-TO (SUBJAREA, “EART”) OR LIMIT-TO (SUBJAREA, “AGRI”))	12/05/19	36
03	IEEE	data AND literacy Filters Applied: Conferences Journals & Magazines Books Early Access Articles 2010 - 2019	12/05/19	308
04	Proquest	noft(analytics) AND noft(skills); Materials Business File content only; Additional limits - Source type: Conference Papers & Proceedings, Dissertations & Theses (mais). Time span 2010-2018.	14/05/19	37
05	Web of Science	TITLE: (analyt*) AND TITLE: ((skills OR compet* OR ability*)) Refined by: WEB OF SCIENCE CATEGORIES: (EDUCATION EDUCATIONAL RESEARCH OR MANAGEMENT OR COMPUTER SCIENCE INFORMATION SYSTEMS OR COMPUTER SCIENCE INTERDISCIPLINARY APPLICATIONS OR BUSINESS OR COMPUTER SCIENCE THEORY METHODS OR BUSINESS FINANCE) Timespan: Last 5 years. Indexes: SCI-EXPANDED, SSCI, A&HCI, CPCI-S, CPCI-SSH, ESCI.	25/05/19	86
06	Google Scholar	skills “machine learning”; skills “analytics”	10/06/19	20
07	Web of Science	“data scientist” AND definition	17/09/19	7
08	Scopus	“data scientist” AND definition	17/09/19	36
09	Elsevier Sciece Direct	“data scientist” AND definition	17/09/19	1
10	IEEE	“data scientist” AND definition	17/09/19	3
11	Proquest	“data scientist” AND definition	17/09/19	21
12	Google Scholar	“data scientist” AND definition	17/09/19	32

Tabela 2 – Relação de buscas realizadas (continuação)

#REF	Base de dados	Fórmula de busca & filtros aplicados	Data da pesquisa	#Documentos identificados
13	Ebsco	“data scientist” AND definition	17/09/19	11
14	Web of Science	TÓPICO: ((“data scientist” OR “cientista de dados” OR “data science”) AND (“compet*” OR “skills” OR “abilit*”)) Refinado por: CATEGORIAS DO WEB OF SCIENCE: (COMPUTER SCIENCE INFORMATION SYSTEMS OR COMPUTER SCIENCE THEORY METHODS OR COMPUTER SCIENCE INTERDISCIPLINARY APPLICATIONS OR COMPUTER SCIENCE ARTIFICIAL INTELLIGENCE OR MANAGEMENT OR MULTIDISCIPLINARY SCIENCES OR EDUCATION SCIENTIFIC DISCIPLINES OR BUSINESS OR MEDICAL INFORMATICS OR BIOCHEMICAL RESEARCH METHODS OR COMPUTER SCIENCE CYBERNETICS OR ECONOMICS) AND TIPOS DE DOCUMENTO: (ARTICLE OR PROCEEDINGS PAPER) Tempo estipulado: Todos os anos. Índices: SCI-EXPANDED, SSCI, A&HCI, CPCI-S, CPCI-SSH, ESCI.	17/09/19	164
15	Scopus	TITLE-ABS-KEY (((“data scientist” OR “cientista de dados” OR “data science”) AND (“compet*” OR “skills” OR “abilit*”))) AND (LIMIT-TO (SUBJAREA, “COMP”) OR LIMIT-TO (SUBJAREA, “ENGI”) OR LIMIT-TO (SUBJAREA, “MATH”) OR LIMIT-TO (SUBJAREA, “SOCI”) OR LIMIT-TO (SUBJAREA, “BUSI”) OR LIMIT-TO (SUBJAREA, “DECI”) OR LIMIT-TO (SUBJAREA, “MEDI”) OR LIMIT-TO (SUBJAREA, “BIOC”)) AND (LIMIT-TO (DOCTYPE, “cp”) OR LIMIT-TO (DOCTYPE, “ar”))	17/09/19	439
16	Web of Science	You searched for: TOPIC: ((“data scientist” OR “data science”) AND (“skills” or “abilities” or “ability” or “competency” or “competencies” or “knowledge”)) Refined by: WEB OF SCIENCE CATEGORIES: (COMPUTER SCIENCE INFORMATION SYSTEMS OR COMPUTER SCIENCE THEORY METHODS OR COMPUTER SCIENCE ARTIFICIAL INTELLIGENCE OR COMPUTER SCIENCE INTERDISCIPLINARY APPLICATIONS OR COMPUTER SCIENCE SOFTWARE ENGINEERING OR MANAGEMENT OR EDUCATION SCIENTIFIC DISCIPLINES OR STATISTICS PROBABILITY OR MULTIDISCIPLINARY SCIENCES OR BUSINESS) AND DOCUMENT TYPES: (PROCEEDINGS PAPER OR ARTICLE) Timespan: All years. Indexes: SCI-EXPANDED, SSCI, A&HCI, CPCI-S, CPCI-SSH, ESCI.	04/10/19	59

Tabela 2 – Relação de buscas realizadas (continuação)


#REF	Base de dados	Fórmula de busca & filtros aplicados	Data da pesquisa	#Documentos identificados
17	Scopus	TITLE-ABS-KEY (“data scientist” AND (“skills” OR “abilities” OR “ability” OR “competency” OR “competencies” OR “knowledge”)) AND (LIMIT-TO (DOCTYPE, “cp”) OR LIMIT-TO (DOCTYPE, “ar”)) AND (LIMIT-TO (SUBJAREA, “COMP”) OR LIMIT-TO (SUBJAREA, “SOCI”) OR LIMIT-TO (SUBJAREA, “BUSI”) OR LIMIT-TO (SUBJAREA, “DECI”)) AND (LIMIT-TO (LANGUAGE, “English”))	04/10/19	162
18	IEEE	“data scientist” AND (skills OR abilit* OR competenc* OR knowledge) Filters Applied: Conferences Magazines Early Access Articles Journals	04/10/19	29
19	Proquest	“data scientist” AND (“skills” or “abilities” or “ability” or “competency” or “competencies” or “knowledge”) Applied filters Scholarly Journals	04/10/19	37
20	Ebsco	AB “data scientist” AND AB (skills or abiliti* or competenc* or knowledge) Ebsco discovery service	04/10/19	56
21	Elsevier Sciece Direct	“data scientist” AND (knowledge or skill or ability or competency or competencies or knowledge) Review articles, research articles	04/10/19	88
22	ACM	Searched for “data scientist” AND (“skills” or “abilities” or “ability” or “competency” or “competencies” or “knowledge”); Searched The ACM Full-Text Collection: 570,825 records	04/10/19	149
		Quantidade total de artigos		2.245

Fonte: elaborado pelo autor.

2.3.2 Seleção e avaliação de estudos primários

A pesquisa nas bases de dados revelou 2.245 artigos, sendo que 54 foram efetivamente aproveitados para a RSL, conforme a Figura 3:

Figura 3 – Bases de dados e resultados



	WoS	Scopus	IEEE	Proquest	Ebsco	Elsevier	ACM	Google Scholar	Total
Resultados Obtidos	780	673	340	95	67	89	149	52	2.245
RSL Fase 1	61	74	20	17	37	8	12	30	259
RSL Fase 2	10	12	5	9	6	2	3	7	54

Fonte: elaborado pelo autor.

Conforme Kitchenham (2004), o processo de seleção foi realizado utilizando critérios previamente definidos. Numa primeira análise (RSL Fase 1), principalmente voltada para excluir documentos, foram usados os seguintes critérios:

- Exclusão de artigos cujo título não está relacionado com a questão de pesquisa. Grande parte das exclusões deram-se porque os resultados das fórmulas relacionadas a *data literacy* revelaram um volume relevante de documentos relacionados a atividades de biblioteconomia, e não relacionados à ciência de dados;
- Exclusão de artigos periféricos ou não diretamente relacionadas ao tema, ou fora do escopo da pesquisa;
- Exclusão de artigos não publicados em periódicos acadêmicos ou conferências;
- Exclusão de artigos cujo conteúdo completo não é acessível de forma gratuita ou através dos convênios da Universidade de São Paulo.

Na Fase 2, os 259 documentos resultantes da Fase 1 da RSL foram analisados com base na leitura dos resumos e das conclusões, atentando para os critérios abaixo:

- Inclusão de artigos cujo conteúdo ajuda no processo de definição da função de um cientista de dados;
- Inclusão de artigos que permitem identificar as áreas de formação de cientistas de dados;
- Inclusão de artigos que permitem identificar um conjunto, ou conjuntos, de habilidades de cientistas de dados;
- Inclusão de artigos que permitem identificar as principais ferramentas utilizadas por cientistas de dados.

Conforme mencionado no início deste tópico, o resultado final da fase de seleção desta revisão identificou 54 artigos que se constituíram como base para responder à questão de pesquisa e atender aos objetivos definidos por ela.

2.3.3 Extração e síntese dos dados

A partir da leitura integral de cada um dos 54 artigos selecionados nas etapas anteriores, foi realizado o processo de extração de dados (Tenório et al., 2016), de forma que todas as informações necessárias para abordar os eixos específicos da RSL fossem identificados (Kitchenham, 2004). Os resultados encontrados serão apresentados na próxima seção.

2.4 RELATOS DA REVISÃO

2.4.1 Eixo 1 – Qual a definição de cientista de dados?

Um ponto frequente observado durante a RSL foi o fato de que o termo “cientista de dados” é amplamente utilizado em diversos trabalhos sem uma definição explícita, implicitamente identificando esses profissionais simplesmente como “aqueles ou aquelas que praticam ciência de dados” (Demchenko et al. 2017; Dichev & Dicheva 2017; Kaleda & Fenstermacher 2018; Pedersen & Caviglia 2019; Yan & Davis 2019; Belloum et al. 2019; Verma et al. 2019; Harris 2013; Mattmann 2013; Wiktorski et al. 2016; Baumer 2017; Meyer 2018; Knorr et al. 2018; Pires & Leitão 2018; Kross & Guo 2019; Demchenko et al. 2019).

Segundo De Mauro et al. (2017), o atual estágio da disciplina de ciência de dados, sendo mais prática e experimental, e não teórica e metodológica, faz com que haja confusão entre o campo de estudo e o que os praticantes – no caso, cientistas de dados – efetivamente fazem.

A consolidação dos resultados da RSL demonstra que não há um consenso sobre uma definição para a função do cientista de dados, conforme pode ser visto a seguir. As principais definições encontradas são apresentadas abaixo (Tabela 3):

Tabela 3 – Definições de cientistas de dados (continua)

Definição traduzida	Definição original	Autor
“indivíduos, poucos no momento, que possuem conhecimentos específicos e experiência em gerenciamento de dados. Funcionam como a interface humana entre a biblioteca e os projetos de ciência digital.”	<i>“Individuals, who are few in number at the moment, possess domain- specific knowledge and data management expertise. They act as the human interface between the library and the eScience projects.”</i>	Choudhury (2008)
“Pessoas que trabalham onde a pesquisa é realizada – ou, se trabalham com dados, em estreita colaboração com os criadores desses dados, bem como podem estar envolvidas em pesquisas e análises criativas, permitindo que outras pessoas trabalhem com dados digitais e desenvolvam tecnologia de banco de dados.”	<i>“People who work where the research is carried out – or, in the case of data center personnel, in close collaboration with the creators of the data and may be involved in creative enquiry and analysis, enabling others to work with digital data, and developments in data base technology.”</i>	Swan & Brown (2008); Cao (2017)
“Alguém que entende como procurar respostas para questões de negócio relevantes a partir do tsunami de informações não estruturadas existentes atualmente.”	<i>“Someone who understands how to fish out answers to important business questions from today’s tsunami of unstructured information.”</i>	Davenport & Patil (2012); Debortoli et al. (2014); Van der Aalst (2014)

Tabela 3 – Definições de cientistas de dados (continuação)

Definição traduzida	Definição original	Autor
“Um membro da equipe [que] poderia criar um fluxo de processamento de vários estágios no Python, projetar um teste de hipótese, executar uma análise de regressão sobre amostras de dados com R, projetar e implementar um algoritmo para algum produto ou serviço baseado em dados no Hadoop, ou ainda comunicar os resultados de nossas análises para outros membros da organização.”	<i>“A team member [who] could author a multistage processing pipeline in Python, design a hypothesis test, perform a regression analysis over data samples with R, design and implement an algorithm for some data-intensive product or service in Hadoop, or communicate the results of our analyses to other members of the organization”</i>	Loukides (2012) apud Debortoli et al. (2014)
“Profissionais de modelagem que resolvem problemas de negócios. Eles incorporam abordagens analíticas avançadas usando ferramentas sofisticadas de análise e visualização de dados para descobrir padrões nos dados. Em muitos casos, esses profissionais trabalham com técnicas de análise bem conhecidas e estáveis, como regressão logística, agrupamento e classificação, para extrair conhecimento dos dados. Esses profissionais têm um profundo conhecimento de negócio e aplicam-no para analisar dados e fornecer resultados que sejam compreendidos de forma intuitiva através de ferramentas avançadas de visualização de dados.”	<i>“The practitioners of the analytics models solving business problems. They incorporate advanced analytical approaches using sophisticated analytics and data visualization tools to discover patterns in data. In many cases, these practitioners work with well-established analytics techniques such as logistic regression methods, clustering methods, and classification methods to draw insights from data. These practitioners have deep understanding of the business domain and apply that effectively to analyze data and deliver the outcomes in a business understandable intuitive manner through advanced data visualization tools.”</i>	Mohanty et al. (2013)
“Requer um conjunto de habilidades integradas, abrangendo matemática, aprendizado de máquina, inteligência artificial, estatísticas, bancos de dados e otimização, além de um profundo conhecimento de formulação de problemas para projetar soluções eficazes.”	<i>“Requires an integrated skill set spanning mathematics, machine learning, artificial intelligence, statistics, databases, and optimization, along with a deep understanding of the craft of problem formulation to engineer effective solutions.”</i>	Dhar (2013)
“Super-heróis com todas as qualidades e conhecimentos para realizar um projeto de ciência de dados bem-sucedido.”	<i>“Super heroes with all the qualities and knowledge to make a data science project successful.”</i>	Viaene (2013)
“Os cientistas de dados bem-sucedidos devem ser capazes de entender problemas de negócios sob uma perspectiva de dados.”	<i>“Successful data scientists must be able to view business problems from a data perspective”</i>	Provost & Fawcett (2013); Waller & Fawcett (2013)
“Nem estatísticos, nem analistas de dados, nem cientistas da computação, nem engenheiros de sistemas, nem analistas de negócios. Tem algum conhecimento em cada uma dessas áreas, mas também alguns conhecimentos fora delas.”	<i>“Not statisticians, nor data analysts, nor computer scientists, nor software engineers, nor business analysts. They have some knowledge in each of these areas but also some outside of these areas.”</i>	Granville (2014)

Tabela 3 – Definições de cientistas de dados (continuação)

Definição traduzida	Definição original	Autor
“Os cientistas de dados devem possuir conhecimento (e obter competências e habilidades) em mineração e análise de dados, visualização e comunicação de informações, bem como em estatística, engenharia e ciência da computação, e adquirir experiências no domínio específico da pesquisa ou da indústria de seus futuros trabalhos e especialização.”	<i>“data scientists must possess knowledge (and obtain competencies and skills) in data mining and analytics, information visualization and communication, as well as in statistics, engineering and computer science, and acquire experiences in the specific research or industry domain of their future work and specialization.”</i>	Manieri et al. (2015)
“Um especialista capaz de extrair valor significativo dos dados e gerenciar todo o ciclo de vida dos dados.”	<i>“An expert who is capable of extracting meaningful value from the data and also managing the whole lifecycle of data.”</i>	Manieri et al. (2015)
“Indivíduos com formação avançada em disciplinas quantitativas”; “Uma base sólida em ciência da computação e matemática, incluindo probabilidade e estatística”	<i>“Individuals with advanced degrees in a quantitative discipline”; “a solid foundation in computer science and mathematics, which includes probability and statistics”</i>	Wilder & Ozgur (2015)
“Um profissional capaz de lidar individualmente com a maioria das necessidades analíticas de uma empresa.”	<i>“a professional able to individually cope with most analytical needs of a company”</i>	De Mauro (2016)
“Especialistas com sólida formação técnica e profundo conhecimento das tecnologias que utilizam dados de forma intensiva.”	<i>“Specialists with strong technical background and deep knowledge of the data intensive technologies.”</i>	Demchenko et al. (2016)
“Um profissional com sólido conhecimento em negócios, habilidades analíticas e engenharia de sistemas, que gerencia o processo metodológico, do começo ao fim, em cada estágio do ciclo de vida do <i>big data</i> .”	<i>“A practitioner who has sufficient knowledge in the overlapping regimes of expertise in business needs, domain knowledge, analytical skills, and programming and systems engineering expertise to manage the end-to-end scientific method process through each stage in the big data lifecycle.”</i>	Demchenko et al. (2016)
“É alguém que é melhor em programação que um estatístico e melhor em estatística que um cientista da computação.”	<i>“Is someone who is better at programming than a statistician and better at statistics than a computer scientist”</i>	Başkarada & Koronios (2017)
“Geralmente são conhecidos por possuir habilidades analíticas para analisar <i>big data</i> .”	<i>“Are typically known to possess analytical skills to interrogate and analyze big data.”</i>	Kotzé (2017)
“Cria modelos analíticos sofisticados usados para criar novos conjuntos de dados e obter conhecimento a partir desses dados.”	<i>“Create sophisticated analytical models used to build new datasets and derive new insights from data.”</i>	Markow et al. (2017)
“Cientistas de computação, engenheiros e programadores de bancos de dados e sistemas, atuando de forma disciplinada [<i>disciplinary experts</i>], curadores e comentaristas especializados, bibliotecários, arquivistas e outros, que são cruciais para o gerenciamento efetivo de uma coleta de dados digitais.”	<i>“The information and computer scientists, database and software engineers and programmers, disciplinary experts, curators and expert annotators, librarians, archivists, and others, who are crucial to the successful management of a digital data collection.”</i>	Cao (2017)

Tabela 3 – Definições de cientistas de dados (continuação)

Definição traduzida	Definição original	Autor
“Cientistas que têm formação em ciência da computação, para se tornarem curadores de dados usando método disciplinado (científico) e avançar na arte da ciência de dados. Foco em todas as partes do ciclo de vida dos dados.”	<i>“Scientists who come from information or data curators in disciplines and advance the art of data science. Focus on all parts of the data life cycle.”</i>	Cao (2017)
“Cientistas de dados estão envolvidos na coleta de dados, manipulando-os até uma forma mais compreensível, fazendo com que os dados contem uma história e apresentando essa história a outras pessoas.”	<i>“Data scientists are involved with gathering data, massaging it into a tractable form, making it tell its story, and presenting that story to others.”</i>	Ecleo & Galido (2017)
“Um profissional sênior com treinamento e curiosidade para fazer descobertas no mundo de <i>big data</i> .”	<i>“A high-ranking professional with the training and curiosity to make discoveries in the world of big data.”</i>	Davenport & Patil (2012); Carillo (2017); Mikalef (2018); Miller (2019)
“Alguém curioso, capaz de olhar para os dados e identificar tendências. É quase como um indivíduo renascentista que realmente quer aprender e trazer mudanças para uma organização.”	<i>“Somebody who is inquisitive, who can stare at data and spot trends. It’s almost like a Renaissance individual who truly wants to learn and bring change to an organization.”</i>	Hu et al. (2018)
“Encontre as perguntas que podem ser feitas a um conjunto de dados específicos, traduza essas perguntas em um conjunto de hipóteses e escreva o código no computador que preparará e analisará os dados; e faça a análise para responder às perguntas e testar as hipóteses.”	<i>“Find the questions that can be asked of particular data, to translate these questions into a set of hypotheses, and to write the computer code that will prepare and interrogate the data; and perform the analysis to answer the questions and test the hypothesis.”</i>	Miller (2019)
“Há abundância de dados e é necessário que alguém coordene, compreenda, minere e extraia valor destes dados.”	<i>“There is a glut of data, and there is need for a subject to command, comprehend, mine and extract value from it.”</i>	Gehl (2015)
“Uma pessoa que trabalha com dados impactando os processos de negócios, entendendo como encontrar respostas para importantes questões de negócio e explorando dados em grande quantidade e com alta diversidade, e fazendo todas estas atividades utilizando método científico.”	<i>“A person who works on data applications impacting the business processes, understanding how to find answers to important business questions and exploring a voluminous and diverse set of data through a scientific way of doing things.”</i>	Costa & Santos (2017)

Fonte: elaborado pelo autor.

2.4.2 Eixo 2 – Quais as principais áreas de formação?

Neste estudo foram consideradas como áreas de formação aquelas formais onde pode-se obter um diploma de bacharelado. Exemplos são matemática, física e engenharia. Em oposição, outros tipos de formação encontrados, como visualização de dados ou reconhecimento de padrões, foram considerados como habilidades e serão apresentados na Seção 2.4.3.

A formação em ciência de dados não foi considerada como uma formação específica por não ser, ao menos neste momento, algo formalizado de forma ampla no mundo acadêmico. O consenso na comunidade acadêmica é que a ciência de dados é, de fato, uma nova disciplina, assim como a ciência da computação surgiu da matemática quando os computadores se tornaram abundantes nos anos 80 (Mikalef, 2018). Diversas universidades criaram programas de qualificação em ciência de dados, mas estes novos programas tendem a estar associados às disciplinas de ciência da computação, matemática ou estatística (Gibert et. al., 2018).

Liu et al. (2009) discutem a construção da disciplina de ciência de dados e apresentam como exemplos alguns esforços na criação de comunidades voltadas para a ciência de dados, consideradas inspiradoras pelos autores. Dos quatro exemplos de comunidades apresentados, todos eles criados em universidades, três citam os departamentos onde estão fundeados: ciência da computação, engenharia e matemática.

Vangelova (2014 apud Chatfield et al., 2014), baseado em entrevistas com profissionais da área, indica que a maior parte dos cientistas de dados é formada em ciência da computação, matemática, estatística ou outras ciências naturais ou sociais que utilizam métodos quantitativos.

Gehl (2015), no sentido de informar sobre a formação de cientistas de dados, cita o sítio Kaagle (www.kaggle.com), que se define como “a principal plataforma para competições de modelagem preditiva” e que compreende “a maior comunidade de cientistas de dados do mundo”. Neste sítio, a formação dos cientistas de dados é informada como sendo majoritariamente em campos quantitativos como ciência da computação, estatística, economia, matemática e física.

Cegielski & Jones-Farmer (2016), em seu estudo sobre o desenvolvimento de habilidades para posições iniciais de mercado relacionadas a *big data analytics*, direcionaram a lente de seu trabalho principalmente para cursos de graduação em faculdades de negócios, ou seja, não voltados para ciências de dados especificamente. Cegielski & Jones-Farmer (2016) informam que analisar dados e associar essas análises aos objetivos estratégicos de uma

empresa (análise de negócios) faz parte das atividades deste público mais abrangente, mas que habilidades mais técnicas, como, por exemplo, desenvolver estruturas de dados ou algoritmos para análise – atividades mais pertinentes a cientistas de dados – requerem uma formação em ciência da computação, engenharia ou matemática, que estão além dos currículos das faculdades de negócios.

Başkarada & Koronios (2017) informam que muitas organizações estão buscando cientistas de dados “unicórnios”, que podem realizar todas as tarefas de um projeto de ciência de dados. Segundo os autores, esses profissionais buscados são especialistas em muitas disciplinas tradicionalmente distintas, incluindo matemática, estatística, ciência da computação, inteligência artificial e outras. Na busca por “criaturas míticas indescritíveis” (sic), os autores avaliaram cursos de pós-graduação em ciência de dados oferecidos por universidades australianas e, apresentando os requisitos de admissão, informaram ser necessário um diploma de bacharel nas formações de matemática, ciência da computação, física, engenharia, contabilidade, finanças ou economia.

Cao (2017), apresentando diversas características que fazem de um profissional um bom cientista de dados, cita formações específicas, com diplomas de mestrado ou doutorado, em ciência de computação, estatística, matemática, engenharia e física.

Parte dessas formações – matemática, estatística e ciência da computação – são também as principais encontradas por Kotzé (2017), que afirma que um cientista de dados deve possuir pelo menos um diploma de bacharel, embora uma pós-graduação seja fortemente recomendada.

Segundo Costa & Santos (2017), o cientista de dados é visto principalmente como um profissional multidisciplinar, cujo perfil é uma combinação de diferentes áreas como a ciência da computação, a estatística e a matemática.

Pires & Leitão (2018) conduziram um estudo sobre caminhos de aprendizado existentes na academia para cientistas de dados, e consideram que a formação acadêmica é muito importante, uma vez que não existem cursos totalmente delineados para esta formação e os profissionais precisam vir de áreas adjacentes. Em seu estudo, Pires & Leitão (2018) citam as seguintes formações: engenharia, matemática, estatística, ciência da computação, economia e física.

Hu et al. (2018) coletaram dados de ofertas de emprego do sítio Monster (www.monster.com) para analisar, entre outros, perfis de cientistas de dados, e observaram que a formação como bacharel de ciência de computação é a mais provável de ser encontrada, com 73%. Importante citar que Hu et al. (2018) também informaram que a probabilidade de encontrar um bacharel em ciência de dados é de 69%, o que contraria todos os demais estudos

analisados nesta RSL, onde não há referência a um bacharelado em ciência de dados. Este viés de análise pode se dever ao fato de que a base da pesquisa de Hu et al. (2018) é de dados coletados de ofertas de emprego.

Yan & Davis (2019), em seu estudo sobre a formação de um curso de ciência de dados, efetivamente ocorrendo desde o outono de 2015, informam que 60% dos alunos têm formação em uma lista ampla: matemática, ciência da computação, biologia, engenharia elétrica e mecânica, contabilidade e sistemas de informação.

Apesar da maioria dos artigos indicar uma formação eminentemente técnica, e, por isso, várias habilidades necessárias já fazerem parte dos currículos de ciência da computação, engenharia e outras formações relacionadas à tecnologia, há várias outras que não são ensinadas, ainda que sejam muito importantes (Mikalef, 2018). Essas habilidades serão apresentadas no próximo tópico.

2.4.3 Eixo 3 – Quais principais habilidades e ferramentas?

Dos 54 trabalhos analisados na revisão sistemática de literatura, 30 apresentaram conteúdo passível de extração de informações referentes a habilidades e ferramentas. Inicialmente serão relacionadas as habilidades e ferramentas identificadas, que em seguida serão apresentadas de forma consolidada para, então, serem apresentadas as considerações sobre os achados da literatura.

Segundo Cao (2017), as habilidades que fazem de um profissional um bom cientista de dados são as seguintes:

- a) Capacidade de pensar de forma analítica, criativa, crítica e inquisitiva;
- b) Metodologias e conhecimento de sistemas e abordagens complexas para conduzir resolução de problemas;
- c) Profunda compreensão de modelos e metodologias de estatística, mineração de dados e aprendizado de máquina;
- d) Capacidade de implementar, manter e solucionar problemas de infraestrutura de *big data*, como computação em nuvem, infraestrutura de computação de alto desempenho e processamento distribuído;
- e) Conhecimento de interações homem-computador, visualização e gestão de conhecimento;
- f) Experiência em engenharia de *software*, incluindo projetos e análise de sistemas;

- g) Experiência em trabalhar com grandes conjuntos de dados, de vários tipos e a partir de várias fontes, em ambiente de rede distribuído;
- h) Experiência em extração e processamento de dados, entendimento e relação de recursos e análise;
- i) Interesse ativo e conhecimento em estudos multidisciplinares e transdisciplinares em ciências sociais e ciências da vida;
- j) Experiência substancial com *scripts*, estruturas de dados, linguagens de programação e plataformas de desenvolvimento de última geração, orientadas para *analytics*, em ambiente Linux, nuvem ou distribuído;
- k) Domínio de conhecimento para a avaliação de técnicas e de negócios em relação aos achados provenientes de *analytics*;
- l) Excelente comunicação escrita e verbal, organização, capacidade de escrever e editar materiais e relatórios analíticos para diferentes públicos; capacidade de transformar conceitos e resultados analíticos em interpretações facilmente interpretáveis para os negócios e capacidade de comunicar-se de forma não técnica.

Debortoli et al. (2014) realizaram uma comparação de habilidades de inteligência de negócios e de *big data*, e afirmam que especialistas em *big data* podem ser considerados como tendo um papel similar àqueles de cientistas de dados. Em seu estudo, Debortoli et al. (2014) listam as seguintes habilidades técnicas: análise quantitativa, aprendizado de máquina, teste de *software*, *data warehousing*, bancos de dados NoSQL, programação (Java, .NET, PHP e JS), engenharia de *software* e administração de bancos de dados.

Kotzé (2017) realizou uma pesquisa sobre cientistas de dados na África do Sul, através da análise qualitativa de perfis na rede social LinkedIn. Na discussão de seu trabalho, ele sugere que as seguintes habilidades devem integrar o currículo de um cientista de dados:

- a) Conhecimentos em estatística e matemática;
- b) Aprendizado de máquina e tecnologias de *big data* como Apache Hadoop, Apache Spark e Hadoop Hive, que devem ser utilizadas em conjunto com linguagens como Python, Pig, R e Scala;
- c) Curadoria de data (*data munging*), incluindo preparação e gestão de dados, em todo o processo de solução de um problema;
- d) Otimização de algoritmos e engenharia de *software*, aliando conhecimento teórico e prático;
- e) Comunicação efetiva com tomadores de decisão, capacidade de visualizar grandes quantidades de dados e *storytelling*;

- f) Visualização de dados utilizando ferramentas como Tableau ou Gephi;
- g) Habilidade para trabalhar em time; relacionamento interpessoal.

Gibert et al. (2018) discutiram a necessidade de cientistas de dados serem capazes de sintetizar produtos que adicionem valor, especificamente citando a capacidade de superar a complexidade dos dados e as limitações da estatística clássica e das técnicas de aprendizado de máquina, como, por exemplo, lidando com dados tão variados como vídeo e texto.

Meyer (2018) pesquisou habilidades de cientistas de dados especificamente na indústria de saúde, através de análise de vagas, e identificou 20 principais habilidades:

- a) Estatística, por exemplo modelagem linear em geral e análise de variância;
- b) Linguagem R;
- c) Técnicas de aprendizado de máquina;
- d) *Storytelling*; resultados que possam ser efetivamente utilizados (*actionable results*);
- e) Linguagem Python;
- f) Comunicação de descobertas;
- g) Desenvolvimento de produtos;
- h) Solução de problemas orientada a dados;
- i) Manipulação de dados;
- j) Desenvolvimento de algoritmos;
- k) Configuração e manutenção de plataformas de dados;
- l) SQL;
- m) Implementação de modelos em produção;
- n) SAS;
- o) Trabalho em equipes multidisciplinares;
- p) Criação de visualizações;
- q) Identificação de problemas de negócios;
- r) Lidar com dados em grandes quantidades e distribuídos;
- s) Hadoop;
- t) Trabalhar com dados não estruturados (por exemplo bancos de dados NoSQL e mineração de texto).

De Mauro et al. (2017) realizaram um estudo sistemático para classificar recursos humanos para trabalhar com *big data*, separando-os em famílias. Diferentemente das disciplinas mais tradicionais da ciência, as fronteiras do campo de estudo da ciência de dados não foram formalmente esclarecidas. A heterogeneidade das muitas facetas de cientistas de dados são uma indicação da confusão gerada sobre esse conceito, que associou habilidades de forma

indiscriminada sob o termo genérico “cientista de dados”. Em sua revisão de literatura, De Mauro et al. (2017) evidenciam esta situação identificando dois grupos distintos, ambos associados a cientistas de dados, sendo um com foco em dados e tecnologia e outro com foco em negócios, contendo as seguintes habilidades. No caso do grupo com foco em dados e tecnologia, constam as seguintes facetas:

- a) Especialista em ferramentas de *big data*;
- b) Programador;
- c) Estatístico e analista quantitativo;
- d) Pesquisador;
- e) *Hacker* de dados.

Para o foco em negócios, constam:

- f) Auditor;
- g) Gerente de ética em dados;
- h) Gerente de dados e estrategista;
- i) Especialista em visualização;
- j) Comunicador;
- k) Gerente de projetos;
- l) Consultor e especialista em negócios.

Em relação à sua pesquisa em si, De Mauro et al. (2017) analisaram vagas de emprego disponibilizadas de forma *on-line* coletando dados de diversos sítios, e classificaram as publicações de vagas em famílias, identificando habilidades para cada uma delas. Uma das famílias identificadas foi a de cientista de dados, que considera ofertas de emprego com títulos como engenheiro de dados, cientista de dados, analista de dados e consultor de dados, e que possui as seguintes habilidades:

- a) Identificar padrões, aplicar contexto e inteligência, extrair informações relevantes ocultas em grandes volumes de dados, projetar e implementar modelos de dados e métodos estatísticos, integrar pesquisa e melhores práticas para evitar problemas e melhorar continuamente;
- b) Técnicas analíticas específicas como classificação, filtragem colaborativa, regras de associação, redes neurais, abordagens heurísticas;
- c) Linguagens de programação como Python, SQL, Java e Ruby;
- d) Plataformas estatísticas como R, SAS e Matlab.

Markow et al. (2017) estudaram o mercado de trabalho de ciência de dados e *analytics* (DSA, *Data Science & Analytics*), e identificaram que existe um desbalanceamento entre oferta

e demanda, que é agravado pela falta de uma estrutura comum e vernacular nas publicações de vagas e suas respectivas habilidades. Cargos não são consistentes em muitos casos: um empregado denominado “cientista de dados” em uma empresa pode possuir habilidades diferentes de um “cientista de dados” em outra empresa, dificultando a análise ampla do perfil deste cargo. Em relação às publicações onde a ocupação é “cientista de dados”, Markow et al. (2017) citam as seguintes principais habilidades:

- a) Ciência de dados;
- b) Aprendizado de máquina;
- c) Linguagem Python;
- d) Linguagem R;
- e) Apache Hadoop.

Costa & Santos (2017) propõem um modelo conceitual para o cientista de dados, mesmo objetivo que se propõe este estudo, e comparam seu modelo proposto em relação às competências de tecnologias da informação e das comunicações (TIC), particularmente em relação ao *European e-Competence framework* (e-CF) e o *Skills Framework for the Information Age* (SFIA). Os resultados de seu estudo indicam que uma parte relevante da base de conhecimento e conjunto de habilidades dos cientistas de dados está relacionada às TIC, incluindo programação, aprendizado de máquina e bancos de dados. O modelo apresentado em seu estudo está bastante relacionado aos dois *frameworks*, mas tem principalmente a característica multidisciplinar, combinando diferentes áreas como ciência da computação, estatística e matemática. Costa & Santos (2017) apresentam as principais habilidades de cientistas de dados (“*A Data Scientist is able to*”) em seis grandes grupos:

- a) Identificar padrões e tendências em dados: explorar, analisar e visualizar dados (inclusive *big data*), analisar similaridades, criar experimentos para responder questões específicas, encontrar padrões para fazer previsões e análises *what-if*, definir e testar hipóteses, validando conclusões, e definir relações causais;
- b) Planejar, elaborar, implementar e otimizar produtos de dados: algoritmos, produtos de dados, análise de dados, visualizações, relatórios, modelos estatísticos e matemáticos, soluções de ciência de dados que sejam efetivas, escaláveis, robustas e prontas para serem colocadas em produção;
- c) Lidar com dados em diferentes volumes e com diferentes estruturas;
- d) Comunicar e disseminar: histórias baseadas em dados (engajamento verbal e visual), melhores práticas de manipulação de dados, resultados e achados com outros times;

- e) Colaborar no gerenciamento e performance do negócio: aconselhar a administração com base em dados, comandar estratégias e recomendações de produtos e ações, encontrar respostas para questões relevantes para o negócio, informar, influenciar, suportar e executar decisões sobre lançamento de produtos, melhorar a performance do negócio, sugerir novos caminhos e novas estratégias para o negócio (mudança no negócio), definir e monitorar métricas de negócio, prever ameaças através de dados, entender interação entre usuários;
- f) Assegurar eficiência no fluxo de dados e em tarefas relacionadas a dados: transformar dados, extrair valor a partir dos dados, identificar fontes de dados, respeitar princípios éticos, de privacidade e de segurança, pensar dados de forma analítica, integrar dados a partir de diversas fontes, lidar com dados complexos, assegurar qualidade dos dados.

Conforme já mencionado, Baškarada & Koronios (2017) realizaram um estudo junto a diversas organizações governamentais na Austrália procurando identificar cientistas de dados “unicórnios”, definidos como profissionais únicos que podem executar todas as tarefas de ciência de dados. Os autores informam que seu estudo não encontrou evidências de sua existência, mas que sua pesquisa permitiu identificar seis papéis que cientistas de dados podem desempenhar nas organizações, incluindo em cada um desses papéis habilidades primárias e secundárias, que podem ser resumidos abaixo:

- a) Especialista em domínio: o estudo confirmou a importância da experiência em domínio, uma das mais frequentemente citadas habilidades de ciência de dados na literatura (Linden et al., 2015; Waller e Fawcett, 2013; Dhar, 2013; Finzer, 2013; Chen et al., 2012; Swan e Brown, 2008; Laney et al., 2015). Sem conhecimento de domínio, cientistas de dados não possuem o contexto necessário para transformar dados brutos em informações relevantes (Baškarada & Koronios, 2017);
- b) Engenheiro de dados: relacionado principalmente à questão da qualidade dos dados, quando diversos entrevistados se referiram ao princípio “lixo dentro, lixo fora” (*garbage in, garbage out*), nas tarefas de extração, limpeza, enriquecimento e transformação dos dados;
- c) Estatístico: segundo Baškarada & Koronios (2017), estatísticos estão no centro das equipes de ciência de dados, formando uma ponte entre especialistas em domínio, engenheiros de dados e cientistas da computação;
- d) Cientistas da computação: o crescimento exponencial no volume, velocidade e variedade de dados levou ao desenvolvimento de novas ferramentas e tecnologias de *software* de *big data*, como por exemplo Apache Hadoop, Map Reduce e Spark, onde são necessárias

habilidades específicas de cientistas de computação em linguagens de programação como R e Python, e computação em nuvem para implementar e otimizar o processamento e análise de grandes conjuntos de dados;

- e) Comunicador: segundo Baškarada & Koronios (2017), do ponto de vista prático, a ciência de dados somente é útil quando transforma a organização. Desta forma, a capacidade de se comunicar efetivamente com tomadores de decisão é crítica para cientistas de dados. Isso inclui a exploração de problemas e oportunidades, bem como comunicação de resultados. Como tomadores de decisão relevantes frequentemente não têm habilidades estatísticas avançadas, todas as conclusões precisam ser apresentadas de uma forma visualmente atraente, fácil de entender e convincente;
- f) Líder: em relação à liderança, novamente Baškarada & Koronios (2017) referem-se ao termo mítico “unicórnio”, no sentido de que liderar um time exige ao menos um nível mínimo de compreensão de várias funções, além de conhecimento extenso de gerenciamento de projetos, aspectos de ética, privacidade e segurança.

Gardiner et al. (2017) realizaram estudo com base em publicações de vagas de emprego relacionadas à *big data*, no sentido de que cientistas de dados são os profissionais habilitados a trabalhar com tal tecnologia. Os resultados são apresentados em uma estrutura conceitual de categorias de habilidades e confirmam a natureza multidisciplinar do trabalho dos cientistas de dados. As categorias apresentadas no estudo podem ser interpretadas como habilidades de cientistas de dados:

- a) *Analytics*: ferramentas, técnicas, processos e habilidades usados para extrair informações relevantes dos dados;
- b) Comunicação: capacidade de obter e transmitir efetivamente informações sobre métodos e resultados analíticos;
- c) Dados: habilidades relacionadas à criação e gerenciamento da arquitetura de informação da organização, bem como ao gerenciamento de ativos de dados;
- d) Banco de dados, *data warehouse*: tipos específicos de banco de dados ou tecnologias;
- e) Desenvolvimento: habilidades, técnicas, metodologias e conhecimentos relacionados ao *design*, construção e implantação de sistemas de informação;
- f) Grande volume de dados: habilidade para lidar com grandes conjuntos de dados;
- g) Liderança: características de uma pessoa que atua na posição ou função de um líder, ou uma pessoa que guia ou dirige um grupo;
- h) Tecnologias emergentes: conhecimento ou habilidades relacionadas a tecnologias novas ou emergentes;


- i) Programação: habilidades em programação de computadores e desenvolvimento de *software*;
- j) Linguagens de programação: conhecimento de ao menos uma linguagem de programação;
- k) Projetos: planejamento, coordenação e controle de atividades;
- l) Estatística e matemática: técnicas matemáticas e estatísticas gerais, não necessariamente específicas para *analytics*;
- m) Equipe: trabalhar coletivamente e/ou dentro de um ambiente de equipe.

Mikalef et al. (2018) realizaram um estudo sobre as habilidades de cientistas de dados nas áreas de educação e mercado. Segundo os autores, é amplamente reconhecido por organizações públicas e privadas que o maior desafio enfrentado em utilizar dados de forma efetiva depende de encontrar pessoas com o conjunto de habilidades necessárias para transformar tais dados em inteligência de negócio. Em seu estudo, Mikalef et al. (2018) identificaram 8 habilidades relevantes:

- a) *Big data analytics*;
- b) Visualização de dados e de conhecimento;
- c) Técnicas estatísticas;
- d) Transformação de dados brutos em inteligência de negócios;
- e) Estruturação e análise de conteúdo proveniente da *web* ou de sensores;
- f) Métodos de pesquisa e validação empírica;
- g) Trabalhar com dados não estruturados de alto volume;
- h) Aprendizado de máquina.

Hu et al. (2018) conduziram um estudo de distanciamento métrico de termos, a partir de perfis de cientistas de dados coletados na rede social LinkedIn e no sítio de ofertas de emprego Monster. Especificamente em relação às habilidades de cientistas de dados, os autores produziram a seguinte nuvem de palavras (Figura 4):

Figura 4 – Nuvem de habilidades de HU (2018)



Fonte: Hu et al. (2018).

Ainda que Hu et al. (2018) não tenham disponibilizado em seu estudo uma lista formal de habilidades, é possível discernir algumas delas a partir da nuvem acima, onde o tamanho de cada palavra está relacionado à frequência com que o termo aparece. Dessa forma, podem ser apontadas as seguintes habilidades:

- a) Linguagens R e Python;
- b) *Analysis*;
- c) SQL;
- d) *Machine learning*;
- e) *Modeling*;
- f) Java;
- g) *Analytics*;
- h) *Management*;
- i) *Data mining*.

Kross & Guo (2019) sugerem em seu estudo um exemplo de trilha (“*stack*”) de tecnologias que cientistas de dados atualmente devem percorrer para fazer seu trabalho, escrevendo programas para obter conhecimento (“*insights*”) de forma robusta e reproduzível. As tecnologias citadas são como segue:

- a) Modelagem de dados e bibliotecas de visualização (por exemplo Pandas e R tidyverse);
- b) Programação (por exemplo Python e R);
- c) Narrativa computacional (por exemplo Jupyter, Rmarkdown);
- d) Suporte a desenvolvimento de aplicações (por exemplo Git e gerenciadores de pacotes em Python ou R);
- e) Unix através de linha de comando;

f) Infraestrutura de reprodutibilidade (por exemplo *Docker* e *Virtual Machines*).

Verma et al. (2019) estudaram habilidades relacionadas a *analytics* analisando o conteúdo de uma amostra de ofertas de empregos *on-line*, identificando analistas de negócios, analistas de inteligência em negócios, analistas de dados e cientistas de dados. Especificamente para este último, os autores identificaram cinco conjuntos de habilidades, apresentadas a seguir:

- a) Tomada de decisão: *analytics*, modelagem, gestão de projetos, implementação e comunicação;
- b) Estatística: estatística, R, SAS, Microsoft Excel, regressão;
- c) Organização: trabalho em equipe, organização, liderança, gestão, comunicação interpessoal;
- d) Domínio: ciência da computação, *marketing*, financeiro, saúde, cadeia de suprimento;
- e) Programação: Python, Java, C, Scala, PERL.

Pires & Leitão (2018) analisaram perfis de cientistas de dados do ponto de vista de sua formação acadêmica e de suas habilidades, estas últimas segregadas em dois grupos pelo autor como *hard skills* e *soft skills*. Segundo Pires & Leitão (2018), o primeiro representa conhecimentos e capacidades que podem ser adquiridos através de programas de educação e treinamento, enquanto o segundo, também chamado de *people skills*, é a capacidade de se relacionar com outras pessoas para expressar ideias e o desejo de realizar o trabalho.

Os *hard skills* identificados por Pires & Leitão (2018) são:

- a) Linguagens de programação: R, Python, SQL e JAVA;
- b) *Softwares* para análise de dados: Hadoop, Qlik, Hive, Tableau;
- c) Aspectos técnicos: fluência em inglês, aprendizado de máquina, *deep learning*, *big data* e redes neurais.

Os *soft skills* identificados por Pires & Leitão (2018) são:

- a) Comunicação;
- b) Resolução de problemas;
- c) Atenção aos detalhes;
- d) Trabalho em equipe;
- e) Proatividade;
- f) Senso de responsabilidade;
- g) Liderança;
- h) Paixão.

Miller (2019) estudou a influência das competências e da estrutura de times no sucesso de projetos de ciência de dados. O foco do estudo é centrado nas hipóteses de como suprir, com

um time multidisciplinar, as habilidades de um cientista de dados na situação em que ele não está presente no projeto. Para o que além a este estudo, interessam os quatro grupos de habilidades descritos pelo autor:

- a) Técnicos: plataforma, arquitetura;
- b) Domínio: experiência no domínio ou experiência funcional;
- c) *Analytics*: análise quantitativa, aprendizado de máquina, análise preditiva;
- d) Dados: *data warehouse*, bancos de dados NOSQL.

Chatfield et al. (2014) defendem que a falta de especificações claras de habilidades de cientistas de dados é uma das barreiras fundamentais para a realização dos benefícios que a tecnologia de *big data* pode trazer para as organizações. Neste sentido, os autores identificaram os principais atributos de cientistas de dados, aí incluídos, além de habilidades, suas áreas de formação e outros atributos cuja classificação não é tão clara, como, por exemplo, “curiosidade”. Os atributos identificados por Chatfield et al. (2014) são como segue:

- a) Empreendedorismo e domínio de negócios;
- b) Ciência de computação;
- c) Comunicação eficaz;
- d) Criação de valor através de conhecimento efetivo para o negócio;
- e) Curiosidade;
- f) Estatística e modelagem;
- g) Visualização de dados;
- h) Matemática;
- i) Gerenciamento de dados;
- j) *Analytics*;
- k) Engenharia de *software*;
- l) Qualificação acadêmica (doutoramento);
- m) Programação;
- n) Entendimento dos desafios de negócios;
- o) Aprendizado de máquina;
- p) Economia;
- q) Tecnologia e análises quantitativas;
- r) Trabalho em equipe;
- s) Experiência com grandes conjuntos de dados;
- t) Otimização;
- u) Interdisciplinaridade;

v) Inteligência artificial.

Baumer (2017) é o autor do livro *The Sabermetric Revolution: Assessing the Growth of Analytics in Baseball*, que relata seu trabalho como estatístico no time de baseball norte-americano Oakland's A, que passou a ser amplamente conhecido pelo filme *Moneyball* com o ator Brad Pitt. O foco do estudo de Baumer (2017) é a situação em que cientistas de dados trabalham isolados, fora do contexto de um time multidisciplinar ou em times muito pequenos, dentro de grandes organizações. Conquanto seu trabalho não esteja diretamente relacionado com as habilidades de cientistas de dados, é possível depreender o que o autor considera relevante, conforme abaixo:

- a) Reprodutibilidade (*rmarkdown*, *rknitr*);
- b) Colaboração e controle de versionamento (*git*);
- c) Utilização de pacotes e bibliotecas pré-existentes;
- d) Pré-processamento de dados (ETL, “*extract-transform-load*”);
- e) Linguagens R e Python;
- f) Controle de orçamento, utilizando *software* livre (por exemplo, substituindo Windows por Ubuntu, SAS por R, Oracle por MySQL/PostgreSQL, e .NET por PHP);
- g) Disseminação de conhecimento;
- h) Bancos de dados SQL;
- i) Relacionamento com *stakeholders*;
- j) Domínio de conhecimento, apresentado no estudo como conhecimento do negócio;
- k) Comunicação verbal e em apresentações;
- l) Aprendizado contínuo (por exemplo experimentando novos *softwares*, fazendo cursos *on-line*);
- m) Conhecimento rigoroso de estatística.

Dichev & Dicheva (2017), em seu estudo, discutem a alfabetização (*literacy*) em ciência de dados, sugerindo o planejamento e implementação de cursos voltados para o público não técnico. Conquanto o foco dos autores não seja a discussão de habilidades de cientistas de dados, que atuam exclusivamente nesta área, é possível, a partir do artigo, identificar determinadas habilidades que são importantes, de uma forma geral, em projetos que utilizam dados. Segundo os autores, a alfabetização em ciência de dados é a soma das alfabetizações em computação, estatística, aprendizado de máquina, visualização e ética, que, traduzidas em habilidades, podem ser resumidas como segue:

- a) Formular perguntas produtivas;
- b) Pensar de forma computacional;

- c) Pensar de forma analítica;
- d) Visualizar e sumarizar dados.

Adicionalmente, a sugestão do programa do curso que atenderia o objetivo de alfabetizar profissionais permite depreender ainda outras habilidades, de forma mais específica:

- a) Linguagem Python, utilizando ambiente Jupyter notebook;
- b) Estruturas de dados;
- c) Coleta e processamento de dados (Pandas, *web scrap*, limpeza de dados);
- d) Modelagem e análise estatística (estatística descritiva, intervalos de confiança, teste de hipóteses, regressão linear, correlação);
- e) Comunicação visual (pacotes padrão Python, Seaborn).

De forma análoga a Dichev & Dicheva (2017), Yan & Davis (2019) propõem um curso introdutório em ciência de dados, baseado no ciclo de vida de um projeto de ciência de dados, ou seja, baseado nas diversas etapas práticas de um processo desde a coleta dos dados até o nascimento ou a conclusão de um produto. A partir da análise do currículo do curso proposto, é possível depreender as seguintes habilidades:

- a) Fazer perguntas interessantes, isto é, perguntas que fazem sentido para resolver um problema, a partir da análise dos dados;
- b) Conhecer linguagem R;
- c) Capacidade de gerar amostras de forma consistente;
- d) Realizar análise exploratória de dados, incluindo estatística descritiva;
- e) Gerar visualizações de dados;
- f) Transformar dados e realizar seleção de atributos;
- g) Utilizar técnicas de agrupamento (*clustering*);
- h) Modelar utilizando regressão linear;
- i) Realizar análise de confirmação e testes de hipótese.

Luna-Reyes (2018) sugere um *framework* que inclui cinco conjuntos principais de habilidades. Segundo o autor, as habilidades dos cientistas de dados têm natureza tão diversa que é mais provável que a ciência de dados evolua a partir de um esforço coletivo envolvendo especialistas em diferentes áreas de domínio e níveis de conhecimentos, provenientes de diferentes áreas organizacionais. Independentemente de sua evolução, Luna-Reyes (2018) elenca os seguintes principais grupos de habilidades:

- a) Pensamento computacional (linguagens Java, C#, PHP, .NET, R ou Python, técnicas de modelagem, simulação e aprendizado de máquina, estatística);
- b) Domínio de conhecimento, ou seja, domínio do contexto de negócio;

- c) Gerenciamento de dados (curadoria, preparação, análise exploratória, integração de diversas fontes de dados);
- d) Arquitetura (infraestrutura de tecnologia, computação em nuvem);
- e) Engajamento de *stakeholders* (fazer perguntas relevantes, usar visualização de dados).

Attwood et al. (2017) discutiram as necessidades de treinamento de profissionais de ciência de dados no contexto da bioinformática para enfrentar os desafios de médio prazo. Apresentando os resultados das diversas pesquisas objeto de seus estudos (nominalmente SEB 2013, GOBLET 2014, ABPI 2014, ELIXIR 2014, NSF 2016 e EMBL-ABR 2016), Attwood et al. (2017) classificaram necessidades de treinamentos que, no contexto deste estudo, podem ser entendidos como habilidades de cientistas de dados. Essas habilidades são como segue:

- a) Análise de dados, incluindo visualização e interpretação;
- b) Mineração, manipulação e gestão de dados;
- c) Integração de dados;
- d) Computação em nuvem e computação de alta performance;
- e) Noções de programação, *scripts*;
- f) Estatística;
- g) Ferramentas e recursos de bioinformática.

Ecleo & Galido (2017) realizaram pesquisa na rede social LinkedIn especificamente nas Filipinas. A partir da análise de 100 perfis de cientistas de dados, dos quais foram extraídas suas habilidades, Ecleo & Galido definiram três classes (sistemas, negócios e técnicas) e segregaram as habilidades conforme abaixo:

- a) Desenvolvimento: conhecimentos gerais sobre tecnologia, gestão de dados, projeto, análise, implementação e teste, conhecimento de metodologias de desenvolvimento, integração, programação, documentação, operações e manutenção;
- b) Solução de problemas: análise quantitativa, matemática e estatística, modelagem, pensamento analítico/lógico, orientação ao cliente, pensamento estratégico (visão estratégica), criatividade e inovação;
- c) Social: comunicação interpessoal;
- d) Negócios: conhecimento de indústria específica, negócios digitais, conhecimento gerais sobre negócios;
- e) Gestão: monitoramento e controle, planejamento, gestão, treinamento, liderança, organização, gestão de projetos, gestão de mudança;

- f) *Software*: pacotes e *frameworks*, processamento de dados, visualização, linguagem de programação, bancos de dados, conhecimento geral sobre *software*, sistemas operacionais e plataformas, desenvolvimento para aplicativos móveis;
- g) Redes: arquitetura geral de redes, computação em nuvem, cliente-servidor e redes distribuídas, internet, LAN e WAN, *devices* de rede (*firewall*, *routers*);
- h) *Hardware*: conhecimento geral sobre *hardware*, servidores e estações de trabalho, sistemas embarcados.

Abidin et al. (2017), utilizando técnica Delphi com especialistas, identificaram 46 habilidades necessárias para profissionais de tecnologia de informação capacitarem-se como cientistas de dados de forma a extrair valor de tecnologias baseadas em dados como, por exemplo, *big data*. As habilidades identificadas estão listadas abaixo:

- a) *Analytics*;
- b) Visualização de dados;
- c) Modelagem de dados;
- d) Tomada de decisão;
- e) Ética;
- f) Comunicação;
- g) Gestão básica de bases de dados;
- h) Algoritmos;
- i) Negócios;
- j) Hadoop;
- k) Estatística;
- l) Manipulação de dados;
- m) Processamento de dados;
- n) SQL;
- o) Hive;
- p) Economia;
- q) Matemática;
- r) Programação R;
- s) Programação básica;
- t) Python;
- u) Probabilidade;
- v) Inteligência artificial;
- w) Processamento de linguagem natural;

- x) *MapReduce*;
- y) Mineração de dados;
- z) Armazenamento de dados;
- aa) Aprendizado de máquina;
- bb) Matlab;
- cc) Inteligência de negócios;
- dd) Arquitetura de sistemas;
- ee) Linguagem C, C ++ e C #;
- ff) Linguagem Java;
- gg) SAS;
- hh) Privacidade e segurança;
- ii) Pig;
- jj) Clojure;
- kk) Simulação;
- ll) Mahout;
- mm) Scala;
- nn) Apache Spark;
- oo) NoSQL.
- pp) Análise de Redes Sociais.
- qq) Narrativa (“*storytelling*”);
- rr) Estratégia de negócios;
- ss) Previsões (“*forecast*”);
- tt) Pensamento crítico;

Mikalef et al. (2019) investigaram habilidades técnicas e de negócios através de entrevistas com executivos-chave de empresas norueguesas. As principais habilidades técnicas identificadas foram classificadas da seguinte maneira:

- a) Análise exploratória de dados;
- b) Visualização de dados;
- c) Técnicas de aprendizado de máquina;
- d) Mineração de dados;
- e) Modelagem de dados;
- f) Limpeza e preparação de dados;
- g) Métodos de pesquisa e validação empírica;
- h) Redes neurais;

- i) Processamento de dados;
- j) Análise estatística;
- k) Integração de dados;
- l) Gestão de dados;
- m) Modelagem preditiva;
- n) Algoritmos e programação;
- o) Armazenamento de dados;
- p) Computação em nuvem;
- q) Outras técnicas de inteligência artificial;
- r) Aplicativo baseado na Web;
- s) Desenvolvimento;
- t) Programação estruturada múltipla;
- u) Programação distribuída e computação;
- v) Linguagens de consulta (“*query*”);
- w) Processamento de linguagem natural (NLP);

Sobre as habilidades de negócio, foram identificadas por Mikalef et al. (2019) as seguintes:

- a) Arquitetura de *big data*;
- b) Formulação da estratégia de *big data*;
- c) Aplicação de *analytics* em problemas de negócio;
- d) Desenvolvimento de políticas de governança de *big data*;
- e) Implementação de planos corporativos;
- f) Conectar negócios e dados;
- g) Identificação de problemas e de soluções;
- h) Gerenciamento de projetos;
- i) Conhecimento do domínio;
- j) Economia;
- k) Habilidades de inovação digital;
- l) Entendimento dos principais motivadores da competitividade digital;
- m) Conhecimento de casos de sucesso;
- n) Liderar projetos de *big data*;
- o) Orquestração de negócios e TI;
- p) Desenvolvimento de cultura orientada a dados;
- q) Desenvolvimento de planos de negócios;

- r) Experiência em desenvolvimento de processos;
- s) Empreendedorismo digital;
- t) Gestão de times multifuncionais;
- u) Orquestração de tecnologias e recursos humanos;
- v) Habilidades de *marketing* e vendas.

O estudo de Waller & Fawcett (2013), voltado para a gestão da cadeia de suprimentos (*Supply-Chain Management*, SCM), procurou identificar oportunidades do uso de ciência de dados, análise preditiva e *big data* especificamente nesta área. Procurando exemplos de aplicação em análise preditiva, Waller & Fawcett (2013) identificaram as disciplinas listadas abaixo. Considerando que o profissional que executa este tipo de análise é o cientista de dados, as disciplinas podem ser entendidas no contexto de suas habilidades:

- a) Estatística;
- b) Previsões (*forecast*);
- c) Otimização;
- d) Simulação de eventos discretos;
- e) Probabilidade aplicada;
- f) Mineração de dados;
- g) Modelagem matemática.

Knorr et al. (2018) não tratam especificamente sobre habilidades de cientistas de dados, mas fazem questionamentos relevantes sobre aspectos de privacidade, ética e segurança da informação no contexto do que denominam como “era da *big data*”.

Através dos estudos de Manieri et al. (2015), Wiktorski et al. (2017) e Demchenko et al. (2019) foi possível identificar o projeto EDISON (“*Education for Data Intensive Science to Open New Science Frontiers*”), iniciativa criada para acelerar o aumento do número de cientistas de dados competentes e qualificados, principalmente na Europa. Com fundos do projeto da comunidade europeia denominado *Horizon 2020*, no montante de 2,5 bilhões de euros, o projeto foi executado no período de setembro de 2015 até agosto de 2017. O principal artefato do projeto EDISON foi uma estrutura, *EDISON Data Science Framework* (EDSF), reunindo materiais e informações de treinamento para ajudar educadores, instrutores, organizações e pesquisadores a identificar, recrutar e inspirar os profissionais de ciência de dados do futuro. O EDSF pode ser usado para desenvolver novos cursos em ciência de dados, avaliar módulos e cursos existentes, elaborar descrições de cargos e planejar e projetar equipes eficientes de pesquisa intensiva em dados em uma variedade de disciplinas científicas (Demchenko, 2018).

O EDSF pode ser considerado como a única iniciativa estruturada governamental e multinacional identificada na revisão de literatura conduzida. O principal documento do Projeto EDISON, no contexto deste estudo, é o denominado CF-DS (“*Data Science Competence Framework*”), que fundamenta as bases para, entre outros, a certificação de cientistas de dados. O CF-DS é o resultado do estudo do mercado de trabalho apoiado por uma extensa pesquisa em *blogs* profissionais, discussões da comunidade e visão geral de padrões e práticas existentes, revisada por grupos de especialistas e especialistas individuais, com *feedback* recebido de várias universidades, organizações de treinamento profissional e diferentes projetos que lidam com dados e gerenciamento de habilidades relacionadas (Demchenko et al., 2019).

Segundo o documento CF-DS, os cinco grupos de habilidades identificados fornecem uma base para definir programas de educação, treinamento para trabalhos relacionados à ciência de dados, requalificação e certificação profissional. Os grupos de habilidades identificados são:

- a) Análise de dados, incluindo análise estatística, aprendizado de máquina, mineração de dados, análise de negócios e outros;
- b) Engenharia de ciência de dados, incluindo engenharia de *software* e aplicativos, *data warehouse*, *big data*, infraestrutura e ferramentas;
- c) Conhecimento e experiência em domínio (assunto/científico);
- d) Gerenciamento e governança de dados, incluindo gerenciamento, curadoria e preservação de dados;
- e) Métodos de pesquisa, tanto no contexto de pesquisa acadêmica como no contexto de negócios.

O CF-DS divide as habilidades específicas em dois grupos, sendo um voltado para os conhecimentos necessários para a prática de ciência de dados (“*Skills Group A*”), e outro voltado para linguagens, ferramentas, plataformas, gestão de dados e de infraestrutura (“*Skills Group B*”).

As habilidades do grupo A são as seguintes:

- a) *Machine learning*, algoritmos, ferramentas (incluindo aprendizado supervisionado, não supervisionado ou de aprendizado por reforço);
- b) Mineração de dados, inclusive mineração de dados de texto;
- c) Técnicas gerais de análise estatística e análise descritiva;
- d) Análises quantitativa e qualitativas;
- e) Análises preditiva e prescritiva;
- f) Análises gráficas;
- g) Análise e estatística para preparação e pré-processamento de dados;

- h) Uso de métricas de desempenho para avaliação e validação de análise de dados;
- i) Uso de métodos eficazes de visualização e *storytelling* para criar painéis e relatórios de análise de dados;
- j) Processamento de linguagem natural;
- k) Pesquisa operacional, otimização e simulação;
- l) Princípios de engenharia de sistemas e *software* para o *design* e desenvolvimento de sistemas de informação das organizações, incluindo o *design* de requisitos;
- m) Tecnologias de computação em nuvem;
- n) Tecnologias de *big data* baseadas na nuvem para sistemas e aplicativos de processamento de grandes conjuntos de dados;
- o) Tecnologias de desenvolvimento ágil, como DevOps e ciclo de aprimoramento contínuo, para aplicativos orientados a dados;
- p) Desenvolvimento e implementação de sistemas e segurança de dados, acesso a dados, incluindo anonimização e controle de acesso;
- q) Modelos de segurança baseados em conformidade, em particular para proteção de privacidade;
- r) Bancos de dados relacionais e não relacionais (SQL e NoSQL), soluções de *data warehouse*, processos ETL (extrair, transformar, carregar), OLTP, OLAP para dados estruturados e não estruturados;
- s) Uso efetivo de infraestruturas de *big data*, redes de alto desempenho, gerenciamento e operação de infraestrutura e serviços;
- t) Uso e aplicação de tecnologias e sistemas de modelagem e simulação;
- u) Uso integrado com sistemas corporativos e colaborativos;
- v) Algoritmos eficientes para acessar e analisar grandes quantidades de dados, incluindo API para diferentes bancos de dados;
- w) Uso de sistemas de recomendação ou classificação;
- x) Especificação, desenvolvimento e implementação do gerenciamento de dados corporativos, bem como definir estratégia para arquitetura de governança de dados;
- y) Sistemas de armazenamento de dados, serviços de arquivo de dados, bibliotecas digitais e seus modelos operacionais;
- z) Definição de requisitos e supervisão da implementação de infraestrutura de gerenciamento de dados híbridos, incluindo serviços e recursos corporativos de nuvem pública e privada;

- aa)Desenvolvimento e implementação de arquitetura de dados, tipos e formatos de dados, modelagem e *design* de dados, incluindo tecnologias relacionadas (ETL, OLAP, OLTP, etc);
- bb)Implementação e suporte ao ciclo de vida dos dados no fluxo de trabalho organizacional;
- cc)Implementação e curadoria contínua dos controles de qualidade dos dados, garantindo integração e interoperabilidade;
- dd)Implementação de proteção de dados, *backup*, privacidade, conformidade com propriedade intelectual, ética e uso responsável de dados;
- ee)Uso e implementação de metadados, propriedade intelectual, registros de dados, padrões e conformidade;
- ff) Adesão aos princípios do *Open Data*, *Open Science*, *Open Access*; usar serviços baseados em ORCID;
- gg)Métodos de pesquisa e gestão de projetos;
- hh)Princípios de métodos de pesquisa no desenvolvimento de aplicativos orientados a dados e na implementação de todo o ciclo de manipulação de dados;
- ii) Projeto de experimentos, desenvolvimento e implementação de processos de coleta de dados;
- jj) Aplicação do modelo de gerenciamento do ciclo de vida dos dados (desde a coleta até a avaliação da qualidade dos dados);
- kk)Aplicação de abordagem estruturada à análise de casos de uso;
- ll) Desenvolvimento e implementação de plano de gerenciamento de dados de pesquisa;
- mm)Aplicação consistente do fluxo de trabalho de gerenciamento de projetos: escopo, planejamento, avaliação, gerenciamento de qualidade e risco e gestão de equipes;
- nn)Métodos de inteligência de negócios para análise de dados; aplicação de tecnologias cognitivas e serviços relevantes;
- oo)Gestão de Processos de Negócios (BPM), processos e operações gerais de negócios para análise e modelagem de processos organizacionais;
- pp)Metodologias ágeis;
- qq)Uso de econometria para análise de dados e aplicativos;
- rr) Gestão de relacionamento com cliente (CRM), requisitos de experiência do usuário (UX) e *design*;
- ss)Abordagem estruturada da análise de casos de uso nos negócios e na indústria;
- tt) Tecnologias de *data warehouse* para integração e análise de dados, incluindo dados abertos e dados de mídia social;

uu) Tecnologias de *marketing* orientadas a dados.

As habilidades do grupo B são as seguintes:

- a) Bibliotecas da linguagem R de análise de dados (cran, ggplot2, dplyr, reshap2, etc.)
- b) Bibliotecas da linguagem Python de análise de dados (pandas, numpy, matplotlib, scipy, scikit-learn, seaborn, etc);
- c) SAS, IBM SPSS, Julia, RapidMiner e outras linguagens analíticas, estatísticas e de programação, como por exemplo WEKA, KNIME, Scala, Stata, Orange etc;
- d) Linguagens baseadas em *scripts* (Octave, PHP, Pig, outros);
- e) Matlab Data Analytics;
- f) Ferramentas de análise (R / R Studio, Python / Anaconda, SPSS, Matlab, etc);
- g) Ferramentas de mineração de dados (RapidMiner, Orange, R, WEKA, NLTK, outros);
- h) Análise de dados em Excel (Analysis ToolPack, Tabelas Dinâmicas, etc);
- i) Bancos de dados e linguagens de consulta (*queries*);
- j) SQL e bancos de dados relacionais de código aberto (PostgreSQL, mySQL, Nettezza, etc);
- k) SQL e bancos de dados relacionais proprietários (Oracle, MS SQL Server, outros);
- l) Bancos de dados NoSQL (Hbase, MongoDB, Cassandra, Redis, Accumulo, etc);
- m) Hive;
- n) Modelagem de dados (UML, ERWin, DDL, etc);
- o) Bibliotecas de visualização de dados (matplotlib, seaborn, D3.js, FusionCharts, Chart.js, outros);
- p) *Software* de visualização (D3.js, Tableau, Raphael, Gephi etc);
- q) Ferramentas de visualização *on-line* (Datawrapper, API de visualização do Google, Google Charts, Flare etc);
- r) Plataforma de gerenciamento e curadoria de dados;
- s) Modelagem de dados e tecnologias relacionadas (ETL, OLAP, OLTP, etc);
- t) Plataforma de *data warehouse* e ferramentas relacionadas;
- u) Plataforma de curadoria de dados, gerenciamento de metadados (ETL, Workbench, DataUp, MIXED, etc);
- v) Gerenciamento de *backup* e armazenamento (iRODS, XArch, Nesstar, outros);
- w) *Big data* e plataformas e serviços de armazenamento baseados em nuvem;
- x) *Big data* e ferramentas de computação distribuída (Hadoop, Spark, MapReduce, Mahout, Lucene, NLTK, Pregel, etc);
- y) Plataformas de *big data analytics* (Hadoop, Spark, Data Lakes, outras);

- z) Sistemas de análise em tempo real e *streaming* (Flume, Kafka, Storm);
- aa) Plataforma Hadoop (Apache, Cloudera, Hortonworks, etc);
- bb) Plataforma Azure Data Analytics (HDInsight, Data Lake Analytics, Power BI, Machine Learning Studio, etc);
- cc) Plataforma Amazon Data Analytics (EMR, Kinesis, Data Pipeline, Machine Learning, etc);
- dd) Plataforma do Google Analytics (Google Data Studio, Machine Learning, TensorFlow, outros);
- ee) IBM Watson Analytics;
- ff) Outras plataformas de análise de dados baseadas em nuvem (Cloudera Data Science Workbench, HortonWorks Data Science, Vertica, LexisNexis HPCC System, etc);
- gg) Plataformas cognitivas (como IBM Watson, Microsoft Cortana, outros);
- hh) Competição Kaggle e plataforma colaborativa.
- ii) *Frameworks*: Python, Java, C / C ++, GO, D3.js, jQuery e outros;
- jj) Plataformas de desenvolvimento Python, Java ou C / C ++ ; IDE (Eclipse, R Studio, Anaconda / Jupyter Notebook, Visual Studio Code, Atom, outros);
- kk) Sistema de versionamento Git como plataforma geral para versionamento de *software*;
- ll) Metodologia e plataforma de desenvolvimento ágil Scrum.

Todas as habilidades e ferramentas identificadas nos trabalhos estão apresentados a seguir, consolidadas na Seção 2.5.3.

2.5 CONCLUSÃO DA REVISÃO

A seguir estão apresentadas as conclusões da revisão acadêmica em relação aos eixos da definição de cientistas de dados, de sua formação e de suas habilidades e das ferramentas que utilizam.

2.5.1 Definição de cientista de dados

Analisando as 26 definições coletadas através da frequência de seus termos, desprezando pontuações e palavras que não carregam significados, como por exemplo “de”, “a” e “como”, e considerando apenas os termos que aparece ao menos três vezes, é possível fazer uma representação do tipo “nuvem de palavras” como a Figura 5:

Figura 5 – Nuvem de palavras de termos mais frequentes nas definições de cientista de dados



Fonte: elaborado pelo autor.

Foram realizadas algumas modificações manualmente no dicionário-base para se montar a nuvem de palavras, sendo as principais (a) considerar as ocorrências do termo “negócio” como “negócios”, e (b) considerar os termos “big” e “data” de forma conjunta, como “big data”, de forma a refletir o sentido em que estes termos aparecem nas definições.

Numa nuvem de palavras, o tamanho da palavra na representação gráfica depende de sua frequência e, desta forma, a nuvem de palavras acima tem correspondência com a Tabela 4 a seguir, onde são apresentadas todas as palavras presentes com frequência mínima de 3 ocorrências:

Tabela 4 – Frequência de palavras encontradas nas definições de cientista de dados

Palavra	Frequência
Dados	38
Negócios	8
Conhecimento	6
<i>Big data</i>	6
Cientistas	6
Computação	6
Ciência	6
Análise	5
Analíticas	4
Habilidades	4
Pessoas	3
Profissional	3
Profundo	3
Melhor	3
Visualização	3
Profissionais	3
Conjunto	3
Estatística	3
Perguntas	3
Problemas	3
Trabalham	3
Todas	3
Capaz	3
Projetar	3
Conhecimentos	3
Ciclo	3
Sistemas	3
Formação	3

Fonte: elaborado pelo autor.

Com base em suas frequências, cabem as seguintes considerações sobre as principais palavras identificadas:

- a) O termo “dados” aparece 38 vezes, ou quase 1,5 vezes em cada definição, o que faz sentido dada a natureza do assunto desta pesquisa;
- b) O segundo termo mais frequente é “negócios”, com 8 ocorrências. Essa constatação é interessante no sentido de que a característica do cientista de dados como alguém que tem foco em negócios aparece de forma mais frequente do que termos que estão relacionados com abordagens técnicas;

- c) Para o entendimento do terceiro termo mais frequente, “conhecimento”, com 6 ocorrências, é preciso analisar a origem etimológica do termo original, “*knowledge*”, que vem da palavra grega “*gnosis*”, cujo significado é o aprendizado através da observação ou da experimentação. Esta interpretação está em linha com o contexto dos trabalhos analisados na revisão da literatura;
- d) Analisando os contextos dos termos “ciência” e “cientista”, ambos com 6 ocorrências, verifica-se que estão presentes em função de estarem sendo definidos, e nunca são mencionados em outros contextos, como, por exemplo, o da aplicação de um método científico;
- e) Ainda que a análise de dados, de uma forma geral, seja uma atividade acadêmica e empresarial há muito tempo existente, as 6 ocorrências do termo “*big data*” podem sugerir uma tendência de cientistas de dados trabalharem com dados não estruturados, como textos e mídia, técnicas apenas mais recentemente utilizadas de forma mais ampla;
- f) O termo “computação”, com 5 ocorrências, está em geral associado à formação dos cientistas de dados (“cientista de computação”), indicando sua formação básica mais presente. De fato, conforme evidenciado a seguir na Seção 2.5.2 deste estudo, computação é a única formação presente em todos os autores estudados;
- g) Os termos “análise” e “analíticas”, respectivamente com 5 e 4 ocorrências, possuem a mesma raiz etimológica, o que permite que sejam analisados em conjunto. Segundo o dicionário Houaiss, a palavra “análise” é a “separação de um todo em seus elementos ou partes componentes” ou o “estudo pormenorizado de cada parte de um todo, para conhecer melhor sua natureza, suas funções, relações, causas etc”.

Com base nas considerações acima, é possível propor uma definição abrangente, no sentido de que contemple o que pode ser considerado o mais próximo de um consenso entre as definições de cientistas de dados que foram pesquisadas: “Cientista de dados é um profissional com formações em ciências exatas, mais frequentemente em ciência da computação, mas que possui orientação para negócios. Trabalha com dados digitais utilizando abordagem analítica, não necessariamente através de métodos científicos.”

2.5.2 Formação de cientistas de dados

A Tabela 5 apresenta a consolidação de todas as áreas de formação identificadas nos 11 autores estudados na revisão da literatura que abordaram esta questão.

Tabela 5 – Formações de cientistas de dados encontradas na literatura e suas respectivas frequências

		Ciência da computação	Matemática	Engenharia	Estatística	Física	Contabilidade	Economia	Administração/Finanças	Biologia
2009	Liu et al. (2009)	✓	✓	✓						
2014	Vangelova (2014 apud Chatfield et al., 2014)	✓	✓		✓					
2015	Gehl (2015)	✓	✓		✓	✓		✓		
2016	Cegielski & Jones-Farmer (2016)	✓	✓	✓						
2017	Cao (2017)	✓	✓	✓	✓	✓				
	Costa & Santos (2017)	✓	✓		✓					
	Baškarada & Koronios (2017)	✓	✓	✓	✓	✓	✓		✓	
2018	Pires & Leitão (2018)	✓	✓	✓	✓	✓				
	Gibert (2018)	✓	✓		✓					
	Hu et al. (2018)	✓								
2019	Yan & Davis (2019)	✓	✓	✓			✓			✓
	Total	11	10	6	7	4	2	1	1	1
	Frequência Relativa	100%	91%	55%	64%	36%	18%	9%	9%	9%

Fonte: consolidado pelo autor

A análise da Tabela 5 está em linha com as análises realizadas nas definições de cientistas de dados, em que a única formação presente em todos os estudos analisados é “ciência da computação”.

É válido destacar, também, que das 5 áreas de formação mais presentes (“ciência da computação”, “matemática”, “engenharia”, “estatística” e “física”), todas têm características eminentemente técnicas, o que torna desafiador, para os cientistas de dados, desenvolver suas habilidades de negócios, conforme evidenciado na análise das definições, na seção anterior.

2.5.3 Habilidades de cientistas de dados e ferramentas utilizadas por cientistas de dados

Trinta artigos apresentaram habilidades e ferramentas passíveis de serem coletados, que revelaram cerca de 700 pontos de informação, considerando como ponto de informação uma

habilidade ou ferramenta. Dentre as diversas estratégias estudadas para analisar e resumir as informações obtidas e atingir os objetivos deste trabalho, a alternativa selecionada foi a segregação de todas as informações em três grupos distintos: “*hard skills*”, “*soft skills*” e “ferramentas”. A segregação em “*hard skills*” e “*soft skills*” está presente na revisão de literatura no trabalho de Pires & Leitão (2018).

Cientistas de dados dependem de um arcabouço de infraestruturas e aplicações para realizar seu trabalho. Por ser um campo amplo, existem muitas tecnologias e técnicas, não apenas tradicionais como também emergentes, que crescem anualmente, criando um cenário heterogêneo (Salado-Cid et al., 2018). Desde 2014, a organização FirstMark Capital publica uma visão geral das mais importantes tecnologias associadas à ciência de dados, classificadas em diferentes categorias, como, por exemplo, infraestrutura, *analytics* e aplicativos (Turck, 2019). No sentido de facilitar a compreensão dos resultados pelo leitor, algumas das categorias propostas por Turck (2019) foram utilizadas, tanto para “*hard skills*” como para “ferramentas”.

Foram utilizadas, também, algumas categorias apresentadas no *framework* constante no documento *EDISON Data Science Framework* (EDSF), citado por Manieri et al. (2015), Wiktorski et al. (2017) e Demchenko et al. (2019). A inspiração para a criação de um grupo com foco em negócios, segregado dos outros grupos, eminentemente técnicos, veio do trabalho de De Mauro et al. (2017).

É importante reforçar que a segregação em grupos, e, dentro destes, em categorias, foi realizada para facilitar a leitura de um grande volume de dados. As informações não foram suprimidas, e a segregação em grupos e categorias não prejudica de nenhuma forma o resultado do trabalho. Por exemplo, pode-se questionar se o fato do conceito de *storytelling* estar classificado em *Conhecimentos Gerais em Negócios* está correto, ou se seria melhor que fosse classificado como *Conhecimentos Gerais em Computação e Desenvolvimento de Sistemas*. Do ponto de vista deste estudo, o debate sobre a classificação é menos importante do que o fato de que *storytelling* é efetivamente uma habilidade importante, citada por vários autores, e encontra-se no resultado do trabalho, independentemente de sua classificação.

2.5.3.1 Nota sobre o uso dos termos “habilidade” e “competência” no contexto deste estudo

O mercado, de uma forma geral, utiliza muitas vezes o termo “competência” de forma intercambiável com o termo “habilidade”. O dicionário Webster (1981) define competência, na língua inglesa, como: “qualidade ou estado de ser funcionalmente adequado ou ter suficiente conhecimento, julgamento, habilidades ou força para uma determinada tarefa”. O dicionário de

língua portuguesa Aurélio enfatiza, em sua definição, aspectos semelhantes: “capacidade para resolver qualquer assunto, aptidão e idoneidade”, bem como introduz outro: “capacidade legal para julgar pleito”. O termo “competência” está na pauta das discussões acadêmicas e empresariais, associado a diferentes instâncias de compreensão: no nível da pessoa, das organizações e dos países (Fleury & Fleury, 2001). Nota-se, desta forma, que o termo “competência” está aberto a um conjunto amplo de interpretações.

Já o termo “habilidade” é bem mais restrito e, segundo o dicionário Michaelis da Língua Portuguesa, significa “conjunto de qualificações para o exercício de uma atividade ou cargo; suficiência.” Adicionalmente, a partir da análise exploratória do tema cientista de dados, descrito na Seção 2.1, o termo “*skills*” é prevalente na literatura. Dentre as traduções possíveis da palavra “*skill*” para a Língua Portuguesa, segundo o Google Tradutor, as mais frequentes são “habilidade”, “proficiência”, “perícia” e “destreza”, sendo “habilidade”, dentre elas, a mais frequente. Em função das razões apresentadas, neste estudo, optou-se por utilizar, de forma exclusiva, o termo “habilidade”, com uma única exceção: para evitar a tradução literal de “*hard skill*” e “*soft skill*” como habilidades “duras” ou “moles”, exclusivamente esses termos foram mantidos no inglês original.

2.5.3.2 *Hard skills* e *soft skills*

Na revisão de literatura as definições de *hard skills* e *soft skills* são encontradas no trabalho de Pires & Leitão (2018), sendo que o primeiro representa conhecimentos e capacidades que podem ser adquiridos através de programas de educação e treinamento, enquanto o segundo, também chamado de “*people skills*”, é a capacidade de se relacionar com outras pessoas para expressar ideias e o desejo de realizar o trabalho. Para a apresentação das habilidades de cientistas de dados, as definições de Pires & Leitão (2018) foram expandidas através da análise do trabalho de Laker & Powel (2011), que diferencia “*hard skills*” e “*soft skills*” de forma que o primeiro são habilidades essencialmente técnicas enquanto o segundo está relacionado a habilidades intrapessoais e interpessoais. As definições acima são a base para segregação e apresentação das habilidades de cientistas de dados encontradas na literatura.

2.5.3.3 Resumo da conclusão sobre habilidades e ferramentas

O resultado da consolidação de habilidades e ferramentas encontra-se a seguir, nas Tabelas 6.1 até 6.8, segregadas da seguinte forma:

- a) “*Hard skills*”, segregados em “Conhecimentos gerais em computação e desenvolvimento de sistemas” (Tabela 6.1), “Conhecimentos gerais em negócios” (Tabela 6.2) e “Inteligência artificial” (Tabela 6.3).
- b) “*Soft skills*” (Tabela 6.4).
- c) “Ferramentas”, segregadas em “Ecossistemas, *frameworks* e bancos de dados” (Tabela 6.5), “Linguagens de programação ou *scripts*” (Tabela 6.6), “Visualização de dados” (Tabela 6.7) e “Outros: plataformas específicas, ambientes em nuvem e ambientes integrados” (Tabela 6.8).

Cada uma das tabelas apresenta uma coluna “Notas”, com a referência para informações complementares, que podem ser encontradas logo após a tabela, e uma coluna “Frequência” que apresenta em quantos trabalhos a habilidade ou ferramenta está presente. As tabelas estão ordenadas pelas habilidades ou ferramentas mais frequentes.

Tabela 6.1 – *Hard skills* - Conhecimentos gerais em computação e desenvolvimento de sistemas (continua)

	Notas	Frequência	Chatfield et al. (2014)	Debortoli et al. (2014)	Manieri et al. (2015)	Waller & Fawcett (2013)	Wiktorski et al. (2017)	Abidin et al. (2017)	Attwood et al. (2017)	Başkarada & Koronios (2017)	Baumer (2017)	Cao (2017)	Costa & Santos (2017)	De Mauro et al. (2017)	Dichev & Dicheva (2017)	Ecleo & Galido (2017)	Kotzé (2017)	Markow (2017)	Gardiner et al. (2017)	Gibert et al. (2018)	Hu et al. (2018)	Knorr et al. (2018)	Luna-Reyes (2018)	Meyer (2018)	Mikalef (2018)	Pires & Leitão (2018)	Demchenko et al. (2019)	Kross & Guo (2019)	Mikalef (2019)	Miller (2019)	Verna et al. (2019)	Yan & Davis (2019)
01. Análise de sistemas	a	18	✓	✓	✓	•	✓	✓	✓	•	✓	✓	✓	✓	✓	✓	✓	•	✓	•	•	•	•	✓	•	•	✓	✓	✓	•	•	•
02. <i>Data management</i>	b	15	✓	✓	✓	•	✓	✓	✓	•	•	•	✓	•	✓	✓	•	•	✓	•	•	•	✓	✓	•	•	✓	✓	✓	•	•	•
03. <i>Big data</i>	c	14	✓	•	✓	•	✓	•	•	✓	•	✓	✓	✓	•	•	•	•	✓	✓	•	•	•	✓	✓	✓	✓	•	✓	•	•	•
04. Infraestrutura TI	d	10	•	•	✓	•	✓	•	•	•	•	✓	✓	•	•	•	•	•	•	•	✓	•	✓	✓	•	•	✓	✓	✓	•	•	•
05. Mineração de dados		9	•	•	✓	✓	✓	✓	✓	•	•	•	•	•	•	•	•	•	•	•	✓	✓	•	•	•	•	✓	•	✓	•	•	•
06. Computação em nuvem		8	•	•	✓	•	✓	•	✓	✓	•	✓	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	✓	•	✓	•	•	•
07. <i>Data warehouse</i>	e	6	•	✓	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	✓	•	•	✓	•	•
08. Privacidade e segurança	f	6	•	•	✓	•	✓	✓	•	•	•	•	✓	•	•	•	•	•	•	•	•	✓	•	•	•	•	✓	•	•	•	•	•
09. Ética		5	•	•	•	•	•	✓	•	•	•	•	✓	✓	✓	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•
10. <i>Data quality</i>	g	5	•	•	✓	•	✓	•	•	✓	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
11. Computação de alta performance		4	•	•	✓	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
12. Computação distribuída	h	4	•	•	✓	•	✓	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
13. Pré-processamento de dados, ETL		4	•	•	✓	•	✓	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
14. Computação em tempo real (<i>streaming</i>)	i	3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
15. Controle de Versionamento (“GIT”)		3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•

Tabela 6.1 – *Hard skills* - conhecimentos gerais em computação e desenvolvimento de sistemas (conclusão)

	Notas	Frequência	Chatfield et al. (2014)	Debortoli et al. (2014)	Manieri et al. (2015)	Waller & Fawcett (2013)	Wiktorski et al. (2017)	Abidin et al. (2017)	Attwood et al. (2017)	Başkarada & Koronios (2017)	Baumer (2017)	Cao (2017)	Costa & Santos (2017)	De Mauro et al. (2017)	Dichev & Dicheva (2017)	Ecleo & Galido (2017)	Kotzé (2017)	Markow (2017)	Gardiner et al. (2017)	Gibert et al. (2018)	Hu et al. (2018)	Knorr et al. (2018)	Luna-Reyes (2018)	Meyer (2018)	Mikaléf (2018)	Pires & Leitão (2018)	Demchenko et al. (2019)	Kross & Guo (2019)	Mikaléf (2019)	Miller (2019)	Verma et al. (2019)	Yan & Davis (2019)
16. Armazenamento de dados		2	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•
17. <i>Hardware</i>	j	1	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
18. Integração de dados		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•
19. Limpeza e preparação de dados		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•
20. Métodos de pesquisa e validação empírica		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•
21. Mineração de dados		1	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•

- a) Considera habilidades citadas na literatura em diversas formas, tais como engenharia de *software* e de dados, análise de sistemas, programação, desenvolvimento de *scripts*, desenvolvimento de algoritmos, extração, limpeza, enriquecimento e transformação de dados, “habilidades, técnicas, metodologias e conhecimentos relacionados ao *design*, construção e implantação de sistemas de informação”, “suporte ao desenvolvimento de aplicações”, “conhecimentos gerais sobre tecnologia, gestão de dados, projeto, análise, implementação e teste, conhecimento de metodologias de desenvolvimento, integração, programação, documentação, operações e manutenção, desenvolvimento para aplicativos móveis, algoritmos”, aplicativo baseado na *web*, programação estruturada múltipla, linguagens de consulta (*query*), princípios de engenharia de sistemas e *software* para o *design* e desenvolvimento de sistemas de informação das organizações, incluindo o *design* de requisitos, uso integrado com sistemas corporativos e colaborativos, algoritmos eficientes para acessar e analisar grandes quantidades de dados, incluindo API para diferentes bancos de dados, gestão de relacionamento com cliente (CRM), requisitos de experiência do usuário (UX) e *design*; metodologia e plataforma de desenvolvimento e gerenciamento de *software* ágil Scrum;
- b) Habilidades relacionadas à criação e gerenciamento da arquitetura de informação da organização, bem como gerenciamento de ativos de dados; gerenciamento de dados (curadoria, preparação, análise exploratória, integração de diversas fontes de dados); especificação, desenvolvimento e implementação do gerenciamento de dados corporativos, bem como definir estratégia para arquitetura de governança de dados; desenvolvimento e

implementação de arquitetura de dados, tipos e formatos de dados, modelagem e *design* de dados, incluindo tecnologias relacionadas (ETL, OLAP, OLTP, etc.);

- c) Engloba habilidades referentes a dados não estruturados, como, por exemplo, utilização de bancos de dados NoSQL e mineração de texto; tecnologias baseadas na nuvem para sistemas e aplicativos de processamento de grandes conjuntos de dados; desenvolvimento de políticas de governança de *big data*;
- d) Habilidades que aparecerem na literatura como implementação de modelos em produção, infraestrutura de reprodutibilidade (por exemplo, utilização de Docker e Virtual Machines); orquestração de negócios e TI; gerenciamento e operação de infraestrutura e serviços; utilização de Unix ou de suas variações, como, por exemplo, Linux; arquitetura geral de redes, computação em nuvem, cliente-servidor e redes distribuídas, internet, LAN e WAN, devices de rede (*firewall, routers*);
- e) Habilidades que incluem trabalhar com tecnologias OLTP e OLAP, tanto para dados estruturados como para dados não estruturados;
- f) Na literatura, aspectos de privacidade e segurança aparecem como desenvolvimento e implementação de sistemas e segurança de dados, acesso a dados, incluindo anonimização e controle de acesso; modelos de segurança baseados em conformidade, em particular para proteção de privacidade. Importante ressaltar que nenhum artigo analisado menciona legislação específica sobre privacidade, como por exemplo a europeia *General Data Protection Regulation* (GDPR);
- g) Habilidades relacionadas com qualidade de dados aparecem relacionadas à implementação e curadoria contínua dos controles de qualidade dos dados, garantindo integração e interoperabilidade;
- h) Exemplos que aparecem na literatura citam Hadoop, Spark, MapReduce, Mahout, Lucene e Pregel;
- i) Exemplos que aparecem na literatura citam sistemas de análise em tempo real e *streaming* como Flume, Kafka e Storm;
- j) Habilidades que incluem conhecimento geral sobre *hardware*, servidores e estações de trabalho e sistemas embarcados.

Fonte: elaborado pelo autor.

Tabela 6.2 – *Hard skills* - Conhecimentos gerais em negócios (continua)

	Notas	Frequência	Chatfield et al. (2014)	Debortoli et al. (2014)	Manieri et al. (2015)	Waller & Fawcett (2013)	Wiktorski et al. (2017)	Abidin et al. (2017)	Attwood et al. (2017)	Başkarada & Koronios (2017)	Baumer (2017)	Cao (2017)	Costa & Santos (2017)	De Mauro et al. (2017)	Dichev & Dicheva (2017)	Ecleo & Galido (2017)	Kotzé (2017)	Markowet al. (2017)	Gardiner et al. (2017)	Gibert et al. (2018)	Hu et al. (2018)	Knorr et al. (2018)	Luna-Reyes (2018)	Meyer (2018)	Mikalef (2018)	Pires & Leitão (2018)	Demchenko et al. (2019)	Kross & Guo (2019)	Mikalef (2019)	Miller (2019)	Verma et al. (2019)	Yan & Davis (2019)
01. Negócios, “domain-knowledge”	k	19	✓	•	✓	•	✓	✓	•	✓	✓	✓	✓	✓	•	✓	•	•	•	✓	✓	✓	✓	✓	✓	✓	✓	•	✓	•	✓	•
02. Visualização de dados	l	17	✓	•	✓	•	✓	✓	✓	•	•	✓	✓	✓	✓	✓	✓	•	•	•	•	✓	✓	✓	✓	•	✓	•	✓	•	•	✓
03. Comunicação	m	14	✓	•	•	•	•	✓	•	✓	✓	✓	✓	✓	•	✓	✓	•	✓	•	•	•	•	✓	•	✓	•	✓	•	•	✓	•
04. Gestão de projetos		10	•	•	✓	•	✓	•	•	•	•	✓	✓	✓	•	✓	•	•	✓	•	•	•	•	•	•	•	✓	✓	✓	•	•	•
05. Trabalho em time	n	7	✓	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	✓	•	•	•	•	✓	•	✓	•	•	✓	•	•	•
06. Liderança		6	•	•	•	•	•	•	•	✓	•	•	•	•	•	✓	•	•	✓	•	•	•	•	•	•	✓	•	•	•	✓	•	•
07. Metodologias	o	6	•	•	✓	•	✓	•	•	•	•	✓	•	•	•	✓	•	•	•	•	•	•	•	•	✓	•	✓	•	•	•	•	•
08. <i>Storytelling</i>		6	•	•	✓	•	✓	✓	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	✓	•	•	✓	•	•	•	•	•
09. Resolução de problemas		5	•	•	•	•	•	•	•	•	•	✓	✓	•	•	✓	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	✓
10. Conformidade	p	3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
11. Gestão de processos de negócios	q	3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
12. Conhecimento multidisciplinar		3	✓	•	•	•	•	•	•	•	•	✓	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
13. Gestão		2	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•
14. Gestão de conhecimento		2	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•

Tabela 6.2 – *Hard skills* - Conhecimentos gerais em negócios (conclusão)

	Notas	Frequência	Chatfield et al. (2014)	Debortoli et al. (2014)	Manieri et al. (2015)	Waller & Fawcett (2013)	Wiktoriski et al. (2017)	Abidin et al. (2017)	Attwood et al. (2017)	Baškarada & Koronios (2017)	Baumer (2017)	Cao (2017)	Costa & Santos (2017)	De Mauro et al. (2017)	Dichev & Dicheva (2017)	Ecleo & Galido (2017)	Kotzé (2017)	Markow (2017)	Gardiner et al. (2017)	Gibert et al. (2018)	Hu et al. (2018)	Knorr et al. (2018)	Luna-Reyes (2018)	Meyer (2018)	Mikalef (2018)	Pires & Leitão (2018)	Demchenko et al. (2019)	Kross & Guo (2019)	Mikalef (2019)	Miller (2019)	Verma et al. (2019)	Yan & Davis (2019)
15. Visão estratégica		2	•	•	•	•	•	✓	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
16. Auditoria		1	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
17. Desenvolvimento de produtos		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•
18. Gestão de mudança		1	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
19. Fluência em inglês		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•
20. Orientação ao cliente		1	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•

- Na literatura é prevalente o conhecimento sobre negócios, em geral utilizando o termo “*domain knowledge*”, ou conhecimento sobre domínio. Exemplos citados são *marketing*, finanças, saúde e cadeia de suprimento. Sobre atividades, habilidades nesta categoria são o entendimento dos desafios de negócios, dos principais motivadores da competitividade digital, do conhecimento de casos de sucesso, do desenvolvimento de cultura orientada a dados, do desenvolvimento de planos de negócios;
- Esta categoria contempla a habilidade de utilizar *softwares* de visualização de dados. Aqueles citados na literatura são Datawrapper, API de visualização do Google, Google Charts, Flare, D3.js, Tableau, Raphael, Gephi e Qlik;
- Na literatura, o termo “comunicação” aparece com várias nuances: oral, escrita e não técnica, bem como a habilidade de falar com vários públicos e, ainda, a comunicação interpessoal;
- Habilidade citada na literatura como gestão de times multifuncionais e como orquestração de tecnologias e recursos humanos. Também citada como a habilidade em trabalhar em equipes multidisciplinares;

- e) Habilidades relacionadas a metodologia aparecem na literatura como métodos de pesquisa e validação empírica; métodos de pesquisa, tanto no contexto de pesquisa acadêmica como no contexto de negócios; tecnologias de desenvolvimento ágil, como DevOps e ciclo de aprimoramento contínuo, para aplicativos orientados a dados; conhecimento de pacotes e estruturas (*frameworks*);
- f) Habilidades relacionadas a conformidade estão associadas ao uso e implementação de metadados, propriedade intelectual, registros de dados e padrões;
- g) Processos de negócios (*business process modeling*, BPM) estão relacionados a processos e operações gerais de negócios para análise e modelagem de processos organizacionais;

Fonte: elaborado pelo autor.

Tabela 6.3 – *Hard skills* – Inteligência artificial[illegible]

- a) Habilidades em métodos quantitativos foram agrupadas quando aparecem na literatura de forma genérica, como, por exemplo, análises quantitativas, matemáticas, estatísticas, testes de hipótese, simulação de eventos discretos e probabilidade aplicada. Aparecem também técnicas gerais de análise estatística e análise descritiva, preditiva e prescritiva, métricas de desempenho para avaliação e validação de análise de dados, pesquisa operacional, otimização e simulação;
- b) As habilidades agrupadas na categoria “*machine learning*”, ou aprendizado de máquina, incluem aprendizado supervisionado, não supervisionado ou de aprendizado por reforço, bem como modelagem preditiva. Esta categoria existe para agrupar a habilidade de trabalhar com *machine learning* de forma genérica. Quando o autor do artigo revisado menciona um algoritmo específico, como, por exemplo, *basket analysis*, este é tratado de forma individual;
- c) Habilidades relacionadas à modelagem de dados poderiam ter sido classificadas dentro de conhecimento gerais de TI. A razão por estar agrupada dentro de inteligência artificial é que é uma habilidade essencial na criação de *datasets*, ou conjunto de dados, que são a base para treinamentos de modelos de inteligência artificial. Demchenko et al. (2019) cita ferramentas que tem caráter mais abrangente, como, por exemplo, UML, ERWin e DDL, porém Kross & Guo (2019) citam especificamente o pacote Pandas que é amplamente utilizado por cientistas de dados que utilizam linguagem Python.

Fonte: elaborado pelo autor.

Tabela 6.4 – *Soft skills*

		Notas																															
		Frequência																															
			• Chatfield et al. (2014)	• Debortoli et al. (2014)	• Manieri et al. (2015)	• Waller & Fawcett (2013)	• Wiktorski et al. (2017)	• Abidin et al. (2017)	• Attwood et al. (2017)	• Baškarada & Koronios (2017)	• Baumer (2017)	• Cao (2017)	• Costa & Santos (2017)	• De Mauro et al. (2017)	• Dichev & Dicheva (2017)	• Ecleo & Galido (2017)	• Kotzé (2017)	• Markowet al. (2017)	• Gardiner et al. (2017)	• Gibert et al. (2018)	• Hu et al. (2018)	• Knorr et al. (2018)	• Luna-Reyes (2018)	• Meyer (2018)	• Mikalef (2018)	• Pires & Leitão (2018)	• Demchenko et al. (2019)	• Kross & Guo (2019)	• Mikalef (2019)	• Miller (2019)	• Verma et al. (2019)	• Yan & Davis (2019)	
01. Pensamento analítico		3	•	•	•	•	•	•	•	•	•	↙	↙	•	•	↙	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	
02. Criatividade		2	•	•	•	•	•	•	•	•	•	✓	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	
03. Empreendedorismo		2	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	↙	•	•	•
04. Pensamento crítico		2	•	•	•	•	•	✓	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
05. Aprendizado contínuo		1	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
06. Curiosidade		1	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
07. Paixão		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•
08. Proatividade		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•
09. Relacionamento interpessoal		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•
10. Senso de responsabilidade		1	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•

Fonte: elaborado pelo autor.

Tabela 6.5 – Ferramentas - Ecossistemas, *frameworks* e bancos de dados

		Notas																																
		Frequência																																
			• Chatfield et al. (2014)	• Debortoli et al. (2014)	✓ Manieri et al. (2015)	• Waller & Fawcett (2013)	✓ Wiktorski et al. (2017)	✓ Abidin et al. (2017)	• Attwood et al. (2017)	• Baškarada & Koronios (2017)	✓ Baumer (2017)	• Cao (2017)	• Costa & Santos (2017)		De Mauro et al. (2017)	• Dichev & Dicheva (2017)	• Ecleo & Galido (2017)	• Kotzé (2017)	• Markowet al. (2017)	• Gardiner et al. (2017)	• Gibert et al. (2018)	✓ Hu et al. (2018)	• Knorr et al. (2018)	• Luna-Reyes (2018)	✓ Meyer (2018)	• Mikalef (2018)	✓ Pires & Leitão (2018)	✓ Demchenko et al. (2019)	• Kross & Guo (2019)	• Mikalef (2019)	• Miller (2019)	• Verma et al. (2019)	• Yan & Davis (2019)	
01. SQL		9	•	•	✓	•	✓	✓	•	•	✓	•	•		✓	•	•	•	•	•	•	✓	•	•	✓		•	✓	•	•	•	•	•	
02. Hadoop	u	9	•	•	✓	•	✓	✓	•	✓	•	•	•		•	•	•	✓	✓	•	•	•	•	•	✓		•	✓	•	•	•	•	•	
03. NoSQL	v	6	•	✓	✓	•	✓	✓	•	•	•	•	•		•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	✓	•	
04. Spark		3	•	•	•	•	•	✓	•	✓	•	•	•		•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	
05. Map Reduce		2	•	•	•	•	•	✓	•	✓	•	•	•		•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	
06. .NET		2	•	✓	•	•	•	•	•	•	•	•	•		•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•

a) A utilização do Hadoop como ferramenta por cientistas de dados aparece na literatura tanto na sua forma original, Apache Hadoop, como também através das distribuições específicas Cloudera e Hortonworks;

b) Quando não citado de forma genérica, NoSQL aparece como Hbase, MongoDB, Cassandra, Redis e Accumulo.

Fonte: elaborado pelo autor.

Tabela 6.6 – Ferramentas – Linguagens de programação ou *scripts*

[illegible]

Fonte: elaborado pelo autor.

Tabela 6.7 – Ferramentas – Visualização de dados

[illegible]

Fonte: elaborado pelo autor.

Tabela 6.8 – Ferramentas – Outros: plataformas específicas, ambientes em nuvem e ambientes integrados

	Notas	Frequência	Chatfield et al. (2014)	Debortoli et al. (2014)	Manieri et al. (2015)	Waller & Fawcett (2013)	Wiktorski et al. (2017)	Abidin et al. (2017)	Attwood et al. (2017)	Baškarada & Koronios (2017)	Baumer (2017)	Cao (2017)	Costa & Santos (2017)	De Mauro et al. (2017)	Dichev & Dicheva (2017)	Ecleo & Galido (2017)	Kotzé (2017)	Markowet al. (2017)	Gardiner et al. (2017)	Gibert et al. (2018)	Hu et al. (2018)	Knorr et al. (2018)	Luna-Reyes (2018)	Meyer (2018)	Mikalef (2018)	Pires & Leitão (2018)	Demchenko et al. (2019)	Kross & Guo (2019)	Mikalef (2019)	Miller (2019)	Verma et al. (2019)	Yan & Davis (2019)
01. IBM Watson Analytics		3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	
02. Plataforma Google Analytics		3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
03. Plataforma Amazon AWS		3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
04. Plataforma Microsoft Azure		3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
05. IDEs	w	3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
06. Jupyter Notebook		2	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•
07. NLTK		3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
08. WEKA		3	•	•	✓	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	✓	•	•	•	•	•
09. Mahout		1	•	•	•	•	•	✓	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•

w) IDEs aparecem na literatura como plataformas integradas de desenvolvimento (*integrated development environment*). Especificamente são citadas Eclipse, R Studio, Anaconda Jupyter Notebook, Visual Studio Code e Atom.

Fonte: elaborado pelo autor.

O resultado da consolidação de habilidades e ferramentas, apresentado nas Tabelas 6.1 a 6.8, constituiu-se em uma das principais bases para a pesquisa quantitativa e qualitativa, e os resultados encontrados na revisão de literatura, como um todo, serão discutidos na próxima seção.

3. PESQUISA EXPLORATÓRIA E QUALITATIVA: METODOLOGIA

O objetivo desta seção é descrever aspectos metodológicos, que estão estruturados da seguinte forma: (3.1) método de pesquisa, (3.2) definições operacionais, (3.3) enfoque e abordagem, (3.4) matriz de amarração, (3.5) protocolo de pesquisa, (3.6) comparação entre os achados da pesquisa e da RSL, (3.7) considerações sobre as diferenças e similaridades entre cientistas de dados, analistas de dados, engenheiros de dados e arquitetos de dados, (3.8) proposta de modelo conceitual prévio para cientistas de dados, e (3.9) validação do modelo.

3.1 MÉTODO DE PESQUISA

As pesquisas científicas podem ser classificadas quanto aos seus objetivos e à abordagem do problema investigado. Santos (1999), Lakatos & Marconi (2003) e Andrade (2008) descrevem que o objetivo pode ser exploratório, descritivo ou explicativo; Leech & Onwuegbuzie (2007) e Sampieri et al. (2013) sugerem que o enfoque é quantitativo, qualitativo ou misto. Neste trabalho, o protocolo de pesquisa desenvolvido possui objetivo exploratório e abordagem qualitativa.

As pesquisas exploratórias buscam intuições e ideias que permitam compreender o fenômeno investigado, ampliando o conhecimento do pesquisador sobre os fatos, suportando formulações mais precisas, gerando novas hipóteses e fomentando outros estudos mais estruturados (Selltiz et al., 1987). Assim, a abordagem exploratória geralmente é utilizada quando existe pouco conhecimento sobre a área investigada, fato que impede o desenvolvimento de hipóteses aprimoradas e operacionalizáveis (Gil, 2008). Este é exatamente o caso deste trabalho, onde a literatura não é extensa e o tema, além de emergente, é vibrante e está em rápido e constante desenvolvimento.

3.2 DEFINIÇÕES OPERACIONAIS

Por tratar-se de uma abordagem exploratória, é preciso apresentar as definições de termos que são importantes para o entendimento desta pesquisa. Neste sentido, seguem abaixo as seguintes definições operacionais:

- a) Academia: refere-se às fontes de informação a partir da literatura acadêmica, ou seja, projetos de pesquisa publicados em periódicos científicos e livros de referência;

- b) Mercado: o termo “mercado” origina-se do termo “mercadoria” que é o que se produz para o mercado, isto é, o que se produz para a venda e não para o uso imediato do produtor (Konder, 1999). Este estudo refere-se a “mercado” sempre no sentido das organizações que buscam produzir bens e serviços para auferir lucro;
- c) Mercado de trabalho: associação entre aqueles que oferecem força de trabalho e aqueles que a procuram, em um sistema típico de mercado, onde se negocia a fim de determinar os preços e as quantidades a transacionar.

3.3 ENFOQUE E ABORDAGEM

Como apresentado no Capítulo 1, a questão de pesquisa deste projeto é a seguinte: “quais aspectos definem um cientista de dados, sob as perspectivas da sua formação, de suas habilidades e das ferramentas que utiliza?” Com base nesta questão, o objetivo primário foi a definição de um modelo conceitual para explicar a função de um cientista de dados, considerando a proposta de uma definição de sua atuação e áreas de formação, bem como considerando o conjunto de suas habilidades e as principais ferramentas utilizadas por esses profissionais.


A opção pela elaboração de um modelo conceitual deu-se pelo fato de que é uma forma de apresentar informações numa representação gráfica organizada, esquematizada, resumida e de fácil entendimento.

Para consecução deste objetivo foi realizada uma análise a partir de três perspectivas:

- a) Perspectiva da academia, representada pelo resultado da revisão sistemática da literatura descrita na Seção 2.5 deste estudo;
- b) Perspectiva do mercado, representada pela coleta e análise de dados de vagas de emprego direcionadas para contratação de cientistas de dados;
- c) Perspectivas das pessoas, isto é, de cientistas de dados ou, ainda, dos praticantes de ciência de dados, representada pela análise de dados secundários da pesquisa realizada pelo grupo Data Hackers Brasil em 2019.

As três perspectivas foram analisadas e agregadas de forma a obter o modelo conceitual, cujo exemplo é apresentado na Figura 6.

Figura 6 – Exemplo esquemático de modelo conceitual para cientistas de dados



Fonte: elaborado pelo autor.

As etapas percorridas para a definição do modelo acima estão explicadas a seguir, na apresentação do protocolo de pesquisa.

3.4 MATRIZ DE AMARRAÇÃO

A matriz de amarração (Figura 7) apresenta um resumo da pesquisa e retoma a questão de pesquisa e de seu objetivo primário, além de apresentar cada objetivo secundário, relacionando-os com o procedimento metodológico, as variáveis, as fontes de dados e a técnica de análise de dados necessários para alcançá-los.

Figura 7 – Matriz de amarração

Pergunta	Quais aspectos definem um cientista de dados, sob as perspectivas da sua formação, de suas habilidades e das ferramentas que utiliza?			
Objetivo primário	Definir um modelo conceitual para explicar a função de um cientista de dados, considerando a proposta de uma definição de sua atuação e áreas de formação, bem como considerando o conjunto de suas habilidades e as principais ferramentas utilizadas por esses profissionais.			
Objetivos específicos	Procedimento metodológico	Variáveis fontes de dados	Técnica de análise	
Revisar a literatura de forma sistemática com o objetivo de (a) buscar as definições existentes de cientista de dados e, a partir destas, consolidar a proposta de uma definição abrangente; (b) identificar as principais áreas de formação e o conjunto de habilidades e ferramentas utilizadas por esses profissionais.	Revisão sistemática da literatura.	ACM EBSCO, Elsevier Science Direct, Google Scholar, IEEE, Proquest, Scopus, Web of Science.	Frequência de termos, agrupamento por similaridade.	
Identificar no mercado de trabalho quais principais áreas de formação, habilidades e ferramentas são mais requeridas para exercer a profissão.	Técnica de coleta de dados automatizada e tabulação de dados secundários de pesquisa realizada com cientistas de dados.	Sítios de ofertas de empregos; pesquisa de mercado de Data Science, realizada pelo grupo Data Hackers Brasil.	Frequência de termos, agrupamento por similaridade, NLP (processamento de linguagem natural); tabulação de dados estruturados.	
Comparar, através da análise de habilidades e ferramentas, e sob a perspectiva do mercado de trabalho, diferenças e similaridades entre cientistas de dados e atividades correlatas, como, por exemplo, engenharia de dados e análise de dados.	Comparação quantitativa de habilidades e ferramentas presentes em cada uma das atividades.	Dados de vagas coletadas.	Conversão de dados não estruturados em estruturados; tabulação de dados estruturados.	
Buscar, junto a especialistas da academia e do mercado, a apreciação do modelo conceitual definido no objetivo primário, no sentido de avaliar diferenças e similaridades entre os praticantes de facto de ciência de dados e os achados que foram sumarizados no modelo conceitual.	Questionário eletrônico, balanceado para confirmar ou não os achados da pesquisa e para capturar novas informações.	Achados da pesquisa.	Análise quantitativa de concordância em relação aos achados; análise qualitativa de questões abertas com comentários, críticas e sugestões.	


Fonte: elaborado pelo autor.

3.5 PROTOCOLO DE PESQUISA

O protocolo de pesquisa é um instrumento associado à organização e à confiabilidade do estudo (Yin, 2001). Ele permite o registro de todas as etapas realizadas pelo pesquisador ao descrever as técnicas, os procedimentos e as regras que serão seguidos para atingir os objetivos primário e secundários do estudo. Segundo Yin (2015), o protocolo de pesquisa pode ser usado para assegurar repetibilidade, no sentido de que pesquisadores diferentes, usando o mesmo protocolo, tendem a reduzir a variabilidade dos resultados. Yin (2015) argumenta também que um protocolo de pesquisa com qualidade, em que fica claro o devido zelo na sua elaboração, promove maior confiança nos dados e conclusões da pesquisa. Finalmente, Yin (2015) argumenta que um protocolo de pesquisa contém implicitamente os valores, as expectativas e as perspectivas do pesquisador, ainda que ele deva ser flexível, no sentido de capturar eventuais *insights* que podem aparecer durante sua condução.

Na Figura 8, apresentamos um resumo do protocolo e, a seguir, o detalhamento de cada uma das fases executadas.

Figura 8 – Protocolo de pesquisa



Fonte: elaborado pelo autor.

Com o objetivo de facilitar o entendimento da execução do protocolo de pesquisa, as fases 1 (Coleta de dados), 2 (Tratamento de dados) e 3 (Consolidação de dados) foram agrupadas de acordo com a perspectiva de mercado (Seção 3.5.1 a seguir) e a perspectiva das pessoas (referência 3.5.2 a seguir).

3.5.1 Perspectiva de mercado

3.5.1.1 Coleta de dados

A coleta de dados para entendimento da formação e das habilidades e ferramentas de cientistas de dados, sob a perspectiva do mercado, foi realizada utilizando técnicas de *web scrap* de sítios da internet, método diversas vezes presente na revisão da literatura (Hu et al., 2018; Ecleo & Galido, 2017), bem como outros artigos que foram analisados durante este projeto (Case et al., 2012).

A referência teórica para esta etapa do estudo é o trabalho publicado por Nolan et al. (2015), cujo título é *Exploring Data Science Jobs with Web Scraping and Text Mining* e cujo objetivo foi a coleta e análise de ofertas de emprego *on-line* para diferentes profissões e tipos de posições, buscando encontrar um conjunto de habilidades, além de informações sobre a formação requerida que candidatos devem possuir, como, por exemplo, bacharelado, mestrado ou doutorado. O estudo foi realizado a partir de postagens *on-line* porque, segundo os autores, são atualizadas com mais frequência e são passíveis de serem acessadas a partir de técnicas de programação de computadores.

É importante ressaltar que esta fase de coleta foi adaptada em relação: (a) ao escopo do estudo, (b) às técnicas utilizadas e (c) às palavras-chave a serem pesquisadas, conforme detalhado a seguir.

Em relação ao escopo do estudo, Nolan et al. (2015) utilizaram os sítios *Kaggle Job List* e *CyberCodes.com*. Considerando que ambos não têm operação no Brasil, foram considerados outros, utilizando as orientações dos autores presentes no próprio estudo (“*A Reusable Generic Framework for Arbitrary Sites*”). Em relação a este projeto de pesquisa, foi utilizado exclusivamente o sítio LinkedIn, por ser uma referência para o mercado brasileiro, pela facilidade de se utilizarem técnicas de *web scrap* e pelo fato de que diversos artigos presentes na revisão da literatura também o utilizaram (Kotzé, 2017; Hu et al., 2018; Ecleo & Galido, 2017).

Em relação à técnica utilizada, foi observado como ponto de partida o roteiro proposto por Nolan et al. (2015) em seu *framework* para sítios genéricos, baseado em quatro etapas:

- a) Mecanismo para enviar a consulta de pesquisa e obter a primeira página de resultados;
- b) Extração de *links* para vagas de trabalho individuais;
- c) Função para ler o conteúdo de uma vaga de trabalho individual;
- d) Identificação da próxima página de resultados.

O roteiro original apresentado foi adaptado em relação à linguagem utilizada. O trabalho original de Nolan et al. (2015) utiliza linguagem [R], e a coleta de dados deste estudo foi realizada em linguagem Python, devido à familiaridade do pesquisador com a mesma. A utilização da linguagem Python, ao invés da linguagem R, não traz nenhum prejuízo do ponto de vista de extensão e qualidade do resultado.

Em relação às palavras-chave utilizadas nas buscas, foram usadas diversas alternativas para procurar capturar ofertas de trabalho relacionadas à ciência de dados que, eventualmente, podem ter o título do cargo descrito de outras formas. As alternativas foram identificadas a partir da literatura e são como segue:

- a) Cientista de dados;
- b) Ciência de dados;
- c) *Data scientist*;
- d) Especialista de dados;
- e) Mineração de dados;
- f) Modelagem;
- g) *Big data*;
- h) *Machine learning*;
- i) Gerente de dados;
- j) Engenheiro de dados;
- k) *Data engineer*;
- l) Analista de dados;
- m) Arquiteto de dados;
- n) *Analytics*.

O detalhamento do processo de coleta de dados do sítio LinkedIn está descrito no Apêndice A. As pesquisas foram realizadas de forma automatizada, semanalmente, no período de 28/08/2010 até 08/11/2020. O quadro abaixo mostra um resumo das pesquisas realizadas e das vagas coletadas:

Tabela 7 – Resumo de pesquisas realizadas e vagas coletadas


Pesquisas realizadas	6.021
Pesquisas realizadas sem nenhuma coleta de vagas	4.243
Pesquisas realizadas com vagas coletadas	1.778
Vagas coletadas no período ²	9.427

Fonte: elaborado pelo autor.

3.5.1.2 Fase 2: Tratamento de dados

A coleta de dados a partir de *web scrap* de sítios da internet gerou um volume muito grande de dados estruturados e não estruturados, que precisaram ser limpos, transformados, organizados e tabulados para serem analisados. Um resumo das principais atividades realizadas, que serão descritas em detalhes ao longo desta seção, encontra-se na Figura 9.

Figura 9 – Principais atividades realizadas na fase de tratamento de dados (perspectiva de mercado)



Fonte: elaborado pelo autor.

² Uma pesquisa retorna um número variável de vagas e, desta forma, excluídas as pesquisas que não retornaram nenhum resultado, ou seja, 1.778 pesquisas, foram coletadas 9.427.

3.5.1.2.1 Tratamento de dados estruturados

Os dados estruturados correspondem ao banco de dados único que foi constituído para armazenar as informações do título da vaga oferecida, da empresa ofertante, do local de trabalho, do tempo que a vaga estava em aberto, da quantidade de pessoas que se candidataram à vaga até o momento de coleta, do conteúdo da vaga, da descrição do nível da vaga, do regime de contratação, da função do profissional e das indústrias a que a vaga pertence, além outras informações técnicas referentes ao processo de coleta em si.

O banco de dados consolidado de todas as pesquisas foi constituído com as 9.427 vagas coletadas e sofreram os tratamentos descritos a seguir.

a) Eliminação de vagas duplicadas

Como a coleta de vagas ocorreu semanalmente, é esperado que muitas delas tenham sido coletadas em duplicidade, inclusive mais de uma vez, já que vagas permanecem em aberto por períodos superiores ao intervalo de coleta.

O primeiro passo do tratamento foi eliminar a duplicação de vagas, baseado no título, companhia, local, nível e regime da vaga, o que resultou em 1.928 vagas.

b) Eliminação de vagas por nível

O nível da vaga é um campo pré-definido no seu cadastro e, portanto, menos sujeito a variações. O agrupamento dos níveis foi como segue:

Tabela 8 – Totalização das vagas coletadas por nível requerido

Nível requerido	Frequência
2. Assistente	725
4. Pleno-sênior	541
3. Júnior	490
0. Não aplicável	143
1. Estágio	16
5. Executivo/diretor	13
Total	1.928

Fonte: elaborado pelo autor.

No sentido de manter o foco em profissionais com alguma experiência, e com atividades operacionais, foram desconsideradas as vagas pré-classificadas como “estágio” e cargos de alta gerência (“executivo/diretor”), bem como aquelas onde o contratante classificou o nível como “não aplicável”. Desconsideradas tais vagas, permaneceram na base de análise 1.756 vagas referentes aos níveis assistente, pleno-sênior e júnior.

c) Eliminação de vagas por setor (indústria)

Assim como o nível da vaga, o setor também é um campo pré-definido no seu cadastro e, portanto, menos sujeitos a variações. A diferença é que, no cadastro da vaga, é possível assinalar mais de um setor e, portanto, a soma dos setores identificados não reflete a soma das vagas coletadas. O agrupamento dos setores foi como segue, apresentado na Tabela 9:

Tabela 9 – Totalização das vagas coletadas por setor (indústria)

Setor (indústria)	Identificações	%	% acumulado
Tecnologia da informação e serviços	1.212	34%	34%
Internet	519	15%	49%
Recursos humanos	351	10%	59%
Recrutamento e seleção	229	6%	65%
Marketing e publicidade	182	5%	70%
Serviços financeiros	154	4%	75%
Varejo	145	4%	79%
Bancos	75	2%	81%
Consultoria de gerenciamento	50	1%	82%
Atendimento médico e hospitalar	35	1%	83%
Telecomunicações	34	1%	84%
Alimentos e bebidas	27	1%	85%
Redes	26	1%	86%
Outros	509		14%
Total	3.548		100%

Fonte: elaborado pelo autor.

Mikalef et al. (2019), em seu estudo sobre habilidades de cientistas de dados, afirmam que muitos estudos não consideram as diferenças entre setores (indústrias), considerando que tais habilidades possuem igual importância para todas elas. Uma vez que não é objetivo deste estudo uma análise com viés por setor (indústria), optou-se por não utilizar esta característica como um filtro para eliminação de vagas para análise e, desta forma, todos os setores (indústrias) foram considerados.

d) Eliminação por vagas por local de trabalho da vaga

As vagas foram agrupadas manualmente por unidade da federação, de acordo com o local informado. A Tabela 10 apresenta a distribuição encontrada.

Tabela 10 – Distribuição de vagas por Unidade Federativa

UF	Qte.	%	% acumulado
SP	1046	54%	54%
RJ	208	11%	65%
MG	129	7%	72%
PR	118	6%	78%
RS	112	6%	84%
SC	108	6%	89%
DF	44	2%	92%
PE	35	2%	93%
CE	20	1%	94%
BA	18	1%	95%
AM	14	1%	96%
BR	14	1%	97%
ES	8	0%	97%
GO	5	0%	97%
PB	3	0%	98%
PI	2	0%	98%
PA	2	0%	98%
MA	1	0%	98%
RN	1	0%	98%
outros	40	2%	100%
Total Geral	1.928		100%

Fonte: elaborado pelo autor.

Foi identificado nas chaves de pesquisa que, quando combinadas e envolvendo na geografia a cidade de Franca, em São Paulo, tais pesquisas trouxeram vários resultados para o país França, na Europa. Tais, vagas, classificadas na Tabela 10 como “outros”, no total de 40 vagas, foram desconsideradas, uma vez que o escopo da pesquisa, conforme mencionado na Seção 1.6, é o mercado brasileiro.

e) Conjunto de vagas para análise de conteúdo

Os tratamentos realizados nos dados estruturados das vagas coletadas estão resumidos na Tabela 11 abaixo:

Tabela 11 – Resumo do tratamento de dados estruturados

	Vagas eliminadas	Vagas remanescentes
Vagas coletadas no período		9.427
Eliminação de vagas duplicadas	7.499	1.928
Eliminação de vagas por nível requerido da vaga	172	1.756
Eliminação de vagas por setores (indústrias)	Zero	1.756
Eliminação de vagas por local de trabalho	40	1.716

Fonte: elaborado pelo autor.

Após o tratamento inicial de dados estruturados das vagas coletadas, foram selecionadas 1.716 vagas para análise de conteúdo da vaga, que se constitui de conteúdo não estruturado.

f) Agrupamento por título da vaga

Uma análise do título das vagas demonstrou uma variedade muito grande de como elas são apresentadas, como, por exemplo, os casos a seguir:

- “Estagiário de ciência de dados”;
- “Analista jr - ciência de dados”;
- “Cientista de dados pleno”;
- “Coordenador de dados”;
- “Analista de dados pleno”;
- “Cientista de dados”;
- “Especialista em ciências de dados”;
- “Cientista de dados sênior”;
- “Cientista de dados”;
- “*Design researcher* especialista | dados”;
- “Cientista de dados (9576)”.

Os títulos foram então agrupados com base no critério abaixo (palavras-chave para determinação do título), sendo que a ordem das palavras-chave foi utilizada nos títulos das vagas:

- “Engenheiro de dados”: engenheiro, *engineer*, engenharia, *engineering*;

- “Arquiteto de dados”: arquiteto, *architect*, arquitetura, *architecture*;
- “Cientista de dados”: cientista, *cientist*, ciência, *science*, ciências, *big data*, *machine learning*, modelagem, inteligência artificial, *artificial intelligence*;
- “Analista de dados”: analista de dados, *data analyst*, especialista de dados, *analytics*, consultor de dados, BI (“*business intelligence*”), banco de dados, dados;
- Demais vagas foram classificadas como “Outros” (mas foram consideradas para a análise de dados não estruturados).

A ordem para classificação é um fato relevante. Por exemplo, uma vaga com o título “engenheiro de *big data*” será classificada como “engenheiro de dados” e não como “cientista de dados” porque, no algoritmo que fez a classificação o termo “engenheiro” aparece antes do termo “*big data*”. O agrupamento resultou na Tabela 12:

Tabela 12 – Resumo de pesquisas realizadas e vagas coletadas

Título da vaga	Número de ocorrências
Cientista de dados	569
Engenheiro de dados	401
Analista de dados	456
Arquiteto de dados	96
Outros	194
Total	1.716

Fonte: elaborado pelo autor.

Este é um aspecto importante porque permitiu analisar se existem diferenças, do ponto de vista de habilidades e ferramentas, das vagas oferecidas. A análise será apresentada posteriormente na Seção 3.7.

3.5.1.2.2 Tratamento de dados não estruturados

Os conteúdos das vagas são dados não estruturados e, para serem tratados, foi utilizado como referencial o trabalho de Hu et al. (2018). Segundo os autores, ofertas de emprego têm três grupos de informação principais: a descrição da vaga, as responsabilidades e o que é requerido para a função, conforme exemplo na Figura 10:

Figura 10 – Exemplo de uma oferta típica de vaga de emprego

Job Description	Description
	This position is part of the Analytical Solutions team that provides internal services to various departments, including Software Development, Marketing, and New Business Development. The main focus for this role is on the suite of TV systems for national television, local television, and video on demand. In this role, the Data Scientist will utilize skills and knowledge in statistics and media research, working closely with other members of the Analytical Solutions team, the research team and Software Development department to develop and maintain value-added solutions, both on a syndicated and custom basis, on top of comScore's TV data sets.
ESSENTIAL DUTIES AND RESPONSIBILITIES:	Responsibilities
• Effectively handle large data files in the course of developing and implementing solutions • Precisely execute multiple analytic projects, each involving a great number of steps and analytic decisions • Concisely summarize real-world implications of findings from custom projects and the value proposition of real-world offerings • Translate statistical modeling results into measures of business impact • Implement analytic solutions whose processes are developed with some oversight or guidance	
QUALIFICATIONS:	Requirements
	• Highly competent in quantitative and qualitative analysis, regression, data manipulation, and critical thinking • Intrinsic ability to look at data and identify patterns, problems, or analysis opportunities • Ability to distill large amounts of information into key findings • Excellent written, verbal, and presentation skills and an ability to explain complex systems • Knowledge of data mining applications, including programming and debugging experience in SAS, R, Python or similar language.

Fonte: Hu et al. (2018, p. 3)

Ainda segundo o protocolo de Hu et al. (2018), o tratamento deve seguir dois critérios para filtrar as vagas:

- Remoção de vagas incompletas: vagas onde itens críticos estão ausentes, como, por exemplo, descrição do trabalho, responsabilidades ou requisitos;
- Remoção de vagas irrelevantes: vagas que não são relacionados à ciência de dados.

No sentido de avaliar a qualidade do conteúdo das vagas, foram utilizadas técnicas de NLP (*natural language processing* ou processamento de linguagem natural).

a) Análise de conteúdo utilizando técnicas de NLP

O conteúdo de cada vaga constitui-se num *corpus*. De acordo com Manning (1999), utiliza-se NLP (*natural language processing* ou processamento de linguagem natural) uma vez que a maioria das pessoas não consegue estudar o uso da linguagem utilizando um volume de texto muito grande. Em NLP, utiliza-se o contexto textual como um substituto para situar a linguagem em um contexto do mundo real.

Corpus constitui-se de um texto específico, e sua origem etimológica significa “corpo” em latim. A reunião de *corpus*, constituindo uma coleção, é denominado *corpora*.

Considera-se, neste estudo, que o conteúdo de cada uma das vagas é um *corpus* e que o

conjunto das vagas agrupadas constituem os *corpora*.

No sentido de realizar uma avaliação inicial da qualidade do conteúdo das vagas, e de sua adequação em relação ao tema deste estudo, foi realizado um estudo de frequência de palavras utilizando uma técnica de NLP denominada “*bag-of-words*” (“BOW”).

Segundo Matsubara et al. (2003), esta técnica é uma representação simples, mas que apresenta bom desempenho no processo de mineração de textos. O autor alerta, no entanto, que por ser caracterizada por alta dimensionalidade (ou seja, muitas colunas), uma vez que cada palavra é um atributo nesta representação, é necessária a utilização de ferramentas computacionais que realizem de forma automática a transformação dos documentos, de forma a auxiliar na redução da dimensionalidade. Nesse sentido, antes da aplicação da técnica BOW, foram aplicados dois pré-processamentos para retirar do texto elementos que não acrescentam significado e, assim, reduzir sua dimensionalidade.

O primeiro pré-processamento realizado foi a eliminação, nos *corpora*, de “*stop words*”. Segundo Manning (1999), *stop words* são palavras funcionais que podem ser ignoradas por não possuírem um efeito relevante na precisão da recuperação.

Especificamente neste caso, foram utilizados quatro conjuntos de *stop words*, sendo dois fornecidos pela plataforma NLTK³ (português e inglês), e dois customizados (um produzido por alopes e disponibilizada no Github⁴ e outra elaborada pelo autor). O conjunto final de *stop words* totalizou 462 elementos.

O segundo processamento realizado foi a eliminação de dígitos numéricos e pontuações, que foi executado de forma automática utilizando programa especialmente desenvolvido para este fim em linguagem Python, e com base nos seguintes elementos: “1 2 3 4 5 6 7 8 9 0 ’ ! ” \$ % & \ () * + , / : ; < = > ? @ \ ^ _ ` { | } ~ • ” ” ● # . -”.

Os *corpora* originais, ou seja, com todos os textos das vagas agrupados em um único documento, possuíam 532.969 termos. Eliminando aqueles duplicados, o documento possuía 49.703 termos únicos. Após a fase de pré-processamento, o número total de termos, e de termos únicos, passou a ser 331.716 e 17.351, respectivamente.

Para se obter o BOW dos *corpora* pré-processados foi utilizada a plataforma NLTK, que possui embarcada função para cálculo de distribuição de frequências. O resultado dos termos mais comuns encontrados estão apresentados na Tabela 13.

³ A plataforma NLTK é disponibilizada por Bird et al. (2009).

⁴ <https://gist.github.com/alopes/5358189>

Tabela 13 – Vinte termos mais frequentes nos *corpora* de vagas

Palavra	Número de ocorrências
Dados	5894
Data	4339
Experience	1498
Desenvolvimento	1304
Work	1224
Soluções	1138
Business	1088
Sql	1084
Análise	1021
Analytics	1016
Team	981
Modelos	978
Python	967
Learning	945
Negócio	898
Ferramentas	868
Vale	867
Trabalho	862
Tecnologia	853
Projetos	832

Fonte: elaborado pelo autor.

A análise do resultado traz uma indicação que os principais termos encontrados, tais como “dados”, “data”, “sql”, “python” e “learning”, são atinentes ao tema ciência de dados. No sentido de confirmar os resultados foi realizada análise adicional de frequência de termos, porém utilizando bigramas.

“Bigramas” são pares de palavras que ocorrem lado a lado no texto. Manning (1999) cita exemplos de bigramas mais comuns, extraídos a partir de análise de textos do periódico *New York Times*: “of the”, “in the” e “to the”, entre outros. No caso específico deste estudo, preposições foram retiradas do texto através das *stop words* e, portanto, são esperadas expressões que estejam relacionadas com o tema de estudo.

Para obter os bigramas e suas frequências a partir dos *corpora* pré-processados foi utilizada novamente a plataforma NLTK, que possui embarcada função para identificação e cálculo de distribuição de frequências, incluindo bigramas. O resultado dos bigramas mais comuns encontrados estão apresentados na Tabela 14.

Tabela 14 – Bigramas mais frequentes nos *corpora* de vagas

Bigrama	Número de ocorrências
Machine learning	736
Big data	684
Banco dados	438
Data science	352
Análise dados	344
Vale transporte	343
Vale refeição	309
Seguro vida	297
Years experience	296
Fastest growing	266
Software development	265
Flexible schedules	259
Ciência computação	257
Local trabalho	250
Superior completo	249
Services company	249
Innovative environment	246
Multicultural teams	245
Plano saúde	242
Power bi	229

Fonte: elaborado pelo autor.

A presença dos bigramas “*big data*”, “banco dados”, “*data science*” e “análise dados” como mais frequentes é outro indicativo da qualidade dos dados no sentido de que são atinentes ao tema do estudo. No entanto, os bigramas “vale transporte”, “vale refeição”, “seguro vida” e “plano saúde” indicam que parte relevante dos *corpora* possuem informações sobre benefícios da vaga, que não é objeto deste estudo. Adicionalmente, a presença do bigrama “*software development*”, atividade que é comum em vagas de computação de uma forma geral, mas mais rara em vagas para cientistas de dados, indicou que possivelmente havia vagas direcionadas para posições não relacionadas ao tema do estudo.

A realização das duas análises indicou a necessidade de revisão manual dos 1.716 textos.

b) Protocolo de revisão manual de conteúdo de vagas

Para facilitar a revisão de conteúdo das vagas, os textos foram agrupados num arquivo único, utilizando *script* específico baseado em linguagem Python. Cada uma das vagas foi exportada para o arquivo de texto adotando o seguinte padrão:

- Separação das vagas utilizando uma linha de cerquilhas (“#”);

- Informação padronizada de cada vaga: código interno de identificação da vaga, título da vaga, unidade federativa e nível requerido.

Abaixo encontra-se um exemplo de uma vaga que foi gerada para análise. Vale ressaltar que para esta análise foram utilizados os textos originais, uma vez que a revisão sem “*stop-words*” seria inadequada para a leitura.

#####

[4] [Cientista de dados pleno Boa Vista] [SP 4. pleno-sênior]

A Boa Vista é uma empresa brasileira que alia inteligência analítica à alta tecnologia para transformar dados em soluções para os desafios de clientes e consumidores.

Somos precursoras do cadastro positivo, banco de dados com informações sobre o histórico de pagamentos, que deixa a análise de crédito mais justa e acessível: atualmente é referência no apoio à tomada de decisão em todas as fases do ciclo de negócios: prospecção, aquisição, gestão de carteiras e recuperação. Dados estão em toda parte!

O que a Boa Vista faz é usar inteligência analítica para transformá-los em respostas e soluções às necessidades e desejos dos consumidores e empresas.

#VempraBoa!

Desafios do cargo:

Você trabalhará em um projeto com muita inovação, com um viés exploratório e objetivo de buscar respostas para problemas difíceis;

você desenvolverá modelos estatísticos de crédito e análise preditiva;

Pesquisar, discutir e promover o uso de novas tecnologias para habilitar novas análises e negócios;

Elaborar proativamente análises para direcionar decisões estratégicas nos produtos e na empresa;

Fará parte de um projeto inovador e repleto de desafios que utiliza técnicas de machine learning e ferramentas de big data;

Interface com os times de ciência de dados, engenharia, produto e comercial.

Necessário:

Experiência preparando base de dados para modelagem (exemplo de ferramenta: sql);

Conhecimento em programação (exemplo de ferramenta: r e/ou python);

adorar explorar soluções inovadoras para problemas difíceis;

formação em estatística, matemática ou engenharia.

Desejável:

Experiência com o desenvolvimento de modelos;

possuir vivência e conhecimento em produtos de crédito.

A Boa Vista SCPC oferece um programa de benefícios flexíveis e você poderá distribuí-los de acordo com suas necessidades:

Participação nos resultados (ppr);

Pae – programa de assistência ao empregado e familiares, com atendimento de equipe multidisciplinar por telefone composta por assistente social, psicólogos, advogados e nutricionistas 24 horas por dia, 7 dias da semana sem qualquer custo;

Ambulatório com consultas assistenciais para dependentes legais, incluindo campanhas de vacinas sazonais;

Assistência médica (Bradesco);

Assistência odontológica (Bradesco);

Vale-refeição/alimentação;

Transporte fretado com traslado da estação Antônio João à Boa Vista;

Fretado (conforme disponibilidade);

Previdência privada com coparticipação da Boa Vista;

Seguro de vida;

Convênio farmácia;

Convênio SESC.

Outras vantagens:

Home office, na maioria dos dias da semana (durante o período da pandemia 100% remoto);

Jornada de 40 horas semanais em horário flexível;

Day-off no dia do seu aniversário + ingresso para cinema;

Espaços exclusivos para refeições, lazer e descanso com rede, bebidas quentes, frigobar, televisão, vídeo game, mesa de sinuca, ping-pong e outros jogos.

Nosso escritório:

Localizado em Alphaville.

#####

Ainda que as vagas não tenham apresentado um padrão, a revisão manual observou as diretrizes de Hu et al. (2018) e, adicionalmente, foram eliminadas partes das vagas que descreviam a empresa ofertante e os benefícios da vaga. Isto foi feito no sentido de melhorar a qualidade do resultado da fase de mineração de texto realizada posteriormente.

c) Resultado da revisão manual de conteúdo de vagas

O conteúdo das vagas foi revisado manual e individualmente, sem auxílio de qualquer ferramenta computacional. Esse procedimento permitiu identificar características que foram utilizadas posteriormente na etapa de mineração dos textos.

Na revisão manual foi evidenciado que, na ausência de vagas que não possuem as palavras-chave informadas, o algoritmo do sítio LinkedIn oferece vagas supostamente semelhantes, mas que não estão relacionadas com ciência de dados, como por exemplo as a seguir:

- Analista comercial;
- Analista contábil;
- Analista de cadastro sr – temporária;
- Analista de compliance - Niterói - RJ;
- Analista de contratos júnior;
- Analista de controladoria sênior.

O algoritmo de seleção de vagas do LinkedIn não é de conhecimento público, porém uma análise das vagas excluídas permitiu supor porque estas foram apresentadas pelo LinkedIn. Por exemplo, a vaga de “analista comercial” coloca como uma das atividades “utilização de modelos estatísticos” e como uma das ferramentas “Power BI”, conforme destacado no texto integral da vaga, apresentado a seguir:

Vaga de analista comercial em Santa Catarina, a combinar. Período integral. Área e especialização profissionais: comercial, vendas venda externa nível hierárquico: analista local de trabalho: Joinville, SC. Regime de contratação de tipo outros. Jornada período integral elaboração dos orçamentos de vendas utilizando **modelos estatísticos**; fazer análise dos produtos; elaboração de combos promocionais para alavancar vendas; acompanhamento dos resultados e ações por produto; compilação de dados para tomada de decisão; análise do mercado, sugestão de novos produtos e formas para ter mais êxito frente a concorrência, etc. cargo: analista comercial área profissional: administração comercial/vendas.

Carga-horária: Das 8:00 às 18:00. Número de benefícios: assistência médica, vale refeição, bolsa de estudos, seguro de vida, vale transporte.

Requisitos: Escolaridade mínima: Graduação – concluído.

Obrigatórios idiomas: inglês desejável fala: avançado escrita: avançado, compreensão: avançado, leitura: vançado; espanhol desejável fala: avançado, escrita: avançada, compreensão: avançado, leitura. avançado.

Informática: sap intermediário desejável, excel microsoft avançado desejável, **power bi** intermediário desejável.

Experiências e qualificações: conhecimento na comercial/vendas; habilidade com **modelos estatísticos** e construção de relatórios; conhecimento com desenvolvimento de produtos; capacidade de visão analítica e estratégica sob o negócio.

O mesmo ocorre nas outras vagas identificadas. Essa percepção está em linha com aquela apresentada na revisão da literatura - Chuprina et al. (2018) e Lourenco (2019), que tratam dos *citizen data scientists*. Esta relação será melhor explorada na Seção 3.6, quando os resultados dos levantamentos são confrontados com a literatura.

Outras vagas que foram excluídas são aquelas que estão relacionadas à palavra-chave pesquisada, mas não ao tema de ciência de dados. Exemplos são, por exemplo, da palavra-chave “modelagem”, que trouxe vagas sobre:

- Modelagem náutica: “auxiliar o modelador com o desenvolvimento e criação de maquetes interativas”, “necessário experiência no segmento náutico (embarcações)”;
- Modelagem de vestuário: “área e especialização profissional: moda – costura”, “será um diferencial possuir conhecimento na área de modelagem de calçados”, “vaga de estilista”, “experiência com criação de estilo e desenho de peças”.

Vagas diretamente relacionadas ao tema de tecnologia de informação, mas não à ciência de dados, também foram excluídas. Exemplos:

- Programação e desenvolvimento de sistemas: “analista programador”, “programador”, “analista desenvolvedor c#”, “desenvolvedor de backend”, “desenvolvedor .net”, “desenvolvedor java”, “desenvolvedor de front end”, “desenvolvedor full stack”, “desenvolvedor java – microservices”, “desenvolvedor php”, “desenvolvedor react”, “desenvolvedor web” e “desenvolvedor android”;

- Suporte: “analista de suporte”, “suporte conectividade”, “suporte a banco de dados db2 mainframe” e “técnico de suporte - help desk”;
- Privacidade, proteção de dados e segurança de informação: “analista redes e segurança”, “analista sênior de projetos de segurança”, “consultor de segurança da informação”, “especialista de segurança da informação”, “técnico especialista - segurança eletrônica”, “analista de privacidade e proteção de dados” e “analista de privacidade”.

Finalmente, foram excluídas vagas mal elaboradas⁵ cujo conteúdo não especifica a descrição do trabalho, as atividades e responsabilidades e os requisitos, como, por exemplo, a vaga abaixo, cujo título é “*big data engineer*”:

Valorizamos a diversidade e estamos em busca de todos os ingredientes que se complementam e fortalecem nossa cultura e valores. um crescimento de três vezes ao ano, nos mercados competitivos atuais, só é possível se baseado em um modelo sólido de negócios focado em tecnologia, profissionais de excelência e uma empresa sempre pautada em dados. Quanto mais se cresce, mais informações são geradas e uma equipe de *data & analytics* robusta, competente e alinhada com os valores da empresa se faz cada vez mais necessária para transformar todos esse volume de dados em conhecimento e vantagem competitiva para o negócio. As possibilidades de usar nossos dados com inteligência são infinitas e temos a oportunidade de criar cases de nível mundial como Netflix, Spotify e Airbnb. Queremos gente motivada e capaz para fazer esse sonho acontecer. o time de data platform garante a confiabilidade e disponibilidade dos dados, e funcionamento de suas plataformas de aplicação. isso significa que construímos infraestruturas de dados escaláveis com o propósito de disponibilizar milhões de dados gerados diariamente no (NOME EMPRESA), para que possam ser transformados em conhecimento e aplicados na estratégia, na tomada de decisão, nos processos e produtos, para criar vantagem competitiva. Regime de contratação: a combinar. Área de atuação: outros.

Os textos das vagas remanescentes foram novamente importados para uma base de dados única, onde foram realizados os mesmos procedimentos de pré-processamento anteriores, o que resultou em relevante redução no volume de dados para mineração, conforme Tabela 15.

⁵ O nome da empresa foi propositalmente mascarado no texto.

Tabela 15 – Resultado da revisão manual em números

	<i>Corpora</i> originais	<i>Corpora</i> revisados manualmente	Redução	Redução (%)
Número de vagas	1.716	1.458	258	15%
Número de termos	532.969	297.441	235.528	44%
Número de termos únicos	49.703	19.929	29.774	60%
Número de termos após pré-processamento	331.716	173.008	158.708	48%
Número de termos únicos após pré-processamento	17.351	10.875	6.476	37%

Fonte: elaborado pelo autor.

Adicionalmente à redução do volume de dados, a revisão manual das vagas trouxe melhoria na qualidade das informações, como pode ser observado nas frequências de termos e bigramas, respectivamente nas Tabelas 16 e 17:

Tabela 16 – Vinte termos mais frequentes nos *corpora* de vagas manualmente revisadas

Palavra	Número de ocorrências
Dados	5043
Data	3663
Experience	1339
Sql	1021
Python	935
Modelos	901
Business	883
Learning	850
Análise	837
Desenvolvimento	823
Analytics	787
Ferramentas	738
Soluções	702
Machine	677
Estatística	650
Conhecimentos	626
Big	623
Negócio	614
Modelagem	598
Projetos	567

Fonte: elaborado pelo autor.

Tabela 17 – Bigramas mais frequentes nos *corpora* de vagas manualmente revisadas

Bigrama	Número de ocorrências
Machine learning	664
Big data	569
Banco dados	357
Análise dados	311
Data science	303
Years experience	286
Ciência computação	221
Power bi	218
Modelagem dados	199
Superior completo	198
Ciência dados	178
Python r	176
Bancos dados	175
Experience working	173
Data warehouse	168
Data analytics	148
R python	146
Linguagens programação	143
Data lake	143
Visualização dados	140

Fonte: elaborado pelo autor.

Como pode ser observado na análise das Tabelas 16 e 17, todos os dados identificados são atinentes ao tema cientista de dados.

d) Eliminação de vagas similares

Durante o processo de revisão manual foram identificadas organizações (principalmente “Bairesdev” e “Toptal”) que publicam vaga similares em várias unidades federativas procurando profissionais para trabalho remoto. São vagas que, em função de terem títulos e locais diferentes, não foram desconsideradas no processo de eliminação de duplicações na fase de dados estruturados. Por exemplo, os dois casos apresentados na Tabela 18 possuem a mesma descrição, atividades e requisitos.

Tabela 18 - Exemplos de casos de vagas similares oferecidas em vários locais

	Título	Organização	Local
Caso A	<i>Big data architect</i> - remote ref#4299	Bairesdev	São Paulo
	<i>Big data architect</i> - remote ref#4301	Bairesdev	Rio de Janeiro
	<i>Big data architect</i> - remote ref#10468	Bairesdev	Belo Horizonte
	<i>Big data architect</i> - remote ref#10467	Bairesdev	Porto Alegre
	<i>Big data architect</i> - remote ref#4312	Bairesdev	Olinda
	<i>Big data architect</i> - remote ref#4301	Bairesdev	Niterói
	<i>Big data architect</i> - remote ref#4309	Bairesdev	Florianópolis
	<i>Big data architect</i> - remote ref#4312	Bairesdev	Recife
	<i>Big data architect</i> - remote ref#10469	Bairesdev	Fortaleza
	<i>Big data architect</i> - remote ref#4316	Bairesdev	Salvador
Caso B	<i>Data scientist</i> - remote ref#101346	Bairesdev	Campinas
	<i>Data scientist</i> - remote ref#12177	Bairesdev	Belo Horizonte
	<i>Data scientist</i> - remote ref#5574	Bairesdev	Rio de Janeiro
	<i>Data scientist</i> - remote ref#12178	Bairesdev	Fortaleza
	<i>Data scientist</i> - remote ref#12176	Bairesdev	Porto Alegre
	<i>Data scientist</i> - remote ref#5589	Bairesdev	Salvador
	<i>Data scientist</i> - remote ref#5581	Bairesdev	Curitiba
	<i>Data scientist</i> - remote ref#5585	Bairesdev	Recife
	<i>Data scientist</i> - remote ref#5582	Bairesdev	Florianópolis
	<i>Data scientist</i> - remote ref#5585	Bairesdev	Olinda

Fonte: elaborado pelo autor.

Utilizando um *script* escrito em linguagem *Python* especificamente para remover casos como os apresentados na Tabela 18, 150 duplicações foram removidas, de forma que o banco de dados com as vagas, então com 1.308 documentos remanescentes, constituiu a base para análise dos dados não estruturados.

e) Transformações preliminares

Previamente à análise dos dados não estruturados houve a necessidade de realizar algumas transformações nos *corpora* de forma evitar erros no processo posterior de mineração dos textos das vagas.

Essas transformações incluíram busca e substituição no texto de elementos como, por

exemplo, a linguagem “R”. Extraindo do texto o termo “R”, qualquer elemento contendo a letra “R” (“trabalhaR”, “maRketing”, “lideRaR”) poderia fornecer dados errados sobre esta linguagem ser um requisito para uma vaga.

Casos semelhantes são o termo “BI” (“*Business Intelligence*”), “GO” (linguagem “GO” desenvolvida pelo Google), “SQL” (às vezes grafado como “S.Q.L.”) e “SAP” (*software* integrado “SAP”), entre outros.

Os termos foram substituídos, no texto, por seu equivalente utilizando colchetes (“[]”).

f) Extração de características (*feature extraction*)

Características, ou *features*, são termos específicos relacionados ao tema de estudo. Quando relacionados a cada uma das vagas, permitem estudá-las no sentido de definir quais características são mais prevalentes ou mais específicas, bem como agrupar vagas de acordo com determinadas características.

No caso deste estudo as características são aquelas relacionadas a áreas de formação, a habilidades e a ferramentas de cientistas de dados. Definir o conjunto de características é um passo metodológico fundamental.

Na abordagem de Hu et al. (2018), que é uma das referências metodológicas deste estudo, os autores utilizaram para construir o conjunto de características (a) *domain knowledge*, ou seja, conhecimento dos próprios autores sobre o assunto, determinando palavras-chave de forma manual, e (b) abordagem de NLP denominada TF- IDF (“*term frequency-inverse document frequency*”).

É importante notar que este estudo traz duas complexidades em relação ao artigo de Hu et al. (2018).

Primeiro, as vagas coletadas por Hu et al. (2018) são todas na língua inglesa, enquanto nas 1.308 vagas objeto deste estudo existem vagas tanto em língua portuguesa quanto em língua inglesa. Conquanto determinados termos sirvam a ambas as línguas, como por exemplo “Python”, “[R]” e “SQL”, outras precisam ser traduzidas. “*Machine learning*” é um termo comum, porém o termo “aprendizado de máquina” também precisa ser considerado, assim como, entre outros binômios, “*cloud*” e “nuvem”, “*agile*” e “ágil”, “*statistics*” e “estatística”.

Segundo, para a definição do conjunto de habilidades, Hu et al. (2018) utilizaram base de habilidades disponibilizada pela plataforma LinkedIn. Ocorre que, desde 2007, a plataforma LinkedIn não publica mais esta informação. Também não é possível utilizar técnicas de *web scrap*, porque segundo o Contrato de Uso do LinkedIn (2020), é proibido “utilizar *software*,

dispositivos, *scripts*, robôs ou quaisquer outros meios ou processos para fazer varredura nos Serviços ou copiar de outra forma perfis e outros dados dos Serviços”. A plataforma realiza monitoramento permanente e consistente, e bloqueia o acesso de usuários que utilizam estas técnicas para, de forma automática, coletar informações da plataforma.

A plataforma LinkedIn possui convênio de fornecimento de informações com o Banco Mundial⁶ e, entre outros serviços, é possível baixar conjuntos de habilidades⁷. A análise deste material, no entanto, restou infrutífera porque os dados disponíveis não apresentaram a granularidade necessária. Nas mais variadas indústrias, *data science* é apresentado como uma habilidade única, e não como um conjunto de habilidades.

Considerando os obstáculos apresentados, o conjunto de habilidades utilizado neste estudo foi elaborado utilizando a revisão da literatura, termos coletados a partir da revisão manual, resultados do método TF-IDF, explicado a seguir, e conhecimento do autor sobre o tema.

g) Introdução ao método TF-IDF

A abordagem de Hu et al. (2018) utiliza o método TF-IDF como um dos componentes para extração de características (“*feature extraction*”) do conteúdo de vagas.

O método TF-IDF (“*term frequency-inverse document frequency*”) é um dos campos de estudo de NLP (Manning, 1999), e é utilizado para determinar a importância que uma palavra tem em um documento, que por sua vez está contido num conjunto de documentos (já definido anteriormente como “*corpora*”). Palavras que são mais comuns em um único documento, ou em um pequeno grupo de documentos, tendem a ter valores mais altos de TF-IDF. Dado um corpus D , o valor TF-IDF da palavra t no documento d , a função $tf-idf(t; d; D)$ pode ser calculada da seguinte forma:

$$tf-idf(t; d; D) = tf(t, d) \times idf(t, D)$$

Conforme a equação acima, $tf-idf(t; d; D)$ é um produto de duas métricas, sendo a primeira a frequência com que a palavra aparece no documento [$tf(t; d)$] e segunda a frequência inversa da palavra no corpus [$idf(t; D)$]. O termo frequência $tf(t; d)$ mede o número vezes que a palavra t ocorre no documento d . O inverso da frequência do documento $idf(t; D)$ é uma

⁶ Recuperado de <https://linkedindata.worldbank.org/> Acesso em: 09/06/2021.

⁷ Recuperado de <https://datacatalog.worldbank.org/dataset/skills-linked-in-data> Acesso em: 09/06/2021.

medida de se a palavra é comum ou rara em todos os documentos. Por exemplo, artigos definidos “o” e “e” são palavras comuns e, em si, não carregam significado. Desta forma, uma palavra que tenha um alto valor de TF-IDF ocorrerá quando houver uma frequência alta em um determinado documento e uma baixa frequência nos documentos nos *corpora*.

Utilizando o método TF-IDF, é possível definir as características que compõe cada vaga em duas etapas:

- Identificação de palavras-chave: aplicando nos *corpora* o método TF-IDF é possível determinar palavras-chave.
- Cálculo do valor do TF-IDF: para cada palavra no conjunto de palavras-chave, é possível calcular o valor correspondente TF-IDF em cada documento.

Dessa forma, cada documento (ou, no caso deste estudo, cada vaga coletada, tratada e selecionada), pode ser simplesmente representado pelos valores TF-IDF das palavras-chave associadas a este documento.

Para identificar palavras-chave e calcular o valor de TF-IDF foi utilizada a biblioteca Scikit-learn⁸ e a linguagem Python. Scikit-learn, apresentada em artigo por Pedregosa et al. (2011), é uma biblioteca de código aberto para aprendizado de máquina supervisionado e não supervisionado, porém também oferece diversas ferramentas para pré-processamento de dados e seleção e avaliação de modelos.

A classe *TfidfVectorizer* da biblioteca Scikit-learn foi aplicada nos 1.308 documentos, considerando como parâmetros elementos únicos (termos) e bigramas. O resultado deste processamento produziu 80.391 resultados, sendo que os 20 elementos com maiores TF-IDF estão apresentados na Tabela 19:

⁸ <https://scikit-learn.org>

Tabela 19 – Vinte elementos com maior índice TF-IDF

Elemento (termo ou bigrama)	TF-IDF
dados	0,636762107
data	0,391022031
sql	0,123133708
experience	0,118914994
modelos	0,112850593
python	0,112191419
desenvolvimento	0,104017661
análise	0,103622157
learning	0,097821425
analytics	0,094130051
ferramentas	0,093075372
soluções	0,087010971
estatística	0,080682901
conhecimentos	0,078837213
machine	0,078573544
machine learning	0,076859691
negócio	0,076859691
business	0,075673178
modelagem	0,074618499
projetos	0,071849969

Fonte: elaborado pelo autor.

Como pode ser observado, o conjunto dos elementos identificados (termos ou bigramas) é bastante similar ao conjunto produzido pelo método BOW (Tabelas 16 e 17) apresentado anteriormente, e mais uma vez confirma a qualidade dos dados analisados, uma vez que os termos são atinentes à ciência de dados.

h) Elaboração de conjunto de características

O artigo de Hu et al. (2018) construiu um conjunto de características único para todas as análises realizadas. No caso deste estudo, optou-se por elaborar dois conjuntos de características, um especificamente para as análises referentes à formação de cientistas de dados, e outro especificamente para as análises referentes à suas habilidades e as ferramentas que utilizam.

O processo de construção de ambos os conjuntos, no entanto, foi o mesmo e, considerando os obstáculos apresentados anteriormente, os conjuntos de características foram elaborados da seguinte forma:

- Revisão da literatura

A base para elaboração do conjunto de características para formação de cientistas de dados foi realizada a partir da Tabela 5, presente na Seção 2.4.2 da revisão sistemática de literatura. A base para elaboração do conjunto de características foram as Tabelas 6.1 a 6.8 presentes na Seção 2.4.3 da revisão sistemática de literatura.

- Revisão manual do texto das vagas

A revisão manual das vagas permitiu identificar, principalmente nas vagas com descrições mais detalhadas, diversos elementos que deveriam ser incluídos nos conjuntos de características, tanto em formação quanto em habilidades e ferramentas, e que não estavam presentes na revisão de literatura.

- Resultados produzidos pelo método TF-IDF

Os objetivos do cruzamento dos conjuntos previamente elaborados com o resultado do método TF-IDF são identificar termos presentes neste conjunto, e avaliar se deveriam constar nos conjuntos, bem como identificar, no resultado do método TF-IDF, elementos que deveriam fazer parte de tais conjuntos.

Considerando todos os termos e seus bigramas, bem como aqueles onde devem estar presentes tanto o termo em língua portuguesa e inglesa, os conjuntos de características elaborados a partir dos itens a) e b) acima compreenderam 138 elementos para extração de características de formação e 526 elementos para extração de características de habilidades e ferramentas. Para efeito de comparação, o artigo de Hu et al. (2018), na sua totalidade, utilizou 133 elementos.

Cruzamento com características de áreas de formação

É importante notar que os elementos utilizados para formação envolvem não apenas as áreas de formação em si, como computação ou engenharia, mas, também, elementos que permitiram identificar em cada vaga se a formação estava presente e qual o nível requerido.

Dos 138 elementos presentes no conjunto de características de áreas de formação, 91 foram encontrados entre os 80.391 resultados calculados pelo método TF-IDF. Os 47 termos não encontrados foram analisados individualmente. Por exemplo, “*high school*” foi inserido

manualmente no conjunto características como uma alternativa a “ensino médio” para vagas com conteúdo em língua inglesa. O segundo foi encontrado, o primeiro não. Outro exemplo, o termo “biologia”, presente na revisão de literatura, não foi encontrado no conteúdo das vagas. Ainda, “formação superior completa”, ainda que exista em conteúdo de diversas vagas, não foi encontrado nos resultados do TF-IDF por ser um trígama. Todos os termos não encontrados foram validados.

O cruzamento inverso, ou seja, a busca dos 80.391 elementos do resultado do TF-IDF no conjunto de características de formação previamente elaborado, revelou 73 termos encontrados. Neste caso, foram revisados manualmente os primeiros 20 mil resultados do TF-IDF no sentido de identificar eventuais outros elementos que deveriam fazer parte do conjunto de características de formação. Foram identificados os elementos “jornalismo” e “estatísticos” (no sentido de que existem vagas que mencionam “procuramos estatísticos”, e essa forma de linguagem deve ser considerada como um indicativo de formação), e “formação superior” (um dos indicativos de requisito de formação) que não haviam sido considerados anteriormente. Outro termo não encontrado foi “arquitetura”, porém analisando o conteúdo das vagas este termo está associado a características técnicas de ambiente de computação, e não a uma área de formação. Neste sentido, o termo “arquitetura” não foi considerado no conjunto de características de áreas de formação. Este procedimento trouxe segurança que todos os termos relevantes foram considerados nas análises.

Cruzamento com características de habilidades e ferramentas

Dos 521 elementos presentes no conjunto de características de habilidades e ferramentas, 354 foram encontrados entre os 80.391 resultados calculados pelo método TF-IDF calculados. Os 167 termos não encontrados foram analisados individualmente. Por exemplo, “computação em tempo real” e “armazenamento de dados” não foram encontrados porque não são elementos únicos ou bigramas, e o mesmo acontece com “dados não estruturados” e “mineração de dados”. Alguns poucos termos citados na literatura, como por exemplo “*strategic vision*”, “aprendizado contínuo” e “habilidades analíticas”, não foram encontrados no conteúdo das vagas. Esta análise também identificou elementos que não foram encontrados porque sua grafia, no conjunto original de características, estava incorreta (por exemplo “conhecimento multidiciplinar” (SIC), ao invés de “conhecimento multidisciplinar”, e “*ehtics*” ao invés de “*ethics*”).

O cruzamento inverso procurou identificar, nos 20 mil maiores resultados de TF-IDF encontrados, eventuais termos relevantes, exceto os 354 termos encontrados dos 521

pesquisados. Da mesma forma que em relação aos termos referentes às áreas de formação, esta revisão consumiu tempo considerável, mas foi profícua no sentido de identificar diversos elementos como “*elasticsearch*”, “*airflow*”, “*oracle cloud*”, “*alteryx*” e “*talend*” que não estavam presentes na literatura, bem como não foram identificadas na revisão manual do conteúdo das vagas. Este procedimento, de forma análoga à revisão nos resultados do TF-IDF das áreas de formação, trouxe segurança de que todos os termos relevantes foram considerados nas análises.

- Revisão com base no conhecimento do autor

Assim como em Hu et al. (2018), o conhecimento do autor (*domain knowledge*) também foi considerado nesta pesquisa, porém, após as três etapas (a, b e c) citadas anteriormente, eventuais palavras que poderiam ser propostas pelo autor já se encontravam nos conjuntos de características.

i) Resultado da elaboração de conjunto de características

Após modificações realizadas com base nos passos anteriores, o conjunto de características de áreas de formação totalizou 138 elementos e o conjunto de características de habilidades e ferramentas totalizou 526 elementos. Os conjuntos e seus elementos finais utilizados estão apresentados nos Apêndices B e C.

3.5.1.3 Fase 3: Consolidação de dados

3.5.1.3.1 Áreas de formação

Carillo (2017) conclui em seu estudo que a educação, num contexto mais amplo, pode “perder o trem de transformação de dados” (“*miss the data-transformation train*”) e, portanto, falhar em lidar com os desafios educacionais contemporâneos que dizem respeito à “datificação” (“*datification*”) da sociedade e da humanidade em geral. Inspirada em sua conclusão, a primeira análise realizada no conteúdo das vagas foi feita em relação aos requisitos de experiência *versus* aqueles relacionados à formação de cientistas de dados.

Com base no tratamento realizado na fase anterior, foi possível identificar, através de palavras-chave, requisitos de formação e de experiência, para as vagas que mencionam termos

relacionados com o primeiro (por exemplo: “superior completo”, “ensino superior”, “bacharelado” e “graduação”) e com o segundo (por exemplo: “experiência”, “vivência”, “proficiência” e “*background*”). As palavras-chave utilizadas estão descritas no Apêndice B.

A consolidação da existência dos termos no conteúdo das vagas está representada na Tabela 20:

Tabela 20 – Cruzamento das vagas que mencionam experiência com as que mencionam nível de formação

		Existência de palavras-chave relacionadas à experiência		Total
		Ausente	Presente	
Existência de palavras-chave relacionadas à formação	Ausente	216 (17%)	87 (7%)	303 (23%)
	Presente	610 (47%)	395 (30%)	1.005 (77%)
Total		826 (63%)	482 (37%)	1.308 (100%)

Fonte: elaborado pelo autor.

A análise da Tabela 20 revela que a presença do requisito de formação nas vagas analisadas é um fator importante na perspectiva de mercado. Isto é confirmado na análise a seguir, referente ao nível requerido das vagas. Para esta análise foram utilizadas palavras-chave como “ensino médio”, “pós-graduação”, “mba”, “mestrado” e “doutorado”, entre outras. A consolidação está apresentada na Tabela 21.

Tabela 21 – Totalização das vagas coletadas e frequência de palavras-chave

Nível de formação requerido	Frequência de palavras-chave
Não mencionado	415
1. ensino médio	2
2. ensino superior	556
3. pós	606
4. mestrado	59
6. doutorado	41
Total	1.679

Fonte: elaborado pelo autor.

É importante notar que o total apresentado na Tabela 21 não corresponde ao total de vagas analisadas (1.308 vagas) porque existem vagas que citam mais de um nível, como por exemplo “mestrado” e “doutorado”.

A presença de “ensino médio” merece atenção. Existem apenas duas vagas que mencionam ensino médio como um nível requerido, cujos extratos de conteúdo estão

apresentados abaixo:

cursando ensino médio, técnico em logística, técnico em administração e áreas afins. conhecimento em pacote office (excel) atividades o (colaborador) auxiliará na conferência de estoque diário, baixa de materiais no sistema, liberação de materiais para funcionários, alimentação de planilhas de controle e demais tarefas do setor. #engenheiro de dados

atuar na área de automação de processos de um renomado banco em são paulo. formação acadêmica ensino médio completo. experiência em elaboração de rotinas para detecção de anomalias (outliers) e avaliação de padrões utilizando bibliotecas python (como scikit-learn, pandas, pyod ou similares) de aprendizado não supervisionado. salário a combinar cargo analista de sistemas empresa cast informática desenvolvimento de software. ramo informática/ tecnologia

É interessante notar que, no segundo caso, apesar de a vaga comentar sobre diversas habilidades típicas de cientistas de dados – a mais notória dessas habilidades sendo a biblioteca Scikit-learn, cujo foco é *machine learning* –, o recrutador opta pela experiência em relação ao nível de formação. Demchenko et al. (2016) comentam em seu estudo que uma das formas de aprendizado é a educação baseada em competências (“CBE, *Competences Based Training*”), uma forma de educação diferente da abordagem tradicional, onde o que é medido é o aprendizado efetivo ao invés do tempo de estudo em si (“*Carnegie unit credit hour*”).

Conquanto exista no mercado uma visão de que a ciência de dados é uma atividade essencialmente prática, a consolidação do nível de vagas demonstra o contrário: o mercado demanda profissionais com nível de formação superior e, também, especialização, fazendo dos exemplos apresentados acima exceções. Mesmo dentre as 415 vagas em que o nível de formação não é explicitamente mencionado, em 380 são citados requerimentos como engenharia, matemática e estatística que, essencialmente, exigem formação superior.

Em relação às áreas de formação em si, 40 das 1308 vagas não mencionam nenhum tipo de formação. Das restantes, e considerando apenas aquelas que mencionam pelo menos formação superior, totalizando 891 vagas, a consolidação das áreas de formação, em relação ao nível requerido, está demonstrada na Tabela 22.

Tabela 22 – Totalização das vagas coletadas por nível requerido

	2. ensino superior	3. pós-graduação	4. mestrado	6. doutorado	Total
computação	552	603	59	41	885
engenharia	320	243	41	24	414
estatística	301	270	40	27	414
matemática	219	174	34	22	275
comunicação	76	97	11	11	124
<i>marketing</i>	74	76	2	1	106
economia	80	61	13	5	100
administração	66	34	-	-	76
física	51	50	14	7	68
exatas	38	33	10	5	45
publicidade	3	1	-	-	4
propaganda	3	2	-	-	4
química	3	1	-	-	3
jornalismo	2	1	-	-	2
contabilidade	2	-	-	-	2
biologia	1	-	-	-	1
ciências sociais	-	1	-	-	1
Total	1.791	1.647	224	143	2.524

Fonte: elaborado pelo autor.

Como pode ser observado, prevalecem as vagas com formação quantitativa em computação, engenharia, estatística e matemática. As vagas em comunicação e *marketing* têm um volume relevante em função de diversas vagas terem seu foco em análises voltadas para *marketing* digital. Na Seção 3.6.1 é apresentada uma análise específica das áreas de formação encontradas em relação àquelas levantadas segundo a literatura.

3.5.1.3.2 Habilidades e ferramentas

As habilidades e ferramentas de cientistas de dados foram analisadas com base na mesma segregação utilizada na revisão de literatura para a composição das Tabelas 6.1 a 6.8:

- a) “*Hard skills* – Conhecimentos gerais em computação e desenvolvimento de sistemas” (Tabela 6.1);
- b) “*Hard skills* – Conhecimentos gerais em negócios” (Tabela 6.2);
- c) “*Hard skills* – Inteligência artificial” (Tabela 6.3);
- d) “*Soft skills*” (Tabela 6.4).

- e) “Ferramentas”, segregadas em “Ecossistemas, *frameworks* e bancos de dados” (Tabela 6.5);
- f) “Linguagens de programação ou *scripts*” (Tabela 6.6);
- g) “Visualização de dados” (Tabela 6.7);
- h) “Outros: plataformas específicas, ambientes em nuvem e ambientes integrados” (Tabela 6.8).

As 20 principais habilidades e ferramentas identificadas estão consolidadas na Tabela 23.

Tabela 23 – Vinte principais habilidades e ferramentas identificadas no conteúdo das vagas analisadas (continua)

	<i>Hard skills –</i> Conhecimentos gerais em computação e desenvolvimento de sistemas	<i>Hard skills –</i> Conhecimentos gerais em negócios	<i>Hard skills –</i> Inteligência artificial	<i>Soft skills</i>	Ecosistemas, frameworks e bancos de dados	Linguagens de programação ou scripts	Visualização de dados	Outros: plataformas específicas, ambientes em nuvem e ambientes integrados
1	Programação (454)	Conhecimento do negócio (<i>domain knowledge</i>) (1149)	Modelagem (773)	Paixão (162)	SQL (797)	Python (744)	Power BI (295)	IDE (Geral) (635)
2	<i>Big data</i> (375)	Idioma Inglês (493)	<i>Machine learning</i> (498)	Pensamento analítico (99)	Hadoop (236)	Spark (373)	Tableau (214)	Google Analytics (71)
3	<i>Cloud</i> (367)	Metodologias ágeis (490)	Otimização (168)	Proatividade (56)	NoSQL (136)	[R] (330)	QlikView/ QlikSense (105)	NLTK (10)
4	Amazon AWS (333)	Gestão (315)	Scikit-learn (136)	Raciocínio lógico (46)	MongoDB (67)	Scala (313)	Google Data Studio (40)	IBM Watson (8)
5	Banco de dados (288)	Comunicação (286)	Construção de <i>datasets</i> (114)	Multicultural (45)	Cassandra (48)	Java (203)	Looker (34)	Jupyter Notebook (4)

Tabela 23 – Vinte principais habilidades e ferramentas identificadas no conteúdo das vagas analisadas (continuação)

	<i>Hard skills –</i> Conhecimentos gerais em computação e desenvolvimento de sistemas	<i>Hard skills –</i> Conhecimentos gerais em negócios	<i>Hard skills –</i> Inteligência artificial	<i>Soft skills</i>	Ecosistemas, <i>frameworks</i> e bancos de dados	Linguagens de programação ou <i>scripts</i>	Visualização de dados	Outros: plataformas específicas, ambientes em nuvem e ambientes integrados
6	ETL (263)	Trabalho em time (258)	Pandas (91)	Relacionamento interpessoal (37)	Lambda (39)	JavaScript (58)	Metabase (30)	Visual Studio (4)
7	GIT (243)	Gestão de conhecimento (248)	<i>Deep Learning</i> (80)	Curiosidade (31)	Snowflake (23)	Matlab (40)	Microstrategy (25)	Mahout (3)
8	Implementação (241)	Visualização de dados (178)	Inteligência artificial (71)	Criatividade (26)	Cloudera (21)	C, C++, C# (36)	Pentaho (19)	Swagger (3)
9	Análise de dados (237)	Metodologia (no sentido mais geral; conhecimento de métodos) (151)	NLP (68)	Raciocínio rápido (11)	Hortonworks (16)	VBA (29)	Preparação de dados (5)	Weka (2)

Tabela 23 – Vinte principais habilidades e ferramentas identificadas no conteúdo das vagas analisadas (continuação)

	<i>Hard skills –</i> Conhecimentos gerais em computação e desenvolvimento de sistemas	<i>Hard skills –</i> Conhecimentos gerais em negócios	<i>Hard skills –</i> Inteligência artificial	<i>Soft skills</i>	Ecossistemas, frameworks e bancos de dados	Linguagens de programação ou scripts	Visualização de dados	Outros: plataformas específicas, ambientes em nuvem e ambientes integrados
10	Integração de dados (204)	Administração e finanças (126)	TensorFlow (67)	Pensamento crítico (8)	Redis (14)	Julia (19)	Superset (3)	[R] Studio (2)
11	<i>Pipeline</i> (201)	Metodologias (125)	Numpy (63)	Empreendedorismo (4)	Map Reduce (13)	Pig (10)	Orange (2)	
12	Azure (172)	SAS (82)	<i>clustering</i> (52)	Comunicação interpessoal (2)	Adobe Analytics (11)	Ruby (8)	Redash (2)	
13	Hive (155)	<i>frameworks</i> (79)	Regressão (51)		.NET (8)	PHP (5)		
14	<i>Data warehouse</i> (140)	DevOps (75)	Keras (48)			Perl (3)		
15	<i>Business intelligence</i> (136)	Liderança (70)	Classificação (44)			Gradle (3)		

Tabela 23 – Vinte principais habilidades e ferramentas identificadas no conteúdo das vagas analisadas (conclusão)

	<i>Hard skills –</i> Conhecimentos gerais em computação e desenvolvimento de sistemas	<i>Hard skills –</i> Conhecimentos gerais em negócios	<i>Hard skills –</i> Inteligência artificial	<i>Soft skills</i>	<i>Ecosystems,</i> <i>frameworks e</i> <i>bancos de</i> <i>dados</i>	Linguagens de programação ou scripts	Visualização de dados	Outros: plataformas específicas, ambientes em nuvem e ambientes integrados
16	Oracle (121)	Resolução de problemas (69)	Redes neurais (37)			Stata (3)		
17	Mineração de dados (116)	Idioma Espanhol (44)	PyTorch (32)			Clojure (1)		
18	Infraestrutura TI (112)	Gestão de projetos (39)	<i>Forecast</i> (31)			Riak (1)		
19	Postgres (106)	Kanban (29)	Random Forest (28)					
20	MySQL (81)	<i>Leadership</i> (28)	Análise preditiva (27)					

Fonte: elaborado pelo autor.

3.5.2 Perspectiva de pessoas com base em dados secundários da Pesquisa Data Hackers


3.5.2.1 Fase 1: Coleta de dados

De acordo com a revisão da literatura, o termo cientista de dados é amplamente utilizado em diversos estudos sem uma definição formal, implicitamente identificando cientistas de dados simplesmente como “aqueles ou aquelas que praticam ciência de dados” (Demchenko et al., 2017; Dichev & Dicheva, 2017; Kaleda & Fenstermacher, 2018; Pedersen & Caviglia, 2019; Yan & Davis, 2019; Belloum et al., 2019; Verma et al., 2019; Harris, 2013; Mattmann, 2013; Wiktorski et al., 2016; Baumer, 2017; Meyer, 2018; Knorr et al., 2018; Pires & Leitão, 2018; Kross & Guo, 2019; Demchenko et al., 2019). Neste contexto, a forma primária de identificar cientistas de dados é através de profissionais que se autointitulam como tais.

Segundo Cao (2017), muitos grupos de interesse profissional foram criados nas mídias sociais, incluindo Grupos do Google, LinkedIn e Facebook. Grupos são a forma mais popular para profissionais de *big data*, ciência de dados e *analytics* compartilharem conhecimento e fazerem *networking*, ou seja, criarem conexões profissionais.

O grupo Data Hackers Brasil intitula-se “a maior comunidade de ciência de dados do Brasil”. Em maio de 2020, sua principal plataforma de interação, a ferramenta de colaboração Slack, tinha aproximadamente 35 mil membros e 235 mil mensagens. O grupo distribui informativos semanais através de e-mails (com um total de 129 informativos, com cerca de 14 mil inscritos), publica áudio na forma de *podcasts* (com um total de 24 episódios e cerca de 14,5 mil *downloads*) e dissemina conhecimento através de *posts* técnicos na plataforma Medium (com um total de 200 *posts* e cerca de 26 mil “curtidas”), conforme a Figura 11 abaixo:

Figura 11 – Estatísticas do grupo Data Hackers BR



Fonte: <https://datahackers.com.br> Acesso em 29/05/2020.

Em novembro de 2019 o grupo Data Hackers realizou a “Pesquisa de Mercado de Data Science” e publicou os dados não agregados da pesquisa, anonimizados, no sítio kaggle.com (DataHackers, 2020). Foram coletadas 1.765 observações. As perguntas originais constam do Apêndice D e, em suma, possuíam as seguintes principais informações:

- a) Idade, gênero;
- b) Local de moradia e de nascimento;
- c) O profissional vive no Brasil?
- d) Nível de ensino;
- e) Área de formação;
- f) Situação atual de trabalho;
- g) Setor de atuação;
- h) Porte da empresa atual;
- i) Cargo atual e ocupação como gestor;
- j) Faixa salarial;
- k) Tempo de experiência na área de dados;
- l) Tempo de experiência na área de TI/Engenharia;
- m) O profissional considera-se um profissional que atua na área de ciência de dados?
- n) Identificação de métodos, linguagens, fontes de dados, nuvens, bancos de dados, plataformas, ferramentas de BI e ferramentas de ETL;
- o) Formas de atualização no mundo dos dados;
- p) Plataformas preferidas para cursos na área de ciências de dados.

3.5.2.2 Fase 2: Tratamento de dados

O tratamento dos dados sob as perspectivas das pessoas, i.e., dos autointitulados cientistas de dados, foi mais simples do que em relação à perspectiva do mercado. As principais etapas de tratamento a partir dos dados da pesquisa foram as seguintes:

3.5.2.2.1 Segregação dos casos de pessoas que informaram viverem no Brasil

Este tratamento foi realizado com base na pergunta P3 (“Atualmente você vive no Brasil?”). Dos 1.765 casos foram considerados 1.731 que responderam afirmativamente à pergunta.

3.5.2.2.2 Análise dos cargos anonimizados dos respondentes

A variável derivada D6 (“Cargo anonimizado”) foi consolidada pelos pesquisadores do Data HackersBR com base na pergunta P15 (“Qual das opções abaixo definem melhor seu cargo de trabalho atual?”) e apresentou o seguinte resultado:

Tabela 24 – Cargos presentes na pesquisa Data Hackers BR

Cargo	Frequência
Desenvolvedor ou Engenheiro de <i>Software</i>	225
Outras	220
<i>Data Scientist</i> /Cientista de Dados	167
<i>Data Analyst</i> /Analista de Dados	163
<i>Business Intelligence</i> /Analista de BI	150
<i>Data Engineer</i> /Engenheiro de Dados	130
<i>Business Analyst</i> /Analista de negócios	72
Analista de inteligência de mercado	29
Engenheiro	26
Analista de <i>marketing</i>	19
Engenheiro de <i>machine learning</i>	15
DBA/Administrador de Banco de Dados	14
Estatístico	11
Economista	10

Fonte: elaborado pelo autor.

Conforme mencionado na Seção 3.5.1.1, o termo cientista de dados é amplamente utilizado em diversos estudos sem uma definição formal, implicitamente identificando cientistas de dados simplesmente como “aqueles ou aquelas que praticam ciência de dados” e, neste contexto, a forma primária de identificar um cientista de dados é através de profissionais que se autointitulam como tal.

Por tratar-se de uma pesquisa especificamente sobre ciência de dados, foi assumido que todos os respondentes se autointitulam cientistas de dados, independente do cargo que ocupam e, portanto, neste quesito, todas as 1.731 respostas foram consideradas.

3.5.2.2.3 Definição da base de dados para análise

Como o resultado da pesquisa já apresentou os dados tratados, para efeito de consolidação dos resultados, a única segregação foi a apresentada anteriormente, ou seja, eliminação dos respondentes que não vivem no Brasil.

É importante notar que este projeto de pesquisa não teve nenhum envolvimento com o planejamento, coleta e análise dos dados da Pesquisa de Mercado de Data Science do Data Hackers BR, e, portanto, não há informação suficiente que assegure rigor estatístico para fazer inferências.

3.5.2.3 Consolidação dos dados

3.5.2.3.1 Áreas de formação

Os dados referentes às áreas de formação, bem como ao nível de formação, foram consolidados a partir da variável derivada D3 (“Área de formação anonimizada”) e da pergunta 8 (“Qual seu nível de ensino?”). A consolidação cruzada de ambas as informações é apresentada na Tabela 25:

Tabela 25 – Referência cruzada de áreas e nível de formação

Área de formação	1. Doutorado ou Phd	2. Mestrado	3. Pós-graduação	4. Graduação/ Bacharelado	5. Estudante de Graduação	7. Prefiro não informar	Não informado	Total	Total (%)
Computação/Engenharia de <i>Software</i> /Sistemas de Informação	18	103	304	336	235			996	58%
Outras Engenharias	4	31	58	92	55			240	14%
Economia/Administração/Contabilidade/Finanças	3	16	67	55	31			172	10%
Estatística/Matemática / Matemática Computacional	7	18	22	28	26			101	6%
Outras	4	6	32	35	13			90	5%
Marketing/Publicidade/ Comunicação/Jornalismo		3	22	15	6			46	3%
Química/Física	7	9	5	4	2			27	2%
Ciências Sociais	2	4	10	7	2			25	1%
Não informado						1	33	34	2%
Total	45	190	520	572	370	1	33	1731	100%
Total (%)	3%	11%	30%	33%	21%	0%	2%	100%	

Fonte: elaborado pelo autor.

3.5.2.3.2 Habilidades e ferramentas

A Pesquisa de Mercado de Data Science do Data Hackers BR considerou perguntas específicas sobre habilidades e ferramentas referentes a métodos, linguagens, fontes de dados, nuvens, bancos de dados, plataformas, ferramentas de BI e ferramentas de ETL, conforme abaixo:

- a) Pergunta_20: Quais dos métodos listados abaixo você costuma utilizar no trabalho?
- b) Pergunta_21: Quais das linguagens de programação listadas abaixo você utiliza no trabalho?
- c) Pergunta_23: Quais das fontes de dados listadas você já analisou no trabalho?
- d) Pergunta_25: Quais das opções de *cloud* listadas abaixo você utiliza no trabalho?
- e) Pergunta_26: Quais dos bancos de dados/fontes de dados listados abaixo você utiliza para consultar informações, e posteriormente analisar, no trabalho?

f) Pergunta_27: Quais as ferramentas de *business intelligence* você utiliza no trabalho?

g) Pergunta_28: Quais as tecnologias são utilizadas como ferramenta de ETL no seu trabalho?

A consolidação dos resultados das perguntas acima está apresentada nas Tabelas 26 a 30:

Tabela 26 – Consolidação de habilidades e ferramentas –
Pesquisa Data Hackers BR - P20 - Métodos

	Total	Total %
linear_regression	508	12%
decision_tree	430	10%
logistic_regression	393	10%
cluster_analysis	355	9%
random_forest	346	8%
neural_networks	257	6%
nlp	247	6%
bayesian_inference	217	5%
svms	171	4%
gradient_boosted_machines	171	4%
ensemble	161	4%
glms	129	3%
cnns	98	2%
longitudinal_data_analysis	97	2%
rnns	95	2%
jointanalysis	77	2%
markov_chains	76	2%
survival_analysis	70	2%
gans	24	1%
hmms	17	0%
Outros métodos	187	5%
Total	4.126	100%

Fonte: elaborado pelo autor.

Tabela 27 – Consolidação de habilidades e ferramentas –
Pesquisa Data Hackers BR - P21 - Linguagens

	Total	Total %
python	761	34%
sql_	696	31%
r	305	14%
java	85	4%
visual_basic_vba	82	4%
c_c++_c#	61	3%
sas_stata	59	3%
scala	58	3%
Php	46	2%
dotnet	35	2%
matlab	27	1%
julia	13	1%
Outras linguagens	8	0%
Total	2.236	100%

Fonte: elaborado pelo autor.

Tabela 28 – Consolidação de habilidades e ferramentas –
Pesquisa Data Hackers BR - P23 - Fontes de dados

	Total	Total %
sql	811	33%
sheets	742	30%
nosql	367	15%
nlp	321	13%
images	155	6%
videos	34	1%
Outras fontes de dados	34	1%
Total	2.464	100%

Fonte: elaborado pelo autor.

Tabela 29 – Consolidação de habilidades e ferramentas –
Pesquisa Data Hackers BR - P25 - Nuvem (*cloud*)

	Total	Total %
aws	397	33%
gcp	219	18%
azure	185	15%
cloud_própria	159	13%
on_premise_servers	146	12%
ibm	44	4%
Outras nuvens	69	6%
Total	1.219	100%

Fonte: elaborado pelo autor.

Tabela 30 – Consolidação de habilidades e ferramentas –
Pesquisa Data Hackers BR - P27 - Bancos de dados

	Total	Total %
mysql	356	15%
postgresql	332	14%
sql_server	327	14%
oracle	217	9%
mongodb	203	9%
s3	180	8%
elasticsearch	112	5%
sqlite	95	4%
mariadb	63	3%
Redis	44	2%
dynamodb	41	2%
firebase	40	2%
db2	38	2%
google_bigtable	36	2%
ms_access	32	1%
Hbase	31	1%
cassandra	26	1%
Aurora	23	1%
neo4j	19	1%
Sybase	14	1%
vertica	5	0%
coachdb	5	0%
datomic	3	0%
Outros bancos de dados	93	4%
Total	2.335	100%

Fonte: elaborado pelo autor.

Tabela 31 – Consolidação de habilidades e ferramentas –
Pesquisa Data Hackers BR - P28 - Ferramentas de BI

	Total	Total %
microsoft_powerbi	386	27%
tableau	202	14%
metabase	142	10%
google_data_studio	125	9%
only_excel_gsheets	105	7%
qlik_view_qlik_sense	95	7%
microstrategy	26	2%
redash	23	2%
ibm_analytics_cognos	20	1%
sap_business_objects	17	1%
superset	16	1%
looker	14	1%
oracle_business_intelligence	10	1%
birst	2	0%
Outras ferramentas de BI	81	6%
Não utilizo ferramentas de BI	169	12%
Total	1.433	100%

Fonte: elaborado pelo autor.

Tabela 32 – Consolidação de habilidades e ferramentas –
Pesquisa Data Hackers BR - P29 - Ferramentas de ETL

	Total	Total %
sql_&_stored_procedures	284	23%
pentaho	169	14%
apache_airflow	151	12%
sis_sql_server_integration_services	124	10%
aws_glue	101	8%
talend	39	3%
ibm_data_stage	38	3%
alteryx	37	3%
oracle_data_integrator	37	3%
sap_bw_etl	23	2%
luigi	14	1%
Outras ferramentas de ETL	199	16%
Total	1.216	100%

Fonte: elaborado pelo autor.

3.6 COMPARAÇÃO ENTRE OS ACHADOS DA PESQUISA E DA REVISÃO SISTEMÁTICA DA LITERATURA

A confrontação com a literatura é um passo importante da metodologia no sentido de verificar os pontos de similaridade e de diferença entre a academia e o mercado corporativo, incluindo aí os profissionais que dele fazem parte. Ela foi realizada segregando a análise entre as áreas de formação e as habilidades e ferramentas.

É importante ressaltar que a literatura abrange um período de análise de 10 anos (2009-2019), enquanto a análise de dados reflete um passado recente (Pesquisa DataHackers BR no 2º semestre de 2019 e a coleta de dados de vagas no 2º semestre de 2020).

3.6.1 Áreas de formação

O confronto da literatura com os dados levantados a partir de vagas e da pesquisa Data Hackers BR são similares.

Predomina a formação nas áreas de exatas (computação, engenharia, estatística e matemática), com destaque para a área de computação. A formação nas áreas de administração, economia e contabilidade também estão presentes, ainda que em menor número.

Chama a atenção, na análise de vagas, a presença da formação nas áreas de comunicação, *marketing*, publicidade e propaganda, presentes em cerca de 10% das vagas

analisadas, mas ausentes na literatura. Com base nas análises das vagas que pedem este tipo de formação, nota-se que, efetivamente, são vagas de cientistas de dados relacionadas à análise de dados de mercado, particularmente de dados provenientes de mídias sociais. Esta diferença entre a literatura e o mercado pode indicar uma tendência de profissionais mais especializados neste tipo de atividade, que não era evidente no período pesquisado na literatura.

3.6.2 Habilidades e ferramentas

A partir dos resultados da revisão de literatura, da pesquisa de vagas e da pesquisa junto aos profissionais, pode-se afirmar que os resultados do protocolo de pesquisa são similares aos da literatura, sob as perspectivas de mercado e de pessoas, apresentando diferenças pontuais principalmente decorrentes:

- a) do protocolo de pesquisa, que foi bastante abrangente ao procurar coletar a maior quantidade possível de habilidades e ferramentas. Neste sentido, existe a tendência de surgirem técnicas, ambientes e ferramentas que não estão presentes na literatura analisada;
- b) da diferença de cerca de dois anos entre os trabalhos mais recentes analisados na literatura e a coleta dos dados referentes ao protocolo de pesquisa. O melhor exemplo desta situação é o *Apache Airflow*⁹, plataforma de gerenciamento de fluxo de trabalho de código aberto. Criada pela empresa Airbnb em outubro de 2014, foi incubada pela fundação Apache em março de 2016 e tornou-se um dos projetos principais desta fundação em janeiro de 2019, a partir daí ganhando cada vez mais atenção da comunidade. Em 2020, tornou-se uma habilidade bastante requisitada nas vagas de emprego, mas ainda não era relevante na literatura em 2019.

No sentido de facilitar o entendimento sobre as diferenças encontradas, manteve-se a segregação utilizada na revisão de literatura para a composição das Tabelas 6.1 a 6.8, e na consolidação dos resultados do protocolo de pesquisa para a composição da Tabela 23:

- a) “*Hard skills* – Conhecimentos gerais em computação e desenvolvimento de sistemas” (Tabela 6.1);
- b) “*Hard skills* – Conhecimentos gerais em negócios” (Tabela 6.2);
- c) “*Hard skills* – Inteligência artificial” (Tabela 6.3);

⁹ Recuperado de <https://airflow.apache.org/docs/apache-airflow/stable/project.html> Acesso em: 09/06/2021.

- d) “*Soft skills*” (Tabela 6.4).
- e) “Ferramentas”, segregadas em “Ecosystems”, *frameworks* e bancos de dados” (Tabela 6.5);
- f) “Linguagens de programação ou *scripts*” (Tabela 6.6);
- g) “Visualização de dados” (Tabela 6.7);
- h) “Outros: Plataformas específicas, ambientes em nuvem e ambientes integrados” (Tabela 6.8).

É importante destacar que as comparações apresentadas a seguir complementam a literatura, uma vez que as habilidades e ferramentas presentes nela estão presentes no resultado do protocolo de pesquisa.

Este fato evidencia que a literatura revisada não se mostra desconectada da realidade do mercado. É importante destacar, também, que não foram encontradas contradições entre a literatura e os resultados do protocolo de pesquisa.

3.6.2.1 *Hard skills* – Conhecimentos gerais em computação e desenvolvimento de sistemas

A pesquisa identificou algumas habilidades e ferramentas específicas relacionadas a desenvolvimento de sistemas, sendo as principais GIS (relacionado a dados geográficos), Shell (interpretador de linha de comando para sistemas operacionais do tipo Unix), linguagens específicas como HTML e CSS, bem como formatos de dados específicos, como JSON e XML.

Sob a perspectiva de gerenciamento de dados, um dos termos presentes nos resultados do protocolo de pesquisa é “*pipeline*”, que em computação significa um conjunto de elementos de processamento de dados conectados em série, onde a saída de um elemento é a entrada do próximo. O conceito aparece na literatura, mas não como uma habilidade específica para cientistas de dados.

Ainda sob a perspectiva de gerenciamento de dados, bancos de dados SQL são prevalentes tanto na literatura como nos resultados do protocolo de pesquisa, sendo que, neste último, destacam-se habilidades em bancos de dados específicos não citados na literatura, como Oracle, PostgreSQL e MySQL.

Sob a perspectiva de infraestrutura de tecnologia, a virtualização, ou seja, a implementação de aplicações em ambientes isolados, denominados contêineres, que possuem toda a infraestrutura necessária para sua operação e são específicos para uma determinada finalidade, é citada tanto na literatura como nos resultados do protocolo de pesquisa, sendo considerado o Docker como a plataforma mais citada. Nos resultados do protocolo de pesquisa,

no entanto, adicionalmente ao Docker, a plataforma Kubernetes aparece com destaque. A diferença fundamental entre o Kubernetes e o Docker é que o primeiro deve ser executado em um *cluster*, enquanto o segundo é executado em um único nó e, desta forma, o Kubernetes, dada sua capacidade de escalar nós, torna-se mais eficiente para lidar com volumes maiores de dados.

Em relação à nuvem, que é citada na literatura de forma genérica, nos resultados do protocolo de pesquisa aparecem habilidades em ambientes específicos, sendo os mais citados o Amazon Web Services (“AWS”), o Microsoft Azure e o Google Cloud Platform, ou em ferramentas específicas, como o Hive (*framework* para soluções de *data warehouse* específico para ambiente Hadoop), o Redshift (serviço de armazenamento de dados da Amazon para grandes volumes de dados), o Airflow (ferramenta de código aberto para gerenciamento de fluxo de operações com dados, já citada anteriormente), o Glue (serviço de pré-processamento da Amazon para preparação e transformação de dados) e o BigQuery (serviço de *data warehouse* do Google voltado para análise de grandes volumes de dados).

Um tema ausente da literatura, mas presente nos resultados do protocolo de pesquisa, é o versionamento. O versionamento consiste em metodologias de classificação adotadas por desenvolvedores de sistemas com o intuito de controlar e acompanhar o histórico de alterações de um sistema. Existem diversas ferramentas de versionamento¹⁰ (de código aberto: CVS, Mercurial, GIT e SVN, e comerciais: SourceSafe, TFS, PVCS e ClearCase), mas nos resultados de pesquisa é citado especificamente o GIT, considerado *de facto* como padrão de mercado. Também está presente nos resultados do protocolo de pesquisa o GitHub. A diferença entre GIT e GitHub é que o primeiro é uma ferramenta para controlar versões, enquanto o segundo é um repositório na internet cuja principal característica é manter um serviço de versionamento, daí seu nome.

3.6.2.2 *Hard skills* – Conhecimentos gerais em negócios

Não foram identificadas diferenças relevantes entre a literatura e os resultados do protocolo de pesquisa.

¹⁰ Recuperado de https://pt.wikipedia.org/wiki/Sistema_de_controle_de_versões Acesso em: 09/06/2021.

3.6.2.3 *Hard skills* – Inteligência artificial

A literatura e os resultados da pesquisa demonstram similaridade no que se refere às habilidades e ferramentas para cientistas de dados. Em relação às ferramentas, aparecem com destaque nos resultados do protocolo de pesquisa os pacotes Scikit-learn, TensorFlow e Keras, relacionados especificamente a *machine learning* e *deep learning*, e o pacote matemático numpy da linguagem Python.

3.6.2.4 *Soft skills*

Os *soft skills* presentes na literatura são similares aos resultados da pesquisa, com destaque para “Paixão”. Na literatura, apenas Pires & Leitão (2018) incluem “Paixão” como um *soft skill*, mas nos resultados da pesquisa este *soft skill* aparece em 77 ocorrências.

3.6.2.5 Ecossistemas, *frameworks* e bancos de dados

Os resultados do protocolo de pesquisa estão alinhados com a literatura, com destaque para a prevalência de “SQL” como principal estrutura de dados e “Hadoop” como ecossistema de armazenamento de arquivos.

3.6.2.6 Linguagens de programação ou *scripts*

Os resultados do protocolo de pesquisa estão alinhados com a literatura, com destaque para a linguagem Python, que se firma como a principal linguagem de ciência de dados. A única linguagem que não está presente na literatura, sendo bastante citada nas vagas pesquisas, é a linguagem Spark, voltada para processamento de grandes volumes de dados e construída com foco em velocidade, facilidade de uso e análises sofisticadas.

3.6.2.7 Visualização de dados

As três principais ferramentas de visualização de dados, de acordo com relatório “*Magic Quadrant for Analytics and Business Intelligence Platforms do Instituto Gartner*” (2021) são Microsoft Power BI, Tableau e QlikView/QlikSense. Estas são as três mais citadas nas vagas pesquisadas; no entanto, é importante destacar que a ferramenta da Microsoft, Power BI, aparecendo como a mais citada na pesquisa, não é citada na literatura.

Figura 12 – Gartner: “*Magic Quadrant for Analytics and Business Intelligence Platforms*”



Fonte: Gartner (2021)

3.6.2.8 Outros: plataformas específicas, ambientes em nuvem e ambientes integrados

Não foram identificadas diferenças entre a literatura e os resultados do protocolo de pesquisa.

3.7 CONSIDERAÇÕES SOBRE AS DIFERENÇAS E SIMILARIDADES ENTRE CIENTISTAS DE DADOS, ANALISTAS DE DADOS, ENGENHEIROS DE DADOS E ARQUITETOS DE DADOS

Um dos objetivos secundários deste estudo é a comparação, através da análise de habilidades e ferramentas, e sob a perspectiva do mercado de trabalho, das diferenças e similaridades entre cientistas de dados e atividades correlatas, como por exemplo, as de analista de dados e engenheiro de dados.

De Mauro et al. (2017) afirmam que o atual estágio da disciplina de ciência de dados, sendo mais prática e experimental, e não teórica e metodológica, faz com que haja confusão entre o campo de estudo e o que os praticantes – no caso, os cientistas de dados – efetivamente fazem, e que a heterogeneidade das muitas facetas de cientistas de dados é uma indicação da confusão gerada sobre esse conceito, que associou habilidades de forma indiscriminada sob o termo genérico “cientista de dados”. É exatamente sobre esta perspectiva que trata esta seção.

Conforme apresentado na Seção 3.5.1.2, onde são detalhados os tratamentos realizados em relação às vagas coletadas, os títulos das mesmas foram agrupados com base no critério abaixo (palavras-chave para determinação do título), sendo que a ordem das palavras-chave foi utilizada na identificação nos títulos das vagas:

- a) “engenheiro de dados”: engenheiro, *engineer*, engenharia, *engineering*;
- b) “arquiteto de dados”: arquiteto, *architect*, arquitetura, *architecture*;
- c) “cientista de dados”: cientista, *cientist*, ciência, *science*, ciências, *big data*, *machine learning*, modelagem, inteligência artificial, *artificial intelligence*;
- d) “analista de dados”: analista de dados, *data analyst*, especialista de dados, *analytics*, consultor de dados, *bi*, *business intelligence*, banco de dados, dados.

A Tabela 12, apresentada na Seção 3.5.1.2, identificou 569 “cientistas de dados”, 401 “engenheiros de dados” e 456 “analistas de dados”, entre outros, considerando 1.716 vagas. No entanto, após diversos tratamentos e revisões realizadas, como, por exemplo, na eliminação de vagas duplicadas e similares, detalhados na Seção 3.5.1.2.2, foram consideradas como base para as análises 1308 vagas. E, destas, 493 foram agrupadas como “cientistas de dados”, 420 como “analistas de dados”, 317 como “engenheiro de dados” e 73 como “arquiteto de dados”.

Na Seção 3.5.1.2 também é apresentado o processo de elaboração dos conjuntos de características-base para a análise das vagas. Em relação a habilidades e ferramentas, o conjunto final totalizou 526 elementos, que estão apresentados no Apêndice C.

Na Seção 3.5.1.3.2, “Habilidade e ferramentas”, é apresentada a consolidação das vagas analisadas em relação ao conjunto de características, considerando todas as vagas analisadas, independente do profissional requerido no título da vaga (por exemplo “cientista de dados” ou “engenheiro de dados”).

No sentido de atender um dos objetivos secundários deste estudo, citado no início desta seção, foi realizada uma análise do conjunto de características em relação ao título das vagas que, conforme demonstrado anteriormente, foram agrupados de acordo com o tipo de profissional requerido.

As 50 habilidades e ferramentas que apresentam maior frequência na análise das vagas

são apresentadas na Tabela 33. “Ocorrências” indicam o número de vagas analisadas onde a habilidade ou ferramenta está presente. Por exemplo, “Conhecimento do negócio” está presente em 742 das vagas analisadas, que totalizam 1.308.

Das 742 ocorrências de “Conhecimento do negócio”, 307 aparecem nas vagas agrupadas como “Cientistas de dados”, o que representa 62% deste grupo específico (que totalizam 493 vagas). Ainda, 245 ocorrências estão presentes em “Analista de dados”, sendo que este número corresponde a 58% das vagas agrupadas sobre este título (420 vagas).

Tabela 33 – Principais habilidades e ferramentas presentes na análise de vagas, segregadas por profissional requerido no título da vaga (continua)¹¹

Habilidade ou Ferramenta	Ocorrências	Cientista de dados		Analista de dados		Engenheiro de dados		Arquiteto de dados	
Conhecimento do negócio	742	307	62%	245	58%	142	45%	48	66%
SQL	793	283	57%	252	60%	226	71%	32	44%
Modelagem	588	292	59%	150	36%	119	38%	27	37%
Python	743	364	74%	152	36%	210	66%	17	23%
IDE (Geral)	633	266	54%	200	48%	130	41%	37	51%
<i>Machine learning</i>	415	299	61%	46	11%	62	20%	8	11%
Inglês	491	188	38%	157	37%	113	36%	33	45%
Metodologias ágeis	307	114	23%	96	23%	78	25%	19	26%
Programação	449	253	51%	86	20%	91	29%	19	26%
<i>Big data</i>	361	146	30%	58	14%	127	40%	30	41%
Spark	332	150	30%	27	6%	147	46%	8	11%
<i>Cloud</i>	344	104	21%	47	11%	162	51%	31	42%
Amazon AWS	282	95	19%	29	7%	145	46%	13	18%
[R]	330	228	46%	80	19%	21	7%	1	1%
Scala	313	120	24%	30	7%	122	38%	41	56%
Gestão	305	84	17%	115	27%	84	26%	22	30%
Power BI	284	63	13%	154	37%	55	17%	12	16%
Banco de dados	282	88	18%	109	26%	69	22%	16	22%
Comunicação	261	102	21%	87	21%	61	19%	11	15%
ETL	263	53	11%	48	11%	142	45%	20	27%
Trabalho em time	257	126	26%	64	15%	43	14%	24	33%
Gestão de conhecimento	246	76	15%	92	22%	66	21%	12	16%
GIT	243	93	19%	93	22%	54	17%	3	4%
Implementação	223	86	17%	52	12%	68	21%	17	23%
Análise de dados	237	90	18%	125	30%	16	5%	6	8%
Hadoop	226	104	21%	15	4%	94	30%	13	18%

¹¹ Os percentuais são referentes às quantidades relativas de quantas vezes a habilidade ou ferramenta está presente no total de ocorrências, em relação ao agrupamento de vagas analisado.

Tabela 33 – Principais habilidades e ferramentas presentes na análise de vagas, segregadas por profissional requerido no título da vaga (conclusão)

Habilidade ou Ferramenta	Ocorrências	Cientista de dados		Analista de dados		Engenheiro de dados		Arquiteto de dados	
Tableau	214	71	14%	92	22%	45	14%	6	8%
Integração de dados	156	24	5%	34	8%	74	23%	24	33%
Java	202	64	13%	29	7%	99	31%	10	14%
Pipeline	201	26	5%	19	5%	140	44%	16	22%
Visualização de dados	175	74	15%	70	17%	27	9%	4	5%
Azure	172	43	9%	28	7%	82	26%	19	26%
Otimização	159	85	17%	40	10%	32	10%	2	3%
Paixão	98	52	11%	9	2%	20	6%	17	23%
Hive	155	64	13%	14	3%	71	22%	6	8%
Metodologia	151	64	13%	47	11%	31	10%	9	12%
MongoDB	80	23	5%	9	2%	38	12%	10	14%
Data warehouse	133	18	4%	23	5%	85	27%	7	10%
Business intelligence	136	27	5%	66	16%	25	8%	18	25%
Scikit-learn	80	61	12%	4	1%	13	4%	2	3%
NoSQL	136	53	11%	13	3%	60	19%	10	14%
Metodologias	123	51	10%	39	9%	28	9%	5	7%
Administração e finanças	119	54	11%	53	13%	7	2%	5	7%
Oracle	119	22	4%	37	9%	51	16%	9	12%
Mineração de dados	65	44	9%	11	3%	10	3%		0%
Construção de datasets	105	49	10%	21	5%	35	11%		0%
Infraestrutura TI	112	33	7%	8	2%	60	19%	11	15%
QlikView/ QlikSense	69	20	4%	31	7%	16	5%	2	3%
Postgres	63	17	3%	13	3%	30	9%	3	4%
Pensamento analítico	98	35	7%	36	9%	17	5%	10	14%
Vagas analisadas		493	100%	420	100%	317	100%	73	100%

Fonte: elaborado pelo autor.

Em uma análise da Tabela 33, pode-se perceber que as 50 principais habilidades e ferramentas estão presentes em todas as vagas, exceto “Mineração de dados” e “Construção de datasets” que não foram identificadas em vagas de “Arquiteto de dados”.

Em função dos títulos das vagas, é possível inferir algumas atividades que os profissionais realizam. Por exemplo, ETL (*Extraction, Transformation and Load*) parece ser uma atividade mais relacionada a “Engenharia de dados” e “Arquitetura de dados”. De fato, percebe-se que este conhecimento é mais frequente nestas vagas (45% e 27%, respectivamente), no entanto, também está presente nas vagas de “Cientista de dados” e de “Analista de dados” (11% em ambos os casos).

De forma análoga, “Modelagem” é uma habilidade esperada na vaga “Cientista de dados”, mas não nas demais. No entanto, apesar de possuir uma incidência maior em “Cientista

de dados”, também está presente nas demais vagas, ainda que com uma frequência menor.

A partir desta análise, é possível concluir que, apesar de o mercado utilizar títulos diferentes para os profissionais que está buscando contratar, do ponto de vista das habilidades e ferramentas, de uma forma geral, o mercado não diferencia estes profissionais. Neste contexto, não foram realizadas diferenciações em relação ao modelo conceitual de cientista de dados proposto, apresentado na próxima seção.

3.8 PROPOSTA DE MODELO CONCEITUAL PRÉVIO PARA CIENTISTAS DE DADOS

Conforme apresentado na Seção 1.6, o objetivo primário deste projeto é a definição de um modelo conceitual para explicar a função de um cientista de dados, considerando a proposta de uma definição de sua atuação e áreas de formação, bem como considerando o conjunto de suas habilidades e as principais ferramentas utilizadas por esses profissionais.

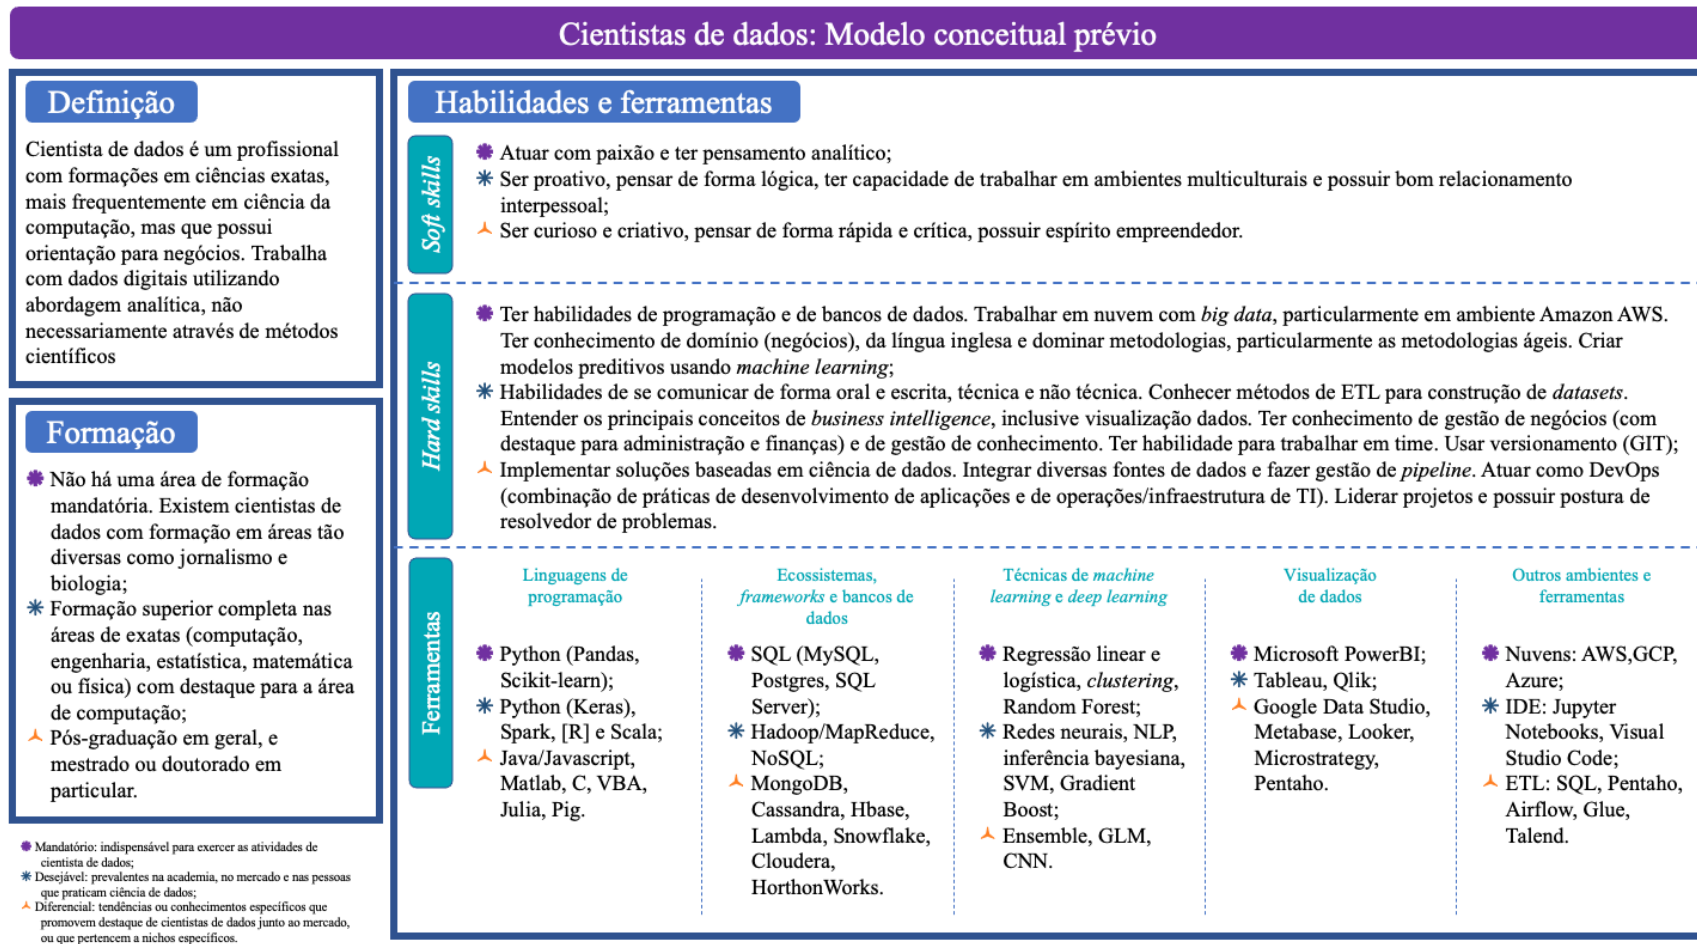
A proposta de uma definição abrangente, no sentido de que contemple o que pode ser considerado o mais próximo de um consenso entre as definições de cientistas de dados que foram pesquisadas na literatura, foi sugerida na Seção 2.5.1 e consta da proposta de modelo prévio, apresentado a seguir, na Figura 13.

A proposta de um modelo conceitual apresentando as principais áreas de formação, bem como habilidades e ferramentas, foi elaborada a partir da análise dos resultados de três perspectivas:

- a) Perspectiva da academia, representada pelo resultado da revisão sistemática da literatura, descrita na Seção 2.5 deste estudo;
- b) Perspectiva do mercado, representada pela coleta e análise de dados de vagas de emprego direcionadas para a contratação de cientistas de dados, cujos resultados estão consolidados na Seção 3.5.1.3;
- c) Perspectivas das pessoas, isto é, de cientistas de dados ou, ainda, dos praticantes de ciência de dados, representadas pela análise de dados secundários da pesquisa realizada pelo grupo Data Hackers Brasil em 2019, cujos resultados estão consolidados na Seção 3.5.2.3.

As três perspectivas foram analisadas e agregadas de forma a obter o modelo conceitual prévio, que está apresentado na Figura 13.

Figura 13 – Modelo conceitual prévio para cientistas de dados


 Mais informações www.fabianocastello.com.br/cd Revisão: beta 0.01 Fev/21; © 2021 Fabiano Castello

Fonte: elaborado pelo autor.

3.9 VALIDAÇÃO DO MODELO

3.9.1 Protocolo de validação

A proposta de modelo conceitual prévio para cientistas de dados foi validada através de um questionário criado pela plataforma Google Forms. Nele, os participantes foram informados, através de Termo de Consentimento Livre e Esclarecido (TCLE), obrigatório na Universidade de São Paulo, que os conhecimentos resultantes da pesquisa seriam constituídos por dados estatísticos e que eles não seriam identificados, bem como que a pesquisa poderia ser divulgada em revistas científicas e/ou congressos na área de Administração, e que os dados coletados constituiriam um banco de dados que ficaria sob a guarda dos pesquisadores por cinco anos, podendo ser utilizados em pesquisas futuras. Os dados de contato da Comissão de Pesquisa da FEA/USP foram informados e respostas foram coletadas apenas para os participantes que consentiram com o TCLE.

O questionário, que está disponibilizado de forma integral no Apêndice E, foi elaborado de forma a coletar as percepções dos participantes sobre o modelo conceitual prévio para a definição de cientistas de dados, em relação a:

- a) Definição de cientistas de dados;
- b) Áreas de formação;
- c) *Soft skills*;
- d) *Hard skills*;
- e) Linguagens de programação;
- f) Ecossistemas, *frameworks* e bancos de dados;
- g) Técnicas de *machine learning* e *deep learning*;
- h) Visualização de dados.

Não foram coletados dados sobre a classificação “Outros: plataformas específicas, ambientes em nuvem e ambientes integrados” por ser um item que considera assuntos diversos e genéricos. Por opção do autor, este item foi suprimido do modelo final proposto e, portanto, não foi analisado.

Para cada um dos oito itens, foram coletados os níveis de concordância através de escala Likert de 4 pontos (1: discordo muito, 2: discordo, 3: concordo; 4: concordo muito), bem como opiniões qualitativas, além de uma questão adicional sobre a opinião do participante em relação a como o modelo foi segregado.

No sentido de proporcionar análises mais detalhadas, foram coletados dados demográficos (profissão, cargo, tempo de experiência e CEP de residência).

3.9.2 Coleta de respostas

Conforme mencionado na seção anterior, as respostas foram coletadas através de Google Forms.

A divulgação do questionário foi realizada através da rede de relacionamento do autor, de redes sociais (LinkedIn e WhatsApp), de correio eletrônico para a comunidade FEA/USP e de grupos temáticos de ciência de dados no LinkedIn. Adicionalmente, foram enviadas manualmente 682 mensagens privadas na rede LinkedIn para indivíduos que se descrevem, nesta rede social, com os termos “*data scientist*”, “cientista de dados”, “*data science*”, “ciência de dados”, “engenheiro de dados” e “*data engineer*”.


No período de 07/04/21 a 24/05/21 foram coletadas 207 respostas. Eliminando duplicações e respostas onde se declarou que o modelo não foi avaliado, foram consideradas válidas 201 respostas.

3.9.3 Resultado quantitativo

A Figura 14 demonstra graficamente os resultados médios de cada um dos 8 itens analisados. Considerando todos os itens, a média geral de concordância foi de 75%, equivalente à nota 3 em uma escala variando de 1 (discordo muito) a 4 (concordo muito).

Os itens com maior concordância estão relacionados (a) às áreas de formação, (b) aos *soft skills* e (c) aos ecossistemas, *frameworks* e bancos de dados (todos com nota média de 3,4). Os itens com menor concordância estão relacionados à definição de cientista de dados (nota média de 2,7) e à visualização de dados (nota média de 2,8).

Figura 14 – Resultado quantitativo global do questionário para validação da proposta de modelo conceitual para cientistas de dados



Fonte: elaborado pelo autor.

Um ponto interessante sobre as respostas obtidas é que elas não variam de forma relevante de acordo com as faixas de idade. Como pode ser observado na Figura 15, os participantes da pesquisa que declararam possuir de 1 a 2 anos de experiência, quando comparados àqueles que declaram possuir mais de 10 anos de experiência, seguem o mesmo padrão e não variam, em nenhum dos itens pesquisados, mais do que 20%.

O item que aparece com maior diferença – visualização de dados – quando desconsiderados os profissionais com menor nível de experiência (nota 3,3), não apresenta diferença em relação às outras faixas de idade (nota 2,7).

Em relação às profissões declaradas pelos respondentes, foi realizada uma padronização manual para efeito de agrupamento. Desta forma, por exemplo, “*data scientist*” e “cientista de dados” foram agrupados dentro de uma mesma categoria.

Das 201 respostas válidas obtidas, a maior parte (162, 80%) foi proveniente de profissionais que se autointitularam cientistas de dados, seguida por outros que se autointitularam engenheiro de dados (19, 10%). Outras profissões totalizaram também 19 respondentes (10%) e estão representadas por professores, consultores, profissionais de TI e de saúde, entre outros. Em relação às médias de concordância, não existem diferenças relevantes entre as profissões (média geral variando entre 3,0 e 3,4).


Sobre a localização geográfica, a maioria dos respondentes são do Estado de São Paulo

(131 respostas) e Estado do Rio de Janeiro (18 respostas), porém também responderam ao questionário profissionais dos Estados do Acre, Amazonas, Bahia, Ceará, Espírito Santo, Goiás, Maranhão, Minas Gerais, Mato Grosso do Sul, Pará, Paraíba, Paraná, Rio Grande do Sul e Santa Catarina, bem como do Distrito Federal.

É importante destacar que, de todos os questionários respondidos, apenas em quatro casos a média geral das questões ficou abaixo da nota 2, que significaria discordância em relação ao modelo, e em apenas dois casos a nota foi igual a 2, significando neutralidade em relação ao modelo proposto. Nas demais 195 respostas, a média geral foi superior à nota 2, indicando concordância dos respondentes.

Desta forma, com base nos dados quantitativos coletados e analisados, pode-se considerar que o modelo conceitual prévio teve boa aceitação junto à comunidade de cientistas de dados. A concordância com o modelo proposto, no entanto, não eximiu os respondentes de opinarem sobre diversos aspectos, que foram apontados nas perguntas abertas do questionário, e serão abordados na próxima seção.

Figura 15 – Resultados quantitativos do questionário para validação da proposta de modelo conceitual para cientistas de dados



Fonte: elaborado pelo autor.

3.9.4 Resultado qualitativo

Todas as questões quantitativas foram acompanhadas de questões abertas para que os participantes pudessem expressar opiniões, críticas e sugestões. A seguir encontram-se análises sobre cada um dos itens do questionário e como eles influenciaram o modelo final proposto deste estudo.

Do ponto de vista do método da análise, este foi realizado de forma manual, para cada um dos itens analisados, considerando quatro etapas. Primeiro, os comentários foram lidos de forma integral. Segundo, os assuntos de maior frequência foram selecionados. Terceiro, o material foi lido novamente para efeito de verificação. Finalmente, trechos foram selecionados para serem utilizados a título de exemplo.

É importante ressaltar que o questionário não constituiu a parte central do estudo, mas apenas uma ferramenta para coletar opiniões, críticas e comentários de profissionais que atuam em ciência de dados. Desta forma, a base do modelo é a literatura, as vagas analisadas e os dados secundários da pesquisa Data Hackers BR 2019, sendo que as perguntas abertas foram utilizadas para refinar o modelo, e não para defini-lo.

Em tempo, exceto para a definição de cientista de dados, houve segregação nas classificações em três camadas (mandatório, desejável e diferencial), que estão detalhadas abaixo:

- a) Mandatório: indispensável para exercer as atividades de cientista de dados;
- b) Desejável: prevalentes na academia, no mercado e entre as pessoas que praticam ciência de dados;
- c) Diferencial: tendências ou conhecimentos específicos que promovem o destaque de cientistas de dados junto ao mercado.

No modelo final proposto, a segregação permanece a mesma, exceto pela camada “diferencial”, onde foi incluído “...junto ao mercado, ou que pertencem a nichos específicos”.

3.9.4.1 Definição de cientista de dados

A definição apresentada no modelo proposto foi a seguinte:

Cientista de dados é um profissional com formações em ciências exatas, mais frequentemente em ciência da computação, mas que possui orientação para negócios. Trabalha com dados digitais utilizando abordagem analítica, não necessariamente através de métodos científicos.

É importante ressaltar que a definição proposta foi elaborada exclusivamente a partir de diversas definições de cientistas de dados extraídas de artigos científicos, analisados na etapa da revisão sistemática da literatura.

No questionário, a pergunta aberta “Tem alguma sugestão para modificar a definição?” recebeu 145 respostas com sugestões ou comentários.

A análise de tais respostas revelou que a principal crítica à definição está relacionada à citação “não necessariamente através de métodos científicos”. Muitos respondentes entendem que a utilização do método científico – aí citados, principalmente, a construção e o teste de hipóteses – é o que diferencia um cientista de dados de um analista tradicional que utiliza dados em formato digital. Frequentes foram comentários como “impossível fazer ciência de dados de forma séria sem usar método científico”. Nenhum respondente discorda que o método científico é importante, porém alguns respondentes flexibilizam o rigor do método do científico, alegando não ser sempre necessário ou mesmo não sempre existem casos em que a agilidade é necessária. Nas palavras de um respondente, “difícil usar método científico quando o chefe pede uma informação e precisa em 10 minutos”. Cabe aqui ressaltar os já citados De Mauro et al. (2017), que colocam que o atual estágio da disciplina de ciência de dados, sendo mais prática e experimental, e não teórica e metodológica, faz com que haja confusão entre o campo de estudo e o que os praticantes – no caso, cientistas de dados – efetivamente fazem.

Outro ponto de destaque nas respostas está relacionado ao trecho “mais frequentemente em ciência da computação”. Inúmeros respondentes apontam que a maioria dos cientistas de dados que conhecem e/ou com quem trabalham não são cientistas da computação. Não há discordância em relação a um *background* sólido em relação ao conhecimento de métodos quantitativos, sendo as ciências mais citadas a estatística e a matemática. Em diversas respostas aparecem citações às ciências humanas, particularmente as ciências sociais aplicadas, como Administração e Economia.

É subliminar, porém bastante presente, que a formação é um aspecto secundário para a definição, no sentido de que um cientista de dados é um profissional dinâmico que está em constante aprendizado. Particularmente, esta característica está endereçada na Seção 4.2.

Também é importante destacar um aspecto interessante levantado por um respondente, no sentido de que a definição não deveria começar pela formação. Segundo este respondente, da forma como foi apresentada a definição, dá-se um peso maior à área de formação do que às atividades que um cientista de dados realiza, o que é, efetivamente, menos relevante.

Alguns respondentes consideraram “orientação para negócios” um termo genérico, porém diversos respondentes consideraram que o conhecimento do negócio é fundamental. Segundo um respondente, a melhor definição seria que um cientista de dados “impacta o negócio, direta ou indiretamente”, e esta citação foi aproveitada por este autor para ser incluída na definição.

Finalmente, diversos respondentes entenderam ser necessário incluir que a principal atividade de um cientista de dados é a criação de modelos usando técnicas de *machine learning*.

Consideradas todas as análises acima, propomos a definição atualizada abaixo:

Cientista de dados é um profissional orientado para impactar o negócio através da criação de modelos utilizando técnicas de *machine learning* e, preferencialmente, métodos científicos. Pode possuir formações diversas, mas, necessariamente, possui sólidos conhecimentos de métodos quantitativos.

3.9.4.2 Áreas de formação

A classificação apresentada no modelo proposto foi a seguinte:

- a) MANDATÓRIO: Não há uma área de formação mandatória. Existem cientistas de dados com formações em áreas tão diversas como jornalismo e biologia;
- b) DESEJÁVEL: Formação superior completa nas áreas de exatas (computação, engenharia, estatística, matemática ou física), com destaque para a área de computação;
- c) DIFERENCIAL: Pós-graduação em geral, e mestrado ou doutorado em particular.

No questionário, a pergunta aberta “Tem algum comentário sobre as áreas de formação?” recebeu 75 respostas com sugestões ou comentários.

De forma similar à discussão na seção que trata da definição, existem diversos comentários que divergem sobre o destaque para a área de computação, ainda que a maior parte dos comentários reforce a necessidade de um *background* robusto nas áreas de exatas. Segundo um respondente, “...profissionais sem a bagagem de exatas são apenas rodadores de código (SIC)”.

É interessante notar que, apesar de muitos respondentes colocarem a questão da formação como secundária, como por exemplo no comentário “resultados podem ser obtidos com uma série de minicursos em tópicos específicos”, a formação superior completa é recorrente nas vagas que procuram cientistas de dados e, em certo sentido, está também alinhada com a necessidade de o cientista de dados utilizar o método científico, conforme discutido no item anterior.

Diversos respondentes concordam que não existe uma formação mandatória, inclusive com diversos exemplos, como por exemplo “...existem linguistas se aventurando no mundo de NLP”, ou seja, existem pessoas com formação em Letras, uma formação essencialmente das ciências humanas, trabalhando com processamento de linguagem natural (NLP).

Ainda em relação às formações mandatórias, diversos respondentes sugerem, com razão, que incluir exemplos como biologia e jornalismo, no contexto em que foram apresentados, discrimina tais profissões, dando uma ideia de que são “áreas menores” (SIC).

Consideradas as análises acima, propomos a classificação atualizada abaixo:

- a) MANDATÓRIO: Não há uma área de formação mandatória, mas há necessidade de *background* em métodos quantitativos;
- b) DESEJÁVEL: Formação superior completa, preferencialmente em áreas de exatas (computação, estatística, matemática, engenharia ou física);
- c) DIFERENCIAL: Pós-graduação em geral, e mestrado ou doutorado em particular.

3.9.4.3 *Soft skills*

A classificação apresentada no modelo proposto foi a seguinte:

- a) MANDATÓRIO: Atuar com paixão e ter pensamento analítico;
- b) DESEJÁVEL: Ser proativo, pensar de forma lógica, ter capacidade de trabalhar em ambientes multiculturais e possuir bom relacionamento interpessoal;
- c) DIFERENCIAL: Ser curioso e criativo, pensar de forma rápida e crítica, possuir espírito empreendedor.

No questionário, a pergunta aberta “*Soft skills* - você concorda com a classificação abaixo?” recebeu 86 respostas com sugestões ou comentários.

O comentário mais frequente na análise das respostas é em relação a “ser curioso”. Na maioria dos comentários, esta característica é sugerida como mandatória. De fato, Patil (2011) aponta a curiosidade, ou o desejo de ir mais profundamente na solução de um problema através de um conjunto claro de hipóteses, com uma das características que formam um bom cientista de dados. O autor também cita outra característica, o *storytelling*, ou a habilidade de usar dados e estar apto a comunicar-se de forma efetiva, que também é apontada como muito importante para um cientista de dados por diversos respondentes (sendo que, em geral, citam o *data storytelling*). Comunicar-se de forma efetiva, nos comentários dos respondentes, é uma

capacidade que, diversas vezes, aparece na habilidade de conseguir traduzir assuntos complexos para uma linguagem não técnica, voltada para públicos leigos. Citando um dos respondentes, “muitas pessoas dessa área [ciência de dados] não têm essa habilidade [comunicação] e os modelos feitos não são usados, pois não são bem explicados”. Essas considerações, como um todo, poderiam ser traduzidas como a “habilidade de se comunicar, de forma efetiva, com públicos diversos”.

Diversos respondentes criticaram que “paixão”, além de não ser algo mandatório, é um termo genérico e sujeito a um gama vasta de interpretações. Conquanto este autor concorde com os respondentes, a “paixão”, além de ser citada na literatura, aparece com um item de destaque nas vagas ofertadas para cientistas de dados.

Um ponto de atenção está em duas respostas que mencionaram a questão da ética, no sentido de que a “...inteligência artificial pode ser tanto para o bem como para o mal”. Este ponto é citado na literatura e na análise das vagas, ainda que discretamente. No entanto, ele é fundamental, e as discussões sobre ética e inteligência artificial estão neste momento ganhando destaque: elas são, inclusive, parte da proposta sobre regulação em inteligência artificial da comunidade europeia, cujos objetivos estão relacionados ao desenvolvimento de inteligência artificial de forma segura, confiável e ética (Publications Office of the EU, 2021). Sendo “ética” incluída no modelo proposto, não há como classificá-la como uma característica que não seja mandatória.

Consideradas as análises acima, propomos a classificação atualizada abaixo:

- a) MANDATÓRIO: Ser curioso, atuar de forma ética e com paixão, e ter pensamento analítico;
- b) DESEJÁVEL: Ser proativo, pensar de forma lógica, ter capacidade de trabalhar em ambientes multiculturais, possuir bom relacionamento interpessoal e a capacidade de comunicar-se de forma efetiva com públicos diversos;
- c) DIFERENCIAL: Ser criativo, pensar de forma rápida e crítica, possuir espírito empreendedor.

3.9.4.4 *Hard skills*

A classificação apresentada no modelo proposto foi a seguinte:

- a) MANDATÓRIO: Ter habilidades de programação e de bancos de dados. Trabalhar em nuvem com *big data*, particularmente em ambiente Amazon AWS. Ter conhecimento de domínio (negócios), da língua inglesa e dominar metodologias, particularmente as

metodologias ágeis. Criar modelos preditivos usando *machine learning*;

- b) DESEJÁVEL: Habilidades de se comunicar de forma oral e escrita, técnica e não técnica. Conhecer métodos de ETL para a construção de *datasets*. Entender os principais conceitos de *business intelligence*, inclusive visualização dados. Ter conhecimento de gestão de negócios (com destaque para administração e finanças) e de gestão de conhecimento. Ter habilidade para trabalhar em time. Usar versionamento (GIT);
- c) DIFERENCIAL: Implementar soluções baseadas em ciência de dados. Integrar diversas fontes de dados e fazer gestão de *pipeline*. Atuar como DevOps (combinação de práticas de desenvolvimento de aplicações e de operações/infraestrutura de TI). Liderar projetos e possuir postura de resolvidor de problemas.

No questionário, a pergunta aberta “Tem algum comentário sobre *hard skills*?” recebeu 116 respostas com sugestões ou comentários.

Dentre as inúmeras contribuições recebidas, a mais frequente crítica está relacionada a “Trabalhar em nuvem com *big data*, particularmente em ambiente Amazon AWS”. As críticas estão relacionadas a três pontos.

Primeiro, em relação ao ambiente Amazon AWS. Este ambiente de nuvem apareceu na definição por ser o mais citado nas vagas, porém inúmeros comentários sugerem não restringir a obrigatoriedade a este ambiente, uma vez que existem outros, como o Microsoft Azure, o Google Cloud e o IBM Cloud, que são tão prevalentes quanto o da Amazon. Segundo um dos comentários: “...descrição quase perfeita; tiraria o termo ‘particularmente em ambiente Amazon AWS’”.

Segundo, também foi amplamente criticado o aspecto de que trabalhar em nuvem seja uma atividade mandatória. Diversos exemplos foram citados entre os respondentes onde cientistas de dados trabalham com dados *on premises*, ou seja, com dados que estão fisicamente armazenados em equipamentos locais, caracterizando a habilidade de trabalhar em nuvem como algo desejável, mas não mandatório.

Terceiro, em relação ao termo *big data*. Diversos respondentes o consideram genérico e pouco explicativo. Segundo um dos respondentes, “...é uma *buzz-word* e acaba tirando o foco das demais habilidades”. Outro respondente, como sugestão, comentou: “...seria melhor utilizar [o termo] dados estruturados e não estruturados” que, na verdade, já está implícito na definição em “integrar diversas fontes de dados”.

Outra habilidade tema de diversos comentários foi a questão da comunicação. Na

definição, “Habilidades de se comunicar de forma oral e escrita, técnica e não técnica” foi considerada no modelo original proposto como um *hard skill* de acordo com a definição de Pires & Leitão (2018), já citado na revisão de literatura, onde *hard skills* representam conhecimentos e capacidades que podem ser adquiridos através de programas de educação e treinamento. Porém, na mesma definição, os autores definem *soft skills* como a capacidade de se relacionar com outras pessoas para expressar ideias e o desejo de realizar o trabalho. Neste contexto, o estudo reclassificou os aspectos relacionados à comunicação como *soft skills*, utilizando “capacidade de comunicar-se de forma efetiva com públicos diversos”.

Sobre “dominar metodologias, particularmente as metodologias ágeis”, foi criticado por alguns respondentes o fato de que metodologias ágeis estão mais relacionadas a projetos de gestão do que a projetos de dados. No entanto, foi feita a opção por manter as metodologias ágeis porque são bastante citadas como uma habilidade requerida nas vagas sobre cientista de dados. Em complemento à questão das metodologias, alguns respondentes comentaram a falta de referência de cientistas de dados em relação a algum *framework* mais especificamente relacionado a projetos de dados, sendo citado mais de uma vez o *framework* CRISP-DM (*Cross Industry Standard Process for Data Mining*). Esta informação foi considerada na Seção 3.9.4.6.

É importante destacar que diversos respondentes apontam, especificamente neste item que trata de *hard skills*, a questão da “super-qualificação”. Comentários como “conheço cientistas [de dados] excelentes, mas poucos possuem todos estes *hard skills*. Imagino que os pedidos colocam o sarrafo bem alto buscando os unicórnios, mas que raramente encontram”, “quem faz tudo, nada faz com excelência”, e “é muito conhecimento para uma pessoa só, se eu tenho um excelente cientista que programa em R ou Python mas que não sabe SQL para banco de dados, não irei o perder (SIC)” demonstram que, realmente, é improvável encontrar profissionais com todas as qualificações que, efetivamente, emanam da literatura e da pesquisa de vagas de cientistas de dados. Isto está endereçado em uma das conclusões do trabalho, mais adiante, na Seção 4.3.

Finalmente, diversos respondentes questionam a termo “DevOps”, comentando que é um termo mais associado ao desenvolvimento de sistemas, e sugerem o termo “MLOps”, mais moderno e que tem o mesmo significado, porém é mais apropriado no contexto de projetos de ciência de dados.

Consideradas as análises acima, propomos a classificação atualizada abaixo:

- a) MANDATÓRIO: Ter habilidades de programação e de bancos de dados. Ter

conhecimento de domínio (negócios), da língua inglesa e dominar metodologias, particularmente as metodologias ágeis. Criar modelos preditivos usando *machine learning*;

- b) DESEJÁVEL: Trabalhar em nuvem. Conhecer métodos de ETL para a construção de *datasets*. Entender os principais conceitos de *business intelligence*, inclusive visualização dados. Ter conhecimento de gestão de negócios (com destaque para administração e finanças) e de gestão de conhecimento. Ter habilidade para trabalhar em time. Usar versionamento (GIT);
- c) DIFERENCIAL: Implementar soluções baseadas em ciência de dados. Integrar diversas fontes de dados, estruturados e não estruturados, e fazer gestão de *pipeline*. Atuar como MLOps (combinação de práticas de desenvolvimento de modelos e do seu uso em ambiente de produção). Liderar projetos e possuir postura de resolvidor de problemas.

3.9.4.5 Linguagens de programação

A classificação apresentada no modelo proposto foi a seguinte:

- a) MANDATÓRIO: Python (Pandas, Scikit-learn);
- b) DESEJÁVEL: Python (Keras), Spark, [R] e Scala;
- c) DIFERENCIAL: Java/Javascript, Matlab, C, VBA, Julia, Pig.

No questionário, a pergunta aberta “Acrescentaria alguma linguagem à lista acima?” recebeu 96 respostas com sugestões ou comentários.

A principal crítica dos respondentes foi com relação ao fato de que [R] deveria ser considerado como mandatório. De acordo com um dos respondentes, “...acredito que R possa ser mandatário, visto que muitas universidades utilizam R como linguagem de formação”.

Diversos respondentes citam “C++” como uma linguagem importante e um diferencial. Segundo um dos respondentes, “...se o profissional souber C em nível avançado apreende Python rapidamente”, o que reforça a presença desta linguagem na classificação. “C” já está na classificação proposta, mas optou-se por inserir, também, “C++”.

SQL foi considerado como um banco de dados, mas respondentes sugerem incluí-lo, também, como uma linguagem. Um dos respondentes escreveu “...conheço profissionais que fazem praticamente tudo com SQL - sinto falta dessa linguagem na lista”.

Alguns respondentes comentaram que VBA não é diferencial. Fazendo uma análise

desta habilidade verificou-se que está presente em apenas 29 das 1.308 vagas pesquisadas e, portanto, optou-se por retirá-la da classificação.

Diversos respondentes apontaram o fato de que a biblioteca Keras indicada na classificação deveria ser substituída pela biblioteca original, TensorFlow, bem como deveria ser incluída a biblioteca Pytorch.

Finalmente, diversos respondentes apontaram, corretamente, que Spark não é uma linguagem, e sim um *framework*. O ajuste foi feito na nova classificação, e Spark foi movido para a seção de “Ecossistemas, *frameworks* e bancos de dados”.

Consideradas as análises acima, propomos a classificação atualizada abaixo:

- a) MANDATÓRIO: Python (Pandas, Scikit-learn) ou [R];
- b) DESEJÁVEL: Python (TensorFlow/PyTorch), Scala, SQL (linguagem);
- c) DIFERENCIAL: Java, Javascript, Matlab, C/C++, Julia, Pig.

3.9.4.6 Ecossistemas, *frameworks* e bancos de dados

A classificação apresentada no modelo proposto foi a seguinte:

- a) MANDATÓRIO: SQL (MySQL, Postgres, SQL Server);
- b) DESEJÁVEL: Hadoop/MapReduce, NoSQL;
- c) DIFERENCIAL: MongoDB, Cassandra, Hbase, Lambda, Snowflake, Cloudera, HortonWorks.

No questionário, a pergunta aberta “Tem algum comentário sobre a lista acima?” recebeu 55 respostas com sugestões ou comentários.

Ao contrário dos itens anteriores, não houve prevalência de nenhuma consideração específica, apenas comentários pontuais.

Alguns respondentes sugeriram a inclusão dos bancos de dados Oracle e DB2 e, sobre isto, outros respondentes sugeriram deixar apenas o conhecimento em SQL como mandatório, sugerindo que o fornecedor é irrelevante.

Alguns respondentes comentaram sobre Lambda ser um serviço e não um ecossistema, *framework* ou bancos de dados. Neste sentido, optamos por retirar o termo da classificação proposta após validar que a informação estava correta.

Um ponto importante levantado por diversos respondentes é o fato de não ser citado nenhum *framework* que reflita o ciclo de um projeto de ciência de dados, como por exemplo

CRISP-DM ou KDD. Isto foi endereçado nesta classificação.

Consideradas as análises acima, propomos a classificação atualizada abaixo:

- a) MANDATÓRIO: SQL (em geral) e *frameworks* de projeto de ciência de dados, por exemplo CRISP-DM;
- b) DESEJÁVEL: Hadoop/MapReduce, Spark, NoSQL;
- c) DIFERENCIAL: MongoDB, Cassandra, Hbase, Snowflake, Cloudera, HorthonWorks.

3.9.4.7 Técnicas de *machine learning* e *deep learning*

A classificação apresentada no modelo proposto foi a seguinte:

- a) MANDATÓRIO: Regressão linear e logística, *clustering*, Random Forest;
- b) DESEJÁVEL: Redes neurais, NLP, inferência bayesiana, SVM, Gradient Boost;
- c) DIFERENCIAL: Ensemble, GLM, CN.

No questionário, a pergunta aberta “Tem algum comentário sobre a lista acima?” recebeu 81 respostas com sugestões ou comentários.

Especificamente neste item do questionário, a avaliação de especialistas foi de grande valia, uma vez que o campo de estudo das técnicas de inteligência artificial é muito amplo e foi possível contar com opiniões de profissionais de diversas áreas de atuação. Seguem exemplos de comentários que, após análise e confirmação, foram utilizados para ajustes na classificação proposta:

- a) “Random Forest é específico, melhor utilizar algoritmos baseados em árvore de decisão”.
De forma análoga, optamos pelo mesmo critério em relação à Gradient Boost;
- b) “CNN está contido em redes neurais”;
- c) “GLM é redundante se já estiverem citados modelos de regressão”;
- d) “NLP é uma área muito abrangente. E, nessa linha porque NLP e não visão computacional, por exemplo?”

Alguns respondentes levantaram questões que este tópico (“Técnicas de *machine learning* e *deep learning*”) deveria considerar técnicas estatísticas. Por exemplo, “...o nome do tópico está errado. Regressão linear e logística, inferência bayesiana, por exemplo, são técnicas estatísticas e não *de machine learning*. Mas a ideia está correta.” De acordo com Shmueli et al.,

Because of the hybrid parentry of data mining, its practitioners often use multiple terms to refer to the same thing. For example, in the machine learning (artificial intelligence) field, the variable being predicted is the output variable or target variable. To a statistician, it is the dependent variable or the response. (Shmueli et al., 2018, p. 27)

Conquanto entendamos que este é um ponto válido para discussão, utilizamos como base a opinião do autor acima citado e, para facilitar o entendimento, mantivemos o nome do tópico como definido originalmente.

Consideradas as análises acima, propomos a classificação atualizada abaixo:

- a) MANDATÓRIO: Regressão linear e logística, *clustering*, algoritmos baseados em árvores de decisão (por exemplo: Random Forest e Gradient Boost);
- b) DESEJÁVEL: Redes neurais, inferência bayesiana, SVM, NLP, visão computacional;
- c) DIFERENCIAL: *Ensemble* (combinação de classificadores).

3.9.4.8 Visualização de dados

A classificação apresentada no modelo proposto foi a seguinte:

- a) MANDATÓRIO: Microsoft PowerBI;
- b) DESEJÁVEL: Tableau, Qlik;
- c) DIFERENCIAL: Google Data Studio, Metabase, Looker, Microstrategy, Pentaho.

No questionário, a pergunta aberta “Acrescentaria alguma ferramenta à lista acima?” recebeu 125 respostas com sugestões ou comentários.

A classificação original foi realizada com base na literatura e, principalmente, na análise de vagas. A principal crítica nos comentários dos respondentes está relacionada ao fato de que a maioria das ferramentas citadas são ferramentas de analistas de BI, e não ferramentas de cientistas de dados (exemplos: “PowerBi não é ciência de dados, é BI”, “Foram descritas ferramentas de BI, que geralmente pessoas que estão na área de BI usam, e não cientistas de dados” e “Todas são ferramentas de BI”, “Não acredito que ferramentas de BI sejam mandatórias apesar de ser um pedido frequente nas vagas” e “Tais ferramentas é necessário ao um analista bi e ã a um cientista de dados (SIC)”).

Uma conclusão, que está presente na Seção 4, é a distância que existe entre as empresas contratantes e a realidade da prática de ciência de dados do ponto de vista de seus praticantes. Enquanto as empresas demandam, em vagas de ciência de dados, as ferramentas apresentadas, a maior parte dos respondentes cita pacotes de visualização que estão disponíveis no contexto

das próprias linguagens utilizadas (por exemplo Matplotlib, Seaborn e Dash para Python e ggplot2 e Shiny para [R]).

Ademais, diversos respondentes consideram que, sobre visualização de dados, o importante é conhecer os conceitos, sendo que a ferramenta é um conhecimento secundário (“O importante é saber apresentar os dados, a ferramenta é irrelevante”).

Ainda demonstrando a distância entre as empresas contratantes e a prática de ciência de dados em si, diversos respondentes citam Google Data Studio e Looker como ferramentas importantes no contexto do trabalho de cientistas de dados. Mesmo que sejam citadas nas vagas analisadas, elas aparecem de forma bem mais discreta que PowerBI, Tableau ou Qlik.

Finalmente, também é prevalente a crítica sobre a forma como a classificação foi apresentada originalmente, dando a entender que cientistas de dados devem conhecer de forma mandatória o PowerBI (que aparece como o mais citado nas vagas analisadas) e, também, de forma diferencial, Tableau e Qlik. Na verdade, as ferramentas podem ser consideradas como equivalentes e o mais correto seria apresentá-las desta forma.

Consideradas as análises acima, propomos a classificação atualizada abaixo:

- a) MANDATÓRIO: Utilização de visualização de dados em geral, e de pacotes de visualização em particular (por exemplo: Matplotlib, Seaborn e Dash para Python e ggplot2 e Shiny para [R]);
- b) DESEJÁVEL: Microsoft PowerBI, Tableau, Qlik, Google Data Studio ou Looker;
- c) DIFERENCIAL: Microstrategy, Pentaho.

3.9.4.9 Comentários sobre a forma de segregação do modelo

No questionário, a pergunta aberta “Você acredita que a forma como o modelo está segregado (*soft skills*, *hard skills*, ferramentas) é adequado? Entende que há uma forma melhor de separação?” recebeu 153 respostas com sugestões ou comentários.

Dos comentários recebidos, apenas 3 deles são categóricos em relação à discordância da forma de segregação proposta sem, entretanto, sugerir o que poderia ser modificado. Adicionalmente, os 3 respondentes não registraram concordância em serem contactados para maiores esclarecimentos.

Por outro lado, a ampla maioria dos comentários foram favoráveis sobre a forma como o modelo foi segregado. Um dos respondentes, inclusive, comentou sobre o alinhamento do

modelo com a metodologia de Recursos Humanos “CHA” (Conhecimentos/ferramentas, Habilidades/*hard skills* e Atitudes/*soft skills*).

Particularmente, um dos respondentes comentou “acho que estar dessa forma facilita aos recrutadores a entender o básico do que procurar em uma pessoa cientista de dados”, o que está em linha com uma das justificativas apresentadas na Seção 1.7 do estudo: “Esta informação poderá ser útil [...] (c) para empresas publicarem vagas com maior clareza e, conseqüentemente, atraírem candidatos mais assertivos para essas posições e, com isso, melhorarem a produtividade e diminuir a rotatividade de colaboradores.”

Ainda em relação à justificativa do estudo, um dos respondentes comentou “[que] ajuda entender bem como trilhar um desenvolvimento de estudos”, que está alinhado com a justificativa de que “Esta informação poderá ser útil (a) para cidadãos, particularmente jovens, no momento de definição de seus primeiros passos profissionais, que desejam tornar-se cientistas de dados”.

Outro comentário, novamente, reforça a questão da super-qualificação: “Entendo que está bem postado. Contudo, é muito difícil encontrar um profissional que domine todas essas habilidades”.

Dois respondentes comentaram sobre a necessidade do desenvolvimento de modelos que trouxessem uma separação indicando o nível de proficiência do cientista de dados, como, por exemplo, júnior, pleno e sênior. Conquanto entendamos que este é um comentário válido, ele está além dos objetivos deste estudo, e foi referenciado na Seção 4.6, sobre estudos futuros.

4 APRESENTAÇÃO DOS RESULTADOS E PROPOSTAS DE ESTUDOS FUTUROS

O estudo foi concluído com êxito no sentido de que respondeu à questão de pesquisa (“quais aspectos definem um cientista de dados, sob as perspectivas da sua formação, de suas habilidades e das ferramentas que utiliza?”), bem como atingiu os objetivos propostos, tanto o primário como os secundários.

A leitura da Seção 3, que demonstra metodologicamente como foi realizada a pesquisa, dada sua extensão e a forma como foi realizada, já apresenta alguns resultados parciais. Nesta seção, no entanto, são apresentados formalmente os resultados encontrados, de forma consolidada, sendo o principal deles o modelo conceitual para cientistas de dados, que é o objetivo primário deste estudo.

Conforme mencionado na justificativa (Seção 1.7), os resultados encontrados contribuirão para a discussão sobre a definição do que é e o que faz um cientista de dados, e quais são as áreas de formação, quais as habilidades necessárias e as principais ferramentas utilizadas, e esta informação será ser útil (a) para cidadãos, particularmente jovens no momento de definição de seus primeiros passos profissionais, que desejam tornar-se cientistas de dados; (b) para profissionais já maduros, ou sem oportunidades de trabalho no seu ofício corrente, que percebem-se vislumbrando outra profissão; e (c) para empresas publicarem vagas com maior clareza e, conseqüentemente, atraírem candidatos mais assertivos para essas posições e, com isso, melhorarem a produtividade e diminuir a rotatividade de colaboradores.

Especificamente em relação ao item (c) acima, Markow et al. (2017), em seu estudo sobre o mercado de trabalho de ciência de dados, identificaram que existe um desbalanceamento entre oferta e demanda, que é agravada pela falta de uma estrutura comum e vernacular nas publicações de vagas e suas respectivas habilidades. Cargos não são consistentes em muitos casos: um empregado denominado “cientista de dados” em uma empresa pode possuir habilidades diferentes de um “cientista de dados” em outra empresa, dificultando a análise ampla do perfil deste cargo. O estudo dos autores, desta forma, corrobora uma das justificativas deste estudo, e sugere a existência de grupos ou famílias de cientistas de dados. Este é um dos resultados que será apresentado a seguir, na Seção 4.3.

Adicionalmente, o método utilizado, expandido e aprimorado a partir do trabalho de Hu et al. (2018), com o uso extensivo de recursos de processamento de linguagem natural e mineração de texto, poderá ser automatizado e utilizado por outros autores para futuros estudos

de perfis de profissionais, inclusive para outras profissões que não cientistas de dados.

4.1 MODELO CONCEITUAL PARA CIENTISTAS DE DADOS


Conforme apresentado na Seção 1.6, o objetivo primário deste projeto é a definição de um modelo conceitual para explicar a função de um cientista de dados, considerando a proposta de uma definição de sua atuação e áreas de formação, bem como considerando o conjunto de suas habilidades e as principais ferramentas utilizadas por esses profissionais.

A Figura 13, na Seção 3.8, apresentou um modelo conceitual prévio, elaborado com base na literatura, no levantamento de dados de mercado e nos dados secundários da pesquisa realizada pelo grupo Data Hackers Brasil em 2019.

Este modelo foi então publicado para a validação de especialistas (processo detalhado na Seção 3.9), sendo que mais de 200 respostas foram coletadas e o nível de concordância global dos respondentes foi de 75%, equivalente a nota 3 de uma escala Likert de 4 pontos (1: discordo muito, 2: discordo, 3: concordo; 4: concordo muito). Todas as notas foram acompanhadas de perguntas abertas que foram analisadas na Seção 3.9.4.

A Figura 16 apresenta o modelo final proposto, considerando todas as análises realizadas.

Figura 16 – Modelo conceitual para cientistas de dados



Mais informações www.fabianocastello.com.br/cd Revisão: Jun/21; © 2021 Fabiano Castello

Fonte: elaborado pelo autor.

4.2 DINAMISMO DA PROFISSÃO DE CIENTISTA DE DADOS

Com base nas análises realizadas na literatura, nas vagas pesquisadas, nos comentários dos especialistas na pesquisa do Data Hackers BR, pode ser constatado que ciência de dados é um campo extremamente dinâmico, com novas ferramentas e soluções sendo criadas e adotadas pelo mercado de forma constante. Isto é confirmado pelos já citados Salado-Cid et al. (2018), que afirmam que cientistas de dados dependem de um arcabouço de infraestruturas e aplicações para realizar seu trabalho. Por ser um campo amplo, existem muitas tecnologias e técnicas, não apenas tradicionais como também emergentes, que crescem anualmente, criando um cenário heterogêneo.

Machine learning, uma das atividades centrais da profissão de cientista de dados, vem alcançando sucessos consideráveis nos últimos anos. No entanto, esse sucesso depende crucialmente de especialistas que selecionam recursos, fluxos de trabalho, paradigmas de aprendizagem de máquina, algoritmos e seus hiperparâmetros apropriados. O rápido crescimento dos aplicativos de aprendizado de máquina criou uma demanda por métodos de aprendizado de máquina prontos para uso, que podem automatizar uma série de atividades normalmente realizadas, de forma manual, por cientistas de dados. Segundo ICML (2017), esta área de pesquisa que visa a automação progressiva do aprendizado de máquina denomina-se AutoML, e, apesar de baseada em um conceito antigo, vem ganhando espaço através de uma série de ferramentas que têm sido criadas para este fim.

Um exemplo de AutoML que mostra o dinamismo da profissão é a ferramenta PyCaret¹² (Hotti & Virpi, 2021). Segundo a documentação da ferramenta, a PyCaret é definida conforme abaixo:

PyCaret is an open-source, low-code machine learning library in Python that automates machine learning workflows. It is an end-to-end machine learning and model management tool that speeds up the experiment cycle exponentially and makes you more productive. In comparison with the other open-source machine learning libraries, PyCaret is an alternate low-code library that can be used to replace hundreds of lines of code with few words only. This makes experiments exponentially fast and efficient. PyCaret is essentially a Python wrapper around several machine learning libraries and frameworks such as scikit-learn, XGBoost, LightGBM, CatBoost, spaCy, Optuna, Hyperopt, Ray, and many more.

O objetivo de citar a PyCaret não é pela ferramenta em si, já que ela é apenas uma das várias opções de AutoML utilizadas pela comunidade de cientistas de dados, mas para destacar

¹² Recuperado de <https://pycaret.org/> Acesso em: 09 jun. 2021.

que é uma ferramenta extremamente recente. Sua primeira versão estável foi publicada em abril de 2020¹³, ou seja, há pouco mais de um ano em relação ao momento que esta dissertação foi finalizada. Desta forma, o dinamismo da profissão reflete-se também nas ferramentas utilizadas, uma vez que, analisando suas evoluções, é possível supor que, no médio prazo, outras ferramentas substituirão o PyCaret que, como mencionado, está presente neste estudo apenas como um exemplo.

O exemplo acima tem a intenção de *ressaltar a importância para um cientista de dados em manter-se atualizado*. Na fase de validação do modelo conceitual prévio, apenas dois respondentes citaram habilidades como autodidatismo e aprendizado contínuo como relevantes. Curiosamente, apesar do dinamismo da profissão ser evidente, estas habilidades não são prevalentes nem na literatura nem nas vagas analisadas.

4.3 “SUPER-QUALIFICAÇÃO” DE CIENTISTAS DE DADOS

A questão da “super-qualificação” de cientistas de dados, no sentido de que as habilidades requeridas são extensas e heterogêneas, numa atividade extremamente dinâmica, fica evidente no modelo conceitual, que considera a revisão da literatura, a análise das vagas, a pesquisa do grupo Data Hackers BR e, em sua versão final, o resultado da avaliação por especialistas.

Em relação aos *hard skills* e ferramentas de cientistas de dados, alguns respondentes na pesquisa de validação referem-se à questão da “super-qualificação” com comentários como: “essa lista de *skills* remete à definição de cientista de dados como um unicórnio” e “imagino que os pedidos [vagas] colocam o sarrafo bem alto buscando os unicórnios, mas que raramente encontram”. O termo “unicórnio” é recorrente na profissão de cientista de dados. Baškarada & Koronios (2017) fazem referência a cientista de dados como “a mais rara das raças”. Viaene (2013, p. 16) define cientistas de dados como “Super-heróis com todas as qualidades e conhecimentos para realizar um projeto de ciência de dados bem-sucedido”.

Considerando a possibilidade de poucos profissionais possuírem um número tão grande de habilidades, retoma-se a questão pendente na academia e no mercado, apresentada na Seção 1.6 da Introdução, sobre a existência de apenas um perfil de cientistas de dados com apenas um

¹³ Recuperado de <https://pypi.org/project/pycaret/1.0.0/> Acesso em: 09/06/2021.

conjunto de habilidades ou se é possível definir grupos ou famílias de cientistas de dados baseando-se no tipo de trabalho que realizam e nas ferramentas que utilizam.

Citados na revisão de literatura, De Mauro et al. (2017) afirmam que o atual estágio da disciplina de ciência de dados, sendo mais prática e experimental, e não teórica e metodológica, faz com que haja confusão entre o campo de estudo e o que os praticantes – no caso, os cientistas de dados – efetivamente fazem. A heterogeneidade das muitas facetas de cientistas de dados é uma indicação da confusão sobre esse conceito, que associou habilidades de forma indiscriminada sob o termo genérico “cientista de dados”. Empiricamente, é possível evidenciar que De Mauro et al. (2017) estão corretos de acordo com os resultados encontrados, ainda que, em sua revisão, tenham encontrado apenas dois grupos distintos, sendo um com foco em dados e tecnologia e outro com foco em negócios.

Outra evidência sobre a existência de grupos ou famílias de cientistas de dados, ainda não explicitamente definidos, é a diferença do entendimento sobre o que é um cientista de dados entre as empresas contratantes e a realidade da prática de ciência de dados do ponto de vista de seus praticantes. A Seção 3.7 demonstrou que não existem diferenças relevantes nas habilidades requeridas quando se comparam vagas entre cientistas de dados, analistas de dados, engenheiros de dados e arquitetos de dados. No entanto, no processo de validação do modelo conceitual, diversos especialistas sugeriram, de diversas formas, que as habilidades apresentadas eram de engenheiros de dados, e não de cientistas de dados. O que parece ser uma diferenciação clara para especialistas que, efetivamente, praticam ciência de dados no seu dia a dia, não é tão clara para as empresas que publicam as vagas. Em tempo, um estudo futuro direcionado para um melhor entendimento sobre semelhanças e diferenças, particularmente entre cientistas de dados e engenheiros de dados, está sugerido na Seção 4.6.3.

Feitas tais considerações, é possível concluir que, em face da impossibilidade de encontrar profissionais com todas as habilidades apresentadas, é provável que existam de fato grupos ou famílias de cientistas de dados. No entanto, em função da profissão ser recente, as fronteiras de tais grupos ou famílias ainda estão em definição.

4.4 NECESSIDADE DO CONHECIMENTO DO NEGÓCIO

A definição proposta de cientista de dados, apresentada no modelo conceitual (Seção 4.1), afirma que cientistas de dados são profissionais orientados para impactar o negócio. No contexto de um modelo conceitual, o termo é propositalmente genérico no sentido de abarcar

uma miríade de organizações, inclusive a academia. Independente da forma como impacta o negócio, uma das premissas é o próprio conhecimento do negócio. De fato, “ter conhecimento de domínio (negócio)” é apresentado como uma das habilidades mandatórias. Na literatura esta habilidade é prevalente, em geral utilizando o termo *domain knowledge*, como pode ser observado na Tabela 6.2 (Seção 2.5.3.3). Na revisão de literatura, onde foram analisadas 23 definições de cientistas de dados, o segundo termo mais frequente é “negócios”, sendo menos frequente que “dados” (termo mais frequente), porém mais frequente que outros como “*big data*”, “análise” e “computação”. Provost & Fawcett (2013) definem cientista de dados bem-sucedidos como capazes de entender problemas de negócios sob uma perspectiva de dados.

Em relação às áreas de formação, as principais encontradas, tanto na literatura como no levantamento de dados (vagas e pesquisa Data Hackers BR), têm perfil eminentemente técnico, como por exemplo ciência da computação, matemática, engenharia, estatística e física. A característica sobre a formação, associada à necessidade do conhecimento do negócio, torna a profissão de cientista de dados extremamente desafiadora, uma vez que este último decorre principalmente de experiência adquirida no dia a dia da profissão, ou seja, da vivência das situações que são traduzidas em tal conhecimento. O conhecimento amplo e necessário sobre negócios não decorre de aprendizados técnicos.

4.5 PYTHON COMO PRINCIPAL LINGUAGEM PARA CIENTISTAS DE DADOS

Segundo Masood (2020), Python é uma linguagem de programação de alto nível e propósito geral, criada por Guido van Rossum e cuja primeira versão data de 1991. Juntamente com a linguagem C, Python é hoje a linguagem mais utilizada globalmente segundo os índices TIOBE e PYPL (Statisticetimes, 2021). Python é considerado como primeira opção para projetos de ciência de dados pela quantidade de bibliotecas, por ser orientado a objetos e por ter uma curva de aprendizado breve.

O estudo de Masood (2020) comparou as linguagens Python, R e Julia processando dois conjuntos de dados usando técnicas de *machine learning*. Nos cinco quesitos analisados (facilidade de desenvolvimento, *on-line help*, complexidade computacional, carregamento e visualização de dados, reuso/manutenção), o Python foi melhor que as duas outras opções em todos os quesitos.

Neste estudo, Python e [R] são citados na literatura com a mesma frequência (16 artigos dos 54 analisados na revisão sistemática de literatura). No entanto, Python aparece como o 5º

termo mais frequente presente nos *corpora* de vagas revisadas (Tabela 16), sendo que [R] e Julia não aparecem nesta análise, que traz os 20 termos mais frequentes. Na análise das habilidades, no contexto de “Linguagens de programação ou *scripts*” (Tabela 23), Python lidera o número de citações com 744 ocorrências, contra 330 de [R] e apenas 19 de Julia.

Considerando que uma das justificativas deste estudo é trazer benefícios para cidadãos que desejam tornar-se cientista de dados, é importante ressaltar que, do ponto de vista de linguagem de programação, Python deve ser hoje considerada como a primeira linguagem a ser aprendida.

4.6 PROPOSTA DE ESTUDOS FUTUROS

A questão de pesquisa deste estudo é “quais aspectos definem um cientista de dados, sob as perspectivas da sua formação, de suas habilidades e das ferramentas que utiliza?”. Para responder esta pergunta foi definido um objetivo primário e três objetivos secundários, apresentados na Seção 1.6. Todos os objetivos foram atendidos, mas a condução do trabalho trouxe oportunidades de estudos futuros, tanto para aprofundar a pesquisa, como também para temas que são relevantes ao assunto tratado. As oportunidades identificadas são sugeridas a seguir.

4.6.1 PORTE DAS EMPRESAS CONTRATANTES

Refazer o estudo considerando o porte das empresas que procuram cientistas de dados. Em que sentido habilidades são requeridas, ou não, considerando empresas de grande porte que já possuem áreas de dados estruturadas, com profissionais especializados, em relação a empresas de médio porte que possuem poucos profissionais que se ocupam de atividades mais generalizadas?

4.6.2 REGULAÇÃO SOBRE INTELIGÊNCIA ARTIFICIAL, ÉTICA E PRIVACIDADE DE DADOS

A questão da ética é pouco citada, bem como questões sobre privacidade de dados. Em que sentido a ética e as novas regulamentações, como por exemplo o GDPR (“*General Data Protection Regulation*”), a LGPD (“Lei Geral de Proteção de Dados”) e a proposta sobre

regulamentação em inteligência artificial da Comunidade Europeia (*Publications Office of the EU*, 2021) afetam ou afetarão o trabalho dos cientistas de dados?

4.6.3 CIENTISTAS DE DADOS E ENGENHEIROS DE DADOS

Como foi mencionado na Introdução (Seção 1.6), existem questões pendentes na academia e no mercado sobre a existência de apenas um perfil de cientista de dados e apenas um conjunto de habilidades ou se é possível definir grupos ou famílias de cientistas de dados baseando-se no tipo de trabalho que realizam e nas ferramentas que utilizam. Os achados deste estudo, particularmente aqueles tratados na Seção 3.7, demonstraram que não existem diferenças relevantes nas habilidades requeridas quando se comparam vagas entre cientistas de dados, analistas de dados, engenheiros de dados e arquitetos de dados. No entanto, muitos respondentes da pesquisa de validação do modelo conceitual, de diversas formas, sugeriram que as habilidades apresentadas são de engenheiros de dados, e não de cientistas de dados.

Do ponto de vista dos praticantes de ciência de dados, quais habilidades são mandatórias, desejáveis e diferenciais quando segregados os grupos dos praticantes que se definem como cientistas de dados e aqueles que se definem como engenheiros de dados? Quais suas áreas de formação? Para ser um engenheiro de dados é preciso ter formação na área de engenharia? Tais questões poderiam ser endereçadas num estudo específico, bem como, especificamente para cientistas de dados, poderiam ser estudados perfis mais detalhados que, ainda que não presentes nos achados da revisão de literatura, apresentam fortes indícios de sua existência quando analisados do ponto de vista do mercado de trabalho.

4.6.4 REALIDADE BRASILEIRA EM RELAÇÃO À REALIDADE INTERNACIONAL

O estudo poderia ser feito considerando vagas de emprego de outros países, comparando os resultados com os apresentados neste estudo, cujo foco é o mercado brasileiro.

4.6.5 CRIAÇÃO DE MODELOS CONCEITUAIS CONSIDERANDO TEMPO DE EXPERIÊNCIA

O estudo poderia ser feito segregando habilidades mandatórias, desejáveis e diferenciais considerando o nível do profissional, como por exemplo júnior, sênior ou pleno.

4.6.6 CRIAÇÃO DE MODELOS CONCEITUAIS SEGREGANDO VAGAS PARA CONSULTORIA VS. VAGAS INTERNAS

Outra análise que pode ser realizada seria um estudo específico segregando vagas de emprego voltadas para a contratação de consultores ou vagas de emprego voltadas especificamente para empresas contratando profissionais diretamente.

4.6.7 FORMAÇÃO DE CIENTISTAS DE DADOS

Uma análise de currículos de universidades e instituições de ensino que oferecem formação para cientistas de dados poderia ser feita, de forma a concluir se as escolas estão oferecendo as habilidades que são requeridas para cientistas de dados. Ao longo do período deste estudo surgiram diversos cursos específicos para ciência de dados, como por exemplo, em 2020, o lançamento da formação de bacharelado em Ciência de Dados, ofertado pela Universidade de São Paulo no *campus* de São Carlos, no Instituto de Ciências Matemáticas e de Computação (ICMC)¹⁴, cujo objetivo é descrito abaixo:

O Bacharelado em Ciência de Dados visa formar um profissional capaz de “pensar com dados”. Diante da enorme quantidade de dados disponíveis atualmente, provenientes das mais variadas fontes (como web, dispositivos móveis, literaturas especializadas e sensores de todo tipo – como satélites, radares e até telescópios), essa capacidade é essencial para a produção de conhecimento novo, útil e relevante para apoio à decisão e resolução de problemas complexos da sociedade. (ICMC, 2020)

A análise de tais currículos e o cruzamento de dados com vagas de emprego, de forma equivalente ao que foi realizado neste estudo, podem identificar se as instituições de ensino estão preparadas para, de forma efetiva, atender o mercado do ponto de vista da formação dos profissionais que nele irão atuar.

4.6.8 FORMAÇÃO POR MEIO DE OUTRAS FORMAS DE APRENDIZADO

Ainda que a exigência de formação superior completa seja recorrente nas vagas que

¹⁴ Recuperado de <https://www.icmc.usp.br/graduacao/ciencia-de-dados-bacharelado>. Acesso em: 09/06/2021.

procuram cientistas de dados, como foi demonstrado na seção 3.9.4.2, diversos especialistas sugerem que a formação de um cientista de dados pode ser realizada por meio de outras formas de aprendizado, como demonstra o comentário de um dos especialistas: “resultados podem ser obtidos com uma série de minicursos em tópicos específicos”. Um estudo que permita segregar profissionais de ciência de dados por sua formação pode ser interessante no sentido, inclusive, de ratificar a necessidade de cursos superiores especificamente voltados para este fim.

REFERÊNCIAS¹⁵

- Abidin et al., W. Z., Ismail, N. A., Maarop, N., & Alias, R. A. (2017, August). Skills Sets Towards Becoming Effective Data Scientists. In *International Conference on Knowledge Management in Organizations* (pp. 97-106). Springer, Cham.
- Andrade, M. M. (2008). *Como preparar trabalhos para cursos de pós-graduação: Noções práticas*. 7a ed. São Paulo: Atlas.
- Attwood, T. K., Blackford, S., Brazas, M. D., Davies, A., & Schneider, M. V. (2017). A global perspective on evolving bioinformatics and data science training needs. *Briefings in Bioinformatics*, 20(2), 398-404.
- Baškarada, S., & Koronios, A. (2017). *Unicorn data scientist: the rarest of breeds*. Program.
- Baumer, B. S. (2017). Lessons from between the white lines for isolated data scientists. *The American Statistician*, 72(1), 66-71.
- Belloum, A. S., Koulouzis, S., Wiktorski, T., & Manieri, A. (2019). Bridging the demand and the offer in data science. *Concurrency and Computation: Practice and Experience*, 31(17), e5200.
- Bird S., Klein E., Loper E. (2009). *Natural Language Processing with Python*. O'Reilly Media Inc. Recuperado de <http://nltk.org/book> Acesso em: 09/06/2021.
- Bloomberg, L. D., & Volpe, M. (2015). Developing and presenting your literature review. In *Completing your qualitative dissertation: A road map from beginning to end*.
- Bunney, S. (1968) How to Find a Scientist. *Nature* Vol. 217, p. 1083.
- Burtch, L. (2016) *Data Science Salary Study*, Recuperado de <http://www.burtchworks.com/2016/02/08/predictions-for-the-2016-analytics-data-science-hiring-market> Acesso em: 09/06/2021.
- Cao, L. (2017). Data science: a comprehensive overview. *ACM Computing Surveys (CSUR)*, 50(3), 1-42.
- Carillo, K. D. A. (2017). Let's stop trying to be "sexy" – preparing managers for the (big) data-driven business era. *Business Process Management Journal*.
- Case, Thomas L., Adrian Gardiner, Paige Rutner, John N. Dyer. (2012). "A LinkedIn Analysis of Career Paths of Information Systems Alumni." *Journal of the Southern Association for Information System*, 1 (1): 1-13. doi: 10.3998/jsais.11880084.0001.102 <https://digitalcommons.georgiasouthern.edu/info-sys-facpubs/10>

¹⁵ De acordo com o estilo APA – American Psychological Association.

- Cegielski C. G., & Jones-Farmer, L. A. (2016). Knowledge, skills, and abilities for entry-level business analytics positions: A multi-method study. *Decision Sciences Journal of Innovative Education*, 14(1), 91-118.
- Chatfield, A. T., Shlemoon, V. N., Redublado, W., & Rahman, F. (2014). *Data scientists as game changers in big data environments*.
- Chen, H., Chiang, R. H. & Storey, V. C. (2012) *Business Intelligence and Analytics: From Big Data to Big Impact*. MIS quarterly, Vol. 36, No. 4, pp. 1165-1188
- Choudhury, G. S. (2008). Case study in data curation at Johns Hopkins University. *Library Trends*, 57(2), 211-220.
- Chuprina S., Igor Postanogov I. & Kostareva E. (2018) A Way How to Impart Data Science Skills to Computer Science Students Exemplified by OBDA-Systems. *International Conference on Computational Science - ICCS 2017*, Zurich, Switzerland.
- Cleveland, W. S. (2001), "Data Science: An Action Plan for Expanding the Technical Areas of the Field of Statistics," *International Statistical Review*, 69, 21–26. doi:10.1111/j.1751-5823.2001.tb00477.x.
- Columbus, L. (2018), "Data Scientist Is the Best Job in America According to Glassdoor's 2018 Rankings". Recuperado de <https://www.forbes.com>. Acesso em: 09/06/2021.
- Columbus, L. (2019), "Data Scientist Leads 50 Best Jobs In America For 2019 According To Glassdoor", Recuperado de <https://www.forbes.com>. Acesso em: 09/06/2021.
- Cooper, D. R., & Schindler, P. S. (2014). *Métodos de pesquisa em Administração* - 12ª edição. McGraw Hill Brasil.
- Costa, C., & Santos, M. Y. (2017). The data scientist profile and its representativeness in the European e-Competence framework and the skills framework for the information age. *International Journal of Information Management*, 37(6), 726-734.
- Data Hackers (2020), *Data Hackers Survey 2019: Resultados da pesquisa de mercado de Data Science realizada pelo grupo Data Hackers*. Recuperado de <https://www.kaggle.com/dataset/521f9e1481fa53fb8a94a6185203a692bd98a1feb34d9e89901e1aed5554cca3/version/1>. Acesso em: 11/05/2020.
- Davenport, T., & Patil, D. (2012). Data Scientist: The Sexiest Job of the 21st Century. *Harvard Business Review*. Recuperado de <https://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century>. Acesso em: 11/05/2020.
- Davenport, H & Patil, D. J. (2012) "Data Scientist: The Sexiest Job of the 21st Century." *Harvard Business Review* 90, no. 10 (October 2012): 70–76.
- Debortoli, S., Müller, O., & vom Brocke, J. (2014). Comparing business intelligence and big data skills. *Business & Information Systems Engineering*, 6(5), 289-300.

- De Mauro, A., Greco, M., Grimaldi, M., & Nobili, G. (2016). Beyond data scientists: a review of big data skills and job families. *Proceedings of IFKAD*, 1844-1857.
- De Mauro, A., Greco, M., Grimaldi, M., & Ritala, P. (2017). Human resources for Big Data professions: A systematic classification of job roles and required skill sets. *Information Processing & Management*, 54(5), 807-817.
- Demchenko, Y., Belloum, A., Los, W., Wiktorski, T., Manieri, A., Brocks, H., ... & Brewer, S. (2016, December). EDISON data science framework: a foundation for building data science profession for research and industry. In *2016 IEEE International Conference on Cloud Computing Technology and Science (CloudCom)* (pp. 620-626). IEEE.
- Demchenko, Y., Belloum, A., de Laat, C., Loomis, C., Wiktorski, T., & Spekschoor, E. (2017, December). Customisable Data Science Educational Environment: From Competences Management and Curriculum Design to Virtual Labs On-Demand. In *2017 IEEE International Conference on Cloud Computing Technology and Science (CloudCom)* (pp. 363-368). IEEE.
- Demchenko, Y. (2018) *EDISON Data Science Framework: Part 1. Data Science Competence Framework* (CF-DS). Pre-Release 3. Recuperado de https://github.com/EDISONcommunity/EDSF/blob/master/data-science-competence-framework/EDISON_CF-DS-release3-v09.pdf Acesso em: 22/05/2019.
- Demchenko, Y., Communiello, L., & Reali, G. (2019, March). Designing Customisable Data Science Curriculum Using Ontology for Data Science Competences and Body of Knowledge. In *Proceedings of the 2019 International Conference on Big Data and Education* (pp. 124-128).
- Dhar, V. (2013). Data science and prediction. *Communications of the ACM*, 56(12), 64-73.
- Dichev, C., & Dicheva, D. (2017, January). Towards Data Science Literacy. In *ICCS* (pp. 2151-2160).
- D'Ignazio, C., Bhargava, R. (2016). DataBasic: design principles, tools and activities for Data Literacy Learners. *The Journal of Community Informatics*, 12(3), 83-107.
- Ecleo J., Galido A, (2017) Surveying LinkedIn Profiles of Data Scientists: The Case of the Philippines, *Procedia Computer Science*, Volume 124, Pages 53-60, ISSN 1877-0509, <https://doi.org/10.1016/j.procs.2017.12.129>.
- Finzer, W. (2013) *The data science education dilemma. Technology Innovations in Statistics Education*, Vol. 7, No. 2
- Fleury, M.T. L. & Fleury, Af (2001). Construindo o conceito de competência. *Revista de Administração Contemporânea*, 5(spe), 183-196. <https://dx.doi.org/10.1590/S1415-65552001000500010>.

- Gardiner, A., Aasheim, C., Rutner, P., & Williams, S. (2017). Skill requirements in big data: A content analysis of job advertisements. *Journal of Computer Information Systems*, 58(4), 374-384.
- Gartner (2021). *Magic Quadrant for Analytics and Business Intelligence Platforms*. Recuperado de <https://www.gartner.com/doc/reprints?ct=200330&id=1-1YOXON7Q>. Acesso em: 18/02/2021.
- Gehl, R. W. (2015). Sharing, knowledge management and big data: A partial genealogy of the data scientist. *European journal of cultural studies*, 18(4-5), 413-428.
- Gibert, K., Horsburgh, J. S., Athanasiadis, I. N., & Holmes, G. (2018). Environmental data science. *Environmental Modelling & Software*, 106, 4-12.
- Gil, A. C. (2008). *Métodos e técnicas de pesquisa social*. 6a ed. São Paulo: Atlas.
- Granville, V. (2014). *Developing analytic talent: Becoming a data scientist*. John Wiley & Sons.
- Harris D. (2013). Kaggle now has 100K data scientists, but what's a data scientist? *GigaOM.com*. Recuperado de <https://gigaom.com/2013/07/11/kaggle-now-has-100k-data-scientists-but-whats-a-data-scientist/> Acesso em: 31/03/2020.
- Hotti, Virpi (2021). *Journal of Physics: Conference Series*, 1828, 012015.
- Hu, H., Luo, Y., Wen, Y., Ong, Y. S., & Zhang, X. (2018). How to find a perfect data scientist: A distance-metric learning approach. *IEEE Access*, 6, 60380-60395.
- ICML (2017) Automatic Machine Learning Workshop ICML 2017. *International Conference on Machine Learning*. Sydney 2017. Recuperado de <https://sites.google.com/site/automl2017icml>. Acesso em: 02/06/2021.
- Kaleda, K., & Fenstermacher, L. (2018, April). Analyst as data scientist: surfing vs drowning in the information environment. In *Next-Generation Analyst VI* (Vol. 10653, p. 106530B). International Society for Optics and Photonics.
- Kitchenham, B. (2004). *Procedures for performing systematic reviews*. Keele, UK, Keele University, 33(TR/SE-0401), 28.
- Knorr, E. M., Riva, G. V. D., & Vakarelov, O. (2018, May). Anatomy of a New Data Science Course in Privacy, Ethics, and Security. In *Proceedings of the 23rd Western Canadian Conference on Computing Education* (pp. 1-5).
- Konder, L. (1999) "Mercadoria". In: *Marx – vida e obra*. São Paulo: Paz e Terra, 1999, p.121-122.
- Kotzé, E. (2017, July). A survey of data scientists in South Africa. In *Annual Conference of the Southern African Computer Lecturers' Association* (pp. 175-191). Springer, Cham.

- Kross, S., & Guo, P. J. (2019, May). Practitioners teaching data science in industry and academia: Expectations, workflows, and challenges. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems* (pp. 1-14).
- Lakatos, E. M., & Marconi, M. A. (2003). *Fundamentos metodologia científica*. 5a ed. São Paulo: Atlas.
- Laker, D. R., & Powell, J. L. (2011). The differences between hard and soft skills and their relative impact on training transfer. *Human Resource Development Quarterly*, 22(1), 111–122.
- Laney, D., Kart, L., Jain, A. & Linden, A. (2015) *How Data Scientist Skills and Qualifications Differ From Those of BI Analysts and Statisticians*. Gartner.
- Leech, N. L., & Onwuegbuzie, A. J. (2009). A typology of mixed methods research designs. *Quality & Quantity*, 43(2), 265-275.
- Linden, A., Kart, L., Randall, L., Beyer, M. A., Duncan, A. D. (2015) *Staffing Data Science Teams*. Gartner.
- LinkedIn (2020) *Contrato do Usuário*. Em vigor a partir de 6 de janeiro de 2020. Recuperado de <https://www.linkedin.com/legal/user-agreement> Acesso em 24/4/2020.
- Loukides, M. (2012) What is data science? O'Reilly Media, Sebastopol
- Lourenco, R. (2019) Demand for Data Scientists Far Exceeds Supply. Here's How Your Company Can Cope. *Dataconomy.com*. Recuperado de <https://dataconomy.com/2019/12/demand-for-data-scientists-far-exceeds-supply-heres-how-your-company-can-cope>. Acesso em: 28/2/2020.
- Liu, L., Zhang, H., Li, J., Wang, R., Yu, L., & Li, P. (2009). Building a community of data scientists: an explorative analysis. *Data Science Journal*, 0906040120-0906040120.
- Luna-Reyes, L. F. (2018). The search for the data scientist: creating value from data. *ACM SIGCAS Computers and Society*, 47(4), 12-16.
- Lundberg, S. & Lee, S.-I. (2017). *A unified approach to interpreting model predictions*. CoRR, abs/1705.07874.
- Manieri, A., Brewer, S., Riestra, R., Demchenko, Y., Hemmje, M., Wiktorski, T., ... & Frey, J. (2015, November). Data Science Professional uncovered: How the EDISON Project will contribute to a widely accepted profile for Data Scientists. In *2015 IEEE 7th International Conference on Cloud Computing Technology and Science (CloudCom)* (pp. 588-593). IEEE.
- Manning C. (1999) *Foundations of Statistical Natural Language Processing*, vol. 999. Cambridge, MA, USA: MIT Press.

- Markow, W., Braganza, S., Hughes, D., & Miller, S. (2017). *The Quant Crunch. How Demand for Data Science Skills Is Disrupting the Job Market*. Boston: Burning Glass Technologies.
- Marr, B. (2020). *Coronavirus: How Artificial Intelligence, Data Science And Technology Is Used To Fight The Pandemic*. Recuperado de <https://www.forbes.com/sites/bernardmarr/2020/03/13/coronavirus-how-artificial-intelligence-data-science-and-technology-is-used-to-fight-the-pandemic>. Acesso em: 20/04/2020.
- Masood, M. (2020). Comparison of Python, R and Julia w.r.t *Machine Learning*. 10.13140/RG.2.2.27590.29769.
- Matsubara, E. T., Martins, C. A., & Monard, M. C. (2003). Pretext: Uma ferramenta para pré-processamento de textos utilizando a abordagem bag-of-words. *Technical Report*, 209(4).
- Mattmann, C. A. (2013). A vision for data science. *Nature*, 493(7433), 473-475.
- Meyer, M. A. (2018). Healthcare data scientist qualifications, skills, and job focus: a content analysis of job postings. *Journal of the American Medical Informatics Association*, 26(5), 383-391.
- Mikalef, P., Giannakos, M. N., Pappas, I. O., & Krogstie, J. (2018). The Human Side of Big Data: Understanding the skills of the data scientist in education and industry. In *2018 IEEE Global Engineering Education Conference (EDUCON)* (pp. 503-512). IEEE.
- Mikalef, P., & Krogstie, J. (2019, April). Investigating the Data Science Skill Gap: An Empirical Analysis. In *2019 IEEE Global Engineering Education Conference (EDUCON)* (pp. 1275-1284). IEEE.
- Miller, G. J. (2019, June). The influence of big data competencies, team structures, and data scientists on project success. In *2019 IEEE Technology & Engineering Management Conference (TEMSCON)* (pp. 1-8). IEEE.
- Mohanty, S., Jagadeesh, M., & Srivatsa, H. (2013). Big data imperatives: Enterprise 'Big Data'warehouse, 'BI'implementations and analytics. Apress.
- Navarro, P., 2008. The MBA core curricula of top-ranked U.S. business schools: A study in failure? *Academy of Management Learning and Education*, 7(1), pp.108–123.
- Nolan, D., & Lang, D. T. (2015). Exploring Data Science Jobs with Web Scraping and Text Mining. *Data Science in R: A Case Studies Approach to Computational Reasoning and Problem Solving*, p. 457.
- Patil, D.J. 2011. "Building Data Science Teams: Data Science Teams Need People with the Skills and Curiosity." Recuperado de <http://radar.oreilly.com/2011/09/building-data-science-teams.html>. Acesso em: 18/11/2019.

- Pedersen, A. Y., & Caviglia, F. (2019). Data literacy as a compound competence. In *The 2018 International Conference on Digital Science* (pp. 166-173). Springer, Cham.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Vanderplas, J. (2011). Scikit-learn: Machine learning in *Python*. *The Journal of Machine Learning Research*, 12, 2825-2830.
- Perakslis, E. (2020). *A Primer on Biodefense Data Science for Pandemic Preparedness*. Patterns, 100018.
- Pires, F., Barbosa, J., & Leitão, P. (2018, July). Data scientist under the Da. Re perspective: analysis of training offers, skills and challenges. In *2018 IEEE 16th International Conference on Industrial Informatics (INDIN)* (pp. 523-528). IEEE.
- Polonsky, J. A., Baidjoe, A., Kamvar, Z. N., Cori, A., Durski, K., Edmunds, W. J., ... & de Waroux, O. L. P. (2019). Outbreak analytics: a developing data science for informing the response to emerging pathogens. *Philosophical Transactions of the Royal Society B*, 374(1776), 20180276.
- Provost, F. & Fawcett, T. (2013). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. *Silicon Valley Data Science*, Mountain View, CA, USA.
- Publications Office of the EU (2021) *Proposal for a Regulation of the European Parliament and the Council laying down requirements for Artificial Intelligence*. Recuperado de <https://op.europa.eu/en/publication-detail/-/publication/e4c43528-ccfc-11ea-adf7-01aa75ed71a1/language-en>. Acesso em: 20/5/2021.
- Ridsdale, C., Rothwell, J., Smit, M., Ali-Hassan, H., Bliemel, M., Irvine, D., Kelley, D., Matwin, S., and Wuetherick, B. (2015) *Strategies and Best Practices for Data Literacy Education: Knowledge Synthesis Report*. Dalhousie University. Recuperado de http://www.mikesmit.com/wp-content/papercite-data/pdf/data_literacy.pdf SCONUL Working Group on Information Literacy (2011). Acesso em: 20/04/2020.
- Sampieri, R. H., Collado, C. F., & Lucio, M. P. B. (2013). *Metodologia de pesquisa*. 5a ed. Porto Alegre: Penso.
- Salado-Cid, R., Ramírez, A., & Romero, J. R. (2018). On the need of opening the big data landscape to everyone: challenges and new trends. In *Digital Marketplaces Unleashed* (pp. 675-687). Springer, Berlin, Heidelberg.
- Santos, A. R. (1999). *Metodologia Científica – a construção do conhecimento*. 1a ed. Rio de Janeiro: DP&A.
- Selltiz, C., Wrightsman, L. S., & Cook, S. W. (1987). *Métodos de Pesquisa das Relações Sociais*. 2a ed. São Paulo: EPU.

- Shmueli, G., Bruce, P. C., Yahav, I., Patel, N. R., & Lichtendahl, K. C. (2018). *Data mining for business analytics: Concepts, techniques, and applications in R*.
- Statisticstimes (2021) *Top Computer Languages 2021*, Recuperado de <https://statisticstimes.com/tech/top-computer-languages.php>. Acesso em: 10/07/21.
- Swan, A., & Brown, S. (2008). *The skills, role and career structure of data scientists and curators: An assessment of current practice and future needs*.
- Tenório, T., Bittencourt, I. I., Isotani, S., & Silva, A. P. (2016). Does peer assessment in on-line learning environments work? A systematic review of the literature. *Computers in Human Behavior*, 64, 94–107. <https://doi.org/10.1016/j.chb.2016.06.020>
- Turck, M. (2019). *A Turbulent Year: The 2019 Data & AI Landscape*. Recuperado de <https://mattturck.com/data2019>. Acesso em: 11/06/2020.
- Van der Aalst, W. M. (2014). Data scientist: The engineer of the future. In *Enterprise interoperability VI* (pp. 13-26). Springer, Cham.
- Verma, A., Yurov, K. M., Lane, P. L., & Yurova, Y. V. (2019). An investigation of skill requirements for business and data analytics positions: A content analysis of job advertisements. *Journal of Education for Business*, 94(4), 243-250.
- Viaene, S. (2013). Data scientists aren't domain experts. *IT Professional*, 15(6), 12-17.
- Wallem, J. (2019) Can Outsourcing Data Science Fill The Jobs Shortage? Fayrix Believes So. *Forbes.com*. Recuperado de <http://forbes.com/sites/joewalleneurope/2019/03/26/can-outsourcing-data-science-fill-the-jobs-shortage-fayrix-believes-so>. Acesso em: 28/02/2020.
- Waller, M. A., & Fawcett, S. E. (2013). Data science, predictive analytics, and big data: a revolution that will transform supply chain design and management. *Journal of Business Logistics*, 34(2), 77-84.
- Whitby, g (2016) The Emergence of the Citizen Data Scientist, *CIO Insight*, Recuperado de <https://www.cioinsight.com/it-strategy/big-data/citizen-data-scientist.html> Acesso em: 01/03/2020.
- Wiktorski, T., Demchenko, Y., Belloum, A., & Shirazi, A. (2016). Quantitative and qualitative analysis of current data science programs from perspective of data science competence groups and framework. In *2016 IEEE International Conference on Cloud Computing Technology and Science (CloudCom)* (pp. 633-638). IEEE.
- Wiktorski, T., Demchenko, Y., & Belloum, A. (2017). Model Curricula for Data Science EDISON Data Science Framework. In *2017 IEEE International Conference on Cloud Computing Technology and Science (CloudCom)* (pp. 369-374). IEEE.
- Wilder, C. R., & Ozgur, C. O. (2015). Business analytics curriculum for undergraduate majors.

INFORMS Transactions on Education, 15(2), 180-187.

Wolff, A., Gooch, D., Cavero Montaner, J.J, Rashid, U., Kortuem, G., (2016). Creating an understanding of data literacy for a data-driven society. *The Journal of Community Informatics*, 12(3), 9-26.

Yan, D., & Davis, G. E. (2019). A First Course in Data Science. *Journal of Statistics Education*, 27(2), 99-109.

Yin, R. K. (2001). *Estudo de Caso: planejamento e métodos*. 2a ed. Porto Alegre: Bookman.

Yin, R. K. (2015). *Qualitative research from start to finish*. Guilford publications.

APÊNDICES

APÊNDICE A – Detalhamento da Coleta de Dados da Perspectiva de Mercado

A coleta de dados da perspectiva de mercado foi baseada nas etapas apresentadas na Seção 3.5.1.1, e sua execução foi realizada como segue.

Ambiente de coleta

Conforme mencionado na Seção 3.5.1.1(b), foi utilizada linguagem Python, em sua versão 3.7. Para a realização do *web scrap*, foram utilizados pacotes Python padrão, como por exemplo Pandas, para manipulação de dados, mas, principalmente, o pacote Selenium para coleta de dados de forma automatizada a partir de navegador Chrome do Google.

Os *scripts* foram desenvolvidos utilizando ambiente Jupyter Notebook em sistema operacional Windows. Após o desenvolvimento foi gerado um *script* Python (“*.py*”) que foi executado de forma automática utilizando o mecanismo de *scheduler* do sistema operacional Windows.

Sítio da coleta e geração de chaves de pesquisa

Conforme mencionado na Seção 3.5.1.1, a pesquisa foi concentrada no sítio de vagas de emprego do sítio LinkedIn, utilizando o endereço e as palavras-chave mencionadas na mesma seção:

- a) cientista de dados;
- b) ciência de dados;
- c) *data scientist*;
- d) especialista de dados;
- e) mineração de dados;
- f) modelagem;
- g) *big data*;
- h) *machine learning*;
- i) gerente de dados;
- j) engenheiro de dados;
- k) *data engineer*;
- l) analista de dados;

m) arquiteto de dados;

n) *analytics*.

Uma característica do sítio de vagas do LinkedIn.com é que este identifica, através do IP da máquina que está realizando a pesquisa, o local geográfico e, portanto, a pesquisa tende a apresentar resultados que estão geograficamente próximos. Ainda que isto não esteja explicitamente declarado no sítio, isto foi detectado empiricamente nas primeiras pesquisas realizadas.

Uma vez que o escopo deste trabalho, conforme mencionado na Seção 1.8, é o mercado brasileiro, a limitação do sítio LinkedIn foi contornado criando palavras-chave combinadas com cidades brasileiras. Utilizar a geografia como parte das chaves de pesquisa foi também uma estratégia adotada por Hu et al. (2018) em seu artigo, que é uma das referências metodológicas deste estudo.

Utilizando como referência a Wikipedia (Lista de municípios do Brasil acima de cem mil habitantes), foram consideradas 326 cidades, bem como as 27 unidades federativas e distrito federal, produzindo 350 localizações geográficas, já considerando a eliminação de duas duplicações (“São Paulo” e “Rio de Janeiro” são ambos nomes de cidades e de unidades federativas). As cidades consideradas foram, em ordem alfabética, as seguintes: abaetetuba, abreu e lima, acre, águas lindas de goiás, alagoas, alagoinhas, almirante tamandaré, altamira, alvorada, amapá, amazonas, americana, ananindeua, angra dos reis, anápolis, aparecida de goiânia, apucarana, aracaju, aracruz, araguari, araguaína, arapiraca, arapongas, araraquara, araras, araruama, araucária, araxá, araçatuba, ariquemes, assis, atibaia, açailândia, bacabal, bagé, bahia, balneário camboriú, barbacena, barcarena, barra do pirai, barra mansa, barreiras, barretos, barueri, bauru, belford roxo, belo horizonte, belém, bento gonçalves, betim, birigui, blumenau, boa vista, botucatu, bragança, bragança paulista, Brasília, breves, brusque, cabo de santo agostinho, cabo frio, cachoeirinha, cachoeiro de itapemirim, caieiras, camaragibe, camaçari, cambé, cametá, campina grande, campinas, campo grande, campo largo, campos dos goytacazes, canoas, caraguatatuba, carapicuíba, cariacica, caruaru, cascavel, castanhal, catalão, catanduva, caucaia, caxias, caxias do sul, ceará, chapecó, codó, colatina, colombo, conselheiro lafaiete, contagem, coronel fabriciano, corumbá, cotia, crato, criciúma, cubatão, cuiabá, Curitiba, diadema, distrito federal, divinópolis, dourados, duque de caxias, embu das artes, erechim, espírito santo, eunápolis, fazenda rio grande, feira de santana, ferraz de vasconcelos, florianópolis, formosa, fortaleza, foz do iguaçu, franca, francisco morato, franco da rocha,

garanhuns, goiás, goiânia, governador valadares, gravataí, guarapari, guarapuava, guaratinguetá, guarujá, guarulhos, hortolândia, ibirité, igarassu, iguatu, ilhéus, imperatriz, indaiatuba, ipatinga, itabira, itaboraí, itabuna, itacoatiara, itaguaí, itaituba, itajaí, itanhaém, itapecerica da serra, itaperuna, itapevi, itapipoca, itaquaquecetuba, itatiba, itu, ituiutaba, itumbiara, jaboatão dos guararapes, jacareí, jandira, japeri, jaraguá do sul, jataí, jáú, jequié, jiparaná, joinville, joão pessoa, juazeiro, juazeiro do norte, juiz de fora, jundiaí, lagarto, lages, lauro de freitas, lavras, leme, limeira, linhares, londrina, luziânia, macapá, macaé, maceió, magé, mairiporã, manaus, marabá, maracanaú, maranguape, maranhão, maricá, maringá, marituba, marília, mato grosso, mato grosso do sul, mauá, mesquita, minas gerais, mogi das cruzeiras, mogi guaçu, montes claros, mossoró, muriaé, natal, nilópolis, niterói, nossa senhora do socorro, nova friburgo, nova iguaçu, nova serrana, novo gama, novo hamburgo, olinda, osasco, ourinhos, palhoça, palmas, paragominas, paranaguá, paraná, parauapebas, paraíba, parintins, parnamirim, parnaíba, pará, passo fundo, passos, patos, patos de minas, paulista, paulo afonso, paulínia, paço do lumiar, pelotas, pernambuco, petrolina, petrópolis, piauí, pindamonhangaba, pinhais, piracicaba, piraquara, ponta grossa, porto alegre, porto seguro, porto velho, pouso alegre, poá, poços de caldas, praia grande, presidente prudente, queimados, recife, resende, ribeirão das neves, ribeirão pires, ribeirão preto, rio branco, rio claro, rio das ostras, rio de janeiro, rio grande, rio grande do norte, rio grande do sul, rio verde, rondonópolis, rondônia, roraima, sabará, salto, salvador, santa bárbara do oeste, santa catarina, santa cruz do capibaribe, santa cruz do sul, santa luzia, santa maria, santa rita, santana, santana de parnaíba, santarém, santo andré, santo antônio de Jesus, santos, sapucaia do sul, senador canedo, sergipe, serra, sertãozinho, sete lagoas, simões filho, sinop, sobral, sorocaba,umaré, suzano, são bernardo do campo, são caetano do sul, são carlos, são felix do xingu, são gonçalo, são gonçalo do amarante, são José, são José de ribamar, são José do rio preto, são José dos campos, são José dos pinhais, são João de meriti, são leopoldo, são lourenço da mata, são luís, são mateus, são paulo, são pedro da aldeia, são vicente, taboão da serra, tailândia, tangará da serra, tatuí, taubaté, teixeira de freitas, teresina, teresópolis, teófilo otoni, timon, tocantins, toledo, trindade, três lagoas, tubarão, tucuruí, uberaba, uberlândia, ubá, umuarama, uruguaiana, valinhos, valparaíso de goiás, varginha, vespasiano, viamão, vila velha, vilhena, vitória, vitória da conquista, vitória de santo antão, volta redonda, votorantim, várzea grande e várzea paulista.

As pesquisas foram iniciadas considerando a pesquisa das 14 palavras-chave sem localização geográfica e, também, a combinação das 14 palavras-chave associadas às 350

localizações geográficas. Utilizando esta forma de pesquisa, a cada ciclo de *web scrap* foram realizadas 4.914 pesquisas que, para seu processamento, demandaram cerca de 50 horas e, em sua maioria, resultavam em muitas pesquisas sem nenhum resultado.

Visando a otimização da coleta de dados, os resultados obtidos foram analisados e então foram determinadas 40 cidades que apresentavam resultados de forma regular. As cidades, em ordem alfabética, foram as seguintes: aracaju, belo horizonte, belém, blumenau, brásilia, campinas, campo grande, cuiabá, curitiba, florianópolis, fortaleza, goiânia, joinville, João Pessoa, Juiz de Fora, Londrina, Macapá, Maceió, Manaus, Maringá, Natal, Niterói, Porto Alegre, Porto Velho, Recife, Ribeirão Preto, Rio de Janeiro, Salvador, Santos, Sorocaba, São Bernardo do Campo, São Carlos, São José do Rio Preto, São José dos Campos, São Luís, São Paulo, Teresina, Uberlândia, Vila Velha e Vitória

A pesquisa otimizada considerou as 14 palavras-chave sem localização geográfica e, também, a combinação das 14 palavras-chave associadas às 40 localizações geográficas selecionadas, resultando num total de 574 pesquisas a cada ciclo de *web scrap*.

Execução e resumo da coleta de dados

As pesquisas foram realizadas de forma automatizada, semanalmente, no período de 28/08/2010 até 08/11/2020. A Tabela 7, presente na Seção 3.5.1.1 e reproduzida abaixo, apresenta um resumo das pesquisas realizadas e das vagas coletadas:

Tabela 7 – Resumo de pesquisas realizadas e vagas coletadas

Pesquisas realizadas	6.021
Pesquisas realizadas sem nenhuma coleta de vagas	4.243
Pesquisas realizadas com vagas coletadas	1.778
Vagas coletadas no período	9.427

Fonte: elaborado pelo autor.

Cada uma das 9.427 vagas coletadas foi armazenada num banco de dados consolidado com as seguintes informações:

Tabela 34 – Informações das vagas coletadas

Campo	Descrição	Observações
title	Título da vaga oferecida	
company	Empresa ofertante	Armazenado quando disponível
local	Local de trabalho	Armazenado quando disponível
desde	Tempo que a vaga estava em aberto	Armazenado quando disponível
qtcand	Quantidade de pessoas que se candidataram a vaga até o momento de coleta	Armazenado quando disponível
Texto	Conteúdo da vaga	
nível	Descrição do nível da vaga	Armazenado quando disponível
regime	Regime de contratação	Armazenado quando disponível
função	Função do profissional da vaga	Armazenado quando disponível
setores	Indústrias	Armazenado quando disponível
link	Endereço URL (“Uniform Resource Locator”) da vaga	
running	Campo gerado de forma automática com data e hora da pesquisa que gerou a coleta da vaga	
key	Chave da pesquisa que gerou a vaga a ser coletada	

Fonte: elaborado pelo autor.

As vagas coletadas foram tratadas segundo procedimentos definidos na Seção 3.5.2.1.

APÊNDICE B – Elementos utilizados para extração de características sobre áreas de formação

Análise sobre EXPERIÊNCIA

palavra-chave “experiência” e elementos alternativos: “experiência”; “experienced”; “vivência”; “anos”; “years”; “proficient”; “proficiência”; “backgorund”;

Análise sobre FORMAÇÃO

palavra-chave “formação” e elementos alternativos: “ba bs”; “b s”; “m s”; “degree”; “superior completo”; “bsc”; “bs c”; “ensino superior”; “university education”; “minor”; “major”; “superior”; “formação superior completa”; “bacharelado”; “bacharel”; “graduação”; “bachelors degree”; “bachelor”; “ba bs”; “ensino médio”; “high school”; “pós”; “pós graduação”; “latu-sensu”; “mba”; “pós-graduação”; “especialização”; “doutorado”; “doctorate degree”; “p h d”; “phd”; “ph d”; “mestrado”; “masters”; “ms c”; “formação”; “escolaridade”; “cursando”; “diploma”; “cursos superiores”; “education”; “graduado”; “graduated”; “formação completa”;

Análise sobre NÍVEL

palavra-chave “1.ensino médio” e elementos alternativos: “ensino médio”; “high school”;

palavra-chave “2.ensino superior” e elementos alternativos: “ba bs”; “b s”; “m s”; “degree”; “superior completo”; “bsc”; “bs c”; “ensino superior”; “university education”; “minor”; “major”; “superior”; “formação superior completa”; “bacharelado”; “bacharel”; “graduação”; “bachelors degree”; “bachelor”; “ba bs”;

palavra-chave “3.pós” e elementos alternativos: “pós”; “pós graduação”; “latu-sensu”; “mba”; “pós-graduação”; “especialização”;

palavra-chave “4.mestrado” e elementos alternativos: “mestrado”; “masters”; “ms c”;

palavra-chave “6.doutorado” e elementos alternativos: “doutorado”; “doctorate degree”; “p h d”; “phd”; “ph d”;

Análise sobre DEGREE

palavra-chave “marketing” e elementos alternativos: “marketing”; “digital marketing”; “marketing digital”;

palavra-chave “economia” e elementos alternativos: “economia”; “economy”;

palavra-chave “matemática” e elementos alternativos: “matemática”; “mathematics”;

palavra-chave “estatística” e elementos alternativos: “estatística”; “statistics”;

palavra-chave “computação” e elementos alternativos: “computação”; “ciência computação”; “computation”; “informática”; “sistemas informação”; “information systems”; “analise sistemas”; “análise sistemas”; “engenharia de software”; “technology”; “tecnologia”; “computer science”; “computer engineering”; “ti”;

palavra-chave “engenharia” e elementos alternativos: “engenharia”; “engineering”; “engenharias”;

palavra-chave “publicidade” e elementos alternativos: “publicidade”; “publicity”;

palavra-chave “jornalismo” e elementos alternativos: “jornalismo”;

palavra-chave “comunicação” e elementos alternativos: “comunicação”;

palavra-chave “ciênciassociais” e elementos alternativos: “ciências sociais”;

palavra-chave “administração” e elementos alternativos: “administração”; “administration”;

palavra-chave “contabilidade” e elementos alternativos: “contabilidade”; “accounting”;

palavra-chave “física” e elementos alternativos: “física”; “physics”;

palavra-chave “química” e elementos alternativos: “química”; “chemistry”;

palavra-chave “biologia” e elementos alternativos: “biologia”; “biology”;

palavra-chave “propaganda” e elementos alternativos: “propaganda”; “advertising”;

palavra-chave “exatas” e elementos alternativos: “exatas”;

Números de elementos: 138; número de elementos únicos: 96

APÊNDICE C – Elementos utilizados para extração de características sobre habilidades e ferramentas

Análise sobre 6A (em referência aos dados da tabela 6.1)

palavra-chave “6a-outros” e elementos alternativos: “pré-processamento de dados”; “computação em tempo real”; “armazenamento de dados”; “mainframe”; “data pre-processing”; “streaming”; “data storage”; “kinesis”; “integração de dados”; “computação distribuída”; “distributed computing”; “flume”; “kafka”; “storm”; “mapreduce”; “lucene”; “pregel”; “data integration”; “hardware”; “servers”; “workstations”; “sistemas embarcados”; “embeded systems”; “informática”;

palavra-chave “bigdata” e elementos alternativos: “big data”; “bigdata”; “dados não estruturados”; “mineração de dados”; “grandes conjuntos de dados”; “governança de big data”; “governança de bigdata”; “unstructured data”;

palavra-chave “cloud” e elementos alternativos: “cloud”; “nuvem”; “azure”;

palavra-chave “datamanagement” e elementos alternativos: “análise exploratória”; “integração”; “ingestão”; “governança de dados”; “queries”; “etl”; “olap”; “oltp”; “arquitetura de dados”; “banco de dados”; “data exploration”; “integration”; “ingestion”; “data governance”; “data management”; “data architecture”;

palavra-chave “datamining” e elementos alternativos: “data mining”; “mining”;

palavra-chave “dataquality” e elementos alternativos: “qualidade dados”; “data quality”; “curadoria”; “curator”; “data warehousing”; “cyber security”;

palavra-chave “hpc” e elementos alternativos: “high performance”; “alta performance”;

palavra-chave “infrati” e elementos alternativos: “infraestrutura”; “implementação”; “docker”; “virtual machines”; “unix”; “linux”; “arquitetura de redes”; “cliente-servidor”; “infrastructure”; “implementation”; “deploy”; “deployment”; “back end”; “backend”; “network architecture”; “client-server”; “redes distribuídas”; “firewalls”; “routers”; “tcp ip”; “dns”;

palavra-chave “privacidade” e elementos alternativos: “privacidade”; “lgpd”; “gdpr”; “data privacy”; “data warehouse”; “segurança”; “conformidade”;

palavra-chave “programação” e elementos alternativos: “programação”; “engenharia de software”; “desenvolvimento de sistemas”; “scripts”; “api”; “rest api”; “microserviços”; “micro serviços”; “programming”; “software engineering”; “systems development”; “system development”; “microservices”; “micro services”;

palavra-chave “versionamento” e elementos alternativos: “versionamento”; “version control”; “git”; “github”; “controle de versões”;

Análise sobre 6AP (em referência aos dados da tabela 6.1)

palavra-chave “bi” e elementos alternativos: “bi”;

palavra-chave “alteryx” e elementos alternativos: “alteryx”;

palavra-chave “analytics” e elementos alternativos: “analytics”;

palavra-chave “cloud” e elementos alternativos: “elasticsearch”; “filebeat”; “logstash”; “kibana”; “airflow”; “apache ambari”; “aws”; “labmda”; “big sql”; “big sheets+e5big”; “gpfs”; “bigquery”; “big query”; “synapse”; “oracle cloud”; “hdfs”; “hive”; “oozie”; “solr”; “redshift”; “dynatrace”; “s3”; “gcp”; “google cloud”; “ibm cloud”; “bluemix”; “talented”; “glue”;

palavra-chave “datamanagement” e elementos alternativos: “rdbms”; “sqoop”; “impala”; “dw”; “mysql”; “postgres”; “postgresql”; “oracle”; “mongo”; “db2”; “dynamodb”; “nifi”; “mpp”; “greenplum”; “teradata”; “netezza”; “pipeline”; “workflow”;

palavra-chave “dataquality” e elementos alternativos: “aql”;

palavra-chave “datawrangling” e elementos alternativos: “dados brutos”; “organização dados”; “dados consistentes”; “análise de dados”; “refinamento de dados”; “limpeza de dados”; “transformação de dados”; “enriquecimento de dados”; “raw data”; “organized data”; “consistent data”; “data analysis”; “refined data”; “data cleansing”; “data transformation”; “data enrichment”; “data wrangling”; “data munging”; “data transfer”; “data prep.”; “datatransfer”; “dataprep”;

palavra-chave “hpc” e elementos alternativos: “hpc”; “symphony”;

palavra-chave “infrati” e elementos alternativos: “posix”; “yarn”; “data server”; “networking”; “chef”; “puppet”; “ansible”; “virtualização”; “virtualization”; “xen”; “vmware”; “hyperv”; “apache”;

palavra-chave “programação” e elementos alternativos: “xml”; “json”; “jsqsh”; “html”; “css”; “gis”; “shell”; “mensageria”; “messaging”;

palavra-chave “segurança” e elementos alternativos: “knox”; “data security”; “idm”; “identity management”;

Análise sobre 6B (em referência aos dados da tabela 6.2)

palavra-chave “6b-outros” e elementos alternativos: “gestão de projetos”; “trabalho em time”;

“liderança”; “resolução de problemas”; “conhecimento multidisciplinar”; “gestão”; “gestão de conhecimento”; “auditoria”; “desenvolvimento de produtos”; “gestão de mudança”; “project management”; “team work”; “leadership”; “problem solver”; “multidisciplinary knowledge”; “management”; “knowledge management”; “audit”; “product development”; “change management”;

palavra-chave “bpm” e elementos alternativos: “bpm”; “gestão de processos de negócio”; “business process management”; “operações gerais de negócios”; “modelagem de processos organizacionais”;

palavra-chave “business” e elementos alternativos: “negócios”; “conhecimento de domínio”; “marketing”; “finanças”; “cadeia de suprimentos”; “desafios do negócio”; “competitividade digital”; “casos de sucesso”; “cultura de dados”; “cultura orientada a dados”; “visão estratégica”; “business”; “domain knowlegede”; “finance”; “supply chain”; “business challenges”; “digital competitiveness”; “success cases”; “data-driven culture”; “strategic vision”; “plano de negócio”; “planos de negócio”; “business plan”;

palavra-chave “comunicação” e elementos alternativos: “comunicação”; “oral”; “escrita”; “não-técnica”; “falar em público”; “comunicação interpessoal”; “communication”; “written”; “non-technical”; “public speech”; “interpersonal communication”;

palavra-chave “conformidade” e elementos alternativos: “compliance”; “intellectual property”; “standards”;

palavra-chave “dataviz” e elementos alternativos: “dataviz”; “visualização de dados”; “vizualização de dados”; “data visualization”; “data vizualization”; “storytelling”;

palavra-chave “ética” e elementos alternativos: “ética”; “etichs”;

palavra-chave “linguas” e elementos alternativos: “inglês”; “english”; “espanhol”; “spanish”;

palavra-chave “metodologias” e elementos alternativos: “metodologia”; “metodologias”; “métodos de pesquisa”; “validação empírica”; “pesquisa acadêmica”; “ágil”; “ágeis”; “agile”; “methodology”; “methodologies”; “research method”; “empiric validation”; “academic research”; “business research”; “agile methods”; “devops”; “dataops”; “frameworks”;

Análise sobre 6BP (em referência aos dados da tabela 6.2)

palavra-chave “6bp-outros” e elementos alternativos: “microstrategy”; “cognos”; “powercenter”; “sap”;

palavra-chave “datastudio” e elementos alternativos: “datastudio”;

palavra-chave “metodologias” e elementos alternativos: “scrum”; “sprint”; “kanban”; “squad”; “squads”;

palavra-chave “pentaho” e elementos alternativos: “pentaho”;

palavra-chave “powerbi” e elementos alternativos: “powerbi”; “power bi”; “power-bi”; “dax”;

palavra-chave “sas” e elementos alternativos: “sas”;

Análise sobre 6C (em referência aos dados da tabela 6.3)

palavra-chave “6c-outros” e elementos alternativos: “redes neurais”; “sistemas de recomendação”; “sistemas de classificação”; “regressão”; “agrupamento”; “redes sociais”; “classificação”; “previsão”; “regras de associação”; “neural networks”; “deep learning”; “clustering”; “forecast”; “pytorch”;

palavra-chave “machinelearning” e elementos alternativos: “aprendizado de máquina”; “aprendizado supervisionado”; “aprendizado não supervisionado”; “aprendizado por reforço”; “modelagem preditiva”; “modelos”; “model”; “machine learning”; “supervised learning”; “unsupervised learning”; “reinforcement learning”; “predictive modeling”; “inteligência artificial”;

palavra-chave “métodos quantitativos” e elementos alternativos: “análises quantitativas”; “análise quantitativa”; “matemática”; “estatística”; “teste de hipótese”; “simulação de eventos”; “probabilidade”; “análise estatística”; “análise descritiva”; “análise preditiva”; “análise prescritiva”; “quantitative analysis”; “hypotheses test”; “mathematical”; “statistics”; “hypothesis test”; “event simulation”; “probability”; “statistical analysis”; “descriptive analysis”; “predictive analysis”; “prescriptive analysis”; “validação de dados”; “pesquisa operacional”; “otimização”; “simulação”; “método quantitativo”; “métodos quantitativos”; “data validation”; “operational research”; “optimization”; “simulation”;

palavra-chave “modelagem” e elementos alternativos: “modelagem”; “criação de datasets”; “conjuntos de dados”; “conjunto de dados”; “uml”; “erwin”; “ddl”; “pandas”; “datasets”; “data sets”;

palavra-chave “nlp” e elementos alternativos: “nlp”; “processamento de linguagem natural”; “natural language processing”;

Análise sobre 6CP (em referência aos dados da tabela 6.3)

palavra-chave “outros” e elementos alternativos: “keras”; “tensorflow”; “scikit”; “numpy”;

“scikit learn”; “scikit-learn”; “sklearn”; “text analytics”;

Análise sobre 6D (em referência aos dados da tabela 6.4)

palavra-chave “softskiils” e elementos alternativos: “pensamento analítico”; “criatividade”; “empreendedorismo”; “pensamento crítico”; “aprendizado contínuo”; “curiosidade”; “paixão”; “proatividade”; “relacionamento interpessoal”; “senso de responsabilidade”; “analytical thinking”; “creativity”; “entrepreneurship”; “critical thinking”; “continuous learning”; “curiosity”; “passion”; “proactivity”; “interpersonal relationship”; “sense of responsibility”;

Análise sobre 6DP (em referência aos dados da tabela 6.4)

“multicultural”; “passionate”; “raciocínio lógico”; “raciocínio rápido”; “habilidades analíticas”; “bom relacionamento”; “logical reasoning”; “quick thinking”; “analytical skills”;

Análise sobre 6E (em referência aos dados da tabela 6.5)

palavra-chave “.net” e elementos alternativos: “net”;

palavra-chave “hadoop” e elementos alternativos: “hadoop”; “apache hadoop”; “cloudera”; “hortonworks”;

palavra-chave “map reduce” e elementos alternativos: “map reduce”;

palavra-chave “nosql” e elementos alternativos: “nosql”; “hbase”; “mongodb”; “cassandra”; “redis”; “acumulo”;

palavra-chave “spark” e elementos alternativos: “spark”;

palavra-chave “sql” e elementos alternativos: “sql”;

Análise sobre 6EP (em referência aos dados da tabela 6.5)

palavra-chave “6ep-outros” e elementos alternativos: “lambda”; “snowflake”; “snow flake”; “flocos de neve”; “flocos de neve”; “adobe analytics”; “flick”;

Análise sobre 6F (em referência aos dados da tabela 6.6)

palavra-chave “[c]” e elementos alternativos: “c”;

palavra-chave “[r]” e elementos alternativos: “r”;

palavra-chave “java” e elementos alternativos: “java”;

palavra-chave “javascript” e elementos alternativos: “java script”; “javascript”; “js”;

palavra-chave “julia” e elementos alternativos: “julia”;
 palavra-chave “perl” e elementos alternativos: “perl”;
 palavra-chave “php” e elementos alternativos: “php”;
 palavra-chave “pig” e elementos alternativos: “pig”;
 palavra-chave “python” e elementos alternativos: “python”;
 palavra-chave “scala” e elementos alternativos: “scala”;

Análise sobre 6FP (em referência aos dados da tabela 6.6)

palavra-chave “riak” e elementos alternativos: “riak”;
 palavra-chave “pyspark” e elementos alternativos: “pyspark”;

Análise sobre 6G (em referência aos dados da tabela 6.7)

palavra-chave “6g-outros” e elementos alternativos: “orange”;
 palavra-chave “dataviz” e elementos alternativos: “datawrapper”; “google visualization api”;
 “google charts”; “flare”; “d3 js”; “raphael”; “gephi”;
 palavra-chave “qlik” e elementos alternativos: “qlik”; “qliksense”; “qlikview”;
 palavra-chave “tableau” e elementos alternativos: “tableau”;

Análise sobre 6H (em referência aos dados da tabela 6.8)

palavra-chave “6h-outros” e elementos alternativos: “nltk”; “weka”; “mahout”;
 palavra-chave “google analytics” e elementos alternativos: “google analytics”;
 palavra-chave “ide” e elementos alternativos: “ide”; “eclipse”; “r studio”; “r-studio”;
 “anaconda”; “visual studio code”; “visual studio”; “atom”; “swagger”;
 palavra-chave “jupyter” e elementos alternativos: “jupyter notebook”;
 palavra-chave “watson” e elementos alternativos: “ibm watson analytics”; “watson”;

Análise sobre 7AP (dados não utilizados)

palavra-chave “diversidade” e elementos alternativos: “diversidade”; “diversity”; “equality”;
 “inclusion”; “igualdade de gênero”; “oportunidades iguais”; “equal opportunity”; “cultura
 inclusiva”; “raça”; “cor”; “ancestralidade”; “religião”; “sexo”; “nacionalidade”; “orientação
 sexual”; “idade”; “cidadania”; “estado civil”; “gênero”;
 palavra-chave “marketing” e elementos alternativos: “google ads”; “google tag manager”;

palavra-chave “pcd” e elementos alternativos: “pcd”; “deficiência”; “reabilitada”;
palavra-chave “experiência” e elementos alternativos: “experiência”; “experienced”;
“vivência”; “anos”; “years”; “proficient”; “proficiência”;
palavra-chave “office” e elementos alternativos: “google sheets”; “pacote office”; “excel”;
“power point”;

Análise sobre 8AP (dados não utilizados)

palavra-chave “certificados” e elementos alternativos: “certificado”; “certificações”;
“certification”;

números de elementos: 526; número de elementos únicos 526

APÊNDICE D – Perguntas da Pesquisa Data Hackers BR 2019

Abaixo encontram-se as perguntas da pesquisa Data Hackers BR realizada em 2019.

1. Pergunta_1 (P1) = Idade?
2. Pergunta_2 (P2) = Gênero?
3. Pergunta_3 (P3) = Atualmente você vive no Brasil?
4. Pergunta_4 (P4) = Em que país você vive hoje?
5. Pergunta_5 (P5) = Em que estado você vive hoje?
6. Pergunta_6 (P6) = Na questão anterior você disse que vive em _____. Esse é seu estado de origem (onde nasceu ou se formou)?
7. Pergunta_7 (P7) = Qual seu estado de origem?
8. Pergunta_8 (P8) = Qual seu nível de ensino?
9. Pergunta_9 (P9) = Qual sua área de formação?
10. Pergunta_10 (P10) = Qual sua situação atual de trabalho?
11. Pergunta_11 (P11) = A empresa em que você trabalha pertence a qual setor?
12. Pergunta_12 (P12) = A empresa em que você trabalha possui quantos funcionários atualmente?
13. Pergunta_13 (P13) = Você atua como gestor?
14. Pergunta_14 (P14) = Qual das opções abaixo definem melhor seu cargo de trabalho atual como gestor?
15. Pergunta_15 (P15) = Qual das opções abaixo definem melhor seu cargo de trabalho atual?
16. Pergunta_16 (P16) = Qual sua faixa salarial atual? [Mascarada]
17. Pergunta_17 (P17) = Quanto tempo de experiência na área de dados você tem?
18. Pergunta_18 (P18) = Quanto tempo de experiência na área de TI/Engenharia de Software você teve antes de começar a trabalhar na área de dados?
19. Pergunta_19 (P19) = Você se considera um profissional que atua na área de Data Science?
20. Pergunta_20 (P20) = Quais dos métodos listados abaixo você costuma utilizar no trabalho?
21. Pergunta_21 (P21) = Quais das linguagens de programação listadas abaixo você utiliza no trabalho?
22. Pergunta_22 (P22) = Entre as linguagens de programação listadas abaixo, qual é a que você mais utiliza no trabalho? [Mascarada]
23. Pergunta_23 (P23) = Quais das fontes de dados listadas você já analisou no trabalho?

24. Pergunta_24 (P24) = Entre as fontes de dados listadas, quais você utiliza na maior parte do tempo? Selecione no máximo duas opções que você mais utiliza.
25. Pergunta_25 (P25) = Quais das opções de Cloud listadas abaixo você utiliza no trabalho?
26. Pergunta_26 (P26) = Quais dos bancos de dados/fontes de dados listados abaixo você utiliza para consultar informações, e posteriormente analisar, no trabalho?
27. Pergunta_27 (P27) = Quais as Ferramentas de Business Intelligence você utiliza no trabalho?
28. Pergunta_28 (P28) = Quais as tecnologias são utilizadas como ferramenta de ETL no seu trabalho?
29. Pergunta_29 (P29) = Sua organização possui um *data warehouse*?
30. Pergunta_30 (P30) = Qual tecnologia utilizada como plataforma do *data warehouse*?
31. Pergunta_31 (P31) = Quais das iniciativas do Data Hackers que você já acessou/acompanhou?
32. Pergunta_32 (P32) = Entre as iniciativas do Data Hackers qual a sua preferida?
33. Pergunta_33 (P33) = De quais outras formas que você costuma se atualizar no mundo dos dados?
34. Pergunta_34 (P34) = Em quais dessas plataformas listadas abaixo você já iniciou/completou cursos na área de Data Science?
35. Pergunta_35 (P35) = Dentre as plataformas listadas abaixo qual foi a sua preferida para cursos de Data Science?
36. Pergunta_36 (P36) = Você deseja participar do sorteio?

A partir das perguntas acima outras colunas foram derivadas:

1. Derivado_1 (D1) = Macrorregião em que mora
2. Derivado_2 (D2) = Macrorregião em que nasceu
3. Derivado_3 (D3) = Área de formação anonimizada
4. Derivado_4 (D4) = Setor de mercado anonimizado
5. Derivado_5 (D5) = Nível de gerência anonimizado
6. Derivado_6 (D6) = Cargo anonimizado

APÊNDICE E – Questionário para validação do modelo conceitual prévio

- a) Você concorda com o Termo de Consentimento Livre e Esclarecido (TCLE)?
- b) O Termo de Consentimento Livre e Esclarecido (TCLE) é obrigatório na Universidade de São Paulo. Os conhecimentos resultantes deste estudo serão constituídos por dados estatísticos. Os sujeitos participantes não serão identificados. A pesquisa poderá ser divulgada em revistas científicas e/ou congressos na área de Administração. Os dados coletados constituirão um banco de dados que ficará sob a guarda dos pesquisadores por cinco anos, podendo ser utilizados em pesquisas futuras. Caso você se sinta constrangido você pode endereçar suas considerações para a Comissão de Pesquisa da FEA/USP (<http://bit.ly/usp-fea-cpq>) ou através do telefone +55(11)3091-5960.
- c) Você revisou o modelo conceitual?
- d) Se você não recebeu o modelo ele está disponível em <http://www.fabianocastello.com.br/fea>
- e) Qual sua profissão?
- f) Aproximadamente há quanto anos você está nesta profissão?
- g) Seu cargo
- h) CEP de sua residência (apenas os primeiros 5 dígitos). Se você estiver no exterior deixe em branco.
- i) Definição de cientista de dados. Você concorda com ela? (nota 1)
- j) Tem alguma sugestão para modificar a definição?
- k) Você concorda com a classificação abaixo sobre as áreas de formação? (nota 1)
- l) Tem algum comentário sobre as áreas de formação?
- m) *Soft skills* - você concorda com a classificação abaixo? (nota 1)
- n) Tem algum comentário sobre *soft skills*?
- o) *Hard skills* - você concorda com a classificação abaixo? (nota 1)
- p) Tem algum comentário sobre *hard skills*?
- q) Linguagens de Programação - você concorda com a classificação abaixo? (nota 1)
- r) Acrescentaria alguma linguagem a lista acima?
- s) Ecossistemas, Frameworks e Bancos de Dados - você concorda com a classificação abaixo? (nota 1)
- t) Tem algum comentário sobre a lista acima?

- u) Técnicas de Machine Learning e Deep Learning - você concorda com a classificação abaixo? (nota 1)
- v) Tem algum comentário sobre a lista acima?
- w) Visualização de Dados - você concorda com a classificação abaixo? (nota 1)
- x) Acrescentaria alguma ferramenta à lista acima?
- y) Você acredita que a forma como o modelo está segregado (*soft skills*, *hard skills*, ferramentas) é adequado? Entende que há uma forma melhor de separação? Comente abaixo.
- z) Se quiser deixar outros comentários escreva abaixo.

Nota 1: questões coletadas na forma de escala Likert de 4 pontos (1: discordo muito, 2: discordo, 3: concordo; 4: concordo muito).