




Big data e ciência de dados


aula 05

Análises não-supervisionadas – pt. 2


Luisa Mariele Strauss

Provost & Fawcett (2016)
Material profa. Patrícia Kuyven

Animação com explicação do método k-means



Etapas do k-means



Fazendo cluster com Python

- Método usado: K-means
- Biblioteca para machine learning - K-means: scikit-learn ou sklearn

```
from sklearn.cluster import KMeans  
from sklearn.preprocessing import scale
```

- Outras bibliotecas: numpy, pandas, matplotlib e seaborn
 - Importante: para k-means, as variáveis devem ser numéricas
-

Explicando cada parâmetro

```
kmeans = KMeans(n_clusters=5, init='k-means++', n_init=10, random_state=1234)
```

- `n_clusters`: Número de clusters que será gerado.
- `init`: Este parâmetro especifica o método de inicialização para os centróides do K-Means.
 - `'k-means++'` é um método inteligente para selecionar os centróides iniciais de forma a acelerar a convergência e usado como “padrão”
 - `'random'`: os centróides iniciais são escolhidos aleatoriamente a partir dos pontos de dados.
 - Um array (ndarray) contendo os centróides iniciais: Você pode fornecer seus próprios centróides iniciais como um array NumPy. Este array deve ter a forma `(n_clusters, n_features)`, onde `n_clusters` é o número de clusters desejado e `n_features` é o número de características (colunas) nos seus dados. Isso permite que você tenha controle total sobre onde o processo de agrupamento começa.
- `n_init`: Este parâmetro determina o número de vezes que o algoritmo K-Means será executado com diferentes sementes de centróides iniciais. É este método que nos dá uma melhor convergência de centróides, ele já apresenta o agrupamento que apresentou a menor Soma dos Quadrados dentro do Cluster (WCSS)
- `random_state`: Este parâmetro é usado para garantir a reprodutibilidade dos resultados. Ao definir um valor inteiro (como 1234 ou qualquer outro), garantimos que as inicializações aleatórias serão as mesmas em diferentes execuções do código, o que é útil para depuração e comparação de resultados. Se definirmos `none`, a cada rodada teremos resultados diferentes.

Etapas



Importar bibliotecas



Carregar o conjunto de dados



Limpar e transformar os dados



Encontrar o número de clusters




Implementar o k-means



Visualizar os clusters

Normalização de dados

- Objetiva deixar os dados em uma mesma “escala”
- Normalização coloca os dados em um intervalo entre 0 e 1 ou -1 e 1
- Função `MaxAbsScaler` da Biblioteca `sklearn`







Considerações importantes

- A ideia é que os elementos de cada grupo tenham alta similaridade entre si, mas diferenças entre outros grupos
- Nem sempre é possível explicar facilmente os grupos gerados
- Então, como analisar e entender os grupos? Como saber se o modelo é adequado?

Exercício

- Rodar o k-means para Wholesales_customer sem normalizar e normalizando dados
- Rodar o k-means para Wholesales_customer com diferentes números de clusters
- Interpretar cada agrupamento
- Escolher um agrupamento
- Rotular o agrupamento
- Levantar possibilidades de ação para cada agrupamento
- Inserir as variáveis Channel e Region e visualizar os diferentes agrupamentos





Mas como saber qual é o
número de clusters ideal?

Elbow Method - Método do cotovelo




Elbow method

Cui (2020)

- O método do cotovelo calcula a diferença quadrada de diferentes valores de k . À medida que o valor k aumenta, o grau médio de distorção torna-se menor. O número de amostras contidas em cada categoria diminui e as amostras ficam mais próximas do centro. À medida que o valor k aumenta, a posição onde o efeito de melhoria do grau de distorção mais diminui é o valor k correspondente ao cotovelo.
- WCSS (Within-Cluster Sum-of-Squares) – quanto menor a soma dos quadrados entre os clusters, melhor! Em outras palavras, é quando a distância entre os membros de cada cluster e seu centróide são menores.

Calculando a Distância



$$d_{AB} = \sqrt{[x_B - x_A]^2 + [y_B - y_A]^2}$$


Imagem obtida em <https://mundoeducacao.uol.com.br/matematica/distancia-entre-dois-pontos.htm>

No Phytton

- Biblioteca sklearn
- Calcular o WCSS n vezes - deve ser definido o número de vezes (função for)
- Plotar o gráfico
- Fazer a análise empírica do gráfico



WCSS em 10
agrupamentos
para
Wholesales
Customers





E quando temos
variáveis categóricas?

- K-modes
- K-prototypes

K-Modes – Usa a “moda” para variáveis categóricas


exemplo compras Istambul

invoice_no	customer_id	gender	age	category	quantity	price	payment_method	invoice_date	shopping_mall
I178410	C100004	Male	61	Clothing	5	15004	Credit Card	sexta-feira, 26 de novembro de 2021	Metrocity
I158163	C100005	Male	34	Shoes	2	120034	Cash	sexta-feira, 3 de março de 2023	Kanyon
I262373	C100006	Male	44	Toys	3	10752	Credit Card	quinta-feira, 1 de dezembro de 2022	Cevahir AVM
I334895	C100012	Male	25	Food & Beverage	5	2615	Cash	domingo, 15 de agosto de 2021	Kanyon
I202043	C100019	Female	21	Toys	1	3584	Credit Card	domingo, 25 de julho de 2021	Metrocity
I303349	C100025	Male	55	Toys	2	7168	Debit Card	quinta-feira, 3 de junho de 2021	Metrocity
I336350	C100028	Female	21	Books	1	1515	Cash	quinta-feira, 25 de novembro de 2021	Kanyon
I134255	C100030	Male	46	Clothing	4	120032	Cash	quinta-feira, 13 de outubro de 2022	Mall of Istanbul
I306929	C100034	Male	60	Clothing	2	60016	Cash	sexta-feira, 6 de agosto de 2021	Kanyon
I280920	C100041	Female	50	Clothing	3	90024	Cash	sexta-feira, 23 de abril de 2021	Kanyon

K-Modes – Usa a “moda” para variáveis categóricas

exemplo compras Istambul


Contagem de price por gender



Contagem de price por payment_method



Contagem de price por shopping_mall



Contagem de price por category



Análise 10 primeiros registros


customer_id	gender	age	category	quantity	price	payment_method	shopping_mall	Distância
C100004	Male	61	Clothing	5	15004	Credit Card	Metrocity	3
C100005	Male	34	Shoes	2	120034	Cash	Kanyon	3
C100006	Male	44	Toys	3	10752	Credit Card	Cevahir AVM	4
C100012	Male	25	Food & Beverage	5	2615	Cash	Kanyon	3
C100019	Female	21	Toys	1	3584	Credit Card	Metrocity	3
C100025	Male	55	Toys	2	7168	Debit Card	Metrocity	4
C100028	Female	21	Books	1	1515	Cash	Kanyon	2
C100030	Male	46	Clothing	4	120032	Cash	Mall of Istanbul	1
C100034	Male	60	Clothing	2	60016	Cash	Kanyon	2
C100041	Female	50	Clothing	3	90024	Cash	Kanyon	1

K-Prototypes

- Método ou algoritmo criado por Huang em 1998
- Combina K-means para variáveis quantitativas e k-modes para dados categóricos
- Baseia-se na dissimilaridade entre os elementos do conjunto

$$d(x_i, Q_l) = \sum_{r=1}^{m_r} (x_{ir} - q_{lr})^2 + \gamma_l \sum_{c=1}^{m_c} \delta(x_{ic}, q_{lc}),$$

- x_{ir} representa o valores dos atributos numéricos
- x_{ic} o valores dos atributos categóricos
- $Q_l = q_{l1}, \dots, q_{lm}$ representa os centroides do cluster



Script k-prototypes

- Biblioteca kmodes – necessário instalar: `!pip install kmodes`

- Importar o arquivo para o Colab, Leitura e análise estatística dos dados

- Definir variáveis numéricas e categóricas

```
categorical_cols = ['gender', 'category', 'payment_method', 'invoice_date',  
                  'shopping_mall']
```


```
numeric_cols = ['age', 'quantity', 'price']
```

- Normalizar as variáveis quantitativas
- Esse método não tem como pré-requisito transformar as variáveis categóricas
- Definir número de clusters - no exemplo, foram 4: `kproto = KPrototypes(n_clusters=4, init='Huang', verbose=2)`

```
clusters = kproto.fit_predict(X, categorical=[3, 4, 5, 6])
```

- Rotula os clusters nos dados originais
- Baixa um novo arquivo csv com os clusters se desejar
- Analisa os clusters gerados

Análise número de clusters – “cotovelo”



Analizando os clusters formados

- 0: Consumo baixo, não consome tecnologia, média de idade 42 anos
- 1: Consumo baixo, consumo maior em roupas e calçados, média de 60 anos. Pessoas da melhor idade
- 2: Consumo baixo, maior em roupas e calçados, média de 30 anos
- 3: Consumo alto, calçados e tecnologia, média de 44 anos. Adulto sem filhos

Exercício

- Rode um algoritmo de agrupamento k-means ou k-prototypes para outra base de dados.
- Analise os agrupamentos. Um exemplo para dados mistos é esta base do Kaggle-
<https://www.kaggle.com/datasets/mahdinavaei/customermarketing/data>.
- Seguir as etapas básicas, rodar o agrupamento com o melhor número de clusters e analisar o agrupamento. Esta análise deve trazer características distintas de cada cluster e sugestões de ações possíveis.



Referências

- Cui, Mengyau. Introduction to the K-Means Clustering Algorithm Based on the Elbow Method. **Accounting, Auditing and Finance** (2020) 1: 5-8
- Silva, Renato S. da. et al. Clusterização de dados mistos para análise da atividade pesqueira artesanal na bacia Araguaia-Tocantins. **Revista Brasileira de Computação Aplicada**, Novembro, 2019.
- Oliveira, Fernanda Robes de. et al. Clusterização de Clientes: um Modelo Utilizando Variáveis Categóricas e Numéricas. **Anais do X Congresso Brasileiro de Engenharia de Produção**, 2020.