




Big data e ciência de dados

aula 08

Análises supervisionadas – Avaliação de modelos


Luisa Mariele Strauss

Provost & Fawcett (2016)
Notas de aula de Felipe Morais

Sumário

- Retomar exercício Base Student
- Variáveis *dummies*
- Análise supervisionada: classificação com regressão logística e árvore de decisão
- Avaliação de modelos
- Recados sobre o Grau A





Base Student Data

Contém dados sobre disciplina de matemática numa escola secundária

- school ID
- gender
- age
- Address (rural/urban)
- Mother education
- Study time
- Father education
- Tempo dedicado aos estudos
- Paid
- Internet
- Absences
- Grades (G1, G2 e G3)



Exercício

- Rodar o exemplo para Base Student
- Qual é a equação resultante?
- Avaliar se é um bom modelo
- Incluir/excluir variáveis e avaliar novamente o modelo
- Como esse modelo poderia ser usado em uma escola? Sugira um sistema ou processo acadêmico/administrativo em que esse modelo poderia ser inserido e usado.

Avaliando o modelo

OLS Regression Results


Dep. Variable:	G3	R-squared:	0.849
Model:	OLS	Adj. R-squared:	0.838
Method:	Least Squares	F-statistic:	80.11
Date:	Thu, 19 Oct 2023	Prob (F-statistic):	2.61e-94
Time:	00:15:16	Log-Likelihood:	-547.67
No. Observations:	276	AIC:	1133.
Df Residuals:	257	BIC:	1202.
Df Model:	18		
Covariance Type:	nonrobust		

Avaliando o modelo

	coef	std err	t	P> t
const	4.5092	2.895	1.557	0.121
age	-0.2756	0.097	-2.838	0.005
studytime	-0.0518	0.151	-0.343	0.732
absences	0.0397	0.014	2.923	0.004
G1	0.2276	0.064	3.551	0.000
G2	0.9389	0.055	17.112	0.000
school_MS	0.0023	0.415	0.006	0.996
sex_M	0.1623	0.246	0.660	0.510
address_U	-0.0990	0.289	-0.343	0.732
Medu_1	-1.3319	1.338	-0.995	0.321
Medu_2	-1.4705	1.330	-1.105	0.270
Medu_3	-1.3615	1.338	-1.018	0.310
Medu_4	-1.1614	1.348	-0.862	0.390
Fedu_1	-0.2791	1.880	-0.148	0.882
Fedu_2	-1.2784	1.879	-0.680	0.497
Fedu_3	-0.5597	1.896	-0.295	0.768
Fedu_4	-1.1832	1.907	-0.621	0.535
paid_yes	0.2958	0.234	1.262	0.208
internet_yes	-0.1442	0.331	-0.436	0.663

Avaliando o modelo

MAE: 1.38
RMSE: 2.10



Mantendo apenas variáveis com p-value < 0,05

```
# Selecionar as variáveis significativas para o  
modelo
```

```
sig_variables = data[["age", "absences", "G1", "G2",  
"G3"]]
```

```
# Definir as variáveis independentes (X) e a variável  
dependente (y)
```

```
X = sig_variables.drop("G3", axis=1)
```

```
y = sig_variables["G3"]
```

Mantendo apenas variáveis com p-value < 0,05

```

=====
OLS Regression Results
=====
Dep. Variable:          G3      R-squared:                0.839
Model:                  OLS      Adj. R-squared:           0.836
Method:                 Least Squares      F-statistic:            352.6
Date:                   Tue, 24 Oct 2023    Prob (F-statistic):      4.45e-106
Time:                   17:21:33      Log-Likelihood:          -556.42
No. Observations:       276      AIC:                     1123.
Df Residuals:           271      BIC:                     1141.
Df Model:                4
Covariance Type:        nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	1.2090	1.521	0.795	0.428	-1.786	4.204
age	-0.2068	0.088	-2.344	0.020	-0.381	-0.033
absences	0.0372	0.013	2.887	0.004	0.012	0.062
G1	0.1896	0.061	3.099	0.002	0.069	0.310
G2	0.9669	0.053	18.297	0.000	0.863	1.071


```

=====

```

Avaliando o
modelo –
segunda
versão

MAE: 1.31
RMSE: 2.07





Regressão linear - equação

- Fórmula padrão:

$$y = a + \beta x, \text{ onde:}$$

y: é o alvo ou variável dependente

a: é uma constante ou "erro"

β : coeficiente da variável x

x: variável explicativa

- $G3 = 1.21 + (-0.21 * age) + (0.04 * absences) + (0.19 * G1) + (0.97 * G2)$

Aplicação prática

Como esse modelo poderia ser usado em uma escola? Sugira um sistema ou processo acadêmico/administrativo em que esse modelo poderia ser inserido e usado.

O que muda em relação à primeira versão (contendo todas as variáveis) e a segunda, contendo apenas as significativas?







Pressupostos e lembretes regressão

A regressão linear (e a maioria das técnicas estatísticas e de ciência de dados que estudamos) avalia a magnitude e associação entre duas ou mais variáveis, não significando que haja **relação de causa e efeito** no comportamento do que está sendo estudado. A causalidade é definida em termos teóricos e a regressão linear é uma ferramenta estatística designada para identificar apenas a existência de associação

Variáveis *dummies*, mudas ou postigas

- Uma variável Dummy é aquela que toma o valor de "zero" ou "um" indicando a ausência ou presença de qualidades ou atributos.
- São um recurso para introduzir características qualitativas, sendo denominadas também de variáveis binárias ou dicotômica.
- São criadas por transformação, em que "0" representa a ausência do atributo e "1" a presença do atributo.





Exemplo – nível de escolaridade

- Variável categórica com as seguintes categorias:
 - Analfabeto
 - Ensino básico incompleto
 - Ensino básico completo
 - Ensino fundamental completo
 - Ensino fundamental incompleto
 - Ensino superior completo
 - Ensino superior incompleto
- Para cada variável categórica, criamos $n-1$ variáveis dummies, sendo n = número de categorias.
- Neste exemplo: $7 - 1 = 6$ variáveis dummies

Exemplo – nível de escolaridade



	Variáveis <i>Dummies</i>					
	<i>Dummy 1</i>	<i>Dummy 2</i>	<i>Dummy 3</i>	<i>Dummy 4</i>	<i>Dummy 5</i>	<i>Dummy 6</i>
Analfabeto	0	0	0	0	0	0
Ensino básico incompleto	1	0	0	0	0	0
Ensino básico completo	0	1	0	0	0	0
Ensino fundamental completo	0	0	1	0	0	0
Ensino fundamental incompleto	0	0	0	1	0	0
Ensino Superior completo	0	0	0	0	1	0
Ensino Superior incompleto	0	0	0	0	0	1

Fonte: Adaptado de Pessanha [200-]

Na nossa
base
Student

school_MS	0.0023
sex_M	0.1623
address_U	-0.0990
Medu_1	-1.3319
Medu_2	-1.4705
Medu_3	-1.3615
Medu_4	-1.1614
Fedu_1	-0.2791
Fedu_2	-1.2784
Fedu_3	-0.5597
Fedu_4	-1.1832
paid_yes	0.2958
internet_yes	-0.1442

Representação
Medu (Mother
Education)

Categorias	Medu_1	Medu_2	Medu_3	Medu_4
0	0	0	0	0
1	1	0	0	0
2	0	1	0	0
3	0	0	1	0
4	0	0	0	4



Análises supervisionadas - classificação

```
mirror_mod = modifier_ob.  
    # Set mirror object to mirror  
    mirror_mod.mirror_object =  
    operation == "MIRROR_X":  
    mirror_mod.use_x = True  
    mirror_mod.use_y = False  
    mirror_mod.use_z = False  
    operation == "MIRROR_Y":  
    mirror_mod.use_x = False  
    mirror_mod.use_y = True  
    mirror_mod.use_z = False  
    operation == "MIRROR_Z":  
    mirror_mod.use_x = False  
    mirror_mod.use_y = False  
    mirror_mod.use_z = True  
  
    # selection at the end -add  
    mirror_ob.select= 1  
    modifier_ob.select=1  
    context.scene.objects.active  
    ("Selected" + str(modifier  
    mirror_ob.select = 0  
    = bpy.context.selected_obj  
    data.objects[one.name].se  
  
    print("please select exactly  
  
    --- OPERATOR CLASSES ---  
  
    types.Operator):  
    # X mirror to the selected  
    object.mirror_mirror_x"  
    mirror X"  
  
    context):  
    context.active_object is not
```


- São técnicas para problemas de classificação, em que as variáveis alvo são **categóricas**
- Exemplos:
 - Bom/mau pagador
 - Aprovado/Reprovado
 - Churn (Cancelou/Não cancelou)
 - Spam/não spam
- Pode ser usado na base Student?

```
mirror_mod = modifier_ob.  
    mirror object to mirror  
    mirror_mod.mirror_object  
    operation == "MIRROR_X":  
        mirror_mod.use_x = True  
        mirror_mod.use_y = False  
        mirror_mod.use_z = False  
    operation == "MIRROR_Y":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = True  
        mirror_mod.use_z = False  
    operation == "MIRROR_Z":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = False  
        mirror_mod.use_z = True  
    selection at the end -add  
    mirror_ob.select= 1  
    modifier_ob.select=1  
    context.scene.objects.active  
    ("Selected" + str(modifier  
    mirror_ob.select = 0  
    = bpy.context.selected_obj  
    data.objects[one.name].se  
    print("please select exactly  
    --- OPERATOR CLASSES ----  
    types.Operator):  
    X mirror to the selected  
    object.mirror_mirror_x"  
    mirror X"  
    context):  
    context.active_object is not
```


Alguns algoritmos

- Árvores de decisão
- Regressão logística
- Naive Bayes

Regressão Logística




Diferença entre regressão linear e logística. Fonte: Estat Site



Árvores decisão

Árvore de Decisão para Jogar Tênis



Naive Bayes

TEMPO	"PLAY"
Sol	Não
Nublado	Sim
Chuva	Sim
Sol	Sim
Sol	Sim
Nublado	Sim
Chuva	Não
Chuva	Não
Sol	Sim
Chuva	Sim
Sol	Não
Nublado	Sim
Nublado	Sim
Chuva	Não

Tabela de frequência		
Clima	Não	Sim
Nublado	0	4
Sol	3	2
Chuva	2	3
Total	5	9

Tabela de probabilidade				
Clima	Não	Sim		
Nublado	0	4	=4/14	0,29
Sol	3	2	=5/14	0,36
Chuva	2	3	=5/14	0,36
Total	5	9		
	=5/14	=9/14		
	0,36	0,64		

—

Como avaliar os modelos?

- Análises supervisionadas
 - Regressão linear
 - Classificação
- Análises não supervisionadas





Avaliando modelos de regressão linear

Métricas estatísticas:

- R^2 ajustado: Representa a proporção da variância para uma variável dependente (y) que é explicada por uma ou mais variáveis independentes ($X_1, X_2...$).
- *p-value*: O valor p para cada termo testa a hipótese nula de que o coeficiente é igual a zero (sem efeito).



Avaliando a “capacidade de predição” do modelo

- RMSE – Raiz do Erro quadrático médio: parte das diferenças entre os valores estimados e valores reais da base de teste, penalizando erros maiores. Quanto menor, melhor.


$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

- MAE – Erro absoluto médio, também parte das diferenças absolutas entre valores estimados e valores reais da base de teste. Quanto menor, melhor. É como se fossem as unidades de distância entre o valor real e o previsto.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$$

Avaliando modelos de classificação

Base de treinamento e de teste!





Exemplo: identificando spam

Classificação de e-mails:


True = Spam

False = Normal

Real	Predito
True	True
True	False
False	False
False	True
True	True
False	False
...	...

Avaliando modelos de classificação

- Matriz de confusão
- Acurácia
- Precisão
- Recall ou revocação
- F1-score



Matriz de confusão

		Predito/Previsto	
		Positivo	Negativo
Valor real	Positivo	Verdadeiro positivo	Falso negativo
	Negativo	Falso positivo	Verdadeiro negativo



Ilustrando
com humor

Acurácia e taxa de erro

Acurácia: indica o percentual de acertos do modelo

$$acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

Taxa de erro: indica o percentual de erros do modelo

$$Taxa\ de\ erro = \frac{FP + FN}{VP + VN + FP + FN}$$

Exemplo

- Total de casos: 100
- Positivos: 60
- Negativos: 40

		Previsto	
		Positivo	Negativo
Valor real	Positivo	VP = 50	FN = 10
	Negativo	FP = 5	VN = 35

$$Acurácia = \frac{50+35}{50+10+5+35}=85\%$$

Precisão

- Precisão: percentual de acertos para casos positivos, ou seja, dentre todas as classificações de classe positivo que o modelo fez, quantas estão corretas. Exemplo de uso: investimentos, pois é mais relevante acertar os investimentos que podem render lucros

$$Precisão = \frac{VP}{VP + FP}$$

Exemplo

- Total de casos: 100
- Positivos: 60
- Negativos: 40

		Previsto	
		Positivo	Negativo
Valor real	Positivo	VP = 50	FN = 10
	Negativo	FP = 5	VN = 35

$$Acurácia = \frac{50+35}{50+10+5+35} = 85\%$$

$$Precisão = \frac{50}{50+5} = 90\%$$

Recall ou revocação

- Recall ou revocação: percentual de acertos em relação a todos os que realmente eram positivos. Exemplo de uso: predição de doenças, pois é mais relevante detectar os casos de risco de doenças

$$Recall = \frac{VP}{VP + FN}$$

Exemplo

- Total de casos: 100
- Positivos: 60
- Negativos: 40

		Previsto	
		Positivo	Negativo
Valor real	Positivo	VP = 50	FN = 10
	Negativo	FP = 5	VN = 35

$$Acurácia = \frac{50+35}{50+10+5+35} = 85\%$$

$$Precisão = \frac{50}{50 + 5} = 90\%$$

$$Recall = \frac{50}{50 + 10} = 83\%$$

F1-score

- É a média harmônica entre precisão e recall, serve para ter uma mensuração única. Ou seja, quando tem-se um F1-Score baixo, é um indicativo de que ou a precisão ou o recall está baixo.

$$F1 - score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$

Exemplo

- Total de casos: 100
- Positivos: 60
- Negativos: 40

		Previsto	
		Positivo	Negativo
Valor real	Positivo	VP = 50	FN = 10
	Negativo	FP = 5	VN = 35

$$Acurácia = \frac{50+35}{50+10+5+35} = 85\%$$

$$Precisão = \frac{50}{50 + 5} = 90\%$$

$$F1 - score = 2 * \frac{0,9 * 0,83}{0,9 + 0,83} = 86,3\%$$

$$Recall = \frac{50}{50 + 10} = 83\%$$



E nas análises não supervisionadas? No caso de clusterização...

- Como não temos alvo, não faz sentido verificar o quanto o modelo “acertou” o alvo
- “várias rodadas” – modelo é iterativo até encontrar a convergência – podemos definir nos parâmetros do algoritmo

```
kmeans = KMeans(n_clusters=5, init='k-means++', n_init=10, random_state=1234)
```

- Método do cotovelo – Elbow: rodar o algoritmo n vezes para n clusters. Para cada número de clusters, calcula o WCSS (Within-Cluster Sum of Squares) para o melhor agrupamento e plotamos em um gráfico, para encontrar o “cotovelo”



Etapas importantes em qualquer modelo de análise supervisionada

1. Importar as bibliotecas
2. Leitura dos dados
3. Análise de descritiva
4. Pré-processamento dos dados: eliminar duplicatas (se houver), decidir o que fazer com dados incompletos etc
5. Definir qual é a análise mais adequada!
6. Padronizar/normalizar os dados, quando pertinente
7. Definir variáveis independentes e dependentes (X e y), com base no conhecimento do negócio e da literatura sobre o tema
8. Transformar variáveis categóricas em *dummies*, quando houver
9. Dividir em base de teste e de treinamento
10. Rodar o modelo
11. Avaliar o modelo
12. Voltar a etapas anteriores e refazer até encontrar um modelo adequado



Etapas importantes em qualquer modelo de análise não-supervisionada

1. Importar as bibliotecas
2. Leitura dos dados
3. Análise de descritiva
4. Pré-processamento dos dados: eliminar duplicatas (se houver), decidir o que fazer com dados incompletos etc
5. Definir qual é a análise mais adequada!
6. Padronizar/normalizar os dados
7. Transformar variáveis categóricas em *dummies*, quando necessário
8. Rodar o modelo
9. Avaliar o modelo
10. Voltar a etapas anteriores e refazer até encontrar um modelo adequado

Método CRISP-DM

