




Big data e ciência de dados

aula 10

Análises supervisionadas – classificação – Regressão logística

Luisa Mariele Strauss

Provost & Fawcett (2016)
Notas de aula Patrícia Kuyven e Alexandro Carvalho




Análises supervisionadas

- São as análises realizadas quando temos um alvo
- Esse alvo, em linguagem de modelagem, é a variável dependente
- O que seria um alvo?
 - Bom/mau pagador
 - Churn (evasão, rotatividade, saída)
 - Aprovado/Reprovado
 - Nota final
 - Salário
 - Lucro anual de uma empresa

Dois tipos principais

- Regressão: alvo numérico, quantitativo (lucro, nota, volume de utilização etc)
- Regressão linear
- Classificação: alvos categóricos ou binários (sim/não, 0/1, favorável/contrário etc)
- Regressão logística
- Árvores de decisão
- Naive Bayes



Regressão linear

- Usado para descrever e prever uma determinada variável alvo - Apenas para dados numéricos

- Fórmula padrão:

$$y = a + \beta x, \text{ onde:}$$

y: é o alvo ou variável dependente

a: é uma constante ou “erro”

β : coeficiente da variável x – parâmetro a ser explicado

x: variável explicativa

- Podemos ter uma longa sequência de variáveis aplicativas, ou seja: $\beta_1 x_1 + \beta_2 x_2 + \beta_n x_n$

```
mirror_mod = modifier_ob.  
    mirror object to mirror  
    mirror_mod.mirror_object  
    operation == "MIRROR_X":  
        mirror_mod.use_x = True  
        mirror_mod.use_y = False  
        mirror_mod.use_z = False  
    operation == "MIRROR_Y":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = True  
        mirror_mod.use_z = False  
    operation == "MIRROR_Z":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = False  
        mirror_mod.use_z = True  
    selection at the end -add  
    mirror_ob.select= 1  
    mirror_ob.select=1  
    context.scene.objects.active  
    ("Selected" + str(modifier  
    mirror_ob.select = 0  
    = bpy.context.selected_obj  
    data.objects[one.name].se  
    print("please select exactly  
    --- OPERATOR CLASSES ---  
    types.Operator):  
    X mirror to the selected  
    object.mirror_mirror_x"  
    mirror X"  
    context):  
    context.active_object is not
```

Regressão Logística

- É uma técnica para problemas de classificação, em que as variáveis alvo são **categóricas**
- Exemplos:
 - Bom/mau pagador
 - Aprovado/Reprovado
 - Churn (Cancelou/Não cancelou)

```
mirror_mod = modifier_ob.  
    mirror object to mirror  
    mirror_mod.mirror_object  
    operation == "MIRROR_X":  
        mirror_mod.use_x = True  
        mirror_mod.use_y = False  
        mirror_mod.use_z = False  
    operation == "MIRROR_Y":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = True  
        mirror_mod.use_z = False  
    operation == "MIRROR_Z":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = False  
        mirror_mod.use_z = True
```

```
selection at the end -add  
mirror_ob.select= 1  
mirror_ob.select=1  
context.scene.objects.active  
("Selected" + str(modifier  
mirror_ob.select = 0  
= bpy.context.selected_obj  
data.objects[one.name].se  
print("please select exactly
```

```
--- OPERATOR CLASSES ---
```

```
types.Operator):  
    X mirror to the selected  
    object.mirror_mirror_x"  
    mirror X"
```

```
context):  
context.active_object is not
```

Regressão Logística

- Equação da função logística:

$$p(x) = \frac{1}{1+e^{-f(x)}}, \text{ onde}$$

$p(x)$: probabilidade de X (a variável dependente que desejamos prever)

e: número de Euler (2,71)

$f(x)$: coeficientes das variáveis independentes, definidas como $\beta_0 + \beta_1 * x_1 + \beta_2 * x_2 + \dots + \beta_n * x_n$

```

mirror_mod = modifier_ob.
    mirror object to mirror
    mirror_mod.mirror_object
    operation == "MIRROR_X":
        mirror_mod.use_x = True
        mirror_mod.use_y = False
        mirror_mod.use_z = False
    operation == "MIRROR_Y":
        mirror_mod.use_x = False
        mirror_mod.use_y = True
        mirror_mod.use_z = False
    operation == "MIRROR_Z":
        mirror_mod.use_x = False
        mirror_mod.use_y = False
        mirror_mod.use_z = True

```

```

    selection at the end -add
    mirror_ob.select= 1
    mirror_ob.select=1
    context.scene.objects.active
    ("Selected" + str(modifier
    mirror_ob.select = 0
    bpy.context.selected_obj
    data.objects[one.name].se
    print("please select exactly

```

----- OPERATOR CLASSES -----

```

types.Operator):
    X mirror to the selected
    object.mirror_mirror_x"
    mirror X"


```

```

context):
    context.active_object is not

```

Regressão Logística




```
mirror_mod = modifier_ob.  
    mirror object to mirror  
    mirror_mod.mirror_object  
    operation == "MIRROR_X":  
        mirror_mod.use_x = True  
        mirror_mod.use_y = False  
        mirror_mod.use_z = False  
    operation == "MIRROR_Y":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = True  
        mirror_mod.use_z = False  
    operation == "MIRROR_Z":  
        mirror_mod.use_x = False  
        mirror_mod.use_y = False  
        mirror_mod.use_z = True
```

```
selection at the end -add  
mirror_ob.select= 1  
modifier_ob.select=1  
context.scene.objects.active  
("Selected" + str(modifier  
mirror_ob.select = 0  
= bpy.context.selected_obj  
data.objects[one.name].se  
print("please select exactly
```

--- OPERATOR CLASSES ---

```
types.Operator):  
    X mirror to the selected  
    object.mirror_mirror_x"  
    mirror X"
```

```
context):  
context.active_object is not
```

Para entender melhor...diferença
entre regressão linear e logística

Logistic Regression...



...Clearly Explained!!!

<https://youtu.be/yIYKR4sgzI8?si=HlxnkvQp5gggKlBj>


```

mirror_mod = modifier_ob.
    mirror object to mirror
    mirror_mod.mirror_object

operation == "MIRROR_X":
    mirror_mod.use_x = True
    mirror_mod.use_y = False
    mirror_mod.use_z = False
operation == "MIRROR_Y":
    mirror_mod.use_x = False
    mirror_mod.use_y = True
    mirror_mod.use_z = False
operation == "MIRROR_Z":
    mirror_mod.use_x = False
    mirror_mod.use_y = False
    mirror_mod.use_z = True

selection at the end -add
mirror_ob.select= 1
modifier_ob.select=1
context.scene.objects.active
("Selected" + str(modifier
mirror_ob.select = 0
= bpy.context.selected_ob
data.objects[one.name].se

print("please select exactly


-- OPERATOR CLASSES -----

types.Operator):
    X mirror to the selected
    object.mirror_mirror_x"
    mirror X"

context):
    context.active_object is not

```

Entendendo a regressão logística



<https://youtu.be/EKm0spFxFG4?si=Pg5tmiThCt7LpUh5>

Pontos de atenção nos vídeos

- Avaliação dos modelos
- Identificação de variáveis relevantes



Exemplo regressão logística: previsão de cancelamento (churn)

- Base: tele_customer_data.csv
- Contém dados de clientes de uma telecom, com alguns valores de perfil e outros de consumo, e a coluna *churn* indica clientes que cancelaram o serviço no último mês



Descrição das Variáveis

- **tenure:** Tempo que o cliente está na empresa (em meses).
- **age:** Idade do cliente (em anos).
- **income:** Renda anual do cliente (em milhares de dólares).
- **ed:** Nível de educação do cliente (1=sem ensino médio, 2=ensino médio, 3=algum ensino superior, 4=graduação, 5=pós-graduação).
- **employ:** Anos empregado na ocupação atual.
- **longmon:** Gasto médio mensal em chamadas de longa distância (no último mês).
- **custcat:** Categoria do cliente (1=Basic service, 2=E-service, 3=Plus service, 4=Total service).
- **churn:** Variável alvo, indica se o cliente cancelou (1) ou não (0).



Exemplo regressão logística: previsão de cancelamento (churn)

Bibliotecas:

```
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split # dividir em treino e
    teste

from sklearn.linear_model import LogisticRegression # regressão Logística
from sklearn.preprocessing import StandardScaler # normalização de dados
from sklearn.metrics import classification_report # métricas de avaliação
from sklearn.metrics import confusion_matrix # matriz de confusão
```



Exemplo regressão logística: previsão de cancelamento (churn)

Função:

```
lr = LogisticRegression(C = 0.1, solver = 'liblinear')
```

Parâmetros:

C: varia de 0 a 1, e quanto menor, previne o overfitting

Solver: algoritmo usada para otimização. Liblinear é bom para datasets pequenos

Os outros são:

- **'lbfgs'**: É o parâmetro default, bom para datasets grandes
- **'newton-cg'**: também indicado para data sets grandes
- **'sag'**: também indicado para data sets grandes
- **'saga'**: bom para dados esparsos



Matriz de confusão

		Predito/Previsto	
		Positivo	Negativo
Valor real	Positivo	Verdadeiro positivo	Falso negativo
	Negativo	Falso positivo	Verdadeiro negativo



Ilustrando
com humor

Acurácia e taxa de erro

Acurácia: indica o percentual de acertos do modelo

$$acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

Taxa de erro: indica o percentual de erros do modelo

$$Taxa\ de\ erro = \frac{FP + FN}{VP + VN + FP + FN}$$

Precisão

- Precisão: percentual de acertos para casos positivos, ou seja, dentre todas as classificações de classe positivo que o modelo fez, quantas estão corretas. Exemplo de uso: investimentos, pois é mais relevante acertar os investimentos que podem render lucros

$$Precisão = \frac{VP}{VP + FP}$$

Recall ou revocação

- Recall ou revocação: percentual de acertos em relação a todos os que realmente eram positivos. Exemplo de uso: predição de doenças, pois é mais relevante detectar os casos de risco de doenças

$$Recall = \frac{VP}{VP + FN}$$

F1-score

- É a média harmônica entre precisão e recall, serve para ter uma mensuração única. Ou seja, quando tem-se um F1-Score baixo, é um indicativo de que ou a precisão ou o recall está baixo.

$$F1 - score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$

Tele customer data

- Casos na base de teste: 60
- Não churn: 43
- Churn: 17

$$Acurácia = \frac{6+42}{60} = 80\%$$

$$Precisão = \frac{6}{6+11} = 36\%$$

$$Recall = \frac{6}{6+11} = 35\%$$

		Previsto	
		Positivo	Negativo
Valor real	Positivo	VP = 6	FN = 11
	Negativo	FP = 1	VN = 42

..
Matriz de Confusão:

```
[[ 6 11]  
 [ 1 42]]
```

	precision	recall	f1-score	support
0	0.79	0.98	0.88	43
1	0.86	0.35	0.50	17
accuracy			0.80	60
macro avg	0.82	0.66	0.69	60
weighted avg	0.81	0.80	0.77	60