



Big data e ciência de dados

Revisão Grau A

Luisa Mariele Strauss

Pesos das atividades

- Fórum sobre ciência de dados: 0,5
- Análise exploratória: 1,0
- Exercício clusterização: 2,0
- Exercício regressão: 0,5
- Prova: 6,0

Questão 5 – letra a

- Clusterização pode ser utilizada para encontrar agrupamentos/padrões dos diferentes perfis de profissionais da área de dados;
- Regressão linear pode ser usada para tentar prever o salário de um profissional baseado nas suas features.



Etapas importantes em análises não supervisionadas - clusterização

1. Definir qual é a análise mais adequada!
2. Analisar e limpar os dados: eliminar duplicatas, decidir o que fazer com dados incompletos etc
3. Transformar variáveis categóricas em *dummies*, quando houver, para k-means (k-prototypes não necessita)
4. Transformar os dados numéricos no mesmo tipo (int, float etc)
5. Padronizar/normalizar os dados
6. Rodar o modelo
7. Avaliar o modelo
8. Voltar aos passos 8 e 9 até encontrar um modelo adequado



Etapas importantes em qualquer modelo de análise supervisionada

1. Definir qual é a análise mais adequada!
2. Analisar e limpar os dados: eliminar duplicatas, decidir o que fazer com dados incompletos, eliminar outliers etc
3. Definir variáveis independentes e dependentes, com base no conhecimento do negócio e da literatura sobre o tema
4. Transformar variáveis categóricas em *dummies*, quando houver
5. Transformar os dados numéricos no mesmo tipo (int, float etc)
6. Padronizar os dados
7. Dividir em base de teste e de treinamento
8. Rodar o modelo
9. Avaliar o modelo
10. Voltar aos passos 8 e 9 até encontrar um modelo adequado

Questão 5 – letra b

Para realizar a regressão linear precisamos realizar os seguintes passos:

- Carregar o dataset no ambiente Python (ou qualquer outro software);
- Verificar se o dataset apresenta dados faltantes e limpá-los de alguma maneira: remover as linhas, atribuir a média (ou moda para variáveis categóricas) nos dados faltantes;
- Identificar as variáveis categóricas e transformá-las em variáveis numéricas utilizando "dummies" com técnicas como one-hot encoding;
- Remover a coluna com os valores que queremos aprender a prever - nesse caso, "salary_in_usd", e guardá-la como um vetor separado. Neste caso em específico, há outra opção de alvo, que seria a coluna "salary". No entanto, para prever corretamente os valores desta coluna, o modelo precisaria aprender o valor das diferentes moedas que estes profissionais recebem para conseguir prever corretamente. Também considerando o fato de que para a nossa compreensão da análise realizada, será necessário utilizar a conversão posteriormente de qualquer forma pois não sabemos a taxa de conversão entre todas as moedas; portanto, faz mais sentido remover ambas as colunas de salário e utilizar a coluna "salary_in_usd" como alvo.
- Separar o dataset e os valores alvos em dados de treinamento e dados de teste, para que seja possível validar posteriormente o quão bem o modelo vai lidar com dados ainda não vistos;
- Executar o algoritmo de regressão linear;
- Por fim, podemos utilizar a equação final do algoritmo de regressão linear para tentar prever os salários dos profissionais nos dados de teste, obtendo uma medida de erro como erro médio quadrado ou erro médio absoluto para entender o quão próximo ou longe as previsões estão dos valores reais.

Questão 5 – letra c

- - dados faltantes: a coluna job_title apresenta dez dados faltantes. Nesse caso, visto que a base de dados é bem grande e essa coluna provavelmente é muito significativa para uma previsão de salário, faz sentido remover as linhas em questão.
- dados duplicados: o dataset parece ter um problema significativo de linhas repetidas, 40434, ou seja, mais de 40 mil linhas são réplicas exatas de alguma linha anterior no dataset. Isso não significa necessariamente que elas realmente são linhas duplicadas

Questão 5 – letra c

- a variável numérica utilizada como alvo
- salary_in_usd:
 - limpeza necessária: apresenta alguns valores no negativo, como -215000.00 por exemplo; nesse caso podemos utilizar média ou mediana, ou remover as linhas com esse problema.
 - também existem alguns outliers, pois a média é 157001.41 mas o valor mais alto é 800000; pode atrapalhar na previsão.
- Salary_currency: pode ser realizado um teste com e um sem esta variável, pois ela tem uma informação muito importante que é o poder de compra em relação ao dólar (que é a moeda da nossa variável alvo).
- Para as variáveis categóricas: fazer a conversão usando OneHotEncoder. No entanto, para a variável job_title existem 316 valores distintos.