



Big data e ciência de dados

Processo CRISP-DM

Projeto prático

Luisa Mariele Strauss

Provost & Fawcett (2016)

Processo CRISP-
DM (Cross
Industry
Standard
Process for Data
Mining)





Compreensão do negócio

- Problemas de negócio não vêm pré moldados – exercício de criatividade e pensamento analítico
- Que tipo de problemas temos em nosso negócio?
- Como podemos aplicar a solução?
- O que queremos fazer?
- Importante: problemas que possamos resolver a partir do uso de dados


Exemplos de perguntas de negócio

- Quem são os clientes mais lucrativos?
- Quais as características dos clientes mais lucrativos?
- Qual a chance de um cliente ser bom pagador?
- Quais são as preferências de nossos clientes?
- Como agrupar nossos clientes?
- Como prever ou estimar o salário de um cidadão a partir de dados de perfil?



É possível identificar se uma cliente está grávida, a partir das compras em nosso comércio?


Cuidado com questões éticas!



Compreensão dos dados

- Quais dados temos disponíveis? Analisar pontos fortes e fracos dos dados – eles nunca são perfeitos
- Quais dados adicionais precisamos? Essa pergunta, às vezes, é respondida após rodar e interpretar o modelo
- Qual o custo de obtenção dos dados?
 - Dados de terceiros
 - Dados inexistentes
 - Dados em sistemas defasados
 - Dados em formatos variados
- Nessa fase, entendemos de fato os dados e, muitas vezes, o negócio. Exemplo: como assegurar a identificação de um cliente correta em todas as bases da empresa?





Preparação dos dados

- 70-80% do tempo gasto em ciência de dados (chute calibrado)
- Definição das variáveis realmente importantes – ciclo iterativo, envolve questões teóricas, de negócio, legais e avaliação do modelo
- Conversão dos dados em formato tabular
- Conversão dos dados no formato requerido para a técnica a ser analisada, como *dummies*
- Decisões sobre dados incompletos
- Armazenamento temporário e final



Arquitetura de dados ou de informações

A arquitetura da informação é a arte e a ciência de **organizar** e **categorizar** artefatos de informação* para favorecer a usabilidade e a facilidade para se encontrar o que se procura.


* Podemos entender como softwares, ferramentas, intranets, portais etc



Arquitetura de dados ou de informações


- Objetiva mostrar, em diferentes níveis de abstração, as diversas camadas e fontes de dados de uma empresa, bem como suas integrações e ciclo de vida
- Definição de taxonomia, ou seja, o significado de cada dado/informação
- Uso de diferentes artefatos para modelagem de dados: conceitual, lógico e "físico"

Arquitetura genérica de um Business Intelligence



(Luiz H. N. Lorena, 2011)

Arquitetura genérica de um Big Data



Quais tipos de análise de dados serão aplicados?

- Exploratória vs explanatória
- Descritiva
- Diagnóstica
- Preditiva
- Prescritiva



Modelagem e avaliação

(em Ciência de Dados)

- Base de treinamento e base de teste
- Uso da técnica específica
- Análise dos resultados: fazem sentido?
- Processo cíclico
- Qual o ponto de parada? Avaliação do modelo
 - Clusterização: método do cotovelo
 - Regressão: R^2 , p-value
 - Classificação: Matriz de confusão, acurácia, precisão e recall

Exemplo

- Total de casos: 100
- Positivos: 60
- Negativos: 40

		Previsto	
		Positivo	Negativo
Valor real	Positivo	VP = 50	FN = 10
	Negativo	FP = 5	VN = 35

$$Acurácia = \frac{50+35}{50+10+5+35} = 85\%$$

$$Precisão = \frac{50}{50 + 5} = 90\%$$

$$Recall = \frac{50}{50 + 10} = 83\%$$



Lembrem do pré-processamento dos dados


1. Resolver dados faltantes
2. Normalizar/padronizar os dados
3. Transformar variáveis categóricas em numéricas
4. Dividir a base em teste e treinamento para análises supervisionadas

Implantação da solução

- Como será inserido no processo atual? Inclusão de sistemas transacionais, painéis de indicadores, emissão de alertas etc. Exemplos:
 - Identificação de ofertas para clientes gera tarefas para equipe de vendas em um sistema CRM
 - Percentual de chance de um cliente ser bom pagador como um resultado de um sistema de apoio a decisão para concessão de crédito
- Será necessário treinar funcionários?
- Qual a aceitação da solução?
- Avaliação contínua dos resultados e do modelo



A chave desse processo é a iteração!



Projeto em solução de problemas usando machine learning - grupos de até 3 integrantes

- Identificar um problema que pode ser resolvido usando ciência de dados
 - Análise descritiva usando ML
 - Análise preditiva
 - Análise prescritiva
- **Problema real**: pode ser na empresa em que vocês trabalham ou um problema social (com dados públicos, por exemplo)
- Para agora: definir o problema e buscar os dados e autorização, caso necessário



Estrutura trabalho

1. Descrição da empresa e do problema
2. Identificação dos dados necessários para entender e solucionar o problema, tanto dados internos quanto externos
3. Propor uma Arquitetura de Dados, especificando as fontes de dados e tecnologias para extração dos dados
4. Extrair e consolidar dados
5. Realizar pelo menos uma análise (supervisionada ou não supervisionada)
6. Indicar as respectivas ações possíveis
7. Projeto de implantação da solução no processo de negócio equivalente





1. Empresa e problema

- Apresentar a empresa, seu negócio, porte, tipo de clientes, de produtos etc
- Explicar o problema selecionado: contextualizar, explorar possibilidades de solução
- Explicar de que forma dados podem ajudar a resolver o problema, ou, ainda, ajudar a entender (diagnóstico)
- Levantar questões éticas envolvidas, se for o caso



2. Identificação dos dados necessários

- Identificar, de forma específica, quais dados são necessários e suas fontes
 - Dados internos: banco de dados, sistema, formato
 - Dados externos: fontes e processo de coleta
- Levantar questões éticas e legais da obtenção desses dados, se for o caso

Exemplo simples

Dado/informação	Interno/externo	Existente?	Fonte	Forma de coleta
Avaliação do fornecedor	Interno	Sim	Sistema ERP – módulo Suprimentos – banco de dados XYZ	SQL/ETL
Dólar comercial	Externa	Não	Dados Abertos do Banco do Brasil	API
Avaliação da entrega pelo cliente	Interno	Não	Desenvolvimento de novo aplicativo	SQL/ETL

Algumas fontes de dados reais abertos/gratuitos

- Portal Brasileiro de Dados Abertos: <https://dados.gov.br/home>
- World Bank Open Data: <https://data.worldbank.org/>
- THE GLOBAL HEALTH OBSERVATORY: <https://www.who.int/data/gho/>
- Balança Comercial e Estatísticas de Comércio Exterior: <https://www.gov.br/produtividade-e-comercio-exterior/pt-br/assuntos/comercio-exterior/estatisticas/>
- Dados Abertos Banco Central: <https://www.bcb.gov.br/acessoinformacao/dadosabertos>
- Preços de commodities: <https://br.investing.com/commodities/>
- Our World in Data: <https://ourworldindata.org/>



3. Arquitetura de dados

- Apresentar um desenho com a arquitetura dos dados, em alto nível
- Essa arquitetura deve conter:
 - As fontes de dados
 - Armazenamento projetado
 - Distribuição/apresentação projetado



4. Extrair e consolidar dados

- Obter os dados das fontes indicadas
- Consolidar e uma base única (necessário para mineração dados e machine learning) – neste momento, será uma base temporária
- Identificar as soluções para dados faltantes (conversar com a professora para verificarmos juntos a melhor abordagem)



5. Realizar a modelagem

- Definir o melhor tipo de análise: supervisionada ou não supervisionada, algoritmo selecionado
- Fazer padronização ou normalização (MaxAbsScaler)
- Transformar variáveis categóricas (OneHotEncoding)
- Dividir em base de teste e treinamento
- Avaliar e interpretar o modelo
- Apresentar o resultado de forma amigável (como você venderia a um gestor?)



6. Projetando a Implantação da solução

- Como essa análise melhora a tomada de decisão?
- Como essa análise ou indicador será inserido no processo atual?
- O que muda no processo de tomada de decisão?
- Quem serão as pessoas que vão consumir esses dados? Será necessário treinar funcionários?



Entrega e apresentação

- Apresentar a solução no dia 13/11. Lembre-se: você está ajudando a vender a ideia para a empresa!
- Postar apresentação em PDF no Moodle + acesso ao script python (ou, se for usado outra ferramenta, indicar instruções para acessar).
- Trazer dados reais sempre que possível, com excertos de tabelas, por exemplo, ainda que anonimizando dados sensíveis
- Trazer visuais com dados reais sempre que possível