





Projeto final em ciência de dados

Luisa Mariele Strauss

Trabalho final

Baseado no
método CRISP-
DM



O que é o trabalho – grupos de até 3 integrantes

- Identificar um problema que pode ser resolvido usando ciência de dados
 - Análise descritiva usando ciência de dados
 - Análise preditiva
 - Análise prescritiva
- Problema real: pode ser na empresa em que vocês trabalham ou um problema social (com dados públicos, por exemplo)
- Para agora: definir o problema e buscar os dados e autorização, caso necessário



Estrutura trabalho

1. Descrição da empresa e do problema
2. Identificação dos dados necessários para entender e solucionar o problema, tanto dados internos quanto externos
3. Propor uma Arquitetura de Dados, especificando as fontes de dados e tecnologias para extração dos dados
4. Extrair e consolidar dados
5. Realizar pelo menos uma análise (supervisionada ou não supervisionada)
6. Indicar as respectivas ações possíveis
7. Projeto de implantação da solução no processo de negócio equivalente





1. Empresa e problema

- Apresentar a empresa, seu negócio, porte, tipo de clientes, de produtos etc
- Explicar o problema selecionado: contextualizar, explorar possibilidades de solução
- Explicar de que forma dados podem ajudar a resolver o problema, ou, ainda, ajudar a entender (diagnóstico)
- Levantar questões éticas envolvidas, se for o caso



2. Identificação dos dados necessários

- Identificar, de forma específica, quais dados são necessários e suas fontes
 - Dados internos: banco de dados, sistema, formato
 - Dados externos: fontes e processo de coleta
- Levantar questões éticas e legais da obtenção desses dados, se for o caso

Exemplo simples

Dado/informação	Interno/externo	Existente?	Fonte	Forma de coleta
Avaliação do fornecedor	Interno	Sim	Sistema ERP – módulo Suprimentos – banco de dados XYZ	SQL/ETL
Dólar comercial	Externa	Não	Dados Abertos do Banco do Brasil	API
Avaliação da entrega pelo cliente	Interno	Não	Desenvolvimento de novo aplicativo	SQL/ETL

Algumas fontes de dados reais abertos/gratuitos reais


- Portal Brasileiro de Dados Abertos: <https://dados.gov.br/home>
- World Bank Open Data: <https://data.worldbank.org/>
- THE GLOBAL HEALTH OBSERVATORY: <https://www.who.int/data/gho/>
- Dados Abertos Banco Central: <https://www.bcb.gov.br/acessoinformacao/dadosabertos>
- Preços de commodities: <https://br.investing.com/commodities/>
- Dados abertos do IPEA (Instituto de Pesquisa Econômica Aplicada): <https://www.ipea.gov.br/portal/dados-abertos>
- Dados abertos IBGE: <https://dados.gov.br/dados/organizacoes/visualizar/instituto-brasileiro-de-geografia-e-estatistica-ibge>
- data.gov EUA: https://catalog.data.gov/dataset?res_format=CSV
- DataPOA: <http://datapoa.com.br/dataset>



3. Arquitetura de dados

- Apresentar um desenho com a arquitetura dos dados, em alto nível
- Essa arquitetura deve conter:
 - As fontes de dados
 - Armazenamento
 - Distribuição/apresentação

Exemplo: arquitetura genérica de um BI



(Luiz H. N. Lorena, 2011)



4. Extrair e consolidar dados

- Obter os dados das fontes indicadas
- Consolidar e uma base única (necessário para mineração dados)
- Identificar as soluções para dados faltantes (conversar com a professora para verificarmos juntos a melhor abordagem)



5. Realizar a modelagem

- Definir o melhor tipo de análise: supervisionada ou não supervisionada, algoritmo selecionado
- Avaliar e/ou interpretar o modelo
- Apresentar o resultado de forma amigável (como você venderia a um gestor?)



6. Projetando a Implantação da solução

- Como essa análise melhora a tomada de decisão?
- O que muda no processo de tomada de decisão?
- Como essa análise ou indicador será inserido no processo atual?
- Quem serão as pessoas que vão consumir esses dados? Será necessário treinar funcionários?



Entrega e apresentação

- Apresentar a solução no dia 13/11. Lembre-se: você está ajudando a vender a ideia para a empresa/organização/órgão público!
- Postar apresentação em PDF no Moodle.
- Trazer dados reais sempre que possível, com excertos de tabelas por exemplo, ainda que anonimizando dados sensíveis
- Trazer visuais com dados reais sempre que possível